

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

ỨNG DỤNG HỌC SÂU
TRONG PHÂN TÍCH HÌNH ẢNH UNG THƯ VÚ

APPLYING DEEP LEARNING
IN BREAST CANCER IMAGES ANALYSIS

Sinh viên: Phan Minh Tài

Mã số: B2113341

Khóa: 47

Giảng viên hướng dẫn: TS. Lưu Tiến Đạo

Cần Thơ, 08/2025

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

ỨNG DỤNG HỌC SÂU
TRONG PHÂN TÍCH HÌNH ẢNH UNG THƯ VÚ

APPLYING DEEP LEARNING
IN BREAST CANCER IMAGES ANALYSIS

Giảng viên hướng dẫn
TS. Lưu Tiến Đạo

Sinh viên thực hiện
Họ và tên: Phan Minh Tài
Mã số: B2113341
Khóa: K47

Cần Thơ, 08/2025

LỜI CẢM ƠN

Để hoàn thành Luận văn tốt nghiệp ngành Khoa học Máy tính này, em xin được bày tỏ lòng biết ơn chân thành và sâu sắc đến Thầy TS. Lưu Tiến Đạo – người đã trực tiếp tận tình hướng dẫn, giúp đỡ em trong suốt quá trình thực hiện đề tài. Nhờ những chỉ dẫn tận tâm và quý báu của Thầy, em đã có định hướng rõ ràng và hoàn thiện đề tài một cách tốt nhất.

Em xin gửi lời cảm ơn chân thành đến quý Thầy Cô giảng viên Đại học Cần Thơ, đặc biệt là quý Thầy Cô thuộc Trường Công nghệ Thông tin và Truyền thông, những người đã truyền đạt những kiến thức nền tảng quý báu, đồng thời luôn tận tình hỗ trợ và tạo điều kiện thuận lợi để em có thể phát triển bản thân cũng như hoàn thành đề tài hiệu quả.

Em cũng xin gửi lời cảm ơn sâu sắc đến Bệnh viện Ung Bướu Cần Thơ đã hỗ trợ cung cấp dữ liệu để thực hiện đề tài, đặc biệt là bác sĩ Trần Thế Đủ đã tận tình giúp đỡ và hỗ trợ kịp thời mỗi khi em gặp khó khăn trong quá trình thu thập và xử lý dữ liệu.

Bên cạnh đó, em xin trân trọng cảm ơn gia đình và bạn bè – những người luôn ở bên động viên, khích lệ và tạo mọi điều kiện thuận lợi để em yên tâm học tập và nghiên cứu.

Dù đã nỗ lực rất nhiều trong quá trình thực hiện, nhưng do hạn chế về thời gian và kinh nghiệm, luận văn tốt nghiệp này chắc chắn không tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp quý báu từ quý Thầy Cô và các bạn để bài luận được hoàn thiện hơn trong tương lai.

Cần Thơ, ngày tháng năm 2025

Người viết

Phan Minh Tài

MỤC LỤC

DANH MỤC HÌNH ẢNH.....	i
DANH MỤC BẢNG BIỂU.....	iii
DANH MỤC TỪ VIẾT TẮT	iv
ABSTRACT	v
TÓM TẮT.....	vi
I. PHẦN GIỚI THIỆU	1
1. Đặt vấn đề	1
2. Lịch sử giải quyết vấn đề	2
3. Mục tiêu đề tài	4
4. Đối tượng và phạm vi nghiên cứu	4
5. Phương pháp nghiên cứu	6
6. Bố cục quyền báo cáo	6
II. PHẦN NỘI DUNG	8
CHƯƠNG 1. MÔ TẢ BÀI TOÁN	8
1.1. Mô tả chi tiết bài toán	8
1.2. Vấn đề giải pháp liên quan đến bài toán	10
1.2.1. Các phương pháp sần lọc ung thư vú	10
1.2.2. Hệ thống phân loại BI-RADS	15
1.2.3. Các mô hình học sâu	16
1.2.4. Tăng độ chính xác bằng phương pháp kết hợp các mô hình.....	21
1.2.5. Phương pháp đánh giá mô hình.....	24
1.2.6. Các thư viện và công cụ hỗ trợ xây dựng hệ thống.....	26
1.2.7. Công cụ hỗ trợ CI/CD trong hệ thống	30
CHƯƠNG 2. THIẾT KẾ VÀ CÀI ĐẶT	31
2.1. Thiết kế hệ thống.....	31
2.1.1. Thiết kế luồng huấn luyện và kiểm thử các mô hình	31
2.1.2. Thiết kế hệ thống website.....	32
2.2. Cài đặt giải pháp	36
2.2.1. Thu thập dữ liệu.....	36
2.2.2. Tiền xử lý dữ liệu	39
2.2.3. Tổng hợp và phân chia dữ liệu để huấn luyện.....	42
2.2.4. Huấn luyện các mô hình học sâu.....	44
2.2.5. Cài đặt hệ thống website tích hợp CI/CD.....	51
CHƯƠNG 3. KIỂM THỬ VÀ ĐÁNH GIÁ	54

3.1. Giao diện sản phẩm.....	54
3.2. Kết quả thực nghiệm	59
3.2.1. Kết quả kiểm thử các mô hình.....	59
3.2.2. Kết quả kiểm thử hệ thống	66
3.3. Thảo luận về kết quả đạt được	67
III. PHẦN KẾT LUẬN	68
1. Kết quả đạt được	68
2. Hạn chế	68
3. Hướng phát triển	68
TÀI LIỆU THAM KHẢO	69
PHỤ LỤC	71

DANH MỤC HÌNH ẢNH

Hình 1.1. Những căn bệnh ung thư mà phụ nữ mắc nhiều nhất năm 2022 [8]	8
Hình 1.2. Ảnh X-Quang tuyến vú của bệnh nhân	9
Hình 1.3. Ví dụ ảnh chụp X-Quang tuyến vú	11
Hình 1.4. Mô tả góc chụp CC, MLO	12
Hình 1.5. Ví dụ ảnh chụp MRI tuyến vú	12
Hình 1.6. Ví dụ ảnh siêu âm tuyến vú 2 bên	13
Hình 1.7. Sinh thiết khối u vú có hướng dẫn từ siêu âm	14
Hình 1.8. Kiến trúc mô hình mạng học sâu ResNet50	17
Hình 1.9 Ví dụ cho các residual block (kết nối tắt)	17
Hình 1.10. Kiến trúc mô hình mạng học sâu MobileNetV2	18
Hình 1.11. Kiến trúc mô hình mạng học sâu InceptionV3	20
Hình 1.12. Confusion matrix	25
Hình 1.13. Các nhà cung cấp dịch vụ điện toán đám mây hàng đầu quý 3 năm 2024	28
Hình 2.1. Quy trình huấn luyện và kiểm thử mô hình	31
Hình 2.2. Chức năng của các người dùng trong hệ thống	32
Hình 2.3. Phân bố số lượng ảnh thu thập từ CBIS-DDSM	36
Hình 2.4. Phân bố số lượng ảnh thu thập từ InBreast	37
Hình 2.5. Phân bố số lượng ảnh thu thập từ VinDr-Mammo	38
Hình 2.6. Phân bố số lượng ảnh thu thập từ Bệnh viện Ung Bướu Cần Thơ	38
Hình 2.7. Tổng hợp số lượng ảnh theo từng lớp sau khi thu thập	39
Hình 2.8. Minh họa việc chuyển đổi các ảnh sang định dạng PNG	40
Hình 2.9. Chuẩn hóa kích thước ảnh về 256x256 pixels	40
Hình 2.10. Minh họa việc tăng cường ảnh một cách ngẫu nhiên	41
Hình 2.11. Số lượng ảnh mỗi lớp sau khi tăng cường lớp BI-RADS 0	42
Hình 2.12. Biểu đồ loss khi huấn luyện ResNet50	45
Hình 2.13. Biểu đồ F1 trên tập train và tập validation của ResNet50	45
Hình 2.14. Biểu đồ loss khi huấn luyện MobileV2	46
Hình 2.15. Biểu đồ F1 trên tập train và tập validation của MobileNetV2	47
Hình 2.16. Biểu đồ loss khi huấn luyện InceptionV3	47
Hình 2.17. Biểu đồ F1 trên tập train và tập validation của InceptionV3	48
Hình 2.18. Biểu đồ loss của ResNet50 cho bài toán 2 lớp	49
Hình 2.19. Biểu đồ loss của MobileNetV2 cho bài toán 2 lớp	49
Hình 2.20. Biểu đồ loss của InceptionV3 cho bài toán 2 lớp	50
Hình 2.21. Kiến trúc hệ thống website tích hợp CI/CD	51
Hình 2.22. workflow của quy trình CI/CD trong hệ thống	52
Hình 3.1. Giao diện trang chủ hệ thống	54
Hình 3.2. Giao diện làm câu hỏi trắc nghiệm tầm soát ung thư vú	54
Hình 3.3. Giao diện nhận kết quả tầm soát ung thư vú	55
Hình 3.4. Giao diện hiển thị kết quả chẩn đoán BI-RADS	56
Hình 3.5. Giao diện quản lý user	56
Hình 3.6. Giao diện quản lý lưu lượng của hệ thống website	57
Hình 3.7. Giao diện quản lý thông tin dự đoán và quản lý các mô hình học sâu	57
Hình 3.8. Giao diện quản lý hình ảnh dự đoán	58
Hình 3.9. Giao diện phân chia tỷ lệ huấn luyện để tải xuống	58
Hình 3.10. Ma trận nhầm lẫn của mô hình ResNet50 khi kiểm thử	59
Hình 3.11. Các chỉ số đánh giá mô hình ResNet50	60

Hình 3.12. Ma trận nhầm lẫn của mô hình MobileNetV2 khi kiểm thử	60
Hình 3.13. Các chỉ số đánh giá mô hình MobileNetV2	61
Hình 3.14. Ma trận nhầm lẫn của mô hình InceptionV3 khi kiểm thử	61
Hình 3.15. Các chỉ số đánh giá mô hình InceptionV3	62
Hình 3.16. Ma trận nhầm lẫn của phương pháp bình chọn theo số đông.....	62
Hình 3.17. Các chỉ số đánh giá phương pháp bình chọn theo số đông	63
Hình 3.18. Confusion matrix của phương pháp kết hợp xác suất	63
Hình 3.19. Các chỉ số đánh giá phương pháp kết hợp xác suất.....	64
Hình 3.20. So sánh Accuracy và F1 giữa các mô hình và các phương pháp	64
Hình 3.21. So sánh độ chính xác giữa các mô hình phân loại 2 lớp	65

DANH MỤC BẢNG BIỂU

Bảng 1.1. Hệ thống phân loại BI-RADS	15
Bảng 1.2. Ví dụ cho cách tính phương pháp bình chọn theo số đông.....	22
Bảng 1.3. Ví dụ trường hợp đặc biệt của phương pháp bình chọn theo số đông	22
Bảng 1.4. Ví dụ cách tính phương pháp kết hợp xác suất	24
Bảng 2.1. Collection user	34
Bảng 2.2. Collection user_session.....	34
Bảng 2.3. Collection verification_code	35
Bảng 2.4. Collection prediction.....	35
Bảng 2.5. Collection model	35
Bảng 2.6. Tổng hợp dữ liệu từ các nguồn thu thập	43
Bảng 2.7. Tỷ lệ dữ liệu cho bài toán phân loại 6 lớp BI-RADS	44
Bảng 2.8. Tỷ lệ dữ liệu cho bài toán phân loại 2 lớp lành tính và ác tính.....	44
Bảng 3.1. Kết quả kiểm thử chức năng tải ảnh và dự đoán.....	66

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt (Abbreviation)	Từ viết đầy đủ (Origin word)
1	AWS	Amazon Web Services
2	BI-RADS	Breast Imaging-Reporting And Data System
3	CI/CD	Continuous Integration / Continuous Deployment
4	CNN	Convolutional Neural Network
5	DNN	Deep Neural Network
6	EC2	Elastic Compute Cloud
7	MRI	Magnetic Resonance Imaging
8	R-CNN	Regions with Convolutional Neural Network features
9	ResNet50	Residual Network with 50 layers
10	S3	Simple Storage Service
11	VGG19	Visual Geometry Group 19-layer network
12	VPS	Virtual Private Server

ABSTRACT

Breast cancer is one of the most common and dangerous diseases among Vietnamese women, with over 24,000 new cases in 2022, accounting for nearly 29% of all newly diagnosed cancers. In response to this situation, the study “Deep Learning Application in Breast Cancer Image Analysis” was conducted to classify breast lesions according to the BI-RADS system and determine the likelihood of cancer from mammogram images, thereby assisting doctors in improving diagnostic accuracy and reducing screening time.

The dataset includes mammogram images from the Inbreast, CBIS-DDSM, and VinDr-Mammogram datasets, along with real-world data from Can Tho Oncology Hospital, totaling more than 10,000 samples after standardized preprocessing. Three deep learning models—ResNet50, MobileNetV2, and InceptionV3—were trained to classify images into six BI-RADS categories, combined with model ensemble techniques to enhance accuracy. The website system was developed using ReactJS and TailwindCSS for the frontend, FastAPI for the backend, deployed on AWS (EC2, S3, VPC, DocumentDB, Security Groups, Amplify), and integrated with a CI/CD pipeline for automated deployment.

The results demonstrate high accuracy in benign–malignant classification, with ensemble techniques improving performance in six-class BI-RADS classification, though accuracy in certain intermediate classes remains limited. Nevertheless, the findings indicate the feasibility of applying deep learning models to support breast cancer diagnosis

Keywords: Deep learning, Breast cancer, Medical imaging diagnosis, BI-RADS Classification.

TÓM TẮT

Ung thư vú là căn bệnh phổ biến và nguy hiểm hàng đầu ở phụ nữ Việt Nam, với hơn 24.000 ca mắc mới trong năm 2022, chiếm gần 29% tổng số ca ung thư mới. Trước thực trạng này, đề tài “Ứng dụng học sâu trong phân tích hình ảnh ung thư vú” được thực hiện nhằm phân loại tổn thương tuyến vú theo hệ thống BI-RADS và xác định khả năng mắc ung thư từ ảnh X-quang tuyến vú, qua đó hỗ trợ bác sĩ nâng cao độ chính xác chẩn đoán và rút ngắn thời gian sàng lọc.

Dữ liệu sử dụng gồm ảnh X-quang tuyến vú từ các bộ Inbreast, CBIS-DDSM, VinDr-Mammogram và dữ liệu thực tế từ Bệnh viện Ung Bướu Cần Thơ, với tổng số ảnh lên đến hơn 10.000 mẫu sau khi tiền xử lý chuẩn hóa. Ba mô hình học sâu ResNet50, MobileNetV2 và InceptionV3 được huấn luyện để phân loại 6 cấp độ BI-RADS, có sử dụng phương pháp kết hợp mô hình để tăng độ chính xác. Hệ thống website được phát triển bằng ReactJS, TailwindCSS (frontend) và FastAPI (backend), triển khai trên AWS (EC2, S3, VPC, DocumentDB, Security Groups, Amplify) và tích hợp quy trình CI/CD để tự động hóa triển khai.

Kết quả cho thấy hệ thống đạt độ chính xác cao trong phân loại lành tính – ác tính, nhờ cải thiện nhờ kỹ thuật kết hợp mô hình nên độ chính xác ở phân loại 6 lớp BI-RADS được tăng cường nhưng vẫn còn thấp nhưng cũng cho thấy khả năng áp dụng các mô hình học sâu trong việc hỗ trợ chẩn đoán bệnh ung thư vú là khả thi.

Từ khóa: Học sâu, Ung thư vú, Chẩn đoán hình ảnh y khoa, Phân loại BI-RADS.

I. PHẦN GIỚI THIỆU

1. Đặt vấn đề

Ung thư vú là một trong những loại ung thư thường gặp nhất ở phụ nữ trên toàn thế giới. Theo thống kê mới nhất từ Tổ chức Y tế Thế giới (WHO) năm 2022, có khoảng 2,3 triệu ca mắc ung thư vú mới được ghi nhận trên toàn thế giới, khiến gần 670.000 người tử vong vì căn bệnh này¹. Tại Việt Nam, theo báo cáo GLOBOCAN 2022 của Cơ quan Nghiên cứu Ung thư Quốc tế (IARC), có hơn 24.500 ca ung thư vú mới và hơn 10.000 ca tử vong chỉ trong một năm². Những con số này cho thấy mức độ nghiêm trọng và sự phổ biến ngày càng gia tăng của căn bệnh này không chỉ trên thế giới mà ngay cả tại Việt Nam. Căn bệnh này nếu không được phát hiện và điều trị kịp thời, căn bệnh có thể tiến triển nhanh chóng, lan rộng sang các mô và cơ quan lân cận, thậm chí di căn đến những vị trí xa như phổi hoặc xương, gây ra nhiều biến chứng nguy hiểm và khả năng cao dẫn đến tử vong.

Các phương pháp phổ biến hiện nay trong sàng lọc ung thư vú bao gồm chụp nhũ ảnh, siêu âm tuyến vú, MRI³ (Magnetic Resonance Imaging) và khám lâm sàng. Trong đó, chụp nhũ ảnh là phương pháp tiêu chuẩn vàng, giúp phát hiện sớm tổn thương ngay cả khi chưa có triệu chứng. Việc đánh giá ung thư vú qua ảnh X-quang tuyến vú đòi hỏi bác sĩ phải có chuyên môn cao, kinh nghiệm lâm sàng dày dặn và khả năng tập trung tốt. Bác sĩ cần nhận diện được các dấu hiệu bất thường, các dấu hiệu này thường là những chi tiết rất nhỏ và dễ bị bỏ sót. Quá trình đọc nhũ ảnh không chỉ cần kiến thức chuyên sâu về hình thái học tuyến vú mà còn đòi hỏi kỹ năng phân tích hình ảnh chính xác, tỉ mỉ và khả năng đưa ra nhận định dựa trên hệ thống phân loại BI-RADS⁴ (Breast Imaging-Reporting And Data System) nhằm xác định mức độ nghi ngờ và hướng xử trí phù hợp. Đây là một công việc mang tính chuyên biệt cao, dễ gây sai sót nếu thiếu kinh nghiệm hoặc bị giới hạn bởi yếu tố chủ quan.

Trong những năm gần đây, sự phát triển nhanh chóng của trí tuệ nhân tạo, đặc biệt là các phương pháp học sâu, đã mở ra nhiều hướng tiếp cận mới trong lĩnh vực chẩn đoán hình ảnh y tế. Học sâu cho phép máy tính học và nhận diện được các cấp độ ung thư vú trên ảnh nhũ ảnh và có thể phát hiện các khối u ung thư nhỏ một cách chính xác nhờ học được các đặc trưng từ hình ảnh. Điều này sẽ giúp hỗ trợ bác sĩ trong việc chuẩn đoán bệnh ung thư vú một cách nhanh chóng và hiệu quả. Đặc biệt việc phát hiện ung thư vú ở giai đoạn đầu sẽ giúp cải thiện tỷ lệ phát hiện sớm ung thư, giảm tỷ lệ tử vong cũng như tiết kiệm thời gian và tiền bạc điều trị căn bệnh này. Với những lợi ích thiết thực như vậy, việc áp dụng học sâu vào phân tích hình ảnh ung thư vú là

¹ WHO. Breast Cancer. <https://www.who.int/news-room/fact-sheets/detail/breast-cancer>

² <https://pmc.ncbi.nlm.nih.gov/articles/PMC11609486/#sec3>

³ <https://www.nibib.nih.gov/science-education/science-topics/magnetic-resonance-imaging-mri>

⁴ <https://my.clevelandclinic.org/health/articles/bi-rads-breast-imaging-reporting-and-data-system>

một hướng nghiên cứu đầy tiềm năng, vừa mang tính cấp thiết về mặt y tế, vừa có giá trị thực tiễn cao trong hỗ trợ chẩn đoán và điều trị ung thư.

Xuất phát từ đó, luận văn tốt nghiệp với đề tài “**Ứng dụng học sâu trong phân tích hình ảnh ung thư vú**” được thực hiện nhằm hướng đến việc xây dựng một hệ thống hỗ trợ phân loại ung thư vú từ ảnh X-quang tuyến vú⁵ một cách chính xác và hiệu quả. Đề tài sẽ thu thập dữ liệu hình ảnh nhũ ảnh từ các nguồn công khai có uy tín như CBIS-DDSM, Inbreast và VinDr Mammogram để huấn luyện các mô hình học sâu, đồng thời sử dụng dữ liệu được cung cấp từ Bệnh viện Ung bướu Cần Thơ. Bên cạnh đó hệ thống sẽ được thiết kế và sử dụng các dịch vụ dựa trên nền tảng điện toán đám mây AWS (Amazon Web Services) và sử dụng quy trình CI/CD (Continuous Integration/Continuous Deployment) để tự động hóa quá trình kiểm thử, cập nhật và triển khai, đảm bảo khả năng mở rộng, vận hành linh hoạt và dễ dàng tích hợp vào các hệ thống y tế hiện hữu.

2. Lịch sử giải quyết vấn đề

Trong nước, một số nghiên cứu gần đây đã khai thác các mô hình học sâu để phân lớp ảnh ung thư vú như một nghiên cứu tại Trường Đại học Cần Thơ do Nguyễn Văn Dương và Trần Hữu Đức [1] thực hiện đã kết hợp thuật toán phân tích cụm mờ (Fuzzy C-Means Clustering) với mạng học sâu Inception ResNet-V2 nhằm phân loại ung thư vú từ ảnh nhũ tuyến. Dữ liệu sử dụng là tập ảnh DDSM với hơn 1.000 ảnh X-quang tuyến vú. Hệ thống thực hiện tiền xử lý ảnh bằng cách làm mịn và chuẩn hóa độ sáng, sau đó sử dụng FCM để trích xuất vùng nghi ngờ, và cuối cùng phân loại bằng mô hình Inception ResNet-V2. Kết quả thử nghiệm cho thấy hệ thống đạt độ chính xác 93,75%, độ nhạy 91,67%, và độ đặc hiệu 95,83% trong việc phân biệt các ảnh benign (lành tính) và malignant (ác tính).

Một nghiên cứu nổi bật của nhóm Phan Anh Cang cùng các cộng sự [2] cũng đã đề xuất kỹ thuật phân loại ảnh nhũ tuyến vú sử dụng các kiến trúc mạng học sâu như NasNetLarge, MobileNetV2, InceptionV3, DenseNet121 và đặc biệt là mạng phân loại Vision Transformer. Mục tiêu của nghiên cứu là phân loại ảnh nhũ ảnh thành bình thường, lành tính hoặc ác tính. Các tác giả đã sử dụng bộ dữ liệu Mini-MIAS⁶, bao gồm 322 hình ảnh và một tập dữ liệu kiểm thử riêng biệt từ Bệnh viện Phụ sản TP. Cần Thơ với 300 hình ảnh. Kết quả thực nghiệm cho thấy mô hình Vision Transformer đạt độ chính xác lên đến 99,2% trên tập kiểm thử, cao hơn so với các mô hình CNN (Convolutional Neural Networks) khác như MobileNetV2 (96,3%), InceptionV3 (98,1%), NASNetLarge (98,6%), và DenseNet121 (98,6%).

Trong bài báo của Võ Thành Toàn và cộng sự [3] cũng đã thực hiện nghiên cứu về việc phân loại mật độ vú trên phim nhũ ảnh bằng trí tuệ nhân tạo tại Bệnh viện

⁵ <https://benhvienlaokhoa.vn/chup-xquang-tuyen-vu-mammography>

⁶ <http://peipa.essex.ac.uk/info/mias.html>

Thông Nhất. Mục tiêu của nghiên cứu là xây dựng một kiến trúc mạng CNN tùy chỉnh để phân loại mật độ vú theo thang BI-RADS nhằm giảm sự thiếu đồng nhất trong chẩn đoán. Nghiên cứu đã xây dựng một bộ dữ liệu cục bộ từ Bệnh viện Thông Nhất (698 bệnh nhân, 2.734 hình ảnh) và kết hợp với bộ dữ liệu DDSM (10.661 hình ảnh) để huấn luyện mô hình. Mô hình đã được huấn luyện để giải quyết ba vấn đề: phân loại ảnh chụp bên trái/phải, phân loại góc chụp, và phân loại đậm độ tuyến vú theo BI-RADS. Kết quả cho thấy mô hình đạt độ chính xác tổng thể 76,8% trong việc phân loại mật độ vú trên tập dữ liệu kiểm tra, với độ nhạy tăng dần từ nhóm A (31,8%) đến nhóm D (92,2%) và độ đặc hiệu giảm dần từ nhóm A (100%) xuống nhóm D (83,5%).

Trên thế giới, nhiều nhà nghiên cứu đã thực hiện nhằm phân loại ung thư vú các phương pháp học sâu trên dữ liệu X-quang và MRI.

Nhóm tác giả Pan và cộng sự [4] đã đề xuất một framework học liên kết (federated learning) kết hợp với dữ liệu tổng hợp để phân loại ảnh siêu âm ung thư vú. Ba bộ dữ liệu BUSI, BUS-BRA và UDIAT được sử dụng, gồm hàng nghìn ảnh siêu âm phân loại thành benign và malignant. Hệ thống sử dụng mạng DenseNet121 làm mô hình phân loại, huấn luyện theo giao thức FedAvg và FedProx. Đặc biệt, các hình ảnh tổng hợp được tạo bởi hai mô hình DCGAN riêng biệt cho benign và malignant nhằm tăng độ đa dạng và bảo mật. Kết quả cho thấy việc thêm ảnh tổng hợp giúp tăng AUC trung bình từ 0,9206 lên 0,9237 (với FedAvg) và từ 0,9429 lên 0,9538 (với FedProx), trong khi vẫn đảm bảo an toàn dữ liệu.

Trong nghiên cứu này, Shahzad và các cộng sự [5] đề xuất một mô hình học sâu kết hợp (ensemble) gồm MobileNet và NASNet, gọi là MobNas, nhằm phân loại ảnh siêu âm vú thành ba nhóm: bình thường, lành tính và ác tính. Nhóm tác giả sử dụng augmentation (xoay, cắt, thay đổi độ sáng) và fine-tuning để cải thiện hiệu năng mô hình. Dữ liệu được thu thập từ các bệnh viện với số lượng ảnh lên đến 2.000 tấm, đầy đủ ba loại tổn thương. Mô hình MobNas đạt độ chính xác 94,8% và F1-score trung bình 94,3%, đặc biệt có độ đặc hiệu cao trong việc phát hiện trường hợp lành tính.

Hassairi và cộng sự [6] đã phát triển một phương pháp kết hợp autoencoder học sâu và biến đổi wavelet rời rạc để phân loại ảnh tuyến vú thành hai nhóm chính: lành tính và ác tính. Hệ thống sử dụng kiến trúc Sparse Autoencoder để trích xuất đặc trưng không tuyến tính từ ảnh X-quang vú, sau đó đưa qua mạng phân loại với lớp đầu ra sigmoid. Dữ liệu huấn luyện là bộ CBIS-DDSM bao gồm hơn 1.500 ảnh được gán nhãn bởi chuyên gia. Kết quả đạt độ chính xác 95,7% và F1-score 94,8%, cho thấy mô hình vượt trội so với các kiến trúc CNN đơn thuần như VGG16 hay ResNet34 trong cùng tập dữ liệu.

Mostafa và cộng sự [7] đã cải tiến mô hình YOLOv8 để vừa thực hiện phân vùng (segmentation) và vừa phân loại khối u vú trên ảnh siêu âm. Dữ liệu sử dụng bao gồm ảnh thực tế từ bệnh viện với nhãn bệnh lý từ sinh thiết. Sau bước segmentation, hệ thống phân loại thành benign và malignant bằng một lớp classifier tích hợp. Kỹ thuật

cải tiến gồm tăng độ phân giải ảnh, giảm nhiễu bằng CLAHE và áp dụng anchor box tối ưu hóa theo kênh siêu âm. Mô hình đạt độ chính xác 95,3% và độ nhạy lên tới 96,1%, đặc biệt hiệu quả trong phát hiện các tổn thương nhỏ.

Tuy nhiên, các nghiên cứu hiện tại – cả trong và ngoài nước – phần lớn chỉ tập trung vào bài toán phân lớp cơ bản, tức là phân biệt ảnh bình thường, lành tính hoặc ác tính. Rất ít công trình thực hiện phân loại chi tiết theo thang BI-RADS từ 0 đến 5, vốn có ý nghĩa quan trọng trong đánh giá mức độ nguy cơ và hỗ trợ bác sĩ ra quyết định lâm sàng. Đề tài này hướng đến việc phân loại ảnh X-quang tuyến vú theo từng cấp độ BI-RADS (0–5), kết hợp hai kỹ thuật bình chọn theo đông và kỹ thuật kết hợp xác suất nhằm tăng độ ổn định và độ chính xác, đồng thời xây dựng hệ thống triển khai thực tế trên nền tảng AWS với tích hợp CI/CD, góp phần hỗ trợ bác sĩ sàng lọc ảnh nhanh và hiệu quả hơn.

3. Mục tiêu đề tài

Đề tài “Ứng dụng học sâu trong phân tích hình ảnh ung thư vú” hướng đến mục tiêu áp dụng các mô hình học sâu để hỗ trợ quá trình chẩn đoán sơ bộ ảnh X-quang tuyến vú, làm giảm thời gian xem xét, đánh giá của bác sĩ. Cụ thể là xây dựng một hệ thống hỗ trợ phân loại tổn thương tuyến vú theo hệ thống phân loại kết quả chụp nhũ ảnh BI-RADS (0-5) và phân loại lành tính, ác tính từ ảnh X-quang tuyến vú một cách chính xác và hiệu quả, ngoài ra hệ thống còn cho phụ nữ kiểm tra nguy cơ ung thư vú thông qua bảng câu hỏi tầm soát, hệ thống cũng sẽ có trang admin để quản lý người dùng, quản lý lưu lượng truy cập, quản lý ảnh X-quang của bác sĩ dự đoán và quản lý các mô hình học sâu. Đề tài sẽ thu thập dữ liệu hình ảnh nhũ ảnh từ các nguồn công khai có uy tín như CBIS-DDSM, Inbreast và VinDr Mammogram để huấn luyện các mô hình học sâu, đồng thời sử dụng dữ liệu được cung cấp từ Bệnh viện Ung bướu Cần Thơ. Các mô hình học sâu được sử dụng trong đề tài này là ResNet50, MobileNetV2 và InceptionV3. Ngoài ra hệ thống sẽ được thiết kế và sử dụng các dịch vụ dựa trên nền tảng điện toán đám mây AWS (Amazon Web Services) và có sử dụng quy trình CI/CD (Continuous Integration/Continuous Deployment) để tự động hóa quá trình kiểm thử, cập nhật và triển khai, đảm bảo khả năng mở rộng, vận hành linh hoạt và dễ dàng tích hợp vào các hệ thống y tế hiện hữu.

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đề tài “Phân tích hình ảnh ung thư vú bằng các phương pháp học sâu” bao gồm:

- Các nghiên cứu liên quan đến đề tài: bao gồm tổng hợp và phân tích các nghiên cứu đã công bố có nội dung liên quan đến việc dự đoán ung thư vú, đặc biệt là ứng dụng các mô hình học sâu trong việc nâng cao độ chính xác dự đoán ung thư vú.

- Hệ thống phân loại BI-RADS: các mức độ đánh giá BI-RADS từ 0 đến 5 của bệnh thư vú dựa trên hình ảnh chụp tuyến vú.
- Ảnh y học tuyến vú: cụ thể là các hình ảnh X-quang tuyến vú trong các bộ dữ liệu Inbreast, CBIS-DDSM, VinDr Mammogram và bộ dữ liệu thực tế được cung cấp bởi bệnh viện Ung Bướu thành phố Cần Thơ.
- Các mô hình học sâu: tìm hiểu và áp dụng các mô hình học sâu nổi tiếng như ResNet50, MobileNetV2 và InceptionV3 nhằm phân loại 6 lớp BI-RADS.
- Các phương pháp đánh giá mô hình: tìm hiểu và áp dụng các phương pháp đánh giá mô hình như Precision, Recall và F1,...trong việc so sánh, đánh giá các mô hình đã được huấn luyện.
- Ứng dụng web: sử dụng các công nghệ như ReactJS, Tailwind, FastAPI, MongoDB để xây dựng ứng dụng web hỗ trợ bác sĩ dự đoán ảnh ung thư vú và bệnh nhân có thể tự kiểm tra nguy cơ ung thư vú qua bảng câu hỏi tầm soát.
- Các dịch vụ điện toán đám mây của AWS: tìm hiểu và áp dụng các dịch vụ điện toán đám mây của AWS để triển khai ứng dụng web như: VPC, EC2, S3, Amazon DocumentDB, Security groups, AWS Amplify.
- Các công cụ hỗ trợ CI/CD: để tích hợp CI/CD các công cụ sẽ được sử dụng là Github Action, Automation Test (pytest), Playwright, Docker.

Phạm vi nghiên cứu của đề tài là chủ yếu tập trung vào các vấn đề sau:

- Dữ liệu huấn luyện sẽ tập trung vào ảnh chụp X-quang tuyến vú được thu thập từ các nguồn như Inbreast, CBIS-DDSM, VinDr Mammogram và dữ liệu từ Bệnh viện Ung Bướu Cần Thơ.
- Huấn luyện các mô hình học sâu ResNet50, MobileNetV2 và InceptionV3 để phân loại 6 lớp BI-RADS (0-5). Áp dụng kỹ thuật kết hợp mô hình nhằm tăng độ chính xác dự đoán ảnh.
- So sánh, đánh giá kết quả của các mô hình đã huấn luyện bằng các chỉ số như Accuracy, Precision, Recall và F1 dựa trên Confusion Matrix.
- Xây dựng hệ thống website hỗ trợ bác sĩ chẩn đoán bệnh ung thư vú, hỗ trợ phụ nữ kiểm tra nguy cơ ung thư vú thông qua bảng câu hỏi tầm soát.
- Triển khai website lên nền tảng điện toán AWS và áp dụng kỹ thuật CI/CD để tối ưu hóa quy trình phát triển, kiểm thử, triển khai và bảo trì website.

5. Phương pháp nghiên cứu

Tìm hiểu về bệnh ung thư vú, các nguyên nhân gây nên căn bệnh và các phương pháp sàng lọc và chẩn đoán bệnh ung thư vú như: khám lâm sàng, chụp X-quang tuyến vú và sinh thiết tế bào vú.

Nghiên cứu lý thuyết các khái quát, tiêu chí, giá trị và các chuẩn đánh giá về bệnh ung thư vú và nhũ ảnh. Đồng thời tìm hiểu các nghiên cứu liên quan để có thể lựa chọn và xây dựng được các mô hình phù hợp với bài toán được đưa ra.

Tìm kiếm, thu thập hình ảnh X-quang tuyến vú từ các nguồn công khai trên mạng như Inbreast, CBIS-DDSM, VinDr Mammogram và bộ dữ liệu từ Bệnh viện Ung bướu Cần Thơ.

Tiền xử lý các hình ảnh đã thu thập được như loại bỏ ảnh có chất lượng thấp, đưa ảnh về cùng kích thước cũng như xử lý sao cho phù hợp với yêu cầu đầu vào của các mô hình.

Sau khi xử lý sẽ được huấn luyện với các mô hình học sâu ResNet50, MobileNetV2 và InceptionV3 để phân lớp các loại bệnh theo hệ thống BI-RADS.

Khi huấn luyện xong, các mô hình sẽ được đánh giá dựa trên các chỉ số như Accuracy, Precision, Recall và F1.

Xây dựng website với frontend sử dụng ReactJS, TailwindCSS, backend sử dụng FastAPI, nhằm xây dựng website trực quan, thân thiện với người dùng và dễ sử dụng nhằm hỗ trợ bác sĩ chẩn đoán bệnh ung thư vú, hỗ trợ phụ nữ kiểm tra nguy cơ ung thư vú thông qua bảng câu hỏi tầm soát. Ngoài ra sẽ có các chức năng quản lý người dùng, lưu lượng hệ thống và quản lý ảnh đã được chẩn đoán trên website để có thể tái dụng sử cho việc huấn luyện mô hình nhằm tăng độ chính xác sau này.

Tích hợp các dịch vụ của AWS vào hệ thống như VPC, EC2, S3, Amazon DocumentDB, Security groups, AWS Amplify.

Tích hợp CI/CD vào hệ thống để kiểm thử tự động, tích hợp và triển khai một cách tự động trên AWS.

Nhìn chung, phương pháp nghiên cứu thực hiện đề tài này sẽ bao gồm việc nghiên cứu lý thuyết, thu thập, xử lý dữ liệu để xây dựng và đánh giá các mô hình học sâu và xây dựng ứng dụng website sử dụng các dịch vụ của AWS và có tích hợp CI/CD để kiểm thử, tích hợp và triển khai hệ thống một cách tự động.

6. Bố cục quyển báo cáo

Tài liệu gồm có 03 phần: Giới thiệu, Nội dung và Kết luận.

Phần I: Phần giới thiệu

Giới thiệu tổng quát về đề tài, mục tiêu, phạm vi, phương pháp nghiên cứu và trình bày các vấn đề thực tế dẫn đến việc thực hiện đề tài “Phân tích hình ảnh ung thư vú bằng các phương pháp học sâu”

Phần II: Phần giới thiệu

Chương 1. Mô tả bài toán: mô tả chi tiết bài toán, giới thiệu về nhũ ảnh cũng như các cơ sở lý thuyết liên quan đến các mô hình học sâu và các vấn đề giải pháp để thực hiện đề tài.

Chương 2. Thiết kế, cài đặt giải thuật: đưa ra các mô tả về bộ dữ liệu, các mô hình phân lớp và các tiêu chí đánh giá. Thiết kế và xây dựng ứng dụng web cho việc dự đoán ung thư vú.

Chương 3. Kiểm thử và đánh giá: Trình bày thực nghiệm và ghi nhận các kết quả và đánh giá mô hình nghiên cứu.

Phần III: Phần kết luận


Tổng kết lại kết quả đạt được của nghiên cứu, đưa ra các hạn chế đồng thời nêu các đề xuất phát triển mới.

II. PHẦN NỘI DUNG

CHƯƠNG 1. MÔ TẢ BÀI TOÁN


1.1. Mô tả chi tiết bài toán

Căn bệnh ung thư vú đang là một trong những căn bệnh nguy hiểm nhất, cũng là căn bệnh mà phụ nữ hay mắc phải nhất. Theo WHO [8] đã thống kê căn bệnh ung vú (2022) là căn bệnh mà phụ nữ ở Việt Nam mắc nhiều nhất lên đến hơn 24.000 ca mắc mới, chiếm 28,9% trong tổng số ca mắc ung thư mới, hơn cả ung thư phổi, ung thư trực tràng, ung thư dạ dày và ung thư gan. Thông tin được miêu tả chi tiết ở Hình 1.1.



Hình 1.1. Những căn bệnh ung thư mà phụ nữ mắc nhiều nhất năm 2022 [8]

Với thực trạng như vậy, đề tài “Ứng dụng học sâu trong phân tích hình ảnh ung thư vú” sẽ ứng dụng học sâu trong phân tích hình ảnh X-quang tuyến vú để phân loại tổn thương tuyến vú theo hệ thống BI-RADS – hệ thống đánh giá tổn thương vú, xác định xem tuyến vú có đang mắc ung thư hay không, nhằm tăng cường độ chính xác phân loại ung thư vú, cũng như tiết kiệm thời gian chẩn đoán sơ bộ cho các bác sĩ.



Hình 1.2. Ảnh X-Quang tuyến vú của bệnh nhân

Dữ liệu sử dụng trong đề tài bao gồm các ảnh chụp X-quang tuyến vú của bệnh nhân, như minh họa ở Hình 1.2. Các ảnh này được thu thập từ những nguồn dữ liệu công khai, đáng tin cậy và đã được sử dụng rộng rãi trong cộng đồng nghiên cứu như bộ Inbreast, CBIS-DDSM, VinDr-Mammogram, cùng với một phần dữ liệu thực tế từ Bệnh viện Ung Bướu Cần Thơ. Sau khi thu thập, toàn bộ ảnh sẽ trải qua quá trình tiền xử lý nhằm chuẩn hóa chất lượng và định dạng. Cụ thể, các ảnh bị nhiễu sẽ được loại bỏ, ảnh được đưa về cùng kích thước và tỷ lệ phù hợp để đảm bảo tính nhất quán trong quá trình huấn luyện.

Sau bước tiền xử lý, dữ liệu sẽ được đưa vào huấn luyện và đánh giá bởi ba mô hình học sâu phổ biến và hiệu quả trong xử lý ảnh là ResNet50, MobileNetV2 và InceptionV3. Các mô hình này được lựa chọn vì khả năng trích xuất đặc trưng mạnh mẽ, độ sâu vừa phải và khả năng tổng quát tốt trên ảnh y khoa [9]. Mục tiêu của các mô hình là phân loại các ảnh X-quang tuyến vú vào 6 cấp độ của thang phân loại BI-RADS, từ cấp 0 đến cấp 5. Nhằm cải thiện độ chính xác và tính ổn định của hệ thống, kỹ thuật kết hợp mô hình (model ensemble) [10] sẽ được áp dụng để tổng hợp kết quả dự đoán từ các mô hình riêng lẻ. Đây là một chiến lược phổ biến trong học sâu nhằm tận dụng điểm mạnh của từng mô hình thành phần và giảm thiểu sai số cục bộ. Cuối cùng, hiệu năng của từng mô hình đơn lẻ và mô hình kết hợp sẽ được so sánh, đánh giá thông qua các chỉ số như độ chính xác, độ nhạy, độ đặc hiệu và F1-score, từ đó đưa ra nhận xét về ưu điểm và hạn chế của từng phương pháp.

Cuối cùng sẽ xây dựng một hệ thống website với frontend sử dụng ReactJS, TailwindCSS, backend sử dụng FastAPI, nhằm xây dựng website trực quan, thân thiện với người dùng và dễ sử dụng với mong muốn hỗ trợ bác sĩ trong việc chẩn đoán bệnh ung thư vú, đồng thời cung cấp công cụ kiểm tra nguy cơ mắc bệnh cho phụ nữ thông qua bảng câu hỏi tầm soát. Website sẽ tích hợp các chức năng quản lý người dùng, theo dõi lưu lượng truy cập hệ thống, cũng như quản lý và lưu trữ các ảnh chẩn đoán.

Các ảnh này có thể được tái sử dụng cho mục đích huấn luyện mô hình trong tương lai nhằm cải thiện độ chính xác của hệ thống. Hệ thống sẽ được triển khai trên nền tảng đám mây AWS, tích hợp các dịch vụ như Amazon EC2, S3, VPC, DocumentDB, Security Groups và AWS Amplify để đảm bảo hiệu suất, tính bảo mật và khả năng mở rộng. Ngoài ra, quy trình CI/CD sẽ được tích hợp nhằm tự động hóa việc kiểm thử, triển khai và cập nhật hệ thống một cách liên tục, giúp tối ưu hóa hiệu quả vận hành và rút ngắn thời gian phát triển.

1.2. Vấn đề giải pháp liên quan đến bài toán

1.2.1. Các phương pháp sàng lọc ung thư vú

Sàng lọc bệnh ung thư vú là một quá trình sử dụng các phương pháp khác nhau để phát hiện sớm các bất thường ở vú, đặc biệt là ung thư. Các phương pháp sàng lọc giúp phát hiện ung thư ở giai đoạn sớm hơn, khi khối u còn nhỏ và thường chưa di căn hạch nách, dẫn đến tỷ lệ sống thêm cao hơn đáng kể. Việc phát hiện sớm, đặc biệt là các khối u không sờ thấy được hoặc có kích thước nhỏ, đóng vai trò quan trọng trong việc điều trị hiệu quả và kéo dài thời gian sống. Tỷ lệ sống thêm 5 năm, 8 năm và 10 năm được phát hiện trong các phương pháp sàng lọc lớn theo thứ tự là 88%, 83% và 79% [11]. Hiện nay, các phương pháp sàng lọc ung thư vú phổ biến là: khám lâm sàng, chụp nhũ ảnh, sinh thiết tế bào.

1.2.1.1. Khám lâm sàng

Khám lâm sàng, đặc biệt là sờ nắn tuyến vú, là một phương pháp tiết kiệm thời gian để phát hiện và đánh giá các bất thường tại tuyến vú. Đây là một kỹ thuật đơn giản, mang lại giá trị thực tiễn cao, có thể được thực hiện bởi bác sĩ hoặc chính người bệnh. Tuy nhiên, phương pháp này vẫn tồn tại nhiều hạn chế về độ nhạy và khả năng chẩn đoán phân biệt. Thống kê cho thấy chỉ khoảng 60% các khối u được phát hiện bằng chụp X-quang tuyến vú có thể được sờ thấy khi khám lâm sàng [11].


Bên cạnh đó, cảm nhận lâm sàng không phải lúc nào cũng chính xác. Có khoảng 15% trường hợp được đánh giá là u lành tính trên lâm sàng thực chất lại là u ác tính, và ngược lại, khoảng 10% trường hợp được nghĩ là ác tính lại không có tổn thương ác tính thực sự khi làm xét nghiệm mô bệnh học [11]. Điều này cho thấy hạn chế rõ rệt của phương pháp khám sờ nắn trong việc phân biệt bản chất tổn thương, đặc biệt là ở giai đoạn sớm hoặc với các tổn thương có đặc điểm không điển hình. Việc chẩn đoán nhầm có thể dẫn đến hai hậu quả nghiêm trọng: hoặc bỏ sót tổn thương ác tính cần can thiệp sớm, hoặc gây lo âu không cần thiết và dẫn đến can thiệp quá mức ở những trường hợp lành tính. Vì vậy, khám lâm sàng chỉ nên được coi là bước sàng lọc ban đầu và cần được phối hợp với các phương pháp chẩn đoán khác để đưa ra quyết định chính xác hơn.

1.2.1.2. Chụp ảnh tuyến vú

Chụp ảnh tuyến vú là phương pháp sàng lọc phổ biến nhất trong chẩn đoán ung thư vú, có nhiều phương pháp hình ảnh được sử dụng, tuy nhiên ba kỹ thuật phổ biến và được áp dụng rộng rãi nhất hiện nay là chụp X-Quang tuyến vú (mammography), siêu âm tuyến vú (ultrasound) và chụp cộng hưởng từ tuyến vú (MRI).

a) Chụp X-Quang tuyến vú (mammography)


Chụp X-Quang tuyến vú (mammography) là một kỹ thuật chẩn đoán hình ảnh sử dụng tia X liều thấp để thu được hình ảnh chi tiết của mô tuyến vú. Phương pháp này được xem là tiêu chuẩn vàng trong sàng lọc và phát hiện sớm ung thư vú, đặc biệt hiệu quả ở phụ nữ từ 40 tuổi trở lên. Mammography có khả năng phát hiện các bất thường rất nhỏ trong vú, bao gồm cả các vi vôi hóa – một trong những dấu hiệu sớm của ung thư biểu mô ống tại chỗ [12]. Tuy nhiên, hiệu quả của phương pháp có thể giảm ở phụ nữ có mô vú dày, do hình ảnh thu được bị che khuất bởi mô tuyến.



Hình 1.3. Ví dụ ảnh chụp X-Quang tuyến vú

Hình 1.3. ví dụ một ảnh chụp X-Quang tuyến vú, ảnh X-Quang hiển thị khá chi tiết các tế bào trong tuyến vú, việc này sẽ làm các bác sĩ dễ dàng chuẩn đoán bệnh. Ảnh chụp X-Quang tuyến vú là một kỹ thuật quan trọng, có độ chính xác cao, giá thành rẻ hơn chụp MRI nên đây cũng chính là phương pháp sàng lọc ung thư vú phổ biến nhất hiện nay.

Kỹ thuật chụp này thường có hai kiểu chụp cơ bản được áp dụng khi tiến hành chụp nhũ ảnh là kiểu chụp CC (Craniocaudal) và MLO (Mediolateral Oblique). CC là kiểu chụp góc thẳng từ phía trước của vú, MLO là kiểu chụp ứng với phương nghiêng của vú như Hình 1.4.




Hình 1.4. Mô tả góc chụp CC, MLO⁷

b) Chụp cộng hưởng từ tuyến vú (MRI)

Chụp cộng hưởng từ tuyến vú (MRI) là một phương pháp chẩn đoán hình ảnh tiên tiến sử dụng từ trường mạnh và sóng radio để tạo ra hình ảnh chi tiết của mô tuyến vú mà không sử dụng tia X. Kỹ thuật này có độ nhạy rất cao, thường được áp dụng để phát hiện ung thư vú ở những phụ nữ có nguy cơ cao, đánh giá mức độ lan rộng của tổn thương trước điều trị, hoặc kiểm tra sau phẫu thuật và hóa trị. MRI tuyến vú có khả năng phát hiện các tổn thương mà mammography và siêu âm có thể bỏ sót, đặc biệt ở những bệnh nhân có mô vú dày hoặc hình ảnh X-quang không rõ ràng.

Tuy nhiên, MRI không thể phát hiện vi vôi hóa – một dấu hiệu quan trọng của ung thư biểu mô ống tại chỗ – nên không thể thay thế hoàn toàn mammography trong sàng lọc. Ngoài ra, chi phí cao, thời gian thực hiện kéo dài và khả năng tạo ra kết quả dương tính giả cũng là những yếu tố cần cân nhắc khi chỉ định kỹ thuật này. Hình 1.5. là một ảnh ví dụ về chụp cộng hưởng từ tuyến vú.



Hình 1.5. Ví dụ ảnh chụp MRI tuyến vú⁸


⁷ https://media.springernature.com/lw685/springer-static/image/chp%3A10.1007%2F978-981-99-0035-0_2/MediaObjects/521573_1_En_2_Fig4_HTML.png

c) Siêu âm tuyến vú (ultrasound)

Siêu âm tuyến vú (breast ultrasound) là một phương pháp chẩn đoán hình ảnh sử dụng sóng siêu âm tần số cao để tạo ra hình ảnh mô mềm của tuyến vú. Kỹ thuật này đặc biệt hữu ích trong việc phân biệt giữa khối u đặc và u nang, cũng như đánh giá các tổn thương không rõ ràng trên phim X-quang, nhất là ở những phụ nữ có mô vú dày – đối tượng mà mammography thường kém hiệu quả.

Hiện nay, siêu âm vú vẫn được xem là một phương pháp an toàn, đơn giản, không độc hại do không sử dụng tia phóng xạ, không xâm lấn, không gây đau và cho kết quả nhanh chóng. Ưu điểm lớn là có thể áp dụng cho mọi lứa tuổi, từ phụ nữ trẻ đến người cao tuổi. Bên cạnh đó, so với các kỹ thuật hình ảnh tiên tiến khác, siêu âm có giá thành hợp lý hơn, đặc biệt phù hợp với điều kiện kinh tế của phần lớn người dân Việt Nam. Phương pháp này cũng dễ tiếp cận tại các cơ sở y tế tuyến tỉnh, huyện.

Tuy nhiên, siêu âm phụ thuộc đáng kể vào trình độ và kinh nghiệm của người thực hiện, đồng thời không có khả năng phát hiện vi vôi hóa – một trong những dấu hiệu sớm của ung thư biểu mô ống tại chỗ (DCIS). Do đó, siêu âm thường được sử dụng như công cụ hỗ trợ, kết hợp với các phương pháp chẩn đoán hình ảnh khác như Mammography hoặc MRI để nâng cao hiệu quả tầm soát. Hình 1.6. ví dụ về ảnh siêu âm tuyến vú.



Hình 1.6. Ví dụ ảnh siêu âm tuyến vú 2 bên⁹

Tóm lại có ba phương pháp chẩn đoán hình ảnh tuyến vú phổ biến nhất gồm: chụp X-quang tuyến vú (mammography), siêu âm tuyến vú, và chụp cộng hưởng từ tuyến vú (MRI). Mỗi kỹ thuật có ưu điểm riêng và được lựa chọn tùy theo tình trạng mô vú, độ tuổi, yếu tố nguy cơ và mục đích lâm sàng.

⁸https://www.vinmec.com/static/uploads/20200927_063223_841531_Untitled_max_1800x1800_png_2d4db39c15.png

⁹<https://benhvienthucuc.vn/wp-content/uploads/2023/12/Nhan-giam-am-tuyen-vu-hai-ben-e1701079107420.jpg>


Mammography là kỹ thuật tiêu chuẩn trong sàng lọc ung thư vú, đặc biệt hiệu quả trong việc phát hiện các tổn thương nhỏ và vi vôi hóa. Siêu âm tuyến vú có vai trò hỗ trợ, giúp phân biệt tổn thương đặc hay nang, dễ tiếp cận, chi phí hợp lý và phù hợp với nhiều lứa tuổi. MRI tuyến vú có độ nhạy rất cao, thường được chỉ định trong các trường hợp nguy cơ cao hoặc để đánh giá tổn thương lan rộng, tuy nhiên chi phí cao và không thay thế được mammography trong sàng lọc.

Trong ba kỹ thuật, chụp X-quang tuyến vú vẫn là phương pháp phổ biến và được ứng dụng rộng rãi nhất nhờ sự cân bằng giữa độ chính xác, khả năng phát hiện sớm tổn thương và chi phí hợp lý. Đây là lựa chọn hàng đầu trong các chương trình tầm soát ung thư vú cộng đồng hiện nay.

1.2.1.3. Sinh thiết tế bào

Sinh thiết tế bào là một trong những bước quan trọng trong chẩn đoán xác định ung thư vú, giúp đánh giá trực tiếp bản chất tổn thương thông qua việc thu nhận tế bào hoặc mô từ khối u để phân tích dưới kính hiển vi. Kỹ thuật này thường sẽ được thực hiện sau bước chẩn đoán qua nhũ ảnh của bác sĩ mà kết quả thuộc từ BI-RADS 3 trở lên sẽ được bác sĩ đề nghị sinh thiết. Kỹ thuật này bao gồm các phương pháp như chọc hút kim nhỏ (FNA), sinh thiết kim lõi (core needle biopsy) và sinh thiết mở, tùy thuộc vào độ sâu, vị trí, kích thước của tổn thương và mục đích lâm sàng.

Trong đó, chọc hút kim nhỏ (FNA) là kỹ thuật đơn giản, ít xâm lấn, sử dụng kim mảnh để hút tế bào từ khối nghi ngờ. Phương pháp này đặc biệt hữu ích khi cần đánh giá nhanh tính chất của tổn thương và có thể thực hiện tại phòng khám, với độ nhạy trung bình khoảng 87% và độ đặc hiệu lên tới 100% nếu do bác sĩ giàu kinh nghiệm thực hiện. Tuy nhiên, FNA không cung cấp thông tin về cấu trúc mô, nên không thể phân biệt chính xác giữa ung thư biểu mô ống tại chỗ (DCIS) và ung thư xâm lấn. Hình 1.7. là một ví dụ của việc chọc hút kim nhỏ để lấy tế bào đi xét nghiệm dưới kính hiển vi.



Hình 1.7. Sinh thiết khối u vú có hướng dẫn từ siêu âm¹⁰

¹⁰https://cdn.nhathuoclongchau.com.vn/unsafe/https://cms-prod.s3-sgn09.ftcloud.com/sinh_thiet_vu_la_gi_co_bao_nhiieu_loai_sinh_thiet_vu_1_4119d933b1.jpg

Sinh thiết kim lõi (core biopsy) sử dụng kim có kích thước lớn hơn để lấy mẫu mô đầy đủ hơn, cho phép đánh giá cả mô học và kiến trúc tổn thương. Đây là kỹ thuật phổ biến hiện nay trong thực hành lâm sàng vì độ chính xác cao, có thể đạt độ nhạy trên 90%, và thường được thực hiện dưới hướng dẫn siêu âm hoặc X-quang.

Trong một số trường hợp đặc biệt, sinh thiết mở (open biopsy) hoặc sinh thiết tức thì kèm cắt lạnh vẫn được sử dụng như tiêu chuẩn vàng khi các phương pháp khác chưa đủ độ chính xác. Kỹ thuật này giúp cung cấp mẫu mô đầy đủ, đảm bảo chẩn đoán xác định, với tỷ lệ dương tính giả gần như bằng 0 và tỷ lệ âm tính giả dưới 1%.

Tổng thể, sinh thiết tế bào giữ vai trò quyết định trong quá trình xác định chẩn đoán ung thư vú, giúp bác sĩ không chỉ phân biệt tổn thương lành tính hay ác tính, mà còn xác định được mức độ, yếu tố quan trọng cho việc lên kế hoạch điều trị tiếp theo.

1.2.2. Hệ thống phân loại BI-RADS

BI-RADS (Breast Imaging Reporting and Data System) là hệ thống phân loại chuẩn hóa do Hiệp hội X-quang Hoa Kỳ (American College of Radiology – ACR) phát triển nhằm đồng bộ cách báo cáo kết quả chẩn đoán hình ảnh tuyến vú. Hệ thống này giúp các bác sĩ chẩn đoán hình ảnh mô tả tổn thương một cách thống nhất, hỗ trợ bác sĩ lâm sàng ra quyết định điều trị và theo dõi hiệu quả hơn.

Mỗi tổn thương được phát hiện sẽ được đánh giá và xếp vào một trong các cấp độ từ 0 đến 6, phản ánh mức độ nghi ngờ ác tính và hướng xử trí phù hợp.

Bảng 1.1. Hệ thống phân loại BI-RADS

BI-RADS	Mô tả	Khả năng ác tính	Hướng xử trí
0	Chưa đầy đủ thông tin	Không xác định	Chụp bổ sung
1	Bình thường	~0%	Tiếp tục theo dõi
2	Tổn thương lành tính	~0%	Không cần can thiệp
3	Tổn thương có khả năng lành tính cao	<2%	Theo dõi định kỳ, có thể sinh thiết
4A	Nguy cơ ác tính thấp	>2% đến ≤10%	Sinh thiết
4B	Nguy cơ ác tính trung bình	>10% đến ≤50%	Sinh thiết
4C	Nguy cơ ác tính cao	>50% đến <95%	Sinh thiết
5	Rất nghi ngờ ác tính	≥95%	Cần thực hiện sinh thiết
6	Đã xác định ung thư qua sinh thiết	100%	Lên kế hoạch điều trị ung thư

Quy trình xác định BI-RADS bắt đầu với việc thu thập hình ảnh thông qua các kỹ thuật như chụp X-quang tuyến vú, siêu âm, hoặc MRI. Những hình ảnh này cung cấp thông tin chi tiết về mô vú, giúp các bác sĩ chuyên khoa có cái nhìn toàn diện về tình

trạng của bệnh nhân. Sau khi thu thập hình ảnh, bác sĩ sẽ tiến hành đánh giá để xác định có bất thường nào hay không. Trong giai đoạn này, các đặc điểm như khối u, viêm, và các bất thường về hình dạng và cấu trúc sẽ được xem xét kỹ lưỡng.

Dựa trên kết quả đánh giá, bác sĩ sẽ gán mức BI-RADS phù hợp cho từng trường hợp. Việc gán mức này dựa trên các tiêu chí đã được quy định như loại bất thường, khả năng ung thư, khả năng di căn... Sau khi mức BI-RADS được xác định, bác sĩ sẽ đưa ra các khuyến nghị tiếp theo như theo dõi, làm thêm xét nghiệm, hoặc bắt đầu điều trị. Các khuyến nghị này được điều chỉnh phù hợp với từng mức độ BI-RADS, từ đó tối ưu hóa quy trình tầm soát và điều trị, đồng thời cải thiện kết quả chăm sóc bệnh nhân.

Hệ thống phân loại BI-RADS là một công cụ quan trọng trong chẩn đoán và quản lý bệnh ung thư vú. Việc hiểu rõ các mức độ BI-RADS và quy trình xác định giúp các bác sĩ đưa ra các quyết định lâm sàng chính xác và kịp thời, đồng thời cải thiện giao tiếp và phối hợp giữa các chuyên gia y tế.


1.2.3. Các mô hình học sâu

1.2.3.1. Mô hình ResNet50

Mô hình ResNet (Residual Network) là một bước ngoặt quan trọng trong lĩnh vực học sâu, đặc biệt là trong các bài toán thị giác máy tính. Kiến trúc này được giới thiệu bởi Kaiming He và các cộng sự vào năm 2015 [13], với mục tiêu giải quyết vấn đề khó khăn khi huấn luyện các mạng nơ-ron rất sâu do hiện tượng suy giảm gradient. Sự khác biệt của ResNet nằm ở việc sử dụng các kết nối tắt (skip connections) cho phép thông tin được truyền qua nhiều lớp mà không bị mất mát.


Mô hình này đã chứng minh hiệu quả vượt trội khi đạt được kết quả xuất sắc tại cuộc thi ILSVRC (ImageNet Large Scale Visual Recognition Challenge) 2015. Cụ thể, ResNet giành giải nhất trong nhiệm vụ phân loại ảnh, với tỷ lệ lỗi chỉ 3,57% [13] – một con số kỷ lục thời điểm đó, vượt qua tất cả các mô hình trước đó như VGGNet, GoogLeNet,

Ngoài ra, ResNet có nhiều biến thể chạy trên cùng một khái niệm nhưng có số lượng lớp gộp khác nhau, trong số đó, ResNet-50 là một trong những phiên bản phổ biến và được sử dụng rộng rãi nhất, với tổng cộng 50 lớp có trọng số huấn luyện, cân bằng tốt giữa độ chính xác và tốc độ tính toán. Nó đã trở thành một mô hình tiêu chuẩn trong nhiều tác vụ thị giác máy tính như phân loại ảnh, phát hiện vật thể, trích xuất đặc trưng, và làm backbone cho nhiều mô hình hiện đại.



Hình 1.8. Kiến trúc mô hình mạng học sâu ResNet50¹¹

Hình 1.8. mô tả tổng quan kiến trúc mô hình mạng ResNet50. Cấu trúc của ResNet-50 được chia thành nhiều giai đoạn (stages), bắt đầu với một lớp convolution đầu tiên sử dụng kernel kích thước 7×7 và stride 2, sau đó là một lớp pooling 3×3 . Tiếp theo, mô hình gồm bốn khối chính (conv2_x đến conv5_x), mỗi khối chứa nhiều residual block được thiết kế theo dạng bottleneck. Cụ thể, ResNet-50 bao gồm 3 block ở conv2_x, 4 block ở conv3_x, 6 block ở conv4_x và 3 block ở conv5_x. Mỗi block bottleneck gồm ba lớp convolution liên tiếp với các kernel kích thước 1×1 , 3×3 và 1×1 – trong đó, lớp 1×1 đầu tiên có vai trò giảm số chiều, lớp 3×3 xử lý đặc trưng và lớp 1×1 cuối cùng khôi phục lại số chiều ban đầu. Kết quả từ các lớp này sẽ được cộng với đầu vào thông qua kết nối tắt, tạo thành đầu ra của block.



Hình 1.9 Ví dụ cho các residual block (kết nối tắt)¹²

Phép kết nối tắt ở ResNet50 như Hình 1.9. các khối ở layer trước được cộng trực tiếp vào layer liên sau. Nếu coi layer liên trước là x , sau khi đi qua các xử lý tích chập

¹¹ <https://cdn.educba.com/academy/wp-content/uploads/2022/10/Keras-ResNet50.jpg.webp>


¹² https://phamdinhhkhanh.github.io/assets/images/20200914_Mobilenet/pic4.jpeg

hai chiều ta thu được kết quả $F(x)$ thì output cuối cùng là một residual block có giá trị $x + F(x)$ [14].

Tổng thể, ResNet-50 sở hữu độ sâu vừa phải nhưng vẫn giữ được hiệu suất mạnh mẽ và độ chính xác cao nhờ vào kiến trúc residual. Nhờ thiết kế này, ResNet-50 có thể huấn luyện hiệu quả trên các tập dữ liệu lớn như ImageNet và thường được sử dụng như một backbone trong nhiều mô hình thị giác máy tính hiện đại như Faster R-CNN, Mask R-CNN, RetinaNet và YOLOv5. Với sự cân bằng tốt giữa độ chính xác và chi phí tính toán, ResNet-50 trở thành một trong những mô hình tiêu chuẩn trong nhiều ứng dụng học sâu hiện nay [13].

Kiến trúc ResNet-50 với các residual block sâu và cơ chế skip connection giúp cải thiện việc lan truyền gradient trong quá trình huấn luyện, từ đó giảm thiểu hiện tượng gradient biến mất và cho phép huấn luyện các mạng rất sâu mà vẫn hội tụ tốt. Nhờ khả năng trích xuất đặc trưng mạnh mẽ và ổn định, ResNet-50 đặc biệt phù hợp để nhận diện các đặc điểm bất thường tinh vi trong ảnh X-quang tuyến vú, chẳng hạn như khối u nhỏ, vi vôi hóa, hay tổn thương mô mềm. Điều này giúp mô hình tăng độ chính xác trong phân loại BI-RADS hoặc chẩn đoán ung thư vú, hỗ trợ hiệu quả cho hệ thống hỗ trợ ra quyết định lâm sàng.

1.2.3.2. Mô hình MobileNetV2



Hình 1.10. Kiến trúc mô hình mạng học sâu MobileNetV2¹³

MobileNetV2 là một kiến trúc mạng nơ-ron tích chập sâu được phát triển bởi nhóm nghiên cứu của Google và giới thiệu trong bài báo "*MobileNetV2: Inverted Residuals and Linear Bottlenecks*" vào năm 2018 [15]. Kiến trúc này được thiết kế nhằm tối ưu hóa hiệu suất cho các thiết bị di động và nhúng như Hình 1.10, với mục tiêu giảm thiểu số lượng tham số và phép tính nhưng vẫn duy trì được độ chính xác cao trong các bài toán như phân loại ảnh, phát hiện đối tượng, và trích xuất đặc trưng.

¹³<https://www.researchgate.net/publication/350152088/figure/fig1/AS:1002717703045121@1616077938892/Th-e-proposed-MobileNetV2-network-architecture.png>


MobileNetV2 kế thừa ý tưởng từ MobileNetV1 – vốn sử dụng depthwise separable convolution (tách tích chập theo chiều sâu), giúp giảm đáng kể số lượng phép tính so với tích chập chuẩn. Tuy nhiên, điểm mới nổi bật của MobileNetV2 là việc giới thiệu inverted residual block (khối dư nghịch đảo) kết hợp với linear bottleneck. Trong mỗi khối, đầu vào trước tiên được mở rộng chiều (expansion) thông qua một lớp convolution 1×1 , sau đó được áp dụng depthwise convolution 3×3 , rồi cuối cùng được thu hẹp lại (projection) về số chiều ban đầu thông qua một lớp convolution 1×1 khác [15]. Khác với ResNet, nơi kết nối tắt (skip connection) được áp dụng trực tiếp lên các đầu vào và đầu ra có số chiều lớn, MobileNetV2 sử dụng kết nối tắt giữa các tensor có số chiều nhỏ hơn (sau khi thu hẹp) – do đó gọi là “inverted residual”. MobileNetV2 cũng sử dụng những kết nối tắt như ở mạng ResNet. Tuy nhiên kết nối tắt ở MobileNetV2 được điều chỉnh sao cho số kênh (hoặc chiều sâu) ở input và output của mỗi block residual được thắt hẹp lại. Chính vì thế nó được gọi là các bottleneck layers (bottleneck là một thuật ngữ thường được sử dụng trong deep learning để ám chỉ các kiến trúc thu hẹp kích thước theo một chiều nào đó) [15].

Một cải tiến quan trọng khác là việc loại bỏ hàm phi tuyến (ReLU) ở cuối mỗi block để tránh mất mát thông tin trong các không gian chiều thấp, điều này được gọi là linear bottleneck. Nhờ thiết kế này, MobileNetV2 cho phép mạng giữ lại thông tin đặc trưng tốt hơn, đặc biệt khi số chiều giảm mạnh.

Nhờ vào thiết kế tiết kiệm tài nguyên nhưng vẫn giữ được độ chính xác, MobileNetV2 trở thành kiến trúc lý tưởng cho các bài toán học sâu trên các thiết bị có giới hạn về bộ nhớ và hiệu suất tính toán. Mô hình này cũng được dùng rộng rãi như backbone trong nhiều hệ thống thị giác máy tính nhẹ, và được hỗ trợ trong các framework lớn như TensorFlow Lite, PyTorch Mobile, v.v. Chính vì vậy MobileNetV2 là lựa chọn lý tưởng để triển khai các mô hình học sâu trên thiết bị đầu cuối hoặc hệ thống có tài nguyên hạn chế, đồng thời vẫn đảm bảo chất lượng dự đoán. Điều này đặc biệt hữu ích trong ứng dụng tầm soát ung thư vú từ ảnh X-quang, nơi yêu cầu mô hình phải nhanh, chính xác và có khả năng triển khai trong thực tế lâm sàng.

1.2.3.3. Mô hình InceptionV3

InceptionV3 là một phiên bản cải tiến của dòng mô hình Inception (còn gọi là GoogleNet), được giới thiệu bởi Christian Szegedy và các cộng sự. Mô hình này được phát triển với mục tiêu đạt độ chính xác cao trong các bài toán phân loại ảnh mà vẫn đảm bảo hiệu quả tính toán và tối ưu hóa tài nguyên [16].



Hình 1.11. Kiến trúc mô hình mạng học sâu InceptionV3¹⁴

Điểm nổi bật của InceptionV3 là cách xây dựng mạng sử dụng các Inception module – khối mạng cho phép xử lý song song đầu vào qua nhiều nhánh tích chập khác nhau với các kernel có kích thước khác nhau (ví dụ: 1×1 , 3×3 , 5×5), sau đó nối (concatenate) lại. Điều này cho phép mô hình nắm bắt được đặc trưng ở nhiều mức độ không gian khác nhau, từ chi tiết cục bộ đến ngữ cảnh rộng hơn [16].

Kiến trúc InceptionV3 được xây dựng dựa trên ba loại module chính như ở Hình 1.11, bao gồm Inception Module A, Inception Module B và Inception Module C. Mỗi module có thiết kế đặc trưng, thực hiện một vai trò riêng biệt trong việc trích xuất đặc trưng và tối ưu hiệu quả tính toán của mạng.

Inception Module A được thiết kế để giữ nguyên kích thước không gian của đặc trưng (height $\times$ width) trong khi mở rộng chiều sâu kênh (depth). Module này bao gồm bốn nhánh xử lý song song: nhánh đầu tiên sử dụng một lớp tích chập 1×1 ; nhánh thứ hai gồm một lớp 1×1 convolution tiếp nối bởi một lớp 5×5 convolution; nhánh thứ ba thay thế phép tích chập 5×5 bằng hai lớp 3×3 convolution liên tiếp nhằm giảm chi phí tính toán; nhánh cuối cùng sử dụng average pooling 3×3 sau đó là một lớp 1×1 convolution để giữ lại thông tin tổng quát [16]. Việc kết hợp nhiều nhánh với các kernel khác nhau giúp mô hình trích xuất được đặc trưng ở nhiều mức độ không gian, từ chi tiết cục bộ đến ngữ cảnh rộng hơn.

Inception Module B đóng vai trò giảm kích thước không gian của đặc trưng (downsampling) nhằm giảm chi phí tính toán ở các tầng sâu hơn trong mạng. Khối này gồm ba nhánh chính: một nhánh thực hiện tích chập 3×3 với bước nhảy (stride) bằng 2; một nhánh khác sử dụng chuỗi các lớp convolution: $1 \times 1 \rightarrow 3 \times 3 \rightarrow 3 \times 3$ với bước nhảy ở cuối để giảm kích thước; và một nhánh sử dụng max pooling 3×3 với stride = 2 [16]. Việc sử dụng nhiều kỹ thuật downsampling song song giúp mạng giảm độ phân giải đặc trưng một cách hiệu quả mà vẫn duy trì khả năng trích xuất thông tin.

Inception Module C được sử dụng ở giai đoạn cuối của mạng nhằm tăng chiều sâu và độ phức tạp của biểu diễn đặc trưng, trong khi vẫn giữ nguyên kích thước

¹⁴<https://www.researchgate.net/publication/341563435/figure/fig3/AS:941464410402818@1601474015137/Bloc k-diagram-of-Inception-v3-improved-deep-architecture.png>

không gian. Khối này cũng gồm bốn nhánh: nhánh đầu là lớp 1×1 convolution đơn giản; hai nhánh tiếp theo đều bắt đầu bằng 1×1 convolution, sau đó lần lượt sử dụng các cặp kernel 1×3 và 3×1 được xếp nối tiếp để mô phỏng phép tích chập 3×3 theo hướng ngang và dọc, giúp mạng học được các đặc trưng theo hướng cụ thể; nhánh cuối cùng sử dụng average pooling kết hợp với 1×1 convolution để bổ sung thông tin tổng quát [16]. Việc tách kernel 3×3 thành 1×3 và 3×1 được gọi là factorization, giúp giảm đáng kể số lượng phép tính mà không làm mất hiệu quả học của mạng.

Với thiết kế sử dụng nhiều nhánh tích chập song song có kích thước kernel khác nhau, kiến trúc InceptionV3 cho phép mô hình trích xuất đặc trưng hình ảnh ở nhiều tỉ lệ không gian khác nhau, từ đó nhận diện hiệu quả các bất thường có thể xuất hiện ở các vị trí, kích thước và hình dạng đa dạng trong ảnh X-quang tuyến vú, chẳng hạn như vi vôi hóa, khối u nhỏ hoặc các thay đổi mô mờ nhạt. Bên cạnh đó, mô hình giảm đáng kể số lượng tham số và chi phí tính toán mà không làm ảnh hưởng đến hiệu năng mô hình. Tính linh hoạt và khả năng biểu diễn mạnh mẽ của InceptionV3 khiến nó trở thành một lựa chọn hợp lý và hiệu quả trong bài toán phân loại mức độ nghi ngờ tổn thương theo thang BI-RADS, góp phần hỗ trợ bác sĩ trong việc tầm soát và chẩn đoán sớm ung thư vú từ hình ảnh X-quang.

1.2.4. Tăng độ chính xác bằng phương pháp kết hợp các mô hình

Để nâng cao hiệu suất nhận diện và phân loại mức độ nghi ngờ tổn thương trong ảnh X-quang tuyến vú theo thang BI-RADS, luận văn đề xuất áp dụng kỹ thuật kết hợp mô hình học sâu (deep learning ensemble). Cụ thể, ba mô hình có kiến trúc khác nhau gồm ResNet50, MobileNetV2 và InceptionV3 được huấn luyện độc lập trên cùng tập dữ liệu, sau đó kết quả đầu ra của chúng được tổng hợp lại thông qua hai chiến lược: bình chọn theo số đông (majority voting) và phương pháp kết hợp xác suất từng lớp.

1.2.4.1. Phương pháp bình chọn theo số đông

Phương pháp đầu tiên được áp dụng là bình chọn theo số đông, lấy cảm hứng từ ý tưởng tổng hợp trong mô hình Random Forest [17], nơi kết quả dự đoán cuối cùng được xác định bởi đa số phiếu từ các cây quyết định. Tương tự, trong nghiên cứu này, ba mô hình học sâu – ResNet50, MobileNetV2 và InceptionV3 – hoạt động độc lập như ba “người bỏ phiếu” dự đoán nhãn lớp cho mỗi ảnh đầu vào.

Với mỗi ảnh, ba mô hình sẽ đưa ra ba nhãn dự đoán. Nếu có hai hoặc nhiều mô hình đồng ý về cùng một nhãn, thì nhãn đó được chọn làm kết quả cuối). Cụ thể như ví dụ ở Bảng 1.2. sau:

Bảng 1.2. Ví dụ cho cách tính phương pháp bình chọn theo số đồng

Nhân Mô hình	BI-RADS 0	BI-RADS 1	BI-RADS 2	BI-RADS 3	BI-RADS 4	BI-RADS 5
ResNet50	0	1	0	0	0	0
MobileNetV2	0	0	1	0	0	0
InceptionV3	0	1	0	0	0	0
Tổng	0	2	1	0	0	0
⇒ Kết quả là BI-RADS 1 do có điểm cao nhất (2 điểm)						

Với một tấm ảnh thì mỗi mô hình sẽ dự đoán ảnh đó thuộc lớp nào thì lớp đó sẽ được 1 điểm tương ứng với mô hình đó, kết quả kết cùng là lớp có nhiều điểm nhất. Như ở ví dụ trên thì lớp BI-RADS 1 có nhiều điểm nhất (2 điểm) do có 2 mô hình ResNet50 và InceptionV3 dự đoán ảnh vào lớp BI-RADS 1.

Tuy nhiên, trong trường hợp cả ba mô hình dự đoán ba nhãn khác nhau, thay vì lựa chọn ngẫu nhiên hoặc bỏ qua, hệ thống sẽ chọn nhãn có xác suất cao nhất trong ba đầu ra softmax – tức là nhãn được dự đoán với độ tin cậy cao nhất trong toàn bộ mô hình.

Cụ thể:

- Mỗi mô hình xuất ra vector xác suất phân phối: $p^{(i)} = [p_0^{(i)}, p_1^{(i)}, \dots, p_5^{(i)}]$
- Trong trường hợp 3 mô hình cho ra 3 nhãn khác nhau, thì nhãn mà có xác suất được chọn cao nhất sẽ là kết quả cuối cùng. Gọi γ là nhãn cuối cùng thì sẽ được tính như sau:

$$\gamma = \arg \max_{i,j} (p_j^{(i)}) \quad (1)$$

trong đó $i \in \{1, 2, 3\}$ là chỉ số mô hình, và $j \in \{0, 1, 2, 3, 4, 5\}$ là lớp BI-RADS.

Bảng 1.3. Ví dụ trường hợp đặc biệt của phương pháp bình chọn theo số đồng

Nhân Mô hình	BI-RADS 0	BI-RADS 1	BI-RADS 2	BI-RADS 3	BI-RADS 4	BI-RADS 5
ResNet50	0.01	0.02	0.03	0.01	0.24	0.60
MobileNetV2	0.00	0.01	0.22	0.65	0.08	0.04
InceptionV3	0.01	0.01	0.04	0.07	0.62	0.25
⇒ Kết quả là BI-RADS 3 do có xác suất chọn cao nhất 0.65						

Bảng 1.3. mô tả trường hợp đặc biệt của phương pháp bình chọn theo số đồng, khi 3 mô hình đều dự đoán một ảnh ra 3 lớp khác nhau. Lúc này lớp nào có xác suất được mô hình dự đoán ra cao nhất chính là nhãn, như ví dụ trên thì BI-RADS 3 chính là nhãn cuối cùng do có xác suất của mô hình MobileNetV2 dự đoán cao nhất với 0.65

cao hơn so với 2 mô hình ResNet50 và InceptionV3 với xác suất lần lượt là 0.60 và 0.62.

Phương pháp này cho phép tận dụng sự đồng thuận giữa các mô hình khi có sự nhất trí trong dự đoán, đồng thời vẫn đảm bảo lựa chọn đầu ra có độ tin cậy cao nhất trong trường hợp bất đồng. Nhờ đó, hệ thống có thể giảm thiểu sai số dự đoán và nâng cao tính ổn định tổng thể.

1.2.4.2. Phương pháp kết hợp xác suất

Phương pháp thứ hai được áp dụng là kết hợp trung bình xác suất đầu ra của các mô hình, nhằm khai thác thế mạnh tổng hợp và giảm thiểu nhược điểm riêng lẻ của từng mô hình. Cách tiếp cận này dựa trên nguyên lý trung bình xác suất, trong đó mỗi mô hình đóng góp ngang nhau vào quyết định cuối cùng, bất kể hiệu năng riêng lẻ trên từng lớp. Mục tiêu là làm mượt hóa kết quả dự đoán và tăng tính ổn định bằng cách loại bỏ bớt nhiễu từ các mô hình riêng lẻ.

Với một ảnh X-quang đầu vào ba mô hình học sâu – ResNet50, MobileNetV2 và InceptionV3 – đều nhận cùng một ảnh X-quang tuyến vú đầu vào và xuất ra một vector xác suất phân phối cho 6 lớp BI-RADS:

$$p^{(i)} = [p_0^{(i)}, p_1^{(i)}, p_2^{(i)}, p_3^{(i)}, p_4^{(i)}, p_5^{(i)}] \quad (2)$$

với $p_j^{(i)}$ là xác suất ảnh thuộc lớp j do mô hình i dự đoán.

Quá trình kết hợp xác suất được thực hiện bằng cách lấy trung bình đều theo công thức:

$$p_j = \frac{1}{3} \sum_{i=1}^3 p_j^{(i)} \quad (3)$$

Trong đó:

- $p_j^{(i)}$ xác suất lớp j từ mô hình i
- p_j xác suất tổng hợp của lớp j sau khi kết hợp

Nhãn dự đoán cuối cùng γ được chọn bằng cách lấy lớp có xác suất tổng hợp lớn nhất:

$$\gamma = \arg \max_j (p_j) \quad (4)$$

Ví dụ minh họa được trình bày ở Bảng 1.4:

Bảng 1.4. Ví dụ cách tính phương pháp kết hợp xác suất

Nhân Mô hình	BI-RADS 0	BI-RADS 1	BI-RADS 2	BI-RADS 3	BI-RADS 4	BI-RADS 5
ResNet50	0.05	0.15	0.50	0.10	0.12	0.08
MobileNetV2	0.02	0.18	0.42	0.08	0.20	0.10
InceptionV3	0.04	0.12	0.48	0.07	0.21	0.08
Trung bình	0.0367	0.15	0.4667	0.0833	0.1767	0.0867
⇒ Kết quả là BI-RADS 2 do có xác suất trung bình cao nhất 0.4667						


Kết quả ở ví dụ trên là BI-RADS 2 vì đây là lớp có xác suất trung bình cao nhất.

Phương pháp này có ưu điểm là không phụ thuộc vào quyết định duy nhất của bất kỳ mô hình nào. Ngay cả khi một mô hình đưa ra dự đoán sai với xác suất cao, ảnh hưởng của nó vẫn được cân bằng bởi hai mô hình còn lại. Điều này giúp giảm thiểu rủi ro của các lỗi cực đoan và cải thiện khả năng tổng quát hóa của hệ thống.

Ngoài ra, phương pháp trung bình xác suất đặc biệt hữu ích trong trường hợp các mô hình có xu hướng hỗ trợ lẫn nhau – ví dụ: ResNet50 nhạy với đặc trưng kết cấu mô tuyến, MobileNetV2 phản ứng tốt với hình dạng khối u, còn InceptionV3 nhận diện tốt các vùng tổn thương vì vôi hóa. Khi kết hợp, hệ thống tận dụng được thế mạnh của cả ba, từ đó nâng cao độ chính xác tổng thể và tăng tính ổn định so với việc dùng một mô hình đơn lẻ.

1.2.5. Phương pháp đánh giá mô hình

Để đánh giá một cách toàn diện và chính xác hiệu quả của các mô hình phân loại như ResNet50, MobileNetV2 và InceptionV3, ma trận nhầm lẫn (Confusion Matrix) được sử dụng để đánh giá. Ma trận này giúp trực quan hóa kết quả dự đoán của mô hình so với giá trị thực tế, trong đó mỗi hàng thể hiện các lớp được mô hình dự đoán và mỗi cột biểu thị các lớp thực tế của dữ liệu. Từ ma trận nhầm lẫn, các chỉ số đánh giá quan trọng được tính toán, bao gồm: Accuracy (độ chính xác tổng thể), Precision (đo lường tỷ lệ dự đoán dương tính đúng, đánh giá khả năng tránh lỗi dự đoán sai), Recall (đo lường tỷ lệ các mẫu dương tính được tìm thấy, đánh giá khả năng nhận diện đầy đủ các ca bệnh) và F1-Score (trung bình điều hòa của Precision và Recall, cung cấp một chỉ số cân bằng, đặc biệt hữu ích cho các tập dữ liệu không đồng đều). Việc phân tích các chỉ số này cho phép đưa ra nhận định khách quan về hiệu suất của từng mô hình và lựa chọn giải pháp tối ưu nhất cho bài toán phân loại ung thư vú.



Hình 1.12. Confusion matrix¹⁵

Dựa vào Hình 1.12, ta có thể phân tích các thành phần chính trong confusion matrix như sau:

- True Positive (TP): Số lượng các trường hợp mô hình dự đoán đúng là tích cực (positive) so với thực tế.
- False Positive (FP): Số lượng các trường hợp mô hình dự đoán sai là tích cực (positive), tức là dự đoán là positive nhưng thực tế là negative.
- True Negative (TN): Số lượng các trường hợp mô hình dự đoán đúng là tiêu cực (negative) so với thực tế.
- False Negative (FN): Số lượng các trường hợp mô hình dự đoán sai là tiêu cực (negative), tức là dự đoán là negative nhưng thực tế là positive.

Từ các thành phần trên ta có thể tính các chỉ số đánh giá như sau:

$$Precision = \frac{TP}{TP + FP} \quad (5)$$

Precision [18] thể hiện tỷ lệ mẫu được dự đoán là dương tính mà thực sự là dương tính. Chỉ số này rất quan trọng khi chi phí của dự đoán sai dương tính là cao.

$$Recall = \frac{TP}{TP + FN} \quad (6)$$

Recall [19] thể hiện tỷ lệ mẫu thực sự dương tính mà được mô hình dự đoán đúng. Recall cho biết mô hình có bỏ sót trường hợp dương tính hay không. Chỉ số này sẽ được đánh giá cao trong đề tài này khi phát hiện đúng loại bệnh là ưu tiên hàng đầu.

¹⁵ <https://www.blog.trainindata.com/wp-content/uploads/2024/09/confusion-matrix-1.png>

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (7)$$

F1 [20] là trung bình điều hòa giữa Precision và Recall. F1 cân bằng giữa khả năng không dự đoán nhầm dương tính (precision cao) và không bỏ sót ca bệnh (recall cao). Đây là chỉ số tổng quát, phù hợp khi cần đánh đổi giữa Precision và Recall.

$$Accuracy = \frac{TP + TN}{TP + TN + FN + FP} \quad (8)$$

Accuracy [21] là tỷ lệ số lượng dự đoán đúng (cả dương tính và âm tính) trên tổng số mẫu. Chỉ số này thể hiện độ chính xác tổng thể của mô hình trên tất cả các lớp, chỉ số này cũng sẽ được dùng để đánh giá các mô hình.

1.2.6. Các thư viện và công cụ hỗ trợ xây dựng hệ thống

1.2.6.1. Pytorch

PyTorch là một thư viện học máy mã nguồn mở được phát triển bởi Facebook AI Research (FAIR), ra mắt lần đầu vào năm 2016. Nhờ tính linh hoạt cao và hiệu suất mạnh mẽ, PyTorch nhanh chóng trở thành một trong những công cụ phổ biến nhất trong cộng đồng nghiên cứu và phát triển trí tuệ nhân tạo, đặc biệt trong các lĩnh vực như thị giác máy tính, xử lý ngôn ngữ tự nhiên và học sâu.

Một trong những điểm nổi bật của PyTorch là khả năng xây dựng đồ thị tính toán động (dynamic computational graph), cho phép người dùng dễ dàng thay đổi cấu trúc mô hình ngay trong quá trình thực thi. Điều này mang lại sự linh hoạt và tiện lợi đáng kể khi thử nghiệm các kiến trúc mạng nơ-ron mới hoặc xử lý các bài toán phức tạp. So với các framework khác như TensorFlow (phiên bản tĩnh trước đây), PyTorch mang lại trải nghiệm lập trình gần gũi với Python gốc, dễ gỡ lỗi và trực quan hơn trong quá trình phát triển mô hình.

Bên cạnh đó, PyTorch sở hữu hệ sinh thái phong phú với nhiều thư viện hỗ trợ như torchvision (xử lý ảnh), torchaudio (xử lý âm thanh), và torchtext (xử lý văn bản), giúp đơn giản hóa quá trình tiền xử lý dữ liệu và xây dựng mô hình. Khả năng tích hợp mượt mà với các thư viện như NumPy, cùng với việc tận dụng tối đa sức mạnh của GPU thông qua CUDA, khiến PyTorch trở thành công cụ lý tưởng không chỉ cho nghiên cứu mà còn cho triển khai ứng dụng học sâu trong thực tế.

Với tính năng trực quan, linh hoạt và hiệu quả, PyTorch được lựa chọn để phát triển và huấn luyện các mô hình học sâu trong đề tài.

1.2.6.2. Numpy

NumPy (Numerical Python) là một thư viện mã nguồn mở trong Python, cung cấp các công cụ mạnh mẽ để làm việc với mảng đa chiều (ndarray) và thực hiện các phép toán số học hiệu quả. Đây là nền tảng cơ bản cho nhiều thư viện học máy và xử

lý dữ liệu, đặc biệt là trong các tác vụ liên quan đến thao tác ma trận và đại số tuyến tính.

Trong nghiên cứu này, NumPy được sử dụng chủ yếu để xử lý ảnh X-quang tuyến vú, bao gồm việc đọc, chuẩn hóa giá trị điểm ảnh, chuyển đổi định dạng, cắt ảnh, và thực hiện các thao tác số học cơ bản như cộng, trừ hoặc thay đổi kích thước. Nhờ vào hiệu suất cao và cú pháp đơn giản, NumPy giúp tăng tốc độ xử lý và dễ dàng tích hợp với các thư viện khác như OpenCV, PyTorch và Matplotlib.

Tóm lại, NumPy đóng vai trò quan trọng trong giai đoạn tiền xử lý ảnh, giúp chuẩn bị dữ liệu đầu vào phù hợp cho các mô hình học sâu trong bài toán phân loại BI-RADS từ ảnh X-quang tuyến vú.

1.2.6.3. React

React là một thư viện JavaScript mã nguồn mở do Facebook phát triển, được sử dụng rộng rãi để xây dựng giao diện người dùng (UI) cho các ứng dụng web hiện đại. Với triết lý phát triển dựa trên component – mỗi phần giao diện được chia nhỏ thành các thành phần độc lập và có thể tái sử dụng – React giúp đơn giản hóa việc xây dựng và bảo trì các hệ thống giao diện phức tạp.

Một trong những điểm mạnh nổi bật của React là Virtual DOM – cơ chế giúp cập nhật giao diện nhanh chóng và hiệu quả bằng cách chỉ render lại những phần thay đổi thay vì toàn bộ trang. Bên cạnh đó, cú pháp JSX (JavaScript + XML) cho phép lập trình viên viết code HTML trực tiếp trong JavaScript, tăng tính trực quan và rút ngắn thời gian phát triển.

Trong đề tài này, React được sử dụng để xây dựng giao diện người dùng cho hệ thống hỗ trợ chẩn đoán và phân loại ung thư vú từ ảnh X-quang. Giao diện cho phép người dùng dễ dàng tải ảnh, theo dõi kết quả phân loại BI-RADS từ các mô hình AI, và xem lại các thông tin chẩn đoán. Khả năng phản hồi nhanh, dễ mở rộng và tích hợp linh hoạt với các backend như FastAPI hay các mô hình học máy đã giúp React trở thành một lựa chọn tối ưu cho hệ thống này.

1.2.6.4. FastAPI

FastAPI là một framework web hiện đại và hiệu suất cao dành cho Python, được phát triển bởi Sebastián Ramírez. Ra đời nhằm khắc phục những hạn chế của các framework truyền thống trong việc xây dựng API, FastAPI nhanh chóng trở thành lựa chọn ưu tiên cho các nhà phát triển cần xây dựng các dịch vụ web có hiệu năng cao, dễ bảo trì và an toàn. Nhờ khả năng xử lý yêu cầu nhanh chóng, FastAPI có thể sánh ngang với các framework nổi tiếng như Node.js hay Golang về tốc độ.

Điểm khác biệt nổi bật của FastAPI nằm ở việc tận dụng triệt để các tính năng hiện đại của Python, đặc biệt là type hints và thư viện Pydantic. Nhờ đó, FastAPI tự động sinh ra tài liệu API theo chuẩn OpenAPI (Swagger), đồng thời hỗ trợ kiểm tra và


xác thực dữ liệu đầu vào một cách mạnh mẽ và tự động. Điều này không chỉ giúp hạn chế lỗi trong quá trình phát triển mà còn tăng hiệu suất làm việc thông qua việc cung cấp giao diện API rõ ràng, chi tiết và dễ kiểm soát.

So với các framework phổ biến như Flask hay Django, FastAPI mang lại hiệu năng vượt trội, với tốc độ xử lý nhanh hơn từ 2 đến 3 lần và khả năng tiêu thụ tài nguyên thấp hơn. Framework này hỗ trợ đầy đủ các tính năng hiện đại như async/await, WebSocket, GraphQL, đồng thời dễ dàng tích hợp với các thư viện khác trong hệ sinh thái Python. FastAPI còn hỗ trợ các chuẩn bảo mật như OAuth2, JWT, giúp đơn giản hóa việc xây dựng các hệ thống API phức tạp, đặc biệt là trong lĩnh vực trí tuệ nhân tạo và khoa học dữ liệu.

Trong khuôn khổ luận văn này, FastAPI được sử dụng làm nền tảng phát triển backend cho hệ thống website và phân loại ung thư vú từ ảnh X-quang, đóng vai trò trung gian giữa mô hình học sâu, cơ sở dữ liệu, và giao diện người dùng, đảm bảo tốc độ xử lý nhanh, bảo mật và khả năng mở rộng linh hoạt khi triển khai thực tế

1.2.6.5. Các dịch vụ của Amazon Web Services (AWS)

Amazon Web Services (AWS) là nền tảng điện toán đám mây hàng đầu thế giới, cung cấp một hệ sinh thái dịch vụ toàn diện với hơn 200 sản phẩm, bao gồm lưu trữ, tính toán, và trí tuệ nhân tạo. Với độ tin cậy và hiệu năng vượt trội, AWS là lựa chọn hàng đầu của các cá nhân, doanh nghiệp và tổ chức trên toàn cầu. Minh chứng cho vị thế dẫn đầu của AWS là thị phần lớn nhất trên thị trường điện toán đám mây. Theo thống kê Quý 3 năm 2024 (Hình 1.13), AWS chiếm 31% thị phần toàn cầu, cao hơn đáng kể so với các đối thủ chính là Azure (20%) và Google Cloud (12%).



Hình 1.13. Các nhà cung cấp dịch vụ điện toán đám mây hàng đầu quý 3 năm 2024¹⁶

¹⁶https://cdn.prod.website-files.com/663b80c700da26c11da9a3b1/67866c651066879f5b9f1c12_cloud-market-share.png

Trong đề tài này, AWS được sử dụng để triển khai toàn bộ hệ thống từ frontend, backend và cơ sở dữ liệu, đảm bảo tính linh hoạt, hiệu suất cao, dễ mở rộng và truy cập từ xa. Các dịch vụ từ AWS được đề tài sử dụng là: AWS Amplify, Amazon VPC (Virtual Private Cloud), Amazon EC2 (Elastic Compute Cloud), Security Group, Elastic IP, Amazon S3 (Simple Storage Service), Amazon DocumentDB.

AWS Amplify là dịch vụ hỗ trợ triển khai và lưu trữ frontend hiện đại. Trong hệ thống này, giao diện người dùng được phát triển bằng React và được triển khai trực tiếp lên AWS Amplify. Dịch vụ này hỗ trợ CI/CD tự động: mỗi lần cập nhật mã nguồn trên GitHub, giao diện sẽ tự động được build và triển khai. Amplify giúp rút ngắn thời gian triển khai, dễ dàng mở rộng và tích hợp với các dịch vụ khác như API Gateway, Cognito, S3,...

Amazon VPC (Virtual Private Cloud) là một dịch vụ cung cấp một mạng riêng ảo để cô lập và kiểm soát môi trường mạng. Hệ thống sử dụng VPC để định tuyến dữ liệu một cách an toàn, tạo subnet riêng và đảm bảo các dịch vụ nội bộ không bị truy cập trái phép từ bên ngoài.

Amazon EC2 (Elastic Compute Cloud) là một dịch vụ máy chủ ảo nơi triển khai backend (FastAPI) và chạy mô hình học sâu. EC2 cho phép lựa chọn cấu hình tùy chỉnh về CPU/GPU, bộ nhớ, hệ điều hành, phù hợp với yêu cầu tính toán của hệ thống.

Security Group là lớp bảo mật được gán cho instance EC2 trong VPC. Nó hoạt động như một firewall, kiểm soát lưu lượng mạng vào và ra khỏi EC2. Trong hệ thống, Security Group được cấu hình để chỉ cho phép truy cập từ các cổng cần thiết (như HTTP, HTTPS hoặc SSH), giúp hạn chế tấn công và bảo vệ hệ thống khỏi truy cập trái phép.

Elastic IP là một địa chỉ IP tĩnh được gán cho EC2, đảm bảo hệ thống có thể truy cập ổn định từ frontend và người dùng, không bị thay đổi qua các lần khởi động lại hoặc cập nhật hệ thống.

Amazon S3 (Simple Storage Service) là một dịch vụ lưu trữ đối tượng dùng để lưu ảnh, file PDF, kết quả phân loại, và các dữ liệu tĩnh khác,...Dữ liệu trong S3 có thể truy cập từ backend thông qua API, đồng thời dễ tích hợp vào frontend hoặc các công cụ phân tích.

Amazon DocumentDB là dịch vụ cơ sở dữ liệu NoSQL tương thích MongoDB, dùng để lưu trữ dữ liệu phi cấu trúc như thông tin người dùng, log hệ thống, metadata ảnh,...DocumentDB cung cấp khả năng mở rộng linh hoạt, bảo mật cao, và truy vấn hiệu quả.

1.2.7. Công cụ hỗ trợ CI/CD trong hệ thống

CI/CD (Continuous Integration / Continuous Deployment) là quy trình phát triển phần mềm hiện đại giúp tự động hóa việc tích hợp, kiểm thử và triển khai mã nguồn. CI giúp phát hiện lỗi sớm bằng cách kiểm tra tự động mỗi khi có mã mới được đẩy lên nơi lưu trữ mã nguồn (trong đề tài này là Github). CD đảm bảo việc triển khai phần mềm được thực hiện nhanh chóng, an toàn và nhất quán. Đề tài có tích hợp CI/CD vào hệ thống để tự động hóa việc kiểm thử và triển khai mã nguồn. Cụ thể, khi nhà phát triển đẩy mã nguồn lên GitHub, GitHub Actions sẽ được kích hoạt. Tiếp đó, hệ thống tiến hành xây dựng (build) mã nguồn, thực hiện kiểm thử, và nếu quá trình kiểm thử không phát sinh lỗi, mã nguồn sẽ được triển khai. Quy trình CI/CD trong hệ thống sử dụng một số dịch vụ và công cụ như GitHub Actions, Docker, Pytest, Flake8, Black và Isort.

Github Actions là một nền tảng CI/CD được tích hợp sẵn trong GitHub, cho phép tự động hóa các quy trình như build (chạy dự án), test (kiểm tra code) và deploy (triển khai dự án). Trong hệ thống này, GitHub Actions được cấu hình để kích hoạt mỗi khi có pull request hoặc commit mới, từ đó tự động chạy các bước kiểm thử và nếu mã không lỗi thì sẽ triển khai mã nguồn lên Cloud.

Docker được sử dụng để đóng gói toàn bộ mã nguồn backend cùng với các thư viện và môi trường cần thiết vào một container. Việc này giúp đảm bảo hệ thống backend có thể chạy đồng nhất trên mọi máy chủ, tránh các lỗi do khác biệt môi trường. Nhờ Docker, quá trình triển khai trở nên đơn giản, nhanh chóng và dễ mở rộng trong thực tế. Mã nguồn sẽ được tự động build thành container để triển khai lên Amazon EC2 khi có mã mới được cập nhật, quy trình CI/CD được kích hoạt và việc kiểm thử code không lỗi.

Pytest là framework được sử dụng để kiểm thử các hàm và module trong hệ thống. Các test case được viết sẵn được tích hợp trong quy trình CI/CD, các test case này sẽ tự động kiểm thử mã nguồn khi quy trình CI/CD chạy.

Flake8 là công cụ kiểm tra lỗi cú pháp, vi phạm quy tắc mã hóa và cảnh báo mã không tối ưu trong Python. Ví dụ như biến có khai báo nhưng không dùng, lỗi cú pháp,...


Black là công cụ định dạng lại mã nguồn Python tự động, như sau dấu phẩy phải có khoảng trắng.

Isort là công cụ giúp tự động sắp xếp các lệnh import theo thứ tự chuẩn: các thư viện chuẩn, thư viện bên thứ ba và module nội bộ. Điều này giúp mã dễ đọc, dễ bảo trì và nhất quán hơn trong toàn bộ hệ thống.

CHƯƠNG 2. THIẾT KẾ VÀ CÀI ĐẶT

2.1. Thiết kế hệ thống

2.1.1. Thiết kế luồng huấn luyện và kiểm thử các mô hình



Hình 2.1. Quy trình huấn luyện và kiểm thử mô hình

Quy trình huấn luyện và kiểm thử các mô hình học sâu trong đề tài được thiết kế như Hình 2.1, bao gồm các bước từ thu thập dữ liệu, tiền xử lý, huấn luyện mô hình, cho đến đánh giá và triển khai. Luồng xử lý này đảm bảo tính khách quan và hiệu quả trong việc xây dựng hệ thống hỗ trợ chẩn đoán ung thư vú.

Giai đoạn đầu tiên và quan trọng nhất là thu thập dữ liệu hình ảnh nhũ ảnh. Để đảm bảo tính đa dạng và chất lượng, đề tài sẽ sử dụng dữ liệu từ nhiều nguồn khác nhau, bao gồm các tập dữ liệu công khai uy tín như CBIS-DDSM, Inbreast, VinDr Mammogram và đặc biệt là dữ liệu lâm sàng thực tế được cung cấp bởi Bệnh viện Ung bướu Cần Thơ. Việc kết hợp dữ liệu từ nhiều nguồn giúp mô hình học được các đặc trưng phong phú, nâng cao khả năng khái quát hóa.

Sau khi thu thập, toàn bộ dữ liệu sẽ được đưa qua bước tiền xử lý. Mục tiêu của bước này là chuẩn hóa dữ liệu để phù hợp với yêu cầu đầu vào của các mô hình học sâu. Các kỹ thuật tiền xử lý bao gồm:

- Loại bỏ các ảnh có chất lượng thấp, ảnh bị nhiễu hoặc không rõ ràng.
- Chuẩn hóa kích thước ảnh về một định dạng thống nhất.
- Tăng cường dữ liệu ở lớp bị thiếu dữ liệu bằng các kỹ thuật như lật ảnh, xoay ảnh, thay đổi độ sáng, dịch chuyển,...điều này sẽ làm dữ liệu cân bằng hơn.

Dữ liệu đã được tiền xử lý sẽ được sử dụng để huấn luyện các mô hình học sâu. Đề tài lựa chọn ba kiến trúc mạng nổi tiếng và mạnh mẽ trong lĩnh vực thị giác máy tính là ResNet50, MobileNetV2 và InceptionV3. Các mô hình này được chọn dựa trên hiệu quả và khả năng trích xuất đặc trưng mạnh mẽ. Các mô hình này sẽ huấn luyện


bài toán 6 lớp BI-RADS (0, 1, 2, 3, 4, 5) và bài toán 2 lớp là lành tính là ác tính. Với lớp lành tính sẽ là ba lớp gộp từ các lớp BI-RADS 0, BI-RADS 1 và BI-RADS 2. Với lớp ác tính sẽ là ba lớp còn lại gồm BI-RADS 3, BI-RADS 4 và BI-RADS 5.

Sau khi hoàn tất quá trình huấn luyện, các mô hình sẽ được lưu trữ và tiến hành kiểm thử trên một tập dữ liệu độc lập. Giai đoạn này sử dụng các metrics đánh giá phổ biến như Accuracy, Precision, Recall và F1-Score dựa trên ma trận nhầm lẫn (Confusion Matrix) để so sánh hiệu suất của từng mô hình. Việc đánh giá kỹ lưỡng giúp xác định mô hình nào hoạt động tốt nhất và có độ ổn định cao.

Cuối cùng, mô hình tối ưu nhất sau quá trình kiểm thử sẽ được triển khai vào hệ thống hỗ trợ chẩn đoán. Hệ thống này sẽ tích hợp các mô hình đã huấn luyện để hỗ trợ bác sĩ. Toàn bộ quy trình này từ thu thập, tiền xử lý, huấn luyện, kiểm thử cho đến triển khai tạo thành một vòng lặp khép kín, cho phép cải thiện mô hình liên tục khi có thêm dữ liệu mới hoặc khi áp dụng các kỹ thuật học sâu tiên tiến hơn.

2.1.2. Thiết kế hệ thống website

2.1.2.1. Chức năng của hệ thống



Hình 2.2. Chức năng của các người dùng trong hệ thống

Hệ thống website được xây dựng nhằm phục vụ ba đối tượng người dùng chính, mỗi đối tượng có những vai trò và bộ chức năng riêng biệt nhằm đảm bảo tính bảo mật và hiệu quả vận hành. Sơ đồ chức năng của các nhóm người dùng được thể hiện rõ tại Hình 2.2. với:

Quyền hạn của Quản trị viên (Admin):

Admin là người quản lý cao nhất của hệ thống, chịu trách nhiệm vận hành và giám sát toàn bộ hoạt động. Các chức năng dành cho Admin bao gồm:

- **Quản lý người dùng:** Cho phép Admin thêm, sửa, xóa, và phân quyền cho các tài khoản người dùng, đặc biệt là tài khoản của các bác sĩ.
- **Quản lý lưu lượng website:** Giúp Admin theo dõi các chỉ số về lưu lượng truy cập, tần suất sử dụng các chức năng và các thông số hiệu suất khác để đánh giá tình hình hoạt động của hệ thống.
- **Quản lý ảnh X-quang:** Admin có quyền quản lý kho dữ liệu hình ảnh X-quang được tải lên, bao gồm xem, xóa hoặc sử dụng chúng để cải thiện chất lượng mô hình sau này.
- **Quản lý các mô hình:** Admin có thể giám sát, cập nhật, hoặc triển khai các phiên bản mô hình học sâu mới nhất đã được huấn luyện, đảm bảo hệ thống luôn sử dụng mô hình có độ chính xác cao nhất.

Quyền hạn của bác sĩ:

Bác sĩ là người dùng chính, trực tiếp sử dụng hệ thống như một công cụ hỗ trợ lâm sàng. Để đảm bảo tính bảo mật của dữ liệu bệnh nhân, bác sĩ cần có tài khoản đã được xác thực để truy cập các chức năng sau:

- **Dự đoán BI-RADS:** Đây là chức năng cốt lõi. Bác sĩ có thể tải ảnh X-quang tuyến vú của bệnh nhân lên hệ thống. Ảnh sau đó sẽ được xử lý tự động bởi các mô hình học sâu đã được huấn luyện để đưa ra xác suất phân loại theo từng cấp độ BI-RADS. Kết quả này đóng vai trò là thông tin tham khảo hữu ích, hỗ trợ bác sĩ đưa ra chẩn đoán chính xác và nhanh chóng hơn.
- **Xem lịch sử dự đoán:** Chức năng này cho phép bác sĩ xem lại lịch sử các ca bệnh đã được dự đoán trước đó, thuận tiện cho việc theo dõi, so sánh

Quyền hạn của Người dùng thông thường (Phu nữ):

Nhằm nâng cao nhận thức và hỗ trợ cộng đồng, hệ thống cung cấp một số chức năng công khai mà không yêu cầu người dùng phải đăng ký tài khoản:

- **Tầm soát ung thư vú:** Người dùng có thể thực hiện một bài trắc nghiệm gồm 16 câu hỏi xoay quanh các yếu tố nguy cơ như thói quen sinh hoạt, chỉ số cơ thể, và tiền sử sức khỏe. Dựa trên tổng điểm của các câu trả lời, hệ thống sẽ đưa ra kết quả phân loại nguy cơ ung thư vú ở ba mức độ: "nguy cơ thấp", "nguy cơ trung bình" và "nguy cơ cao".

- **Nhận lời khuyên:** Tương ứng với mỗi mức độ nguy cơ, hệ thống sẽ cung cấp những lời khuyên và hướng dẫn tầm soát phù hợp. Chi tiết về bảng câu hỏi và các lời khuyên sẽ được trình bày trong phần Phụ lục.

2.1.2.2. Cơ sở dữ liệu

Cơ sở dữ liệu được hệ thống sử dụng là cơ sở dữ liệu không quan hệ, để đáp ứng các yêu cầu chức năng của hệ thống, cơ sở dữ liệu gồm các Collection (tương tự như Bảng trong SQL) như sau:

Collection user: phần này sẽ lưu các thông tin của người dùng như Bảng 2.1.

Bảng 2.1. Collection user

Trường	Kiểu dữ liệu	Ràng buộc	Mô tả
id	UUID	Not null	Id định danh user
email	String		Email của user
password_hash	String	Not null	Mật khẩu đã mã hóa
name	String	Not null	Tên của người dùng
auth_provider	String		Bên cung cấp xác thực tài khoản
provider_id	String		Id của bên xác thực
isRevoked	Boolean		Cho biết tài khoản bị thu hồi chưa
confirmed	Boolean	Not null	Cho biết tài khoản có xác thực chưa
role	String	Not null	Vai trò của user

Collection user_session: sẽ lưu các thông tin như Bảng 2.2 nhằm để thống kê lưu lượng sử dụng trang web của user như số lượng người online, tần xuất sử dụng web,...

Bảng 2.2. Collection user_session

Trường	Kiểu dữ liệu	Ràng buộc	Mô tả
session_id	uuid	Not null	Id của session
user_id	UUID	Not null	Id của user
login_at	Date	Not null	Thời điểm đăng nhập
logout_at	Date		Thời điểm đăng xuất
is_activate	Boolean	Not null	Đánh dấu user đang online
auth_provider	String		Bên xác thực tài khoản

Collection verification_code: sẽ lưu các thông tin như Bảng 2.3 nhằm để lưu code để xác nhận tài khoản hoặc lấy lại mật khẩu. Code này sẽ được gửi qua mail của người dùng để xác nhận.

Bảng 2.3. Collection verification_code

Trường	Kiểu dữ liệu	Ràng buộc	Mô tả
id	uuid	Not null	Id định danh user
email	String	Not null	Email của user
code	String	Not null	Mã xác nhận
expires_at	Date	Not null	Thời điểm hết hạn

Collection prediction: sẽ lưu các thông tin của mỗi lần dự đoán hình ảnh X-quang kèm theo kết quả lớp và xác suất tương ứng như Bảng 2.4.

Bảng 2.4. Collection prediction

Trường	Kiểu dữ liệu	Ràng buộc	Mô tả
id	UUID	Not null	Id định danh prediction
doctor_id	UUID	Not null	Id của bác sĩ
image_url	String	Not null	Url public của ảnh
image_keyimage_original_name	String		Tên ảnh
image_key	String	Not null	Id ảnh dùng để xóa
model_name	String		Tên mô hình học sâu
prediction_result	Float		Lớp dự đoán
probability	String		Độ chính xác
created_at	Date		Thời điểm dự đoán
updated_at	Date		Thời điểm chỉnh sửa

Collection model: sẽ chứa các thông tin của mô hình nhằm quản lý version của mô hình, các thông tin được lưu sẽ giống như Bảng 2.5.

Bảng 2.5. Collection model

Trường	Kiểu dữ liệu	Ràng buộc	Mô tả
id	UUID	Not null	Id định danh của mô hình
name	String	Not null	Tên của mô hình
version	String	Not null	Phiên bản của mô hình
model_url	String		Public URL của mô hình
model_key	String		Khóa của mô hình để xóa

model_original_name	String		Tên ban đầu của mô hình
accuracy	Float		Độ chính xác của mô hình
is_active	Boolean	Not null	Đánh dấu mô hình đang được sử dụng bởi website
created_at	Date		Thời điểm thêm mô hình
updated_at	Date		Thời điểm chỉnh sửa mô hình


2.2. Cài đặt giải pháp

2.2.1. Thu thập dữ liệu

Dữ liệu đề tài sử dụng là hình ảnh X-quang tuyến vú được thu thập từ các nguồn CBIS-DDSM, Inbreast, VinDr-Mammo và từ Bệnh viện Ung Bướu Cần Thơ.

2.2.1.1. Dữ liệu từ CBIS-DDSM

CBIS-DDSM [22] là một bộ dữ liệu được tạo ra bằng cách lấy mẫu ngẫu nhiên từ DDSM và chứa hơn 1.000 hình ảnh mammography với các kích thước khác nhau, bao gồm cả ảnh có khối u và không có khối u. CBIS-DDSM lưu trữ các hình ảnh dưới dạng DICOM bao gồm **3.025 ảnh** X-quang tuyến vú đầy đủ. Các hình ảnh X-quang ghi nhận dựa trên 2 phương pháp chụp là MLO và CC. Số lượng ảnh theo từng lớp BI-RADS như Hình 2.3 sau:




Hình 2.3. Phân bố số lượng ảnh thu thập từ CBIS-DDSM

2.2.1.2. Dữ liệu từ Inbreast

Inbreast [23] là một bộ dữ liệu ảnh mammography tuyến vú bao gồm 410 hình ảnh thu thập từ 115 bệnh nhân, trong đó có cả các ảnh được chụp kết hợp với MRI và siêu âm nhằm cung cấp thêm thông tin chẩn đoán. Cụ thể, có 90 trường hợp là phụ nữ có tổn thương ở cả hai vú (mỗi trường hợp gồm 4 ảnh mammography chụp từ các góc khác nhau) và 25 trường hợp là bệnh nhân đã phẫu thuật cắt bỏ một bên vú (mỗi trường hợp gồm 2 ảnh mammography).


Bộ dữ liệu này được đánh giá cao nhờ chất lượng ảnh chuẩn DICOM, chú thích chi tiết và tính đa dạng, hỗ trợ hiệu quả cho các nghiên cứu và ứng dụng trong phát hiện, phân loại và chẩn đoán bệnh lý tuyến vú. Tổng cộng thu thập được **401 ảnh**, số lượng ảnh phân bố mỗi lớp được thể hiện qua Hình 2.4. sau:



Hình 2.4. Phân bố số lượng ảnh thu thập từ InBreast

2.2.1.3. Dữ liệu từ VinDr-Mammo


VinDr-Mammo [24] là bộ dữ liệu công khai lớn về ảnh nhũ ảnh kỹ thuật số toàn trường (FFDM), ảnh thu thập tại Bệnh viện 108 và Bệnh viện Đại học Y Hà Nội giai đoạn 2018–2020. Mỗi kỳ chụp có 4 góc ảnh tiêu chuẩn (CC và MLO cho mỗi bên vú), được hai bác sĩ X-quang đọc độc lập và xác nhận bởi bác sĩ thứ ba. Bộ dữ liệu bao gồm đánh giá BI-RADS, mật độ mô vú và đánh dấu bounding box cho các bất thường như khối u, vi vôi hóa, bất đối xứng, biến dạng cấu trúc...Ảnh từ bộ dữ liệu này sẽ được thu thập để bổ sung cho các lớp bị thiếu ở lớp BI-RADS 1, BI-RADS 2, BI-RADS 3 và BI-RADS 5. Tổng số lượng thu thập ở cơ sở dữ liệu này được **3.799 ảnh**, số lượng cụ thể của mỗi lớp được thể hiện trong Hình 2.5. sau:



Hình 2.5. Phân bố số lượng ảnh thu thập từ VinDr-Mammo


2.2.1.4. Dữ liệu từ Bệnh viện Ung Bướu Cần Thơ

Dữ liệu lấy từ Khoa Chẩn đoán hình ảnh – Bệnh viện Ung Bướu Cần Thơ, bộ dữ liệu tổng cộng bao gồm **1.983 hình ảnh** X-quang tuyến vú. Dữ liệu chỉ bao gồm lớp BI-RADS 4 và BI-RADS 5, số lượng cụ thể được thể hiện qua Hình 2.6.



Hình 2.6. Phân bố số lượng ảnh thu thập từ Bệnh viện Ung Bướu Cần Thơ

Tổng cộng số lượng ảnh thu thập từ 4 nguồn CBIS-DDSM, InBreast, VinDr-Mammo và từ Bệnh viện Ung Bướu Cần Thơ là **9.209 ảnh**, phân bố số lượng từng lớp thể hiện qua Hình 2.7.



Hình 2.7. Tổng hợp số lượng ảnh theo từng lớp sau khi thu thập

Có thể thấy rằng số lượng lớp không được đồng đều, nhất là lớp BI-RADS 0 bị lệch rất nhiều so với các lớp BI-RADS còn lại. Lớp BI-RADS 0 này sẽ được tăng cường hình ảnh ở Phần 2.2.2.


2.2.2. Tiền xử lý dữ liệu

Dữ liệu thu thập từ các nguồn CBIS-DDSM, InBreast, VinDr-Mammo và Bệnh viện Ung Bướu Cần Thơ ban đầu chưa sẵn sàng cho quá trình huấn luyện do sự khác biệt về định dạng, kích thước ảnh và lớp BI-RADS 0 bị lệch quá nhiều so với các lớp còn lại. Việc tiền xử lý hình ảnh là bước quan trọng nhằm chuẩn hóa dữ liệu, cải thiện chất lượng ảnh, trích xuất thông tin quan trọng, hỗ trợ nhận dạng và phân loại chính xác hơn, đồng thời tối ưu đầu vào cho mô hình thị giác máy tính để nâng cao độ chính xác. Quá trình tiền xử lý được thực hiện như sau:

- Chuyển tất cả ảnh về định dạng PNG
- Thay đổi kích thước tất cả ảnh về cùng kích thước 256x256
- Thực hiện tăng cường dữ liệu cho lớp BI-RADS 0


Dữ liệu hình ảnh được thu thập từ các nguồn khác nhau như CBIS-DDSM, Inbreast, VinDr Mammogram và Bệnh viện Ung bướu Cần Thơ có nhiều định dạng khác nhau như DICOM và JPEG. Để đảm bảo tính đồng nhất và tránh các lỗi tương thích trong quá trình xử lý dữ liệu hàng loạt, tất cả các ảnh sẽ được chuyển đổi về một định dạng duy nhất là PNG (Portable Network Graphics) như Hình 2.8. PNG là một định dạng nén không mất dữ liệu (lossless compression), giúp bảo toàn hoàn toàn chất lượng, độ sắc nét và các chi tiết quan trọng trên ảnh y tế. Việc chuẩn hóa này không

chỉ tạo ra một luồng dữ liệu nhất quán mà còn giúp tối ưu hóa hiệu suất của các mô hình học sâu.




Hình 2.8. Minh họa việc chuyển đổi các ảnh sang định dạng PNG

Các ảnh nhũ ảnh có thể có kích thước và tỷ lệ khung hình khác nhau. Để phù hợp với yêu cầu đầu vào của các mô hình học sâu và đảm bảo các mô hình có thể xử lý dữ liệu một cách đồng nhất, tất cả các ảnh sẽ được thay đổi kích thước về một kích thước 256×256 pixels. Kích thước này được lựa chọn dựa trên sự cân bằng giữa việc giữ lại đủ thông tin chi tiết và giảm thiểu chi phí tính toán.



Hình 2.9. Chuẩn hóa kích thước ảnh về 256×256 pixels

Tổng số lượng các lớp theo Hình 2.7. có thể thấy lớp BI-RADS 0 rất ít so với các lớp còn lại. Để khắc phục tình trạng này và đảm bảo mô hình có thể học được các đặc trưng của lớp BI-RADS 0 một cách hiệu quả, kỹ thuật tăng cường dữ liệu sẽ được áp dụng để tăng cường dữ liệu cho lớp BI-RADS. Đặc biệt, dữ liệu tăng cường chỉ được dùng để huấn luyện và xác thực, chứ không dùng để kiểm thử mô hình.




Hình 2.10. Minh họa việc tăng cường ảnh một cách ngẫu nhiên

Mục tiêu là với 1 ảnh BI-RADS 0 sẽ tăng cường ra 6 ảnh được minh họa như Hình 2.10, mỗi ảnh tăng cường sẽ có xác suất thực hiện qua các kỹ thuật tăng cường như sau:

- **Lật ảnh:** Thực hiện lật ngang và lật dọc hình ảnh. Phép biến đổi này giúp mô hình nhận diện các tổn thương bất kể vị trí và hướng của chúng.
- **Xoay ảnh:** Xoay hình ảnh một góc ngẫu nhiên. Điều này giúp mô hình trở nên bất biến trước sự thay đổi góc chụp hoặc định hướng của tuyến vú.
- **Điều chỉnh độ sáng và độ tương phản ngẫu nhiên của ảnh:** Thay đổi độ sáng và độ tương phản của hình ảnh một cách ngẫu nhiên. Phép biến đổi này mô phỏng sự khác biệt về chất lượng ảnh giữa các thiết bị chụp hoặc điều kiện chụp khác nhau, giúp mô hình tăng cường khả năng chịu đựng nhiễu và các biến thể về hình thái.
- **Biến đổi hình học của ảnh kết hợp nhiều phép biến đổi:** Đây là một kỹ thuật mạnh mẽ nhằm tạo ra sự đa dạng lớn hơn cho dữ liệu. Mỗi hình ảnh của lớp BI-RADS 0 sẽ có xác suất 50% được áp dụng đồng thời ba phép biến đổi sau: dịch chuyển vị trí, thay đổi tỷ lệ và xoay nhẹ.

Sau khi áp dụng kỹ thuật tăng cường dữ liệu (data augmentation), số lượng hình ảnh của lớp BI-RADS 0 đã được tăng từ 175 lên 1.225 ảnh. Việc này không chỉ giúp bổ sung đáng kể số lượng mẫu cho lớp thiếu số này mà còn nâng cao tính đa dạng của dữ liệu. **Tổng số hình ảnh trong toàn bộ tập dữ liệu đã tăng lên 10.259 ảnh (Hình 2.11)**, tạo ra một nguồn dữ liệu phong phú và cân bằng hơn cho quá trình huấn luyện.



Hình 2.11. Số lượng ảnh mỗi lớp sau khi tăng cường lớp BI-RADS 0

Như được minh họa trong Hình 2.11, sự chênh lệch về số lượng mẫu giữa lớp BI-RADS 0 và các lớp khác đã được thu hẹp đáng kể. Việc cân bằng lại tập dữ liệu này đóng vai trò then chốt trong việc giảm thiểu rủi ro mô hình bị chệch sang các lớp có nhiều mẫu hơn, từ đó cải thiện độ chính xác và khả năng khái quát hóa của mô hình học sâu. Kết quả là mô hình có thể học được các đặc trưng của lớp BI-RADS 0 một cách hiệu quả hơn.

2.2.3. Tổng hợp và phân chia dữ liệu để huấn luyện

Để đảm bảo quy trình huấn luyện và đánh giá mô hình diễn ra một cách khách quan và khoa học, toàn bộ tập dữ liệu đã được xử lý và cân bằng sẽ được phân chia thành ba tập con độc lập: tập huấn luyện (train), tập kiểm định (validation) và tập kiểm thử (test).

- **Tập huấn luyện (Train):** Được sử dụng để huấn luyện các mô hình học sâu. Mục đích là để mô hình học các đặc trưng và quy luật từ dữ liệu này.
- **Tập kiểm định (Validation):** Được sử dụng để tinh chỉnh các siêu tham số (hyperparameters) và đánh giá hiệu suất của mô hình trong suốt quá trình huấn luyện. Kết quả trên tập này giúp ngăn ngừa tình trạng quá khớp (overfitting).
- **Tập kiểm thử (Test):** Được sử dụng để đánh giá hiệu suất cuối cùng của mô hình sau khi huấn luyện xong. Đây là tập dữ liệu hoàn toàn mới đối

với mô hình, giúp đưa ra một cái nhìn khách quan về khả năng tổng quát hóa của mô hình trên dữ liệu thực tế.

Bảng 2.6. Tổng hợp dữ liệu từ các nguồn thu thập

BI-RADS	CBIS-DDSM	InBreast	VinDr-Mammo	Bv Ung Bướu CT
0	1.225	0	0	0
1	3	67	1.400	0
2	357	220	1.000	0
3	417	22	972	0
4	1.538	43	0	1.537
5	536	49	427	446
Tổng	4.076	401	3.799	1.983
Tổng cộng: 10.259				

Từ Bảng 2.6 là dữ liệu tổng hợp thu được từ bốn nguồn CBIS-DDSM, InBreast, VinDr-Mammo và Bệnh viện Ung Bướu Cần Thơ và đã bao gồm dữ liệu tăng cường, đề tài sẽ tiến hành xây dựng bộ dữ liệu này cho hai bài toán phân loại:

- **Bài toán 1:** Phân loại 6 lớp BI-RADS (0, 1, 2, 3, 4, 5) nhằm nhận diện chính xác giai đoạn và mức độ nghi ngờ tổn thương trên ảnh nhũ ảnh.
- **Bài toán 2:** Phân loại 2 lớp (lành tính và ác tính) nhằm xác định bệnh nhân có nguy cơ ác tính cần sinh thiết hay không. Trong đó, nhóm lành tính gồm BI-RADS 0–2, nhóm ác tính gồm BI-RADS 3–5, vì từ BI-RADS 3 trở lên được xem là có khả năng ác tính.

Cách tiếp cận này vừa đảm bảo bài toán tổng quát cho nhiều mức độ (6 lớp), vừa có bài toán đơn giản hơn phục vụ sàng lọc và hỗ trợ quyết định lâm sàng nhanh chóng.

2.2.3.1. Chia dữ liệu cho bài toán 6 lớp

Để huấn luyện và đánh giá mô hình một cách khách quan, toàn bộ tập dữ liệu đã được xử lý cho bài toán phân loại 6 lớp BI-RADS được phân chia thành ba tập con độc lập: tập huấn luyện (train set), tập kiểm định (validation set) và tập kiểm thử (test set). Cụ thể, tập huấn luyện chiếm **70%** tổng số dữ liệu, tập kiểm định chiếm **20%** và tập kiểm thử chiếm **10%**. Việc phân chia này giúp mô hình học các đặc trưng từ tập huấn luyện, được tinh chỉnh trên tập kiểm định, và cuối cùng là đánh giá hiệu suất khách quan trên tập kiểm thử. Số lượng cụ thể của mỗi lớp trong các tập dữ liệu này được thể hiện chi tiết trong Bảng 2.7.

Bảng 2.7. Tỷ lệ dữ liệu cho bài toán phân loại 6 lớp BI-RADS

Tỷ lệ BI-RADs	Train 70%	Val 20%	Test 10%
0	917	290	18
1	1.029	292	149
2	1.097	321	159
3	981	296	134
4	2.205	595	318
5	1.004	310	144
Tổng	7.233	2.104	922

2.2.3.2. Chia dữ liệu cho bài toán 2 lớp

Ở bài toán 2 lớp lành tính và ác tính dữ liệu cho lớp lành tính bao gồm BI-RADS 0,1 và 2. Dữ liệu cho lớp ác tính gồm BI-RADS 3,4 và 5. Các tập huấn luyện, xác thực và kiểm thử cũng lần lượt được chia theo tỷ lệ 70%, 20% và 10% cụ thể được thể hiện ở Bảng 2.8 sau:

Bảng 2.8. Tỷ lệ dữ liệu cho bài toán phân loại 2 lớp lành tính và ác tính


Tỷ lệ BI-RADS	Train 70%	Val 20%	Test 10%
0-1-2	3.043	903	326
3-4-5	4.190	1.201	596
Tổng	7.233	2.104	922

2.2.4. Huấn luyện các mô hình học sâu

2.2.4.1. Huấn luyện mô hình cho bài toán 6 lớp


a) Huấn luyện ResNet50

Sau nhiều lần thử nghiệm với các bộ siêu tham số khác nhau, mô hình ResNet50 đạt được hiệu suất tốt nhất với các thông số: 300 epoch, kích thước batch (batch size) là 8, kết hợp với các kỹ thuật chuẩn hóa hình ảnh và lớp dropout có tỷ lệ 0,2. Dưới đây là nhận xét về kết quả huấn luyện dựa trên biểu đồ Loss và F1-Score.



Hình 2.12. Biểu đồ loss khi huấn luyện ResNet50

Qua Hình 2.12. cho thấy là Biểu đồ Loss cho thấy mô hình đã học được tương đối tốt. Training Loss (đường màu xanh) giảm liên tục, cho thấy mô hình đã nắm bắt được các đặc trưng từ dữ liệu huấn luyện. Ngược lại, Validation Loss (đường màu cam) giảm nhanh trong giai đoạn đầu nhưng chỉ đạt mức thấp nhất là 0,97 ở epoch 37 và sau đó dao động nhẹ, duy trì ở một mức tương đối ổn định. Điều này cho thấy sự cải thiện của mô hình trên tập dữ liệu kiểm định đã chậm lại đáng kể sau một giai đoạn nhất định.



Hình 2.13. Biểu đồ F1 trên tập train và tập validation của ResNet50


Tương tự, biểu đồ F1-Score ở Hình 2.13 cũng phản ánh quá trình học của mô hình. Training F1-Score (đường màu xanh) tăng đều đặn và đạt giá trị cao nhất là 0,74,

chứng tỏ mô hình có khả năng phân loại tốt trên dữ liệu đã được học. Tuy nhiên, Validation F1-Score (đường màu cam) chỉ đạt đỉnh ở mức 0,63 tại epoch 180 và sau đó không cải thiện thêm. Điều này cho thấy khả năng dự đoán của mô hình trên dữ liệu mới không có sự tiến triển đáng kể ở các epoch cuối cùng.

b) Huấn luyện MobileNetV2


Sau khi thử nghiệm với nhiều bộ siêu tham số khác nhau, mô hình MobileNetV2 đạt được kết quả huấn luyện tốt nhất với các thông số: 200 epoch, kích thước batch (batch size) là 16, kết hợp với các kỹ thuật chuẩn hóa ảnh, lớp dropout tỷ lệ 0,2 và tốc độ học (learning rate) là 0,001.

Biểu đồ Loss ở Hình 2.14. cho thấy Training Loss (đường màu xanh) giảm dần và ổn định, đạt mức tối thiểu 0,47 tại epoch 194. Điều này cho thấy mô hình đã học được các đặc trưng từ dữ liệu huấn luyện một cách hiệu quả. Tuy nhiên, đường Validation Loss (đường màu cam) lại có sự biến động rất lớn, với nhiều điểm tăng đột biến. Validation Loss đạt mức tối thiểu là 0,95 tại epoch 22, nhưng sau đó dao động mạnh xung quanh giá trị này mà không có sự cải thiện rõ rệt. Sự dao động này cho thấy mô hình không ổn định trên tập dữ liệu kiểm định.



Hình 2.14. Biểu đồ loss khi huấn luyện MobileV2


Biểu đồ F1-Score ở Hình 2.15. cũng phản ánh tình trạng tương tự. Training F1-Score (đường màu xanh) tăng đều đặn và đạt giá trị tối đa 0,81 tại epoch 198, cho thấy khả năng phân loại tốt trên dữ liệu huấn luyện. Ngược lại, đường Validation F1-Score (đường màu cam) cũng có nhiều dao động lớn, đạt giá trị cao nhất là 0,63 tại epoch 44. Sau đó, chỉ số này tiếp tục dao động mạnh và không có sự cải thiện đáng kể nào trong suốt phần còn lại của quá trình huấn luyện. Kết quả này cho thấy mô hình MobileNetV2 học được tương đối trên tập huấn luyện nhưng lại thiếu ổn định khi dự đoán trên dữ liệu mới.



Hình 2.15. Biểu đồ F1 trên tập train và tập validation của MobileNetV2

c) Huấn luyện InceptionV3


Mô hình InceptionV3 được huấn luyện với các tham số: 300 epoch, kích thước batch (batch size) là 16, kết hợp với các kỹ thuật chuẩn hóa ảnh, lớp dropout tỷ lệ 0,4 và tốc độ học (learning rate) là 0,0001. Trong quá trình huấn luyện mô hình học sâu, biểu đồ Loss và F1-Score của mô hình như sau:



Hình 2.16. Biểu đồ loss khi huấn luyện InceptionV3

Biểu đồ Loss ở Hình 2.16. cho thấy Training Loss (đường màu xanh) giảm rất nhanh và ổn định, đạt mức tối thiểu gần như tuyệt đối là 0,03 tại epoch 70. Điều này chứng tỏ mô hình đã học được toàn bộ các đặc trưng từ tập dữ liệu huấn luyện. Tuy nhiên, đường Validation Loss (đường màu cam) lại có sự biến động rất lớn, với một số

điểm tăng vọt. Sự dao động và tăng vọt này có thể xuất phát từ việc kích thước batch (batch size) nhỏ, khiến gradient của mỗi lần cập nhật bị nhiễu, dẫn đến quá trình huấn luyện thiếu ổn định. Validation Loss đạt mức tối thiểu là 1,11 tại epoch 14, sau đó dao động mạnh và duy trì ở mức cao, cho thấy mô hình không thể tổng quát hóa được các kiến thức đã học trên dữ liệu mới.



Hình 2.17. Biểu đồ F1 trên tập train và tập validation của InceptionV3

Biểu đồ F1-Score ở Hình 2.17. cũng phản ánh tình trạng tương tự. Training F1-Score (đường màu xanh) tăng rất nhanh và đạt giá trị tối đa hoàn hảo là 1,00 tại epoch 70. Ngược lại, đường Validation F1-Score (đường màu cam) chỉ đạt đỉnh ở mức 0,55 tại epoch 20 và sau đó giảm mạnh, rồi tiếp tục dao động ở mức thấp. Kết quả này cho thấy mô hình InceptionV3 đã học quá sâu vào dữ liệu huấn luyện nhưng khả năng dự đoán trên dữ liệu kiểm định lại khá kém, không hoàn toàn học được đặc trưng tổng quát của dữ liệu.


2.2.4.2. Huấn luyện mô hình cho bài toán 2 lớp

Các tham số của các mô hình phân loại 2 lớp này sẽ thấy lại tham số tốt nhất của mô hình phân loại 6 lớp ở Mục 2.2.4.1.

a) Mô hình ResNet50


Biểu đồ Loss ở Hình 2.18. của ResNet50 cho thấy quá trình học ổn định nhất trong ba mô hình. Cả đường Training Loss (đường màu xanh) và Validation Loss (đường màu cam) đều giảm dần và ổn định. Training Loss đạt mức tối thiểu 0.27 tại epoch 131, trong khi Validation Loss đạt mức tối thiểu 0,31 tại epoch 97. Sự chênh lệch giữa hai đường Loss này là nhỏ và chúng có xu hướng đi song song với nhau trong phần lớn quá trình huấn luyện. Điều này cho thấy mô hình ResNet50 có khả

năng học tốt trên tập dữ liệu huấn luyện và đồng thời duy trì được khả năng tổng quát hóa hiệu quả trên dữ liệu kiểm định, biểu hiện của sự ổn định và hiệu suất cao.



Hình 2.18. Biểu đồ loss của ResNet50 cho bài toán 2 lớp

b) Mô hình MobileNetV2




Hình 2.19. Biểu đồ loss của MobileNetV2 cho bài toán 2 lớp

Biểu đồ Loss ở Hình 2.19 của MobileNetV2 cho thấy Training Loss (đường màu xanh) giảm rất nhanh và gần như chạm mức 0 tại epoch 261, cho thấy mô hình học thuộc dữ liệu huấn luyện một cách rất hiệu quả. Tuy nhiên, Validation Loss (đường màu cam) lại có sự biến động lớn và không giảm đáng kể. Mặc dù đạt giá trị tối thiểu

0,30 tại epoch 12, sau đó đường cong này có xu hướng tăng dần và dao động ở mức cao. Điều này cho thấy mô hình MobileNetV2 học được các đặc trưng trên tập huấn luyện nhưng lại thiếu ổn định và không thể tổng quát hóa tốt trên dữ liệu mới.

c) Mô hình InceptionV3




Hình 2.20. Biểu đồ loss của InceptionV3 cho bài toán 2 lớp

Biểu đồ Loss ở Hình 2.20. của InceptionV3 cũng cho thấy một xu hướng tương tự như MobileNetV2 nhưng ở mức độ nghiêm trọng hơn. Training Loss (đường màu xanh) giảm rất nhanh, đạt mức gần như bằng 0 (0,02) tại epoch 66. Ngược lại, Validation Loss (đường màu cam) lại có sự dao động mạnh với nhiều điểm tăng vọt. Mặc dù đạt giá trị tối thiểu 0,38 ở epoch 8, sau đó Loss trên tập kiểm định tăng đột ngột và duy trì ở mức cao. Điều này cho thấy mô hình InceptionV3 đã học quá sâu vào dữ liệu huấn luyện và không thể tổng quát hóa, dẫn đến hiệu suất khá kém trên dữ liệu.

Dựa trên các biểu đồ Loss, có thể thấy mô hình ResNet50 cho thấy sự ổn định vượt trội và khả năng tổng quát hóa tốt nhất trong bài toán phân loại 2 lớp. Ngược lại, MobileNetV2 và InceptionV3 đều biểu hiện sự thiếu ổn định và không hiệu quả trong việc áp dụng kiến thức đã học vào dữ liệu mới.

2.2.5. Cài đặt hệ thống website tích hợp CI/CD



Hình 2.21. Kiến trúc hệ thống website tích hợp CI/CD


Hệ thống website hỗ trợ phân tích hình ảnh ung thư vú được xây dựng trên nền tảng điện toán đám mây Amazon Web Services (AWS) với quy trình phát triển tự động hóa (CI/CD) như Hình 2.21., đảm bảo tính ổn định, khả năng mở rộng và bảo mật. Kiến trúc của hệ thống bao gồm hai phần chính: quy trình CI/CD cho quá trình phát triển và hạ tầng đám mây cho việc triển khai ứng dụng.

2.2.5.1. Tích hợp CI/CD vào hệ thống

Quy trình CI/CD được xây dựng dựa trên Github Actions, giúp tự động hóa toàn bộ các bước từ khi lập trình viên cập nhật mã nguồn cho đến khi ứng dụng được triển khai.

- **Continuous Integration (CI):** Khi lập trình viên (Developer) thực hiện thay đổi và đẩy (push) mã nguồn lên kho lưu trữ Git, một quy trình tự động trên Github Actions sẽ được kích hoạt. Quy trình này bao gồm các bước kiểm tra mã nguồn, xây dựng (build) ứng dụng và chạy các bài kiểm thử tự động (Automation Test) bằng các thư viện như: Pytest, Flake8, Black và Isort để đảm bảo chất lượng. Nếu Test source code bị lỗi thì sẽ không triển khai, sẽ có mail gửi về cho Developer để thông báo lỗi.
- **Continuous Deployment (CD):** Sau khi các bài kiểm thử tự động thành công, quy trình CD sẽ tiếp tục được thực thi. Hệ thống sẽ xây dựng một Docker Image từ mã nguồn và đẩy (push) image này lên kho lưu trữ công cộng Docker Hub. Điều này giúp đóng gói ứng dụng cùng với các thư viện và môi trường cần thiết, đảm bảo ứng dụng hoạt động nhất quán trên mọi môi trường.

Chi tiết các bước thực hiện CI/CD được biểu diễn qua Hình 2.22.



Hình 2.22. workflow của quy trình CI/CD trong hệ thống

2.2.5.2. Triển khai hệ thống lên AWS


Hệ thống được triển khai trên nền tảng AWS Cloud với một kiến trúc phân tán và an toàn, sử dụng các dịch vụ sau:

- Amazon Amplify (Frontend): Giao diện người dùng (Frontend) được phát triển bằng ReactJS và triển khai thông qua dịch vụ AWS Amplify. Amplify cung cấp một nền tảng phát triển và hosting tích hợp, giúp triển khai các ứng dụng web tĩnh và SPA (Single Page Application) một cách nhanh chóng và dễ dàng. Amplify cũng đảm nhận việc xử lý các yêu cầu từ người dùng, gọi các API để giao tiếp với phần backend.
- EC2 (Backend): Phần xử lý chính của hệ thống (Backend), bao gồm các API phục vụ cho việc tải ảnh, phân tích và trả về kết quả, được triển khai trên một máy chủ ảo EC2 (Elastic Compute Cloud). EC2 là nơi các mô hình học sâu đã huấn luyện được chạy để thực hiện tác vụ phân loại hình ảnh ung thư vú.
- Docker Hub và EC2: Khi có phiên bản mới của Docker Image trên Docker Hub, EC2 sẽ tự động kéo (pull) image mới nhất về và chạy (run) ứng dụng. Điều này giúp đảm bảo rằng hệ thống backend luôn được cập nhật với phiên bản mới nhất.

- VPC và Security Group: Để tăng cường bảo mật, toàn bộ các dịch vụ AWS được đặt trong một VPC (Virtual Private Cloud), tạo ra một mạng ảo riêng biệt. Security Group được cấu hình để kiểm soát lưu lượng mạng vào và ra khỏi máy chủ EC2, chỉ cho phép các yêu cầu hợp lệ từ Amplify và các dịch vụ nội bộ khác.
- Amazon S3 (Lưu trữ ảnh và mô hình): Dịch vụ Amazon S3 (Simple Storage Service) được sử dụng để lưu trữ các tài nguyên tĩnh như hình ảnh của bệnh nhân được tải lên và các tệp mô hình học sâu đã huấn luyện. S3 cung cấp khả năng lưu trữ có độ tin cậy và khả năng mở rộng cao.
- AWS DocumentDB (Cơ sở dữ liệu): Cơ sở dữ liệu của hệ thống được xây dựng trên Amazon DocumentDB, một dịch vụ cơ sở dữ liệu NoSQL tương thích với MongoDB. DocumentDB được sử dụng để lưu trữ thông tin người dùng, lịch sử chẩn đoán, kết quả phân tích và các thông tin liên quan khác.

CHƯƠNG 3. KIỂM THỬ VÀ ĐÁNH GIÁ

3.1. Giao diện sản phẩm




Hình 3.1. Giao diện trang chủ hệ thống

Hình 3.1 là giao diện trang chủ của hệ thống, hệ thống có một số chức năng chính cho khách vãng lai không cần đăng nhập tài khoản như Tầm soát ung thư vú và nhận lời khuyên tương ứng với nguy cơ mắc bệnh. Giao diện chức năng tầm soát như Hình 3.2 sau:


Hình 3.2. Giao diện làm câu hỏi trắc nghiệm tầm soát ung thư vú

Sau khi làm bảng câu hỏi gồm 16 câu trả lời trắc nghiệm, người dùng sẽ nhận được kết quả là lời khuyên dựa trên kết quả làm trắc nghiệm như Hình 3.3.




Hình 3.3. Giao diện nhận kết quả tầm soát ung thư vú

Để bác sĩ có thể sử dụng chức năng dự đoán BI-RADS thì bắt buộc phải có tài khoản, sau khi đăng nhập và tải ảnh X-quang lên để dự đoán thì kết quả trả về như Hình 3.4. nhằm hỗ trợ bác sĩ trong quá trình chẩn đoán. Ngoài ra bác sĩ có thể xem lại lịch dự đoán.




Hình 3.4. Giao diện hiển thị kết quả chẩn đoán BI-RADS

Quản trị viên (Admin) sẽ quản lý website thông qua các chức năng như quản lý user (người dùng), với chức năng này admin có thể quản lý tất cả người dùng trong hệ thống thông qua các tùy chỉnh như xem chi tiết user, tìm kiếm, lọc, xóa tài khoản, cấp quyền/thu hồi tài khoản. Giao diện quản lý user như Hình 3.5 sau:




Hình 3.5. Giao diện quản lý user

Ngoài ra, quản trị viên có thể quản lý lưu lượng truy cập vào hệ thống, quản lý dự đoán và quản lý ảnh. Giao diện các chức năng như sau:




Hình 3.6. Giao diện quản lý lưu lượng của hệ thống website

Từ giao diện quản lý lưu lượng hệ thống ở Hình 3.6, quản trị viên có thể biết rằng mức độ phát triển người dùng website nhằm nâng cấp website khi cần thiết.




Hình 3.7. Giao diện quản lý thông tin dự đoán và quản lý các mô hình học sâu

Giao diện quản lý dự đoán và quản lý mô hình ở Hình 3.7, người quản trị viên có thể theo dõi số lượng ảnh được đã được dự đoán trong hệ thống và xu hướng như thế nào từ đó ra quyết định có nên nâng cấp hệ thống phần cứng hay không. Ngoài ra quản trị viên cũng có thể thêm mô hình mới lên hệ thống để thay thế cho mô hình hiện tại website đang sử dụng.



Hình 3.8. Giao diện quản lý hình ảnh dự đoán

Với giao diện Hình 3.8. admin có thể xem lại các ảnh đã được gửi từ bác sĩ để dự đoán, ngoài ra quản trị viên có thể phân chia tỷ lệ dữ liệu tùy ý để có thể tải xuống nhằm huấn luyện. Giao diện phân chia tỷ lệ huấn luyện ở Hình 3.9. Sau khi phân chia dữ liệu xong có thể tải xuống dữ liệu gồm ảnh và 3 file csv đã chia theo tỷ lệ chia.



Hình 3.9. Giao diện phân chia tỷ lệ huấn luyện để tải xuống


3.2. Kết quả thực nghiệm

3.2.1. Kết quả kiểm thử các mô hình

3.2.1.1. Kiểm thử bài toán 6 lớp

Ở bài toán phân lớp 6 lớp BI-RADS 3 mô hình ResNet50, MobileNetV2 và InceptionV3 được kiểm thử trên tập test đã được trình bày ở Mục 2.2.3.1.

a) Kiểm thử mô hình ResNet50



Hình 3.10. Ma trận nhầm lẫn của mô hình ResNet50 khi kiểm thử


Ma trận nhầm lẫn trong Hình 3.10 cho thấy mô hình ResNet50 có khả năng phân loại tương đối tốt trên tập dữ liệu kiểm thử. Cụ thể, mô hình thể hiện độ chính xác cao đối với các lớp BI-RADS 0 (15/15 mẫu), BI-RADS 1 (125/139 mẫu) và BI-RADS 4 (266/290 mẫu). Tuy nhiên, mô hình vẫn gặp khó khăn trong việc phân loại chính xác các lớp còn lại, đặc biệt là sự nhầm lẫn giữa các lớp cận biên như BI-RADS 2 và BI-RADS 3, cũng như việc dự đoán sai nhiều mẫu BI-RADS 5 thành BI-RADS 4. Nhìn chung, mô hình đã học được các đặc trưng để phân loại 6 lớp BI-RADS.

	precision	recall	f1-score	support
BI-RADS 0	0.4054	0.8824	0.5556	17
BI-RADS 1	0.4562	0.8389	0.5910	149
BI-RADS 2	0.5370	0.3648	0.4345	159
BI-RADS 3	0.5172	0.2239	0.3125	134
BI-RADS 4	0.7112	0.8365	0.7688	318
BI-RADS 5	0.7571	0.3681	0.4953	144
accuracy			0.5939	921
macro avg	0.5640	0.5857	0.5263	921
weighted avg	0.6132	0.5939	0.5692	921

Hình 3.11. Các chỉ số đánh giá mô hình ResNet50

Từ ma trận nhầm lẫn ở Hình 3.10, các chỉ số đánh giá như Precision, Recall, F1 và Accuracy được tính như ở Hình 3.11. Có thể thấy rằng mô hình ResNet50 có hiệu suất không đồng đều trên các lớp BI-RADS. Cụ thể, mô hình đạt F1-Score cao nhất ở lớp BI-RADS 4 (0,7688) và hoạt động tương đối tốt ở lớp BI-RADS 1 (0,5910). Tuy nhiên, hiệu suất giảm đáng kể ở các lớp còn lại, đặc biệt là BI-RADS 3 với F1-Score rất thấp chỉ 0,3125. Độ chính xác tổng thể (Accuracy) của mô hình là 0,5939, cho thấy mô hình còn gặp nhiều khó khăn trong việc phân loại chính xác các trường hợp phức tạp, đặc biệt là các lớp có đặc trưng tương đồng.

b) Kiểm thử mô hình MobileNetV2



Hình 3.12. Ma trận nhầm lẫn của mô hình MobileNetV2 khi kiểm thử


Với ma trận nhầm lẫn của mô hình MobileNetV2 ở Hình 3.12 có thể thấy rằng mô hình nhận diện không bằng ResNet50 khi dự đoán tệ ở cả BI-RADS 1, BI-RADS 2, BI-RADS 3 và BI-RADS 5. MobileNetV2 vẫn dự đoán ảnh khá tốt ở lớp BI-RADS 0 và BI-RADS 4.

	precision	recall	f1-score	support
BI-RADS 0	0.4333	0.7647	0.5532	17
BI-RADS 1	0.4167	0.4362	0.4262	149
BI-RADS 2	0.5000	0.4088	0.4498	159
BI-RADS 3	0.3356	0.3657	0.3500	134
BI-RADS 4	0.7111	0.8050	0.7552	318
BI-RADS 5	0.6566	0.4514	0.5350	144
accuracy			0.5570	921
macro avg	0.5089	0.5386	0.5116	921
weighted avg	0.5587	0.5570	0.5521	921

Hình 3.13. Các chỉ số đánh giá mô hình MobileNetV2

Độ chính xác cũng kém hơn so với mô hình ResNet50, MobileNetV2 chỉ đạt độ chính xác tổng thể ở 0,557. Các chỉ số F1 ở các lớp cũng bị thua thiệt, chỉ dao động từ 0,35 ở BI-RAD 3 đến cao nhất chỉ đạt 0,75 ở BI-RADS 4.

c) **Kiểm thử mô hình InceptionV3**



Hình 3.14. Ma trận nhầm lẫn của mô hình InceptionV3 khi kiểm thử


Mô hình InceptionV3 có confusion matrix ở Hình 3.14 khá tương đồng với mô hình ResNet50, mô hình nhận diện khá tốt, chỉ thua ResNet50 một chút ở các lớp BI-RADS 0, BI-RADS 1, BI-RADS 4. Tuy nhiên ở các lớp BI-RADS 2, BI-RADS 3 và BI-RADS 5, mô hình InceptionV3 có độ chính xác cao hơn so với mô hình ResNet50.

	precision	recall	f1-score	support
BI-RADS 0	0.5926	0.9412	0.7273	17
BI-RADS 1	0.5291	0.6107	0.5670	149
BI-RADS 2	0.5556	0.4717	0.5102	159
BI-RADS 3	0.3944	0.4179	0.4058	134
BI-RADS 4	0.7321	0.7390	0.7355	318
BI-RADS 5	0.6210	0.5347	0.5746	144
accuracy			0.5972	921
macro avg	0.5708	0.6192	0.5867	921
weighted avg	0.5997	0.5972	0.5961	921

Hình 3.15. Các chỉ số đánh giá mô hình InceptionV3

Tương tự với mô hình ResNet50, mô hình InceptionV3 cũng đạt độ chính xác tổng thể là 0.59, các chỉ số F1 ở BI-RADS 0, BI-RADS 4 và BI-RADS 5 đạt khá cao so với hai mô hình ResNet50 và MobileNetV2 với lần lượt đạt 0,72, 0,73 và 0,57.

d) Kiểm thử phương pháp bình chọn theo số đông



Hình 3.16. Ma trận nhầm lẫn của phương pháp bình chọn theo số đông


Với phương pháp bình chọn theo số đông (1.2.3.1) này đã tận dụng được sức mạnh tổng hợp của 3 mô hình ResNet50, MobileNetV2 và InceptionV3. Qua hình 3.16 Có thể lấy số lượng ảnh dự đoán chính xác qua từng lớp có tăng đôi chút so với từng mô hình riêng lẻ trên.

	precision	recall	f1-score	support
BI-RADS 0	0.5161	0.9412	0.6667	17
BI-RADS 1	0.4907	0.7114	0.5808	149
BI-RADS 2	0.5983	0.4403	0.5072	159
BI-RADS 3	0.4369	0.3358	0.3797	134
BI-RADS 4	0.7315	0.8396	0.7818	318
BI-RADS 5	0.7303	0.4514	0.5579	144
accuracy			0.6178	921
macro avg	0.5840	0.6199	0.5790	921
weighted avg	0.6225	0.6178	0.6063	921

Hình 3.17. Các chỉ số đánh giá phương pháp bình chọn theo số đông

Độ chính xác của phương pháp bình chọn theo số đông (Hình 3.17) cũng cao hơn so với 3 mô hình riêng lẻ với độ chính xác tổng thể đạt 0,617. F1 weighted cũng đạt xấp xỉ 0,61.

e) Kiểm thử phương pháp kết hợp xác suất



Hình 3.18. Confusion matrix của phương pháp kết hợp xác suất


Tương tự với phương pháp bình chọn theo số đông, phương pháp kết hợp xác suất cũng đạt hiệu quả hơn so với từng mô hình riêng lẻ khi tận dụng được lợi thế của từng mô hình.

	precision	recall	f1-score	support
BI-RADS 0	0.5161	0.9412	0.6667	17
BI-RADS 1	0.4949	0.6510	0.5623	149
BI-RADS 2	0.6121	0.4465	0.5164	159
BI-RADS 3	0.4333	0.3881	0.4094	134
BI-RADS 4	0.7330	0.8459	0.7854	318
BI-RADS 5	0.7363	0.4653	0.5702	144
accuracy			0.6211	921
macro avg	0.5876	0.6230	0.5851	921
weighted avg	0.6265	0.6211	0.6123	921

Hình 3.19. Các chỉ số đánh giá phương pháp kết hợp xác suất

Độ chính xác của phương pháp này xấp xỉ đạt 0,62, cao hơn hết so với 3 mô hình ResNet50, MobileNetV2 và InceptionV3. Chỉ số F1 cũng tương đối cao đạt 0,61.


Có thể thấy rằng đa số các mô hình dự đoán chính xác khá cao ở lớp BI-RADS 0 và BI-RADS 4. Mô hình ResNet50 và InceptionV3 có phần cao hơn về độ chính xác ở các lớp còn lại so với mô hình MobileNetV2. Hai phương pháp bình chọn theo số đông và phương pháp kết hợp xác suất có hiệu suất không quá nổi bật, nhưng cũng chứng minh được độ hiệu quả khi Accuracy tăng từ 3,3% đến 10,7%, F1 weighted tăng từ 3,4% 10,9% so với 3 mô hình ResNet50, MobileNetV2 và InceptionV3 (Hình 3.20).



Hình 3.20. So sánh Accuracy và F1 giữa các mô hình và các phương pháp

3.2.1.2. Kiểm thử bài toán 2 lớp

Khi kiểm thử 3 mô hình ResNet50, MobileNetV2 và InceptionV3 trên tập kiểm thử, các chỉ số đánh giá Accuracy và F1 weighted được tính ra như Hình 3.21.



Hình 3.21. So sánh độ chính xác giữa các mô hình phân loại 2 lớp

Kết quả đánh giá trên tập dữ liệu kiểm thử cho bài toán phân loại 2 lớp (Lành tính và Ác tính) cho thấy hiệu suất của các mô hình đã được cải thiện đáng kể so với bài toán phân loại 6 lớp BI-RADS. Điều này cho thấy các mô hình đã học được các đặc trưng tương đối tốt để phân biệt hai nhóm bệnh lý lớn này.

Dựa vào biểu đồ so sánh, có thể thấy:

- ResNet50 và MobileNetV2 đạt hiệu suất cao nhất và tương đương nhau. Cả hai mô hình đều đạt Accuracy là 0,84 và F1-Score (có trọng số) lần lượt là 0,85 và 0,84. Kết quả này chứng tỏ hai mô hình có khả năng phân biệt tổn thương lành tính và ác tính một cách rất hiệu quả.
- InceptionV3 cũng đạt được hiệu suất khá tốt, với Accuracy là 0,78 và F1-Score là 0,79. Mặc dù thấp hơn một chút so với hai mô hình còn lại, kết quả này vẫn cho thấy khả năng phân loại đáng tin cậy.

Nhìn chung, cả ba mô hình đều thể hiện khả năng phân loại tốt trong bài toán nhị phân, nhưng ResNet50 và MobileNetV2 tỏ ra vượt trội hơn với các chỉ số Accuracy và F1-Score cao hơn. Sự cải thiện rõ rệt này xác nhận rằng việc gộp các lớp BI-RADS thành hai nhóm chính giúp mô hình dễ dàng học và tổng quát hóa hơn, từ đó đưa ra kết quả dự đoán chính xác và ổn định hơn.

3.2.2. Kết quả kiểm thử hệ thống

Chức năng chính của hệ thống sẽ được kiểm thử ở phần này là chức năng dự đoán 6 lớp BI-RADS của bác sĩ nhằm đảm bảo quá trình xử lý và phản hồi kết quả diễn ra chính xác.

a) Mục tiêu

Nhằm kiểm tra xem chức năng tải ảnh lên hệ thống và dự đoán có hoạt động đúng theo yêu cầu ban đầu hay không, đảm bảo ảnh được gửi từ người dùng được tiếp nhận và xử lý chính xác. Phát hiện các lỗi có thể phát sinh trong quá trình tải ảnh lên như định dạng ảnh không hợp lệ, dung lượng quá lớn hoặc lỗi khi gửi dữ liệu, từ đó kịp thời xử lý và cải thiện trải nghiệm người dùng.

b) Kịch bản kiểm thử

Nội dung của kịch bản kiểm thử bao gồm:

- Kiểm tra khả năng tải ảnh hợp lệ lên hệ thống, nhận diện và trả về kết quả.
- Kiểm tra hành vi hệ thống khi người dùng cố gắng tải ảnh vượt quá dung lượng cho phép.
- Kiểm tra phản hồi của hệ thống khi người dùng tải lên ảnh sai định dạng (.gif, .bmp, .webp).
- Kiểm tra khả năng xử lý khi người dùng không chọn ảnh nhưng vẫn nhấn nút dự đoán.
- Kiểm tra hành vi hệ thống khi người dùng thay đổi ảnh trong lúc ảnh đang được xử lý.
- Kiểm tra hành vi hệ thống khi người dùng thay đổi ảnh trước khi nhấn nút tải lên.
- Kiểm tra phản hồi hệ thống khi tải ảnh lúc server chưa hoạt động.

c) Kết quả kiểm thử

Bảng 3.1. Kết quả kiểm thử chức năng tải ảnh và dự đoán

Trường hợp	Nội dung thực hiện	Kết quả mong đợi	Số lần kiểm thử	Kết quả kiểm thử
1	Tải ảnh hợp lệ (định dạng .jpg, dung lượng < 5MB) và dự đoán	Trả về xác suất dự đoán của 6 lớp BI-RADS	10	Thành công 10/10
2	Tải ảnh có định dạng không hợp lệ (.gif, .webp, .bmp)	Hệ thống hiển thị thông báo lỗi định dạng	10	Thành công 10/10
3	Tải ảnh vượt quá dung lượng	Hệ thống cảnh báo	10	Thành công

	lượng cho phép (> 5MB)	và từ chối tải ảnh		10/10
4	Không chọn ảnh và nhấn nút dự đoán	Hệ thống không cho phép	10	Thành công 10/10
5	Thay đổi ảnh trong lúc ảnh đang xử lý	Hệ thống không cho phép thay đổi ảnh	10	Thành công 10/10
6	Thay đổi ảnh trước khi nhấn nút tải lên	Hệ thống ghi nhận ảnh cuối cùng được chọn	10	Thành công 10/10
7	Tải ảnh lên khi server chưa chạy	Hệ thống thông báo lỗi và yêu cầu thử lại sau	10	Thành công 10/10

3.3. Thảo luận về kết quả đạt được

So sánh với mục tiêu đã đề ra ở phần giới thiệu, về mặt ứng dụng học sâu, đề tài đã triển khai thành công các mô hình học sâu cho cả hai nhiệm vụ: phân loại 6 lớp BI-RADS và phân loại nhị phân lành tính – ác tính. Bên cạnh đó, đề tài đã áp dụng hiệu quả hai phương pháp tăng độ chính xác là bỏ phiếu theo số đông (majority voting) và kết hợp xác suất (probability fusion), trong đó bài toán phân loại 2 lớp đạt độ chính xác tương đối cao, còn bài toán phân loại 6 lớp BI-RADS vẫn cần cải thiện để đạt hiệu quả tốt hơn.

Về mặt triển khai hệ thống, đề tài đã xây dựng thành công một website hỗ trợ bác sĩ trong việc chẩn đoán BI-RADS, giúp rút ngắn thời gian sàng lọc và hỗ trợ đưa ra quyết định. Hệ thống đã được tích hợp các dịch vụ trên nền tảng điện toán đám mây AWS nhằm đảm bảo bảo mật, tối ưu chi phí và tăng khả năng mở rộng.

Ngoài ra, quy trình phát triển CI/CD cũng đã được tích hợp vào hệ thống, cho phép tự động hóa việc triển khai và cập nhật, giảm thiểu rủi ro khi nâng cấp, đồng thời nâng cao hiệu quả vận hành và bảo trì.

III. PHẦN KẾT LUẬN

1. Kết quả đạt được

Đề tài “*Ứng dụng học sâu trong phân tích hình ảnh ung thư vú*” đã đạt được gần như đầy đủ các mục tiêu ban đầu và thu được nhiều kết quả quan trọng. Cụ thể, đề tài đã ứng dụng các mô hình học sâu ResNet50, MobileNet50 và InceptionV3 vào phân tích và chẩn đoán hình ảnh ung thư vú, cho phép phân loại 6 lớp BI-RADS. Hệ thống website được xây dựng thành công, hỗ trợ bác sĩ giảm thời gian chẩn đoán và đưa ra quyết định BI-RADS hiệu quả hơn. Ngoài ra, hệ thống còn có các chức năng dành cho quản trị viên nhằm giám sát, bảo trì, nâng cấp và cải thiện độ chính xác của mô hình thông qua việc sử dụng hình ảnh được lưu trữ trên nền tảng đám mây, có thể tải xuống để tiếp tục huấn luyện. Đề tài cũng đã áp dụng các dịch vụ trên nền tảng điện toán đám mây và triển khai hệ thống như một dự án thực tế, đáp ứng yêu cầu bảo mật, tối ưu chi phí và đảm bảo khả năng mở rộng. Bên cạnh đó, quy trình CI/CD được tích hợp nhằm tự động hóa kiểm thử và triển khai, giảm thiểu rủi ro khi nâng cấp, đồng thời nâng cao hiệu quả trong phát triển và bảo trì website.

2. Hạn chế

Bên cạnh các ưu điểm của đề tài thì đề tài cũng có một số vấn đề hạn chế. Thứ nhất kích thước dữ liệu vẫn còn hạn chế so với các bộ dữ liệu y khoa lớn, đặc biệt ở một số lớp BI-RADS có số lượng ảnh ít, gây mất cân bằng dữ liệu. Hạn chế thứ hai là độ chính xác dự đoán 6 lớp BI-RADS chưa được cao như mục tiêu ban đầu đề ra, nhiều lớp có độ chính xác rất thấp đặc biệt ở các lớp trung gian (ví dụ BI-RADS 3 và 4) dễ gây nhầm lẫn. Thứ ba, chưa triển khai hệ thống trên nền tảng thiết bị di động, gây khó khăn cho một số người dùng.

3. Hướng phát triển

Từ những hạn chế đã nêu, đề tài có thể mở rộng và phát triển theo một số hướng trong tương lai. Trước hết, cần mở rộng và đa dạng hóa dữ liệu bằng cách thu thập thêm ảnh từ nhiều nguồn bệnh viện khác nhau, đặc biệt chú trọng bổ sung các lớp BI-RADS có ít dữ liệu để giảm tình trạng mất cân bằng. Bên cạnh đó, cần tối ưu và cải thiện mô hình thông qua việc áp dụng các kiến trúc học sâu tiên tiến như Vision Transformer hoặc các biến thể cải tiến của CNN, nhằm nâng cao khả năng trích xuất đặc trưng và tăng độ chính xác dự đoán. Ngoài ra, có thể tích hợp nền tảng di động để hỗ trợ bác sĩ và người dùng truy cập kết quả nhanh chóng, thuận tiện hơn. Cuối cùng, hệ thống có thể bổ sung thêm các chức năng hỗ trợ chẩn đoán như gợi ý khu vực nghi ngờ trên ảnh hoặc tự động tạo báo cáo tóm tắt, góp phần nâng cao hiệu quả hỗ trợ ra quyết định y khoa.

TÀI LIỆU THAM KHẢO

- [1] Võ Văn Tài, Lê Thị Xuân Mai, Nguyễn Lê Minh Nhật, Trần Lê Hoàng Bảo, Phạm Toàn Định, «Phân loại ung thư vú sử dụng kết hợp thuật toán phân tích chùm mờ và mạng học sâu Inception ResNet - V2,» Tạp chí Khoa học Đại học Cần Thơ, Cần Thơ, 2024.
- [2] Phan Anh Cang, Võ Đình Nghĩa, Trần Hồ Đạt, Phan Thượng Cang, «Chuẩn đoán ung thư vú trên nhũ ảnh sử dụng các mô hình học sâu và mạng vision transformer,» Cần Thơ, 2023.
- [3] H. N. T. V. T. L. N. T. N. Võ Thành Toàn, «Kết Quả Bước Đầu Phân Loại Mật Độ Vú Trên Phim Nhũ Ảnh Bằng Trí Tuệ Nhân Tạo Tại Bệnh Viện Thống Nhất,» Tạp chí Y Dược Cần Thơ, 2025.
- [4] Hongyi Pan, Ziliang Hong, Gorkem Durak, «Federated Breast Cancer Detection Enhanced by Synthetic Ultrasound Image Augmentation,» Chicago, 2025.
- [5] Tariq Shahzad1, Sheikh Muhammad Saqib, Tehseen Mazhar, Muhammad Iqbal, Ahmad Almogren, Yazeed Yasin Ghadi, Mamoon M. Saeed, Habib Hamam, «MobNas ensembled model for breast cancer prediction,» 2025.
- [6] Sarah A. Alzakari, Salima Hassairi, Amel Ali Al. Hussan, Ridha Ejbal, «Enhancing breast cancer classification using a deep sparse wavelet autoencoder approach,» Scientific Reports, 2025.
- [7] Ayman Mohamed Mostafa, Alaa S. Alaerjan, Bader Aldughayfiq, Hisham Allahem, Alshimaa Abdelraof Mahmoud, Wael Said, Hosameldeen Shabana, and Mohamed Ezz, «Optimized YOLOv8 for enhanced breast tumor segmentation in ultrasound imaging,» Discover Oncology, 2025.
- [8] Ferlay J, Ervik M, Lam F, Laversanne M, Colombet M, Mery L, Piñeros M, Znaor A, Soerjomataram I, Bray F, «Global Cancer Observatory: Cancer Today,» Global Cancer Observatory, 2022. [En línea]. Available: <https://gco.iarc.who.int/media/globocan/factsheets/populations/704-viet-nam-fact-sheet.pdf#page=2.92>. [Último acceso: 03 08 2025].
- [9] Mridha, M. M. R., Shaha, P., Mizan, M. A. I., et al., «MRI-Based Identification of Brain Tumors Using Deep Convolutional Neural Networks: A Case Study on Inception V3,» International Conference on Intelligent Systems and Computing, 2025.
- [10] Sánchez-Moreno, L., Pérez-Peña, A., et al., «Ensemble-based Convolutional Neural Networks for brain tumor classification in MRI: Enhancing accuracy and interpretability using explainable AI,» Computers in Biology and Medicine, Elsevier, 2025.
- [11] PGS. TS. Lê Đình Roanh, TS. Đặng Tiếng Hoạt, Bệnh học ung thư vú, Hà Nội: Nhà xuất bản Y Học Hà Nội, 2004.
- [12] Bhatti, E., & Kaur, P., «Advances in sensor technologies for breast cancer detection: a comprehensive review of imaging and non-imaging approaches,» Biomedical Engineering Letters, Springer, 2025.
- [13] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, «Deep Residual Learning for Image Recognition,» 2015.
- [14] Thanh-Nghi Do, Minh-Thu Tran-Nguyen, Training Deep Network Models for

- Fingerprint, Springer International Publishing, 2021.
- [15] Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov, Liang-Chieh Chen, «MobileNetV2: Inverted Residuals and Linear Bottlenecks,» 2019.
 - [16] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens, «Rethinking the Inception Architecture for Computer Vision,» 2015.
 - [17] Breiman, Leo, «Random Forests,» Machine Learning, 2001.
 - [18] Bochkovskiy, A., Wang, C.Y., Liao, H., «Yolov4: Optimal speed and accuracy of object detection,» 2020.
 - [19] Bosch, A., Zisserman, A., Munoz, X., «Scene classification via pLSA. In: Proceedings of the European Conference on Computer Vision,» 2006.
 - [20] Chollet, F., Keras, 2015. [En línea]. Available: <https://keras.io>.
 - [21] Đỗ Thanh Nghị, Phạm Nguyên Khang, Giáo trình nguyên lý máy học, Cần Thơ: Nhà xuất bản Đại học Cần Thơ, 2012.
 - [22] Sawyer-Lee, R., Gimenez, F., Hoogi, A., & Rubin, «Curated Breast Imaging,» The Cancer Imaging Archive, 2016.
 - [23] Simonyan, Karen, Andrew Zisserman, «Very deep convolutional networks for large-scale image recognition,» arXiv preprint, 2014.
 - [24] Nguyen, Hieu T., Nguyen, Ha Q., Pham, Hieu H., Lam, Khanh, Le, Linh T., Dao, Minh, Vu, Van, «VinDr-Mammo: A large-scale benchmark dataset for computer-aided diagnosis in full-field digital mammography,» medRxiv, 2023.

PHỤ LỤC

Chi tiết về bảng câu hỏi tâm soát:

Bảng câu hỏi tâm soát được cung cấp bởi bác sĩ Trần Thế Đủ - Bệnh viện Ung Bướu Cần Thơ cung cấp và đã xác nhận tính đúng đắn cũng như khoa học của các câu hỏi. Bảng câu hỏi gồm 16 câu hỏi xoay quanh thói quen sinh hoạt, ăn uống cũng như tình trạng sức khỏe của bệnh nhân, gồm có 3 nhóm câu hỏi chính: nguy cơ thấp, nguy cơ trung bình và nguy cơ cao. Mỗi câu trả lời sẽ có điểm số tương ứng, sau đây là các câu hỏi:

❖ Các câu hỏi thuộc nhóm nguy cơ thấp

NGUY CƠ THẤP	
STT	CÂU HỎI
1	Bạn có từng cho con bú trong thời gian dưới 12 tháng không? a. Không. (0 điểm) b. Có. (1 điểm)
2	Bạn có ít tập thể dục (ít hơn 30 phút/ngày hoặc không đều đặn) không? a. Không. (0 điểm) b. Có. (1 điểm)
3	Bạn sinh con đầu lòng sau 30 tuổi, hoặc chưa sinh con, hoặc sinh con nhưng không đủ tháng? a. Không. (0 điểm) b. Có. (1 điểm)
4	Bạn có đang sử dụng thuốc ngừa thai thường xuyên? a. Không. (0 điểm) b. Có. (1 điểm)
5	Bạn có uống rượu thường xuyên (hơn 10g alcohol/lần)? a. Không. (0 điểm) b. Có. (1 điểm)

❖ Các câu hỏi thuộc nhóm nguy cơ trung bình

NGUY CƠ TRUNG BÌNH	
6	Bạn có mô tuyến vú dày (kết quả từ nhũ ảnh/siêu âm)? a. Không. (0 điểm) b. Có. (1 điểm)
7	Bạn đang sử dụng liệu pháp hormon phối hợp (estrogen + progesterone)? a. Không. (0 điểm) b. Có. (1 điểm)
8	Bạn có chỉ số BMI (cân nặng/chiều cao bình phương) trên 30 (béo phì)? a. Không. (0 điểm) b. Có. (1 điểm)
9	Bạn có kinh nguyệt trước 12 tuổi? a. Không. (0 điểm) b. Có. (1 điểm)
10	Bạn mãn kinh sau 55 tuổi? a. Không. (0 điểm) b. Có. (1 điểm)
11	Bạn có tiền sử bệnh lành tính tuyến vú như tăng sản không điển hình, ung thư tiểu thùy tại chỗ hoặc các bệnh lý khác? a. Không. (0 điểm) b. Có. (1 điểm)
12	Bạn từ 40 tuổi trở lên? a. Không. (0 điểm) b. Có. (1 điểm)

❖ Các câu hỏi thuộc nhóm nguy cơ cao

NGUY CƠ CAO	
13	Bạn (hoặc người thân ruột thịt) đã được phát hiện có đột biến gen liên quan ung thư vú (BRCA1, BRCA2, TP53, PTEN, ATM, BRIP1, PALB2, CDH1, STK11...)? a. Không. (0 điểm) b. Có. (2 điểm)
14	Gia đình bạn có mẹ, chị/em ruột bị ung thư vú hoặc buồng trứng dưới 50 tuổi? a. Không. (0 điểm) b. Có. (2 điểm)
15	Gia đình có nhiều người (cô, dì, bà ngoại/nội) bị ung thư vú hoặc buồng trứng? a. Không. (0 điểm) b. Có. (2 điểm)
16	Bạn từng xạ trị vùng ngực trước tuổi 30? a. Không. (0 điểm) b. Có. (2 điểm)

Sau khi người dùng trả lời tất cả 16 câu hỏi sẽ được số điểm tương ứng, phụ thuộc vào số điểm thấp hay cao mà sẽ được xếp vào 3 loại nguy cơ: nguy cơ thấp, nguy cơ trung bình và nguy cơ cao.

Cụ thể, người dùng nhận được từ 0 đến 6 điểm sẽ thuộc nhóm “nguy cơ thấp”, 7 đến 12 điểm sẽ thuộc nhóm “nguy cơ trung bình” và điểm từ 13 đến 20 điểm sẽ thuộc nhóm còn lại – “nguy cơ cao”.

Số điểm	Mức độ nguy cơ
0 điểm - 6 điểm	Nguy cơ thấp
7 điểm - 12 điểm	Nguy cơ trung bình
13 điểm – 20 điểm	Nguy cơ cao

Với mỗi mức độ sẽ có tư vấn phù hợp, cụ thể như sau:

Mức độ nguy cơ	Tư vấn tầm soát ung thư vú
Nguy cơ thấp	- Bắt đầu tầm soát từ năm 40 tuổi. - Phương pháp tầm soát: Tự khám vú + siêu âm tuyến vú + chụp nhũ ảnh.
Nguy cơ trung bình	- Bắt đầu tầm soát từ năm 40 tuổi. - Phương pháp tầm soát: Tự khám vú + siêu âm tuyến vú + chụp nhũ ảnh.
Nguy cơ cao	- Bắt đầu tầm soát từ năm 25 tuổi. - Phương pháp tầm soát: Tự khám vú + siêu âm tuyến vú + chụp nhũ ảnh + kết hợp chụp cộng hưởng từ vú (MRI).