

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



BÁO CÁO
NIÊN LUẬN CƠ SỞ
NGÀNH KHOA HỌC MÁY TÍNH

ĐỀ TÀI:

**“aiMuseum QK9” - ỨNG DỤNG THIẾT BỊ DI ĐỘNG
(Android App) NHẬN DẠNG CỔ VẬT THỜI GIAN THỰC
TẠI BẢO TÀNG LỰC LƯỢNG VŨ TRANG QUÂN KHU 9
VỚI XÁC THỰC BẢO MẬT ĐA NHÂN TỐ**

Sinh viên thực hiện:

Họ và tên: Huỳnh Thanh Phong

MSSV: B2207555

Mã lớp: DI22Z6A1

Giảng viên hướng dẫn:

GVC. Ths. Huỳnh Ngọc Thái Anh

Cần Thơ, ngày 15 tháng 08 năm 2025

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



BÁO CÁO
NIÊN LUẬN CƠ SỞ
NGÀNH KHOA HỌC MÁY TÍNH

ĐỀ TÀI:

**“*aiMuseum QK9*” - ỨNG DỤNG THIẾT BỊ DI ĐỘNG
(*Android App*) NHẬN DẠNG CỔ VẬT THỜI GIAN THỰC
TẠI BẢO TÀNG LỰC LƯỢNG VŨ TRANG QUÂN KHU 9
VỚI XÁC THỰC BẢO MẬT ĐA NHÂN TỐ**

Sinh viên thực hiện:

Họ và tên: Huỳnh Thanh Phong

MSSV: B2207555

Mã lớp: DI22Z6A1

Giảng viên hướng dẫn:

GVC. Ths. Huỳnh Ngọc Thái Anh

Cần Thơ, ngày 15 tháng 08 năm 2025

LỜI CẢM ƠN

Trước tiên, em xin gửi lời cảm ơn sâu sắc nhất đến thầy *Huỳnh Ngọc Thái Anh* – Giảng viên khoa Khoa học máy tính, thầy đã tận tình dạy bảo, hỗ trợ và giúp đỡ em trong suốt quá trình học tập và làm báo cáo này. Những góp ý quý báu và sự hướng dẫn tận tâm của thầy *Huỳnh Ngọc Thái Anh* đã giúp em rất nhiều trong việc củng cố kiến thức về môn học, nâng cao kiến thức chuyên môn cũng như hoàn thiện đề tài “ ***"aiMuseum QK9" – Ứng dụng thiết bị di động (Android App) nhận dạng cổ vật thời gian thực tại Bảo tàng Lực lượng vũ trang Quân khu 9 với xác thực bảo mật đa nhân tố***”. Em luôn trân trọng và biết ơn những lời khuyên, sự động viên mà thầy dành cho em.

Bên cạnh đó, em xin cảm ơn các anh/chị khóa trên trong quá trình thực hiện báo cáo, đã luôn sẵn sàng chia sẻ kinh nghiệm, trao đổi ý tưởng và hỗ trợ về mặt tinh thần. Những lời góp ý mang tính chuyên môn để xây dựng đề tài theo đúng định hướng, những lời động viên của các anh/chị là nguồn động lực lớn giúp em vượt qua những khó khăn trong suốt quá trình làm bài.

Cuối cùng, em xin chân thành gửi lời cảm ơn sâu sắc đến tất cả mọi người xung quanh trong suốt quá trình nghiên cứu trên. Những kiến thức và bài học kinh nghiệm đó sẽ là hành trang cho em sau này vững chắc trên con đường phát triển bản thân.

Em xin chân thành cảm ơn.

Cần Thơ ngày 15 tháng 08 năm 2025
Sinh viên thực hiện

Huỳnh Thanh Phong

TÓM TẮT

Đề tài nghiên cứu “**aiMuseum QK9**” tập trung phát triển một ứng dụng di động trên nền tảng Android nhằm hỗ trợ nhận dạng cổ vật tại Bảo tàng Lực lượng vũ trang Quân khu 9 theo thời gian thực, phục vụ cả khách tham quan và công tác quản lý bảo tàng. Hệ thống ứng dụng mô hình **YOLO (You Only Look Once)** – một thuật toán phát hiện đối tượng tiên tiến – để nhận dạng nhanh và chính xác các cổ vật từ hình ảnh camera, kết hợp cơ chế **Voting cho bài toán phân lớp** nhằm cải thiện độ tin cậy kết quả nhận dạng. Thông tin nhận dạng được đối chiếu và truy xuất từ **cơ sở dữ liệu SQL** chứa dữ liệu mô tả, hình ảnh, video và các tư liệu liên quan đến cổ vật. Bên cạnh chức năng nhận dạng, hệ thống được tích hợp **xác thực bảo mật đa nhân tố (Multi-Factor Authentication – MFA)** kết hợp mật khẩu, sinh trắc học (vân tay hoặc nhận diện khuôn mặt) và mã OTP, nhằm bảo đảm an toàn truy cập cho các tác vụ quản trị và bảo vệ dữ liệu nhạy cảm. Ứng dụng được thiết kế với giao diện thân thiện, hỗ trợ đa ngôn ngữ, tối ưu hóa hiệu suất để xử lý và hiển thị kết quả trong thời gian dưới 2 giây, đảm bảo tính mượt mà và trải nghiệm người dùng tốt ngay cả trên các thiết bị di động cấu hình trung bình. Với sự kết hợp giữa công nghệ thị giác máy tính hiện đại, cơ sở dữ liệu quản lý tập trung và cơ chế bảo mật nâng cao, đề tài “**aiMuseum QK9**” không chỉ đáp ứng nhu cầu số hóa và tự động hóa thông tin trưng bày tại bảo tàng, mà còn góp phần nâng cao trải nghiệm tham quan, hỗ trợ công tác bảo tồn, và quảng bá giá trị lịch sử – văn hóa của Bảo tàng Lực lượng vũ trang Quân khu 9 đến đông đảo công chúng.

ABSTRACT

*The research topic “aiMuseum QK9” focuses on developing a mobile application on the Android platform to support the identification of artifacts at the Military Region 9 Armed Forces Museum in real time, serving both visitors and museum management. The system applies the **YOLO (You Only Look Once)** model - an advanced object detection algorithm - to quickly and accurately identify artifacts from camera images, combined with the **Voting for classification problem** mechanism to improve the reliability of identification results. Identification information is compared and retrieved from a **SQL database** containing descriptive data, images, videos and documents related to artifacts. In addition to the identification function, the system is integrated with **multi-factor authentication (Multi-Factor Authentication - MFA)** combining passwords, biometrics (fingerprint or facial recognition) and OTP codes, to ensure secure access for administrative tasks and protect sensitive data. The application is designed with a friendly interface, multilingual support, optimized performance to process and display results in less than 2 seconds, ensuring smoothness and good user experience even on medium-configuration mobile devices. With the combination of modern computer vision technology, centralized management database and advanced security mechanism, the "aiMuseum QK9" project not only meets the needs of digitizing and automating information displayed at the museum, but also contributes to improving the visiting experience, supporting conservation work, and promoting the historical and cultural values of the Military Region 9 Armed Forces Museum to the public.*

MỤC LỤC

LỜI CẢM ƠN.....	i
TÓM TẮT	ii
ABSTRACT	iii
DANH MỤC HÌNH.....	vii
DANH MỤC BẢNG	viii
DANH MỤC VIẾT TẮT.....	ix
CHƯƠNG 1 GIỚI THIỆU THÔNG QUAN ĐỀ TÀI.....	1
I. LÝ DO CHỌN ĐỀ TÀI.....	1
II. MỤC TIÊU VÀ PHẠM VI NGHIÊN CỨU	1
1. Mục tiêu nghiên cứu	1
2. Phạm vi nghiên cứu	2
III. PHƯƠNG PHÁP TIẾP CẬN	2
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT	4
I. KHAI KHOÁNG DỮ LIỆU VÀ VAI TRÒ CỦA NHẬN DẠNG ẢNH	4
1. Khái niệm về khai phá dữ liệu	4
2. Nhận dạng ảnh trong khai phá dữ liệu	4
3. Vai trò của nhận dạng ảnh trong ứng dụng bảo tàng	5
II. CÁC GIẢI THUẬT MÁY HỌC	5
1. Giải thuật K-Nearest Neighbors (K – Láng giềng).....	5
2. Giải thuật Naive Bayes (Bayes thơ ngây).....	8
3. Giải thuật Support Vector Machine (Máy vector hỗ trợ)	10
4. Giải thuật Multilayer Perceptron (Mạng Perceptron nhiều lớp).....	12
5. Giải thuật Random Forest (Rừng ngẫu nhiên).....	21
6. Giải thuật Votting cho bài toán phân lớp.....	24
III. GIẢI THUẬT HỌC SÂU TRÊN YOLOV8n	25
1. Kiến trúc mô hình và cơ chế dự đoán	25
2. Hàm mất mát và cơ chế tối ưu	26
IV. CÁC TIÊU CHÍ ĐÁNH GIÁ MÔ HÌNH.....	27
1. Ma trận nhầm lẫn (Confusion Matrix).....	27

2. Độ chính xác (Accuracy)	27
3. Precision, Recall và F1-score	27
4. AUC-ROC: Đánh giá khả năng phân tách giữa hai lớp	28
CHƯƠNG 3 TIỀN XỬ LÝ DỮ LIỆU	31
II. THU THẬP DỮ LIỆU	31
1. Mục tiêu của việc thu thập dữ liệu.....	31
2. Nguồn dữ liệu	31
3. Phương pháp thu thập và xử lý ban đầu	32
4. Thách thức và giải pháp.....	32
III. GÁN NHÃN DỮ LIỆU.....	33
1. Mục tiêu gán nhãn.....	33
2. Quy trình gán nhãn	33
3. Lưu định dạng nhãn	34
4. Kiểm tra và hiệu chỉnh.....	34
IV. PHÂN TÍCH VÀ TĂNG CƯỜNG DỮ LIỆU	34
1. Phân tích dữ liệu ban đầu.....	35
2. Trích đặc trưng qua ResNet50	36
3. Phân bố dữ liệu sau giảm chiều	37
4. Mối quan hệ giữa các đặc trưng.....	38
CHƯƠNG 4: ĐÁNH GIÁ KẾT QUẢ CÁC MÔ HÌNH.....	40
I. KẾT QUẢ CÁC GIẢI THUẬT MÁY HỌC.....	40
II. KẾT QUẢ CỦA GIẢI THUẬT HỌC SÂU (YOLO).....	43
III. SO SÁNH CÁC GIẢI THUẬT	47
IV. TÌM NGƯỠNG TỐI ƯU XÁC XUẤT (<i>Confidence Thresholding</i>).....	49
1. Các bước tìm ngưỡng	49
2. Kết quả tìm ngưỡng cục bộ.....	50
CHƯƠNG 5: PHÂN TÍCH THIẾT KẾ HỆ THỐNG	51
I. PHÂN TÍCH YÊU CẦU HỆ THỐNG.....	51
1. Yêu cầu chức năng.....	51
2. Yêu cầu phi chức năng.....	51

3. Quy trình xử lý.....	52
II. XÁC THỰC ĐA NHÂN TỐ.....	52
III. THIẾT KẾ CHỨC NĂNG VÀ CƠ SỞ DỮ LIỆU.....	54
1. Thiết kế chức năng.....	54
2. Thiết kế cơ sở dữ liệu	54
3. Lưu đồ giải thuật.....	55
IV. XÂY DỰNG ỨNG DỤNG	56
CHƯƠNG 6 ĐÁNH GIÁ VÀ HƯỚNG PHÁT TRIỂN	60
I. KẾT QUẢ ĐẠT ĐƯỢC.....	60
1. Những thứ đạt được	60
2. Những hạn chế	60
II. HƯỚNG PHÁT TRIỂN	60
TÀI LIỆU THAM KHẢO	62

DANH MỤC HÌNH

Hình 1 Sơ đồ các bước tiếp cận phương pháp nghiên cứu của đề tài	3
Hình 2 Công thức Khoảng cách Euclidean (ℓ_1 -norm)	6
Hình 3 Công thức Khoảng cách Manhattan (ℓ_2 -norm)	6
Hình 4 Công thức Khoảng cách Minkowski	7
Hình 5 Công thức Khoảng cách Cosine	7
Hình 6 Hình mô tả nhân tử Lagrange	11
Hình 7 PLA biểu diễn các hàm logic đơn giản.	13
Hình 8 Multilayer Perceptron biểu diễn hàm XOR	14
Hình 9 MLP với hai hidden layers (các biases đã bị ẩn).	15
Hình 10 Các ký hiệu sử dụng trong MLP.	16
Hình 11 Hàm kích hoạt sigmoid (trái) và tanh (phải)	17
Hình 12 Hàm ReLU và tốc độ hội tụ khi so sánh với hàm tanh.	17
Hình 13 Mô phỏng cách tính backpropagation. Layer cuối có thể là output layer.	20
Hình 14 Mô hình Votting cho bài toán phân lớp	24
Hình 15 Hình ảnh nguồn dữ liệu thu thập	31
Hình 16 Hình ảnh phân tích dữ liệu ban đầu và sau khi tăng cường	35
Hình 17 Hình ảnh bảng đặc trưng sau khi trích xuất ảnh bằng RestNet50	36
Hình 18 Hình ảnh phân bố sau khi giảm chiều PCA	37
Hình 19 Hình ảnh mối quan hệ giữa các đặc trưng	38
Hình 20 Hình ảnh phân bố dữ liệu Boxplot giữa 2 chiều dữ liệu sau khi giảm chiều PCA	39
Hình 21 Hình ảnh kết quả Cross-validation trong quá trình học của các giải thuật	40
Hình 22 Hình ảnh ma trận nhầm lẫn giữa các giải thuật máy học	42
Hình 23 Hình ảnh kết quả của giải thuật học sâu trên YOLOv8n	43
Hình 24 Hình ảnh ma trận nhầm lẫn của giải thuật học sâu trong YOLOv8n	45
Hình 25 Hình ảnh kết quả phản ánh độ chính xác của giải thuật học sâu trên YOLOv8n	46
Hình 26 Biểu đồ thể hiện F1-score của các giải thuật	47
Hình 27 Kết quả nhận diện ảnh trên YOLOv8n	48
Hình 28 Hình quy trình xử lý của hệ thống	52
Hình 29 Hình ảnh minh họa dấu vân tay	52
Hình 30 Hình ảnh Lưu đồ giải thuật	55
Hình 31 Hình ảnh các công nghệ sử dụng	56
Hình 32 Hình ảnh các giao diện chính của ứng dụng	57
Hình 33 Trang thông tin bảo tàng với trợ lý AI	58
Hình 34 Trang kết quả truy vấn kết quả	58

DANH MỤC BẢNG

Bảng 1 Bảng mô tả chức năng của hệ thống	54
Bảng 2 Bảng mô tả cơ dữ liệu cho hệ thống	54

DANH MỤC VIẾT TẮT

STT	Từ viết tắt	Từ viết đầy đủ	Ý nghĩa
1	AI	Artificial Intelligence	Trí tuệ nhân tạo
2	ML	Machine Learning	Máy học
3	UI	User Interface	Giao diện người dùng
4	UX	User Experience	Trải nghiệm người dùng
5	Yolov8n	You Only Look Once version 8	Một mô hình học sâu trong xử lý ảnh
6	MySQL	My Structured Query Language	Hệ quản trị cơ sở dữ liệu có quan hệ

CHƯƠNG 1 GIỚI THIỆU THỐNG QUAN ĐỀ TÀI

I. LÝ DO CHỌN ĐỀ TÀI

Trong bối cảnh công nghệ ngày càng phát triển, việc ứng dụng trí tuệ nhân tạo (AI) và thị giác máy tính (Computer Vision) vào các lĩnh vực văn hóa, lịch sử đang trở thành xu hướng tất yếu nhằm nâng cao trải nghiệm người dùng và bảo tồn giá trị di sản. Bảo tàng Lực lượng Vũ trang Quân khu 9 (chi nhánh Cần Thơ) hiện là nơi lưu giữ nhiều cổ vật quý giá liên quan đến lịch sử chiến đấu và bảo vệ Tổ quốc của quân và dân khu vực Tây Nam Bộ. Tuy nhiên, cách tiếp cận và tra cứu thông tin hiện nay còn thủ công, hạn chế khả năng tương tác và thu hút giới trẻ.

Xuất phát từ nhu cầu thực tiễn đó, tôi lựa chọn nghiên cứu và phát triển ứng dụng **"aiMuseum QK9"** – một ứng dụng Android có khả năng **nhận dạng các cổ vật trong bảo tàng qua camera thời gian thực**. Ứng dụng sử dụng công nghệ AI để phân tích hình ảnh và cung cấp thông tin về cổ vật một cách nhanh chóng, chính xác và sinh động, từ đó hỗ trợ công tác giáo dục truyền thống, nâng cao trải nghiệm tham quan và góp phần số hóa bảo tàng theo hướng hiện đại, thông minh.

Bên cạnh đó, đề tài còn giúp sinh viên vận dụng kiến thức chuyên ngành về trí tuệ nhân tạo, xử lý ảnh, phát triển ứng dụng di động và tích hợp hệ thống vào một sản phẩm thực tiễn có ý nghĩa xã hội cao. Qua đó, tôi cũng mong muốn góp phần nhỏ vào công cuộc chuyển đổi số trong lĩnh vực bảo tồn và phát huy giá trị văn hóa – lịch sử dân tộc.

II. MỤC TIÊU VÀ PHẠM VI NGHIÊN CỨU

1. Mục tiêu nghiên cứu

1.1 Mục tiêu chính

Phát triển ứng dụng Android **aiMuseum QK9** có khả năng **nhận dạng cổ vật trong Bảo tàng Lực lượng Vũ trang Quân khu 9 (Chi nhánh Cần Thơ)** qua camera thời gian thực. Hiện thị thông tin chi tiết (tên cổ vật, niên đại, xuất xứ, ý nghĩa lịch sử) sau khi nhận dạng tự động.

1.2 Mục tiêu phụ

Xây dựng và huấn luyện mô hình **Computer Vision** (sử dụng máy học/deep learning) để nhận dạng chính xác $\geq 70\%$ các loại cổ vật phổ biến tại bảo tàng. Thiết kế giao diện người dùng thân thiện, vận hành mượt mà trên thiết bị Android phổ biến. Tích hợp mô hình nhận dạng vào ứng dụng Android hướng tới khả năng sử dụng **offline**, phù hợp với môi

trường có kết nối internet hạn chế. Khảo sát đánh giá mức độ hài lòng và hiệu quả trải nghiệm của người dùng khi tham quan bảo tàng với hỗ trợ của ứng dụng.

2. Phạm vi nghiên cứu

2.1 Địa điểm ứng dụng: Bảo tàng Lực lượng Vũ trang Quân khu 9 – Chi nhánh Cần Thơ.

Các loại cổ vật được tập trung nghiên cứu là những hiện vật có sẵn tại bảo tàng, có khả năng tiếp cận để thu thập dữ liệu hình ảnh.

2.2 Phạm vi kỹ thuật

- **Ngành kỹ thuật ứng dụng:** Xử lý ảnh – Nhận diện vật thể, máy học (ML), mô hình deep learning (yolo)
- **Phát triển phần mềm:** Android (Kotlin), tích hợp camera, UI/UX, local database (MySQL) để lưu trữ mô hình và dữ liệu cổ vật.

2.3 Giới hạn và giả thiết nghiên cứu

- Chỉ xử lý dữ liệu ảnh chụp trực tiếp từ camera (không sử dụng ảnh lịch sử, scan 3D).
- Mô hình được huấn luyện trên tập dữ liệu thu thập trực tiếp tại bảo tàng (bao gồm đa góc chụp, nhiều điều kiện ánh sáng).
- Ứng dụng chủ yếu hoạt động offline; chỉ kết nối internet khi cần cập nhật dữ liệu hoặc phản hồi khảo sát người dùng.
- Mức độ nhận dạng cổ vật xem là đạt yêu cầu khi độ chính xác (accuracy) $\geq 90\%$ trong điều kiện ánh sáng và khung nhìn tiêu chuẩn.

III. PHƯƠNG PHÁP TIẾP CẬN


Để hiện thực hóa mục tiêu của đề tài, nhóm nghiên cứu lựa chọn phương pháp tiếp cận dựa trên sự kết hợp giữa công nghệ học sâu (Deep Learning) và phát triển phần mềm di động trên nền tảng Android. Trước hết, nhóm tiến hành khảo sát thực tế tại Bảo tàng Lực lượng Vũ trang Quân khu 9 – Chi nhánh Cần Thơ để xác định danh sách các cổ vật tiêu biểu, có ý nghĩa lịch sử rõ ràng. Từ đó, nhóm xây dựng tập dữ liệu hình ảnh bằng cách chụp ảnh các cổ vật từ nhiều góc độ và điều kiện ánh sáng khác nhau. Dữ liệu thu thập được sẽ được xử lý và gắn nhãn thủ công để phục vụ cho quá trình huấn luyện mô hình.

Sau khi có dữ liệu, nhóm tiến hành huấn luyện mô hình nhận dạng cổ vật bằng các giải thuật máy học cơ bản hoặc mô hình học sâu YOLOv8. Quá trình huấn luyện bao gồm cả bước tiền xử lý và tăng cường dữ liệu để nâng cao khả năng khái quát. Mô hình sau khi huấn luyện sẽ được tối ưu hóa bằng kỹ thuật lượng hóa (quantization) và chuyển đổi sang định dạng hỗ trợ thiết bị di động như TensorFlow Lite để đảm bảo hoạt động ổn định trong môi trường Android.

Tiếp theo, nhóm phát triển ứng dụng Android với giao diện đơn giản, dễ sử dụng. Ứng dụng tích hợp mô hình nhận dạng cổ vật để xử lý ảnh trực tiếp từ camera, hoạt động theo thời gian thực và hiển thị kết quả nhận dạng kèm theo thông tin chi tiết về cổ vật ngay

sau khi phân tích. Ứng dụng cũng được thiết kế để có thể hoạt động offline nhằm đáp ứng điều kiện thực tế tại bảo tàng, nơi kết nối Internet có thể không ổn định.

Cuối cùng, nhóm tiến hành kiểm thử hệ thống bằng cách đánh giá độ chính xác của mô hình trên tập dữ liệu độc lập và đo lường hiệu suất vận hành như tốc độ phản hồi, mức tiêu thụ tài nguyên thiết bị. Đồng thời, nhóm cũng thu thập ý kiến phản hồi từ người dùng thử nghiệm để điều chỉnh giao diện và cải thiện trải nghiệm sử dụng. Phương pháp tiếp cận này không chỉ đảm bảo tính khả thi và hiệu quả thực tiễn mà còn giúp tận dụng tối đa sức mạnh của AI để hỗ trợ bảo tồn và truyền tải giá trị lịch sử – văn hóa một cách hiện đại và sinh động.



Hình 1 Sơ đồ các bước tiếp cận phương pháp nghiên cứu của đề tài

CHƯƠNG 2 CƠ SỞ LÝ THUYẾT

I. KHAI KHOÁNG DỮ LIỆU VÀ VAI TRÒ CỦA NHẬN DẠNG ẢNH

1. Khái niệm về khai phá dữ liệu

Khai phá dữ liệu (Data Mining) là quá trình phân tích dữ liệu từ các góc nhìn khác nhau để trích xuất ra các thông tin hữu ích, từ đó hỗ trợ ra quyết định, dự đoán xu hướng hoặc tìm ra các quy luật ẩn sâu trong dữ liệu. Đây là một nhánh quan trọng trong lĩnh vực trí tuệ nhân tạo (AI), có mối liên hệ chặt chẽ với các lĩnh vực như thống kê, học máy (machine learning), thị giác máy tính và xử lý dữ liệu lớn (big data).

Quy trình khai phá dữ liệu bao gồm các bước:

- **Thu thập dữ liệu:** Dữ liệu có thể ở nhiều dạng như văn bản, hình ảnh, video, âm thanh...
- **Tiền xử lý dữ liệu:** Làm sạch dữ liệu, chuẩn hóa định dạng, xử lý nhiễu, khuyết dữ liệu...
- **Chuyển đổi dữ liệu:** Trích chọn đặc trưng (feature extraction), giảm chiều dữ liệu...
- **Mô hình hóa:** Áp dụng các thuật toán học máy để phân loại, phân cụm, hồi quy, phát hiện bất thường...
- **Đánh giá và diễn giải kết quả:** Đánh giá độ chính xác, độ tin cậy và khả năng ứng dụng của mô hình vào thực tế.

Khai phá dữ liệu ngày càng được ứng dụng rộng rãi trong các lĩnh vực như thương mại điện tử, tài chính, y tế, giáo dục, an ninh quốc phòng, và cả trong lĩnh vực văn hóa – bảo tồn di sản.

2. Nhận dạng ảnh trong khai phá dữ liệu

Nhận dạng ảnh (Image Recognition) là một lĩnh vực ứng dụng đặc biệt của khai phá dữ liệu, trong đó đầu vào là các dữ liệu hình ảnh, và mục tiêu là tự động phân loại, gán nhãn hoặc hiểu nội dung của ảnh. Đây là một trong những thách thức lớn đối với máy tính, vì ảnh là dữ liệu phi cấu trúc, phức tạp và thường chứa nhiều biến thể như góc nhìn, ánh sáng, độ phân giải, nhiễu nền...

Nhờ vào sự phát triển của các mô hình học sâu (deep learning), đặc biệt là mạng nơ-ron tích chập (CNN – Convolutional Neural Network), khả năng nhận diện hình ảnh của hệ thống máy tính đã có những bước tiến vượt bậc, đạt độ chính xác gần bằng hoặc vượt qua con người trong một số tác vụ đặc thù.

Các bước cơ bản của một hệ thống nhận dạng ảnh bao gồm:

- **Tiền xử lý ảnh:** Cân bằng sáng, chuẩn hóa kích thước, loại bỏ nhiễu.

- **Trích xuất đặc trưng:** Sử dụng các lớp tích chập để học ra đặc trưng hình học, màu sắc, biên cạnh...
- **Phân loại ảnh:** Áp dụng các lớp fully-connected để gán nhãn ảnh (ví dụ: “súng AK47”, “bản đồ hành quân”, “đồng hồ quân sự”, “cờ giải phóng”...).
- **Hiện thị kết quả:** Hiện thị tên cổ vật, mô tả lịch sử, năm sử dụng, vai trò chiến đấu...


3. Vai trò của nhận dạng ảnh trong ứng dụng bảo tàng

Trong bối cảnh chuyển đổi số quốc gia, các bảo tàng truyền thống đang hướng tới việc tích hợp công nghệ hiện đại nhằm số hóa nội dung, tăng tính tương tác và thu hút người tham quan, đặc biệt là giới trẻ. Ứng dụng nhận dạng ảnh đóng vai trò then chốt trong việc:

- **Tự động hóa quá trình truy xuất thông tin:** Giúp người dùng dễ dàng tra cứu cổ vật chỉ bằng cách giơ điện thoại lên chụp ảnh hoặc quét camera.
- **Cá nhân hóa trải nghiệm người tham quan:** Mỗi người có thể nhận thông tin theo ngôn ngữ, độ tuổi, mức độ chi tiết khác nhau.
- **Tối ưu hóa công tác quản lý cổ vật:** Hệ thống có thể nhận diện, kiểm kê, và đối chiếu cổ vật thông qua hình ảnh nhanh chóng và chính xác.
- **Nâng cao tính giáo dục và truyền cảm hứng lịch sử:** Thông tin được cung cấp sinh động hơn, trực quan hơn so với biển chú thích truyền thống.
- **Lưu trữ và khai thác tri thức di sản:** Dữ liệu hình ảnh và thông tin nhận diện có thể được lưu trữ để phục vụ nghiên cứu, triển lãm số và học tập sau này.

II. CÁC GIẢI THUẬT MÁY HỌC

1. Giải thuật K-Nearest Neighbors (K – Láng giềng)



K-Nearest Neighbors (KNN) là một thuật toán học có giám sát được sử dụng cho cả phân loại (classification) và hồi quy (regression). KNN không có quá trình huấn luyện mà dựa trên tương đồng giữa dữ liệu mới và dữ liệu đã quan sát trước đó.

Nguồn: <https://towardsai.net/p/l/understanding-k-nearest-neighbors-a-simple-approach-to-classification-and-regression>

a. Nguyên lý hoạt động của KNN

Giả sử ta có một tập dữ liệu huấn luyện với NNN mẫu (x_i, y_i) , trong đó:

- (x_i) là vector đặc trưng.
- (y_i) là nhãn lớp (trong bài toán phân loại) hoặc giá trị thực (trong bài toán hồi quy).


Để dự đoán nhãn cho một điểm dữ liệu mới x :

1. Tính khoảng cách giữa x và tất cả các điểm trong tập huấn luyện.
2. Chọn K điểm gần nhất (hàng xóm gần nhất).
3. Dự đoán nhãn dựa trên các hàng xóm này:
 - + Phân loại: Lấy nhãn lớp phổ biến nhất trong K hàng xóm (bỏ phiếu đa số - majority voting).
 - + Hồi quy: Tính trung bình hoặc trung vị của giá trị trong K hàng xóm.

b. Các hàm khoảng cách trong KNN

Khoảng cách giữa hai điểm dữ liệu $x = (x_1, x_2, x_3, \dots, x_n)$ và $x' = (x'_1, x'_2, x'_3, \dots, x'_n)$ thường được tính bằng các công thức sau:

- Khoảng cách Euclidean (ℓ_1 -norm)




$$d(x, x') = \sqrt{\sum_{i=1}^n (x_i - x'_i)^2}$$

Hình 2 Công thức Khoảng cách Euclidean (ℓ_1 -norm)

Nguồn: https://vi.wikipedia.org/wiki/Kho%E1%BA%A3ng_c%C3%A1ch_Euclid

- Khoảng cách Manhattan (ℓ_2 -norm)




$$d(x, x') = \sum_{i=1}^n |x_i - x'_i|$$

Hình 3 Công thức Khoảng cách Manhattan (ℓ_2 -norm)

Nguồn: <https://www.kaggle.com/code/phamdinhhkhanh/machine-learning-appendix>

- Khoảng cách Minkowski (Tổng quát)




$$d(x, x') = \left(\sum_{i=1}^n |x_i - x'_i|^p \right)^{\frac{1}{p}}$$

Hình 4 Công thức Khoảng cách Minkowski

Nguồn: https://vi.wikipedia.org/wiki/Gi%E1%BA%A3n_%C4%91%E1%BB%93_Minkowski

- Khoảng cách Cosine (đối với dữ liệu văn bản)



$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

Hình 5 Công thức Khoảng cách Cosine

Nguồn: <https://medium.com/data-science/cosine-similarity-how-does-it-measure-the-similarity-maths-behind-and-usage-in-python-50ad30aad7db>

c. Phân loại trong KNN

- Trong bài toán phân loại, nhãn lớp y^* của điểm mới x được xác định bằng bỏ phiếu đa số:

$$y^* = \operatorname{argmax}_y \sum_{i \in N_K} 1.(y_i = y)$$

Trong đó:

N_K là tập hợp K điểm gần nhất của x

$1.(y_i = y)$ là hàm chỉ báo, bằng 1 nếu $y_i = y$. ngược lại bằng 0

- Nếu có trường hợp hòa, ta có thể:
 - + Chọn nhãn của hàng xóm gần nhất.
 - + Giảm giá trị K để tránh hòa.

d. Hồi quy trong KNN

Trong bài toán hồi quy, giá trị dự đoán y^* của x được tính bằng trung bình cộng hoặc trung vị của các nhãn trong K hàng xóm:


$$y^* = \frac{1}{K} \sum_{i \in N_K} y_i$$

Để tránh ảnh hưởng quá mức từ các điểm xa hơn, ta có thể sử dụng trọng số nghịch đảo với khoảng cách

$$y^* = \frac{\sum_{i \in N_K} w_i y_i}{\sum_{i \in N_K} w_i}, \quad w_i = \frac{1}{d(x, x_i) + \epsilon}$$

Với ϵ là một giá trị nhỏ để tránh chia cho 0

2. Giải thuật Naive Bayes (Bayes thơ ngây)



Naive Bayes là một thuật toán phân loại dựa trên xác suất, áp dụng định lý Bayes với giả định mạnh mẽ rằng các đặc trưng độc lập có điều kiện với nhau khi biết nhãn lớp. Thuật toán này thường được dùng trong phân loại văn bản, lọc thư rác, và nhận dạng giọng nói.

Nguồn: <https://interdata.vn/blog/naive-bayes-la-gi/>

a. Định lý Bayes

Cho một tập dữ liệu $x = (x_1, x_2, x_3, \dots, x_n)$ và một nhãn y , xác suất hậu nghiệm được tính bằng định lý Bayes:

$$P(y|x) = \frac{P(x|y) \cdot P(y)}{P(x)} = \frac{P(x_1, x_2, x_3, \dots, x_n|y) \cdot P(y)}{P(x)} = \frac{\prod_{i=1}^n P(x_i|y) P(y)}{P(x)}$$

Trong đó:

- + $P(y|x)$ là xác suất hậu nghiệm: xác suất để dữ liệu thuộc lớp y khi biết đặc trưng x .
- + $P(x|y)$ là xác suất có điều kiện: xác suất để đặc trưng x xuất hiện khi biết trước lớp y .
- + $P(y)$ là xác suất tiên nghiệm của lớp y (prior probability).
- + $P(x)$ là xác suất biên của dữ liệu (thường không cần tính trực tiếp vì nó giống nhau với mọi lớp).

Mục tiêu của Naïve Bayes là tìm nhãn lớp y có xác suất lớn nhất (MAP - Maximum A Posteriori):

$$y^* = \operatorname{argmax}_i P(y|x) = \operatorname{argmax}_i P(y) \prod_{i=1}^n P(x_i|y)$$

Bỏ qua $P(x)$ vì nó giống nhau qua mỗi lớp, ta chỉ cần cực đại hóa:

$$y^* = \operatorname{argmax}_i P(x|y)P(y)$$

b. Các biến thể của Naive Bayes

- Gaussian Naive Bayes (NB liên tục): Khi các đặc trưng x_i là số thực, ta giả định chúng tuân theo phân phối chuẩn (Gaussian):

$$P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} e^{-\frac{(x_i - \mu_y)^2}{2\sigma_y^2}} = \frac{1}{\sqrt{2\pi \frac{1}{N} \sum_{i=1}^N (x_i - \frac{1}{N} \sum_{i=1}^N x_i)^2}} e^{-\frac{(x_i - (\frac{1}{N} \sum_{i=1}^N x_i))^2}{2[\frac{1}{N} \sum_{i=1}^N (x_i - \frac{1}{N} \sum_{i=1}^N x_i)]^2}}$$

Với:

+ μ_y là giá trị trung bình của x_i khi lớp y , công thức:

$$\mu_y = \frac{1}{N} \sum_{i=1}^N x_i, N \text{ là tổng số phần tử thuộc lớp } y$$

+ σ_y^2 là phương sai của x_i khi lớp y , công thức:

$$\sigma_y^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu_y)^2, N \text{ là tổng số phần tử thuộc lớp } y$$

- Multinomial Naive Bayes (NB cho văn bản):

Khi dữ liệu là văn bản (mô hình túi từ - Bag of Words), xác suất $P(x_i|y)$ được tính bằng:

$$P(x_i|y) = \frac{C(x_i, y) + \sigma}{\sum_j C(x_j, y) + \sigma V}$$

Với:

- + $C(x_i, y)$ là số lần từ x_i xuất hiện trong các văn bản thuộc lớp y .
- + V là số lượng từ vựng duy nhất trong toàn bộ tập dữ liệu.
- + σ là tham số Laplace (thường $\sigma = 1$ để tránh xác suất bằng 0)


- Bernoulli Naive Bayes (NB nhị phân)

Khi dữ liệu là nhị phân (ví dụ: có từ đó trong văn bản hay không), ta dùng mô hình Bernoulli:

$$P(x_i|y) = P_y^{x_i} (1 - P_y)^{(1-x_i)}$$

Với P_y là xác suất xuất hiện của từ x_i trong lớp y

3. Giải thuật Support Vector Machine (Máy vector hỗ trợ)



Máy vector hỗ trợ (Support Vector Machine - SVM) là một thuật toán học có giám sát sử dụng để phân loại hoặc hồi quy dữ liệu. SVM hoạt động bằng cách tìm siêu phẳng (hyperplane) tối ưu để phân tách dữ liệu thành các lớp khác nhau.

Nguồn: <https://machinelearningcoban.com/2017/04/09/smv/>

a. Bài toán tìm siêu phẳng tối ưu

- **Siêu phẳng (Hyperplane)**
 - + Với một tập dữ liệu huấn luyện gồm N mẫu $\{(x_i, y_i)\}_{i=1}^N$ trong đó:
 - $x_i \in \mathbb{R}^d$ là điểm dữ liệu đầu vào có d chiều
 - $y_i \in \{-1, +1\}$ là nhãn của dữ liệu
 - + Một siêu phẳng trong không gian d – chiều có phương trình

$$W^T x + b = 0$$

Trong đó:

- W là véc-tơ trọng số (viector pháp tuyến của siêu phẳng)
- b là bias (độ dời của siêu phẳng)
- **Khoảng cách (Margin)**

b. Bài toán tối ưu hóa SVM

- Khoảng cách từ một điểm dữ liệu đến siêu phẳng là: $d_i = \frac{|w^T x + b|}{\|w\|}$
- Biên tối ưu được xác định bởi 2 siêu phẳng song song đi qua các điểm gần nhất thuộc hai lớp:

$$\delta = \begin{cases} w^T x + b = +1 \\ w^T x + b = -1 \end{cases}$$

- Khoảng cách giữa hai siêu phẳng này là: $\frac{2}{\|w\|}$
- Mục tiêu của SVM là cực đại hóa biên này để tăng độ phân biệt giữa 2 lớp, hay là SVM tìm w và b sao cho: $\max_{w,b} \frac{2}{\|w\|}$ thỏa mãn $y_i(w^T x + b) \geq 1, \forall i$

Bài toán này tương đương với bài toán tối ưu lồi $\rightarrow$ Đây là bài toán tối ưu hóa có ràng buộc, có thể giải bằng phương pháp nhân tử Lagrange.

c. Công thức nhân tử Lagrange

- Sử dụng nhân tử Lagrange α_i , ta xây dựng hàm Lagrange:


$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i [y_i(w^T x_i + b) - 1]$$

Ta có hệ phương trình đạo hàm riêng $\vartheta = \begin{cases} \frac{\partial L}{\partial w} = \frac{\partial [\frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i [y_i(w^T x_i + b) - 1]]}{\partial w} \\ \frac{\partial L}{\partial b} = \frac{\partial [\frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i [y_i(w^T x_i + b) - 1]]}{\partial b} \end{cases}$

$$\Leftrightarrow \begin{cases} \frac{\partial L}{\partial w} = \frac{\partial [\frac{1}{2} \|w\|^2]}{\partial w} - \frac{\partial [\sum_{i=1}^N \alpha_i [y_i(w^T x_i + b) - 1]]}{\partial w} \\ \frac{\partial L}{\partial b} = \frac{\partial [\frac{1}{2} \|w\|^2]}{\partial b} - \frac{\partial [\sum_{i=1}^N \alpha_i [y_i(w^T x_i + b) - 1]]}{\partial b} \end{cases}$$

$$\Leftrightarrow \begin{cases} \frac{\partial L}{\partial w} = \frac{\partial [\frac{1}{2} w^T w]}{\partial w} - \frac{\frac{1}{2} \partial [\sum_{i=1}^N \alpha_i y_i (w^T x_i) + \alpha_i y_i b - \alpha_i]}{\partial w} \\ \frac{\partial L}{\partial b} = \frac{\partial [\frac{1}{2} w^T w]}{\partial b} - \frac{\frac{1}{2} \partial [\sum_{i=1}^N \alpha_i y_i (w^T x_i) + \alpha_i y_i b - \alpha_i]}{\partial b} \end{cases}$$

$$\Leftrightarrow \begin{cases} \frac{\partial L}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i x_i \\ \frac{\partial L}{\partial b} = - \sum_{i=1}^N \alpha_i y_i \end{cases}$$



Hình 6 Hình mô tả nhân tử Lagrange

$\Rightarrow$ Giải hệ phương trình đạo hàm riêng để tìm nghiệm tối ưu:

$$\text{Ta có } \vartheta' = \begin{cases} \frac{\partial L}{\partial w} = 0 \\ \frac{\partial L}{\partial b} = 0 \end{cases} \Leftrightarrow \begin{cases} w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \\ - \sum_{i=1}^N \alpha_i y_i = 0 \end{cases} \Leftrightarrow \begin{cases} w = \sum_{i=1}^N \alpha_i y_i x_i \\ \sum_{i=1}^N \alpha_i y_i = 0 \end{cases}$$

- Dẫn đến bài toán đối ngẫu : $\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i x_j$

thỏa mãn $\sum_{i=1}^N \alpha_i y_i = 0$ với $0 \leq \alpha \leq C$

Trong đó C là hiệu số điều chỉnh trong trường hợp SVM mềm (cho phép sai số)

Nguồn: https://vi.wikipedia.org/wiki/Ph%C6%B0%C6%A1ng_ph%C3%A1p_nh%C3%A2n_t%E1%BB%AD_Lagrange

d. Hạt nhân (Kernel Trick)

Trong thực tế, dữ liệu không luôn phân tách tuyến tính được, nên ta sử dụng hàm hạt nhân (Kernel function) để ánh xạ dữ liệu lên không gian bậc cao hơn.

Hạt nhân biến tích vô hướng thành một phép toán phi tuyến:

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$$


Một số hàm hạt nhân phổ biến:

Sau khi sử dụng hạt nhân, bài toán tối ưu trở thành:

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

- + Hàm nhân tuyến tính: $K(x_i, x_j) = x_i^T x_j$
- + Hàm nhân bậc hai: $K(x_i, x_j) = (x_i^T x_j + c)^d$
- + Hàm nhân Gaussian (RBF) : $K(x_i, x_j) = e^{-\frac{\|x_i - x_j\|^2}{2\sigma^2}}$
- + Hàm nhân sigmoid: $K(x_i, x_j) = \tanh(\alpha x_i^T x_j + c)$

4. Giải thuật Multilayer Perceptron (Mạng Perceptron nhiều lớp)




Mạng nơ-ron nhiều lớp (Multilayer Perceptron - MLP) là một mô hình học sâu (Deep Learning) phổ biến, gồm nhiều tầng nơ-ron có thể học các đặc trưng phức tạp của dữ liệu. MLP là dạng mở rộng của Perceptron đơn lớp với ít nhất một tầng ẩn (hidden layer), sử dụng hàm kích hoạt phi tuyến giúp mô hình học được quan hệ phi tuyến.

Bài toán Supervised Learning, nói một cách ngắn gọn, là việc đi tìm một hàm số để với mỗi input, ta sử dụng hàm số đó để dự đoán output. Hàm số này được xây dựng dựa trên các cặp dữ liệu (x_i, y_i) trong training set. Nếu đầu ra dự đoán (predicted output) gần với đầu ra thực sự (ground truth) thì đó được gọi là một thuật toán tốt (nhưng khi đầu ra dự đoán quá giống với đầu ra thực sự thì không hẳn đã tốt, tôi sẽ đề cập kỹ về hiện tượng trong bài tiếp theo).

a. PLA cho các hàm logic cơ bản

Chúng ta cùng xét khả năng biểu diễn (representation) của Perceptron Learning Algorithm (PLA) cho các bài toán binary vô cùng đơn giản: biểu diễn các hàm số logic NOT, AND, OR, và XOR (output bằng 1 nếu và chỉ nếu hai input khác nhau). Để có thể sử dụng PLA (output là 1 hoặc -1), chúng ta sẽ thay các giá trị bằng 0 của output của các hàm này bởi -1. Trong hàng trên của Hình 1 dưới đây, các điểm hình vuông màu xanh là các điểm có label bằng 1, các điểm hình tròn màu đỏ là các điểm có label bằng -1. Hàng dưới của hình dưới là các mô hình perceptron với các hệ số tương ứng.



Hình 7 PLA biểu diễn các hàm logic đơn giản.


Nguồn: <https://machinelearningcoban.com/2017/02/24/mlp/>

Nhận thấy rằng với các bài toán OR, AND, và OR, dữ liệu là *linearly separable*, vì vậy ta có thể tìm được các hệ số cho perceptron giúp biểu diễn chính xác mỗi hàm số. Xem ví dụ với hàm NOT, khi x1=0, ta có a = sgn(-2×0+1) = 1. Khi x1 = 1, a = sgn(-2×1+1) = -1. Trong cả hai trường hợp, predicted output đều giống với ground truth. Bạn đọc có thể tự kiểm chứng các hệ số trong hình với hàm AND và OR.

b. Biểu diễn hàm XOR với Neural Network

Với hàm XOR, vì dữ liệu không *linearly separable*, tức không thể tìm được 1 đường thẳng giúp phân chia hai lớp xanh đỏ, nên bài toán vô nghiệm. Nếu thay PLA bằng Logistic Regression, tức thay hàm activation function từ *sgn* sang *sigmoid*, ta cũng không tìm được các hệ số thỏa mãn, vì về bản chất, Logistic Regression cũng chỉ tạo ra các đường biên có

dạng tuyến tính. Như vậy là các mô hình Neural Network chúng ta đã biết không thể biểu diễn được hàm số logic đơn giản này.



Hình 8 Multilayer Perceptron biểu diễn hàm XOR

Nguồn: <https://machinelearningcoban.com/2017/02/24/mlp/>


Nhận thấy rằng nếu cho phép sử dụng hai đường thẳng, bài toán biểu diễn hàm XOR sẽ được giải quyết như dưới đây:

Các hệ số tương ứng với hai đường thẳng trong hình (trái) được minh họa trên hình (phải) tại các node màu xanh (có hai loại màu xanh). Đầu ra $a_1^{(1)}$ bằng 1 với các điểm nằm về phía (+) của đường thẳng $-2x_1 - 2x_2 + 3 = 0$, bằng -1 với các điểm nằm về phía (-) của đường thẳng này. Tương tự, đầu ra $a_2^{(1)}$ bằng 1 với các điểm nằm về phía (+) của đường thẳng $2x_1 + 2x_2 - 1 = 0$. Như vậy, hai đường thẳng này tạo ra hai đầu ra tại các node $a_1^{(1)}$, $a_2^{(1)}$. Vì hàm XOR chỉ có một đầu ra nên ta cần làm thêm một bước nữa: coi a_1, a_2 như là input của một PLA khác. Trong PLA mới này, input là các node màu lam (đừng quên node bias có giá trị bằng 1), output là các node màu đỏ. Các hệ số được cho trên Hình (phải). Kiểm tra lại một chút, với các điểm hình vuông xanh (hình trái), $a_1^{(1)} = a_2^{(1)} = 1$ khi đó $a^{(2)} = \text{sgn}(1+1-1) = 1$. Với các điểm hình tròn đỏ, $a_1^{(1)} = -a_2^{(1)}$, vậy nên $a^{(2)} = \text{sgn}(a_1^{(1)} + a_2^{(1)} - 1) = \text{sgn}(-1) = -1$. Trong cả hai trường hợp, predicted output đều giống với ground truth. Vậy, nếu ta sử dụng 3 PLA tương ứng với các output $a_1^{(1)}, a_2^{(1)}, a^{(2)}$, ta sẽ biểu diễn được hàm XOR.

c. Các ký hiệu và khái niệm

- Layer

Ngoài *Input layers* và *Output layers*, một Multi-layer Perceptron (MLP) có thể có nhiều *Hidden layers* ở giữa. Các *Hidden layers* theo thứ tự từ input layer đến output layer được đánh số thứ tự là *Hidden layer 1*, *Hidden layer 2*, ... Hình 3 dưới đây là một ví dụ với 2 Hidden layers.



Hình 9 MLP với hai hidden layers (các biases đã bị ẩn).


Nguồn: <https://machinelearningcoban.com/2017/02/24/mlp/>

Số lượng layer trong một MLP được tính bằng số hidden layers cộng với 1. Tức là khi đếm số layers của một MLP, ta không tính input layers. Số lượng layer trong một MLP thường được ký hiệu là L .

- Units

Một *node* hình tròn trong một layer được gọi là một unit. Unit ở các input layer, hidden layers, và output layer được lần lượt gọi là input unit, hidden unit, và output unit. Đầu vào của các hidden layer được ký hiệu bởi z , đầu ra của mỗi unit thường được ký hiệu là a (thể hiện *activation*, tức giá trị của mỗi unit sau khi ta áp dụng activation function lên z). Đầu ra của unit thứ i trong layer thứ l được ký hiệu là $a_i^{(l)}$. Giả sử thêm rằng số unit trong layer thứ l (không tính bias) là $d^{(l)}$. Vector biểu diễn output của layer thứ l được ký hiệu là $a^{(l)} \in R^{d^{(l)}}$

Khi làm việc với những Neural Networks phức tạp, cách tốt nhất để hạn chế lỗi là viết cụ thể chiều của mỗi ma trận hay vector ra, bạn sẽ thấy rõ hơn trong phần sau.



Hình 10 Các ký hiệu sử dụng trong MLP.

Nguồn: <https://machinelearningcoban.com/2017/02/24/mlp/>

- Weights và Biases

Có L ma trận trọng số cho một MLP có L layers. Các ma trận này được ký hiệu là $W^{(l)} \in \mathbb{R}^{d^{(l-1)} \times d^{(l)}}$, $l = 1, 2, \dots, L$ trong đó $W^{(l)}$ thể hiện các kết nối từ layer thứ $l-1$ tới layer thứ l (nếu ta coi input layer là layer thứ 0). Cụ thể hơn, phần tử $w_{ij}^{(l)}$ thể hiện kết nối từ node thứ i của layer thứ $(l-1)$ tới node thứ j của layer thứ l . Các biases của layer thứ l được ký hiệu là $b^{(l)} \in \mathbb{R}^{d^{(l)} \times 1}$. Các trọng số này được ký hiệu như trên hình. Khi tối ưu một MLP cho một công việc nào đó, chúng ta cần đi tìm các weights và biases này.

Tập hợp các weights và biases lần lượt được ký hiệu là W và b .


- Hàm kích hoạt (Phần này chủ yếu được dịch lại từ: <http://cs231n.github.io/neural-networks-1/>)

Mỗi output của một unit (trừ các input units) được tính dựa vào công thức:

$$a_i^{(l)} = f(w_i^{(l)T} a^{(l-1)} + b_i^{(l)})$$

[Lưu ý] Hàm sgn (còn gọi là hard-threshold) chỉ được sử dụng trong PLA, mang mục đích giáo dục nhiều hơn. Trong thực tế, hàm sgn không được sử dụng vì hai lý do: đầu ra là discrete, và đạo hàm tại hầu hết các điểm bằng 0 (trừ điểm 0 không có đạo hàm). Việc đạo hàm bằng 0 này khiến cho các thuật toán gradient-based (ví dụ như Gradient Descent) không hoạt động!

+ Hàm sigmoid và tanh




Hình 11 Hàm kích hoạt sigmoid (trái) và tanh (phải)

Nguồn: <https://cs231n.github.io/neural-networks-1/>

Hàm sigmoid có dạng $f(s) = \frac{1}{1 + e^{-s}}$ với đồ thị như trong Hình (trái). Nếu đầu vào lớn, hàm số sẽ cho đầu ra gần với 1. Với đầu vào nhỏ (rất âm), hàm số sẽ cho đầu ra gần với 0. Hàm số này được sử dụng nhiều trong quá khứ vì có đạo hàm rất đẹp. Những năm gần đây, hàm số này ít khi được sử dụng. Nó có một nhược điểm cơ bản: Sigmoid saturate and kill gradients: Một nhược điểm dễ nhận thấy là khi đầu vào có trị tuyệt đối lớn (rất âm hoặc rất dương), gradient của hàm số này sẽ rất gần với 0. Điều này đồng nghĩa với việc các hệ số tương ứng với unit đang xét sẽ gần như không được cập nhật. Bạn đọc sẽ hiểu rõ hơn phần này trong phần Backpropagation. Hàm tanh cũng có nhược điểm tương tự về việc gradient rất nhỏ với các đầu vào có trị tuyệt đối lớn.

+ Hàm ReLU



Hình 12 Hàm ReLU và tốc độ hội tụ khi so sánh với hàm tanh.

Nguồn: <https://cs231n.github.io/neural-networks-1/>

ReLU (Rectified Linear Unit) được sử dụng rộng rãi gần đây vì tính đơn giản của nó. Đồ thị của hàm ReLU được minh họa trên Hình (trái)). Nó có công thức toán học $f(s) = \max(0, s)$.

Ưu điểm chính của nó là:

- ReLU được chứng minh giúp cho việc training các *Deep Networks* nhanh hơn rất nhiều. Hình (phải) so sánh sự hội tụ của SGD khi sử dụng hai activation function khác nhau: ReLU và tanh. Sự tăng tốc này được cho là vì ReLU được tính toán gần như tức thời và gradient của nó cũng được tính cực nhanh với gradient bằng 1 nếu đầu vào lớn hơn 0, bằng 0 nếu đầu vào nhỏ hơn 0.
- Mặc dù hàm ReLU không có đạo hàm tại $s=0$, trong thực nghiệm, người ta vẫn thường định nghĩa $\text{ReLU}'(0) = 0$ và khẳng định thêm rằng, xác suất để input của một unit bằng 0 là rất nhỏ.

Hàm ReLU có nhiều biến thể khác như Noisy ReLU, Leaky ReLU, ELUs. Tôi xin phép dừng phần này ở đây vì chưa có ý định đi sâu vào Deep Neural Networks.

d. Lan truyền tiến (Forward Propagation)

Ký hiệu và giả thuyết

- MLP có L tầng (không kể tầng vào 0); tầng l có n_l neuron.
 - Input: $x \in R^{n_0}$
 - Tham số tầng l : ma trận trọng số $W^{(l)} \in R^{n_l \times n_{l-1}}$ và vector bias $b^{(l)} \in R^{n_l}$
 - Hàm kích hoạt tại tầng l : $\phi^{(l)}: R^{n_l} \rightarrow R^{n_l}$ (áp dụng theo phần tử hoặc vector).
 - Ta định nghĩa:
 - $Z^{(l)}$ — input affine vào tầng l ,
 - $A^{(l)}$ — output (activation) của tầng l .
- Quy ước: $a^{(0)} = x$

Công thức forward propagation

- Với mỗi tầng $l=1,2,\dots,L$:

$$\gamma = \begin{cases} z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)} \\ a^{(l)} = \phi^{(l)}(z^{(l)}) \end{cases}$$
- Kết quả của mạng (output) là $a^{(L)}$:
- Tổng quát:

$$a^{(L)} = \phi^{(L)}(W^{(L)}\phi^{(L-1)}(\dots \phi^{(1)}(W^{(1)}x + b^{(1)}) \dots) + b^{(L)})$$

Với kích thước:

$$z^{(l)}, a^{(l)}, b^{(l)} \in R^{n_l}, W^{(l)} \in R^{n_l \times n_{l-1}}$$

Chứng minh bằng quy nạp

Mục tiêu: chứng minh rằng sau l bước, giá trị $a^{(l)}$ được tính đúng theo công thức trên.

- **Cơ sở:** $l = 1$

Theo định nghĩa của một neuron/một lớp affine + activation:

$$+ \text{ affine: } z^{(1)} = W^{(1)}a^{(0)} + b^{(1)} = W^{(1)}x + b^{(1)}$$

$$+ \text{ activation: } a^{(1)} = \phi^{(1)}(z^{(1)})$$

$\Rightarrow$ Công thức đúng với $l = 1$

- **Bước quy nạp:** Giả sử công thức đúng với $l = k$, tức đã tính được

$$a^{(k)} = \phi^{(k)}(W^{(k)}a^{(k-1)} + b^{(k)})$$

- **Xét $l = k + 1$:** Theo kiến trúc MLP, tầng $k+1$ lấy $a^{(k)}$ làm input, nên:

$$\gamma = \begin{cases} z^{(k+1)} = W^{(k+1)}a^{(k)} + b^{(k+1)} \\ a^{(k+1)} = \phi^{(k+1)}(z^{(k+1)}) \end{cases}$$

Thay $a^{(k)}$ theo giả thiết quy nạp, ta có biểu thức cho $a^{(k+1)}$ đúng theo công thức chung. Do đó nếu đúng với k thì đúng với $k+1$.

Vì đúng với $l = 1$ và giả thiết quy nạp dẫn tới $l = k+1$, suy ra công thức đúng với mọi $l = 1, 2, 3, \dots, L$

e. Lan truyền ngược (Backpropagation)

Phương pháp phổ biến nhất để tối ưu MLP vẫn là Gradient Descent (GD). Để áp dụng GD, chúng ta cần tính được gradient của hàm mất mát theo từng ma trận trọng số $W^{(l)}$ và vector bias $b^{(l)}$. Trước hết, chúng ta cần tính *predicted output* $\hat{y}$ với một input x :

$$\begin{aligned} a^{(0)} &= x \\ z_i^{(l)} &= W^{(l)}a^{(l-1)} + b^{(l)} \\ z^{(l)} &= W^{(l)T}a^{(l-1)} + b^{(l)}, l = 1, 2, 3, \dots, L \\ a^{(l)} &= f(z^{(l)}), l = 1, 2, 3, \dots, L \\ \hat{y} &= a^{(L)} \end{aligned}$$

Bước này được gọi là *feedforward* vì cách tính toán được thực hiện từ đầu đến cuối của network. MLP cũng được gọi

Giả sử $J(W, b, X, Y)$ là một hàm mất mát của bài toán, trong đó W, b là tập hợp tất cả các ma trận trọng số giữa các layers và biases của mỗi layer. X, Y là cặp dữ liệu huấn luyện với mỗi cột tương ứng với một điểm dữ liệu. Để có thể áp dụng các gradient-based methods (mà Gradient Descent là một ví dụ), chúng ta cần tính được:

$$\frac{\partial J}{\partial W^{(l)}}, \frac{\partial J}{\partial b^{(l)}}, l = 1, 2, 3, \dots, L$$

Sử dụng hàm mất mát là hàm Mean Square Error (MSE) tức *trung bình của bình phương lỗi*.

$$J(W, b, X, Y) = \frac{1}{N} \sum_{i=1}^N \|y_n - \hat{y}\|_2^2 = \frac{1}{N} \sum_{i=1}^N \|y_n - a_n^{(L)}\|_2^2$$

Với N là số cặp dữ liệu (x, y) trong tập training.

Theo những công thức ở trên, việc tính toán trực tiếp giá trị này là cực kỳ phức tạp vì hàm mất mát không phụ thuộc trực tiếp vào các hệ số. Phương pháp phổ biến nhất được


dùng có tên là Backpropagation giúp tính gradient ngược từ layer cuối cùng đến layer đầu tiên. Layer cuối cùng được tính toán trước vì nó gần gũi hơn với *predicted outputs* và hàm mất mát. Việc tính toán gradient của các layer trước được thực hiện dựa trên một quy tắc quen thuộc có tên là *chain rule*, tức *đạo hàm của hàm hợp*.

Stochastic Gradient Descent có thể được sử dụng để tính gradient cho các ma trận trọng số và biases dựa trên một cặp điểm training x, y . Để cho đơn giản, ta coi J là hàm mất mát nếu chỉ xét cặp điểm này, ở đây J là hàm mất mát bất kỳ, không chỉ hàm MSE như ở trên.

Đạo hàm của hàm mất mát theo *chỉ một thành phần* của ma trận trọng số của lớp cuối cùng:

$$\frac{\partial J}{\partial b_j^{(L)}} = \frac{\partial J}{\partial z_j^{(L)}} \cdot \frac{\partial z_j^{(L)}}{\partial b_j^{(L)}} = e_j^{(L)}$$

Với đạo hàm theo hệ số ở các lớp thấp hơn, chúng ta hãy xem hình dưới đây. Ở đây, tại mỗi unit, tôi đã viết riêng đầu vào z và đầu ra a để các bạn tiện theo dõi.



Hình 13 Mô phỏng cách tính backpropagation. Layer cuối có thể là output layer.

Nguồn: <https://cs231n.github.io/neural-networks-1/>

Dựa vào hình trên, ta có thể tính được:

$$\frac{\partial J}{\partial w_{ij}^{(l)}} = \frac{\partial J}{\partial z_j^{(l)}} \cdot \frac{\partial z_j^{(l)}}{\partial w_{ij}^{(l)}} = e_j^{(l)} a_i^{(l-1)}$$

Với:

$$e_j^{(l)} = \frac{\partial J}{\partial z_j^{(l)}} = \frac{\partial J}{\partial a_j^{(l)}} \cdot \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}}$$

$$\begin{aligned}
 &= \left(\sum_{k=1}^{d^{(l+1)}} \frac{\partial J}{\partial z_k^{(l+1)}} \cdot \frac{\partial z_k^{(l+1)}}{\partial z_j^{(l)}} \right) f'(z_j^{(l)}) \\
 &= \left(\sum_{k=1}^{d^{(l+1)}} e_k^{(l+1)} \cdot w_{jk}^{(l+1)} \right) f'(z_j^{(l)}) \\
 &= \left(w_{j:}^{(l+1)} \cdot e^{(l+1)} \right) f'(z_j^{(l)})
 \end{aligned}$$

trong đó $e^{(l+1)} = [e_1^{(l+1)}, e_2^{(l+1)}, e_3^{(l+1)}, \dots, e_{d^{(l+1)}}^{(l+1)}] \in R^{d^{(l+1)} \times 1}$ và $w_{j:}^{(l+1)}$ được hiểu là hàng thứ j của ma trận $w^{(l+1)}$


Dấu sigma tính tổng ở hàng thứ hai trong phép tính trên xuất hiện vì $a_j^{(l)}$ đóng góp vào việc tính tất cả các $z_k^{(l+1)}$, $k = 1, 2, 3, \dots, d^{(l+1)}$. Biểu thức đạo hàm ngoài dấu ngoặc lớn là vì $a_j^{(l)} = f(z_j^{(l)})$. Tới đây, ta có thể thấy rằng việc activation function có đạo hàm đơn giản sẽ có ích rất nhiều trong việc tính toán.

Với cách làm tương tự, bạn đọc có thể suy ra

$$\frac{\partial J}{\partial b_j^{(l)}} = e_j^{(l)}$$

Nhận thấy rằng trong các công thức trên đây, việc tính các $e_j^{(l)}$ đóng một vai trò quan trọng. Hơn nữa, để tính được giá trị này, ta cần tính được các $e_j^{(l+1)}$. Nói cách khác, ta cần tính ngược các giá trị này từ cuối. Cái tên *backpropagation* cũng xuất phát từ việc này.

5. Giải thuật Random Forest (Rừng ngẫu nhiên)



Random Forest là một thuật toán học máy kết hợp nhiều cây quyết định (decision trees) để tăng độ chính xác và giảm overfitting. Mỗi cây được huấn luyện trên tập dữ liệu và đặc trưng được chọn ngẫu nhiên. Khi dự đoán, các cây bỏ phiếu để đưa ra kết quả cuối cùng (đa số với phân loại, trung bình với hồi quy). Random Forest hoạt động hiệu quả, ổn định và dễ sử dụng trong nhiều bài toán thực tế.

Nguồn: <https://vap.ac.vn/Portals/0/TuyenTap/2020/4/27/e28bc8dd2a3f4e77967c747c7a3c4e18/81.pdf>

a. Tổng quan về Random Forest

Random Forest là một mô hình ensemble learning theo hướng Bagging (Bootstrap Aggregating), kết hợp nhiều cây quyết định để:

- Giảm **phương sai** (variance) của mô hình.
- Giữ **độ chệch** (bias) thấp.
- Tăng tính ổn định và khả năng tổng quát hóa (generalization).

b. Công thức tổ hợp mô hình

Giả sử có t cây quyết định $h_1, h_2, \dots, h_T$, mô hình Random Forest tổng quát như sau:

- Với phân loại:

$$\hat{y} = \underset{c}{\operatorname{argmax}} \sum_{t=1}^T 1. (h_t(x) = c)$$

Trong đó :

- + $1(.)$ là hàm chỉ thị (1 nếu đúng, 0 nếu sai)
- + C là các lớp
- Với hồi quy:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T h_t(x)$$

c. Bagging (Bootstrap Aggregating)


Cách làm: Từ tập dữ liệu gốc D kích thước N , tạo ra T tập con $D_1, D_2, \dots, D_T$ mỗi tập có kích thước N , **chọn ngẫu nhiên có hoàn lại** (bootstrap sampling)

→Huấn luyện mỗi cây h_t trên D_T .

d. Tính ngẫu nhiên và đánh giá hiệu quả trong Random Forest

Trong Random Forest, **mỗi cây được huấn luyện trên một tập dữ liệu bootstrap** (chọn ngẫu nhiên có hoàn lại), đồng thời tại **mỗi nút chia**, chỉ **chọn ngẫu nhiên mmm đặc trưng** trong tổng số ddd đặc trưng ban đầu. Thường:

- $m = \sqrt[2]{d}$ với bài toán phân loại



Mục tiêu: Giảm phương sai bằng cách kết hợp nhiều mô hình huấn luyện trên các mẫu khác nhau.

Kết quả: Mỗi cây là một **ước lượng độc lập** và có phân bố riêng, do đó tổ hợp nhiều cây sẽ giảm phương sai của mô hình tổng thể.

- $m = \frac{d}{3}$ với bài toán hồi quy

→ Việc này giúp **tăng tính đa dạng (decorrelation)** giữa các cây, khiến mô hình tổng thể giảm được **phương sai (variance)**.

- **Toán học về giảm phương sai:**

Gọi:

- + $f(x)$: mô hình thực tế
- + $\hat{f}(x)$: mô hình dự đoán
- + MSE tại một điểm x : $E[(\hat{f}(x) - f(x))^2] = Bias^2 + Variance + Noise$

Trong đó:

- + **Bias**: độ lệch trung bình của mô hình so với thực tế
- + **Variance**: độ dao động của mô hình giữa các tập huấn luyện
- + **Noise**: nhiễu vốn có trong dữ liệu

→ **Bagging + Chọn đặc trưng ngẫu nhiên** làm giảm **Variance** mà **không tăng Bias** nhiều, giúp mô hình tổng thể ổn định và chính xác hơn.

- **Tính tầm quan trọng của đặc trưng (Feature Importance):**

Random Forest còn cung cấp khả năng đánh giá ảnh hưởng của từng đặc trưng:

- + **Mean Decrease Impurity (MDI):**
Tổng độ giảm impurity (Gini/Entropy) mà đặc trưng gây ra trong tất cả cây
$$MDI(X_j) = \sum_{t=1}^T \sum_{n \in Nodes(t)} 1 \cdot (f_n = X_j) \cdot (i(n) - p_L \cdot i(n_L) - p_R \cdot i(n_R)) \cdot \frac{N_n}{N}$$
- + **Mean Decrease Accuracy (MDA):**
Đo độ giảm độ chính xác khi hoán đổi (shuffle) giá trị của một đặc trưng trên dữ liệu OOB

$$MDA(X_j) = \frac{1}{T} \sum_{t=1}^T (Acc_{OOB}^{(t)} - Acc_{OOB, shuffled X_j}^{(t)})$$


- **Out-of-Bag (OOB) Error:**

Do mỗi cây chỉ dùng ~63% mẫu để huấn luyện (vì lấy mẫu có lặp), phần còn lại (gọi là **Out-of-Bag**) có thể dùng để:

- + **Đánh giá hiệu quả mô hình**
- + **Không cần tạo thêm tập validation**

⇒ Giúp tiết kiệm dữ liệu và tăng tính khách quan khi kiểm thử.

6. Giải thuật Votting cho bài toán phân lớp



Hình 14 Mô hình Votting cho bài toán phân lớp

- Hệ thống được xây dựng dựa trên phương pháp **Voting Classifier**, là một kỹ thuật học máy tổ hợp, cho phép kết hợp nhiều mô hình phân loại khác nhau nhằm nâng cao độ chính xác dự đoán. Cụ thể, hệ thống sử dụng sáu mô hình thành phần phổ biến gồm: K-Nearest Neighbors (KNN), Naive Bayes, Random Forest, Support Vector Machine (SVM), Logistic Regression và Multilayer Perceptron (MLP). Mỗi mô hình được huấn luyện riêng biệt với các siêu tham số được tối ưu bằng phương pháp **tìm kiếm theo lưới (Grid Search)**.
- Sau khi huấn luyện, mỗi mô hình sẽ dự đoán nhãn riêng cho từng mẫu dữ liệu. Các dự đoán này sau đó được đưa vào cơ chế **bỏ phiếu đa số (majority voting)**. Theo đó, nhãn được chọn làm đầu ra cuối cùng là nhãn nhận được nhiều phiếu nhất từ các mô hình con. Cách tiếp cận này giúp tận dụng ưu điểm của từng thuật toán đơn lẻ, đồng thời làm giảm tác động tiêu cực của các mô hình hoạt động kém hiệu quả trong một số trường hợp nhất định.
- Việc kết hợp đa mô hình như trên đặc biệt hữu ích trong các bài toán phân loại phức tạp, đòi hỏi độ chính xác cao và khả năng tổng quát tốt trên các tập dữ liệu mới. Ngoài ra, việc sử dụng các mô hình có đặc điểm và cấu trúc khác nhau (mô hình tuyến tính, mô hình phi tuyến, mô hình cây, mạng nơ-ron, v.v.) cũng giúp hệ thống trở nên linh hoạt hơn trong việc xử lý đa dạng các dạng dữ liệu thực tế.

So sánh nhanh Votting - Bagging - Boosting

Tiêu chí	Votting	Bagging	Boosting
Loại mô hình	Kết hợp nhiều loại khác nhau (KNN, NB, SVM...) → Tận dụng điểm mạnh của từng loại	Chỉ dùng 1 loại mô hình để nhân bản nhiều bản sao và huấn luyện trên các bootstrap dataset khác nhau .	Chỉ dùng 1 loại, là mô hình sau sửa lỗi mô hình trước → phải có một cách thống nhất để đánh giá lỗi , điều chỉnh trọng số mẫu,...
Cách học	Độc lập hoàn toàn giữa các mô hình	Độc lập (trên mẫu khác nhau)	Phụ thuộc nối tiếp
Triển khai dễ dàng	Rất dễ dùng (VotingClassifier)	Tương đối dễ (BaggingClassifier)	Phức tạp hơn, nhạy với nhiễu
Ổn định kết quả	Trung bình (phụ thuộc mô hình con)	Rất ổn định (giảm phương sai)	Dễ overfit nếu quá mạnh
Độ chính xác	Phụ thuộc mô hình con	Thường rất tốt	Thường cao nhất (giảm bias)
Thường dùng với	Mô hình mạnh/đa dạng	Mô hình yếu như cây nhỏ	Mô hình yếu như cây nhỏ
Ứng dụng	Khi bạn có nhiều mô hình tốt sẵn	Khi mô hình dễ overfitting	Khi mô hình bị underfitting

Bảng 1 Bảng so sánh Bagging – Boosting - Votting

III. GIẢI THUẬT HỌC SÂU TRÊN YOLOV8n

1. Kiến trúc mô hình và cơ chế dự đoán

YOLOv8n là một biến thể nhẹ của mô hình YOLO, được thiết kế để thực hiện bài toán nhận diện đối tượng (object detection) theo cơ chế **anchor-free**.

Cho một ảnh đầu vào $I \in \mathbb{R}^{H \times W \times 3}$, mô hình sinh ra một tensor đầu ra có dạng:

$$T \in \mathbb{R}^{S \times S \times (5+C)}$$

Trong đó mỗi phần tử tương ứng với một điểm ảnh (cell) trên lưới, và chứa:

- (x,y) : tọa độ chuẩn hóa của tâm bounding box;
- (w,h) : chiều rộng và chiều cao (được tính bằng biến đổi log hoặc sigmoid);
- $\text{objectness} \in [0,1]$: xác suất có vật thể tại ô lưới đó;
- C : xác suất thuộc các lớp đối tượng.

Tọa độ bounding box thực được tính qua công thức:

$$\hat{x} = \sigma(t_x) + c_x, \hat{y} = \sigma(t_y) + c_y$$

$$\hat{w} = e^{t_w} \cdot p_w, \hat{h} = e^{t_h} \cdot p_h$$

trong đó:

- t_x, t_y, t_w, t_h là các giá trị đầu ra của mô hình;
- c_x, c_y là tọa độ ô lưới;
- p_w, p_h là các giá trị tham chiếu (anchor hoặc scale bước lưới).

Kiến trúc của YOLOv8n bao gồm:

- **Backbone:** Trích xuất đặc trưng, sử dụng các khối CSP (Cross Stage Partial);
- **Neck:** Sử dụng BiFPN hoặc PANet để kết hợp thông tin từ nhiều tầng;
- **Head:** Dự đoán trực tiếp bounding box theo cơ chế anchor-free.

2. Hàm mất mát và cơ chế tối ưu

YOLOv8n tối ưu một hàm mất mát tổng hợp bao gồm ba thành phần chính:

$$L_{total} = \tau_{box} \cdot L_{CIoU} + \tau_{obj} \cdot L_{obj} + \tau_{cls} \cdot L_{cls}$$

- **Hàm mất mát vị trí (CIoU Loss):**

$$L_{CIoU} = 1CIoU(\hat{b}, b)$$

Trong đó CIoU là độ đo Intersection-over-Union cải tiến, kết hợp khoảng cách tâm, diện tích và tỉ lệ khung hình giữa box dự đoán $\hat{b}$ và ground truth $\bar{b}$.

- **Hàm mất mát objectness (Binary Cross Entropy):**

$$L_{obj} = -[y \log(\hat{p}) + (1 - y) \log(1 - \hat{p})]$$

Hàm mất mát phân lớp (Multi-label BCE):

$$L_{cls} = \sum_{c=1}^C -[y_c \log(\hat{p}_c) + (1 - y_c) \log(1 - \hat{p}_c)]$$

$$IoU(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Sau khi dự đoán, YOLOv8n sử dụng **Non-Maximum Suppression (NMS)** để loại bỏ các bounding box chồng lặp có độ giao nhau (IoU) vượt quá ngưỡng:

→ Chỉ giữ lại các box có độ tin cậy cao nhất, loại bỏ các box trùng lặp.

IV. CÁC TIÊU CHÍ ĐÁNH GIÁ MÔ HÌNH

Để đánh giá hiệu quả của các mô hình phân loại, chúng ta sử dụng các tiêu chí phổ biến như **độ chính xác (Accuracy)**, **Precision**, **Recall**, **F1-score** và **AUC-ROC**. Dưới đây là cơ sở toán học chi tiết của từng tiêu chí.


1. Ma trận nhầm lẫn (Confusion Matrix)

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

Ma trận nhầm lẫn là cơ sở để tính toán các tiêu chí đánh giá mô hình phân loại nhị phân. Một mô hình phân loại dự đoán một mẫu thuộc vào **lớp dương (Positive - P)** hoặc **lớp âm (Negative - N)**, kết quả có thể rơi vào một trong bốn trường hợp

Nguồn: <https://glassboxmedicine.com/2019/02/17/measuring-performance-the-confusion-matrix/>

2. Độ chính xác (Accuracy)



Công thức:

$$Accuracy = \frac{TN+TP}{TP+TN+FB+FN}$$

- **Ý nghĩa:** Tỷ lệ mẫu được dự đoán đúng trên tổng số mẫu.
- **Nhược điểm:** Không phù hợp khi dữ liệu bị mất cân bằng (ví dụ: 90% dữ liệu thuộc một lớp).

Nguồn: https://www.researchgate.net/figure/A-plot-of-accuracy-on-the-training-train-and-validation-valid-datasets-over-training_fig2_332582518

3. Precision, Recall và F1-score

Precision và Recall là hai chỉ số quan trọng trong các bài toán mất cân bằng dữ liệu.

- Precision (Độ chính xác của lớp dương)


$$Precision = \frac{TP}{TP+FP}$$

- + **Ý nghĩa:** Trong số các mẫu được dự đoán là **dương**, bao nhiêu mẫu thực sự là **dương**.
- + **Ứng dụng:** Quan trọng trong bài toán mà **FP** gây **hậu quả nghiêm trọng** (ví dụ: chẩn đoán ung thư).
- **Recall (Độ phủ - Tỷ lệ tìm đúng lớp dương)**

$$\text{Recall} = \frac{TP}{TP + FN}$$
 - + **Ý nghĩa:** Trong số tất cả các mẫu thực sự **dương**, mô hình có thể phát hiện bao nhiêu mẫu.
 - + **Ứng dụng:** Quan trọng trong bài toán mà **FN** gây **hậu quả nghiêm trọng** (ví dụ: phát hiện gian lận).
- **F1-score (Trung bình điều hòa của Precision & Recall)**

$$F_1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$
 - + **Ý nghĩa:** Là sự cân bằng giữa Precision và Recall.
 - + **Ưu điểm:** Hữu ích khi cần đánh đổi giữa Precision và Recall.

4. AUC-ROC OC: Đánh giá khả năng phân tách giữa hai lớp



AUC-ROC (Area Under the Curve - Receiver Operating Characteristic) là một chỉ số đánh giá khả năng của mô hình phân loại trong việc phân biệt giữa hai lớp.

- + **ROC Curve** thể hiện mối quan hệ giữa **True Positive Rate (TPR)** và **False Positive Rate (FPR)** ở các ngưỡng phân loại khác nhau.
- + **AUC (Area Under the Curve)** là diện tích dưới đường cong ROC, phản ánh khả năng xếp hạng của mô hình

Nguồn: <https://blog.roboflow.com/what-is-auc-roc/>

a. Đường cong ROC

Đường cong Đặc tính hoạt động của máy thu (ROC). Trục X là tỷ lệ dương tính giả (FPR), trục Y là tỷ lệ dương tính thật (TPR). Đối với một bộ phân loại nhất định, chúng ta có thể nhận được cặp điểm (TPR, FPR) dựa trên hiệu suất trên các tập kiểm tra. Sau đó, bằng cách điều chỉnh ngưỡng, chúng ta có thể nhận được đường cong từ (0,0) đến (1,1),

đây là đường cong ROC của bộ phân loại này. Nói chung, đường cong này sẽ nằm dưới đường chéo (0,0) (1,1). Bởi vì đường chéo này biểu diễn một bộ phân loại ngẫu nhiên. Nếu đường cong của bạn nằm trên đường chéo này, chỉ cần trao đổi đầu ra của bộ phân loại. Mặc dù đường cong ROC rất đơn giản để biểu diễn hiệu suất của bộ phân loại, nhưng chúng ta muốn có một giá trị biểu diễn tốt hay xấu, đó là Diện tích dưới đường cong ROC (AUC). Nói chung, giá trị AUC nằm trong khoảng 0,5-1,0, AUC càng lớn biểu diễn hiệu suất phân loại càng tốt.

→ Đường ROC: Biểu diễn sự thay đổi giữa TPR và FPR khi thay đổi ngưỡng phân loại.

b. Diện tích dưới đường cong (AUC - Area Under Curve)

AUC là một chỉ số đánh giá hiệu suất của mô hình phân loại, đặc biệt khi sử dụng đường cong ROC. Giá trị AUC nằm trong khoảng từ 0 đến 1, trong đó 0.5 thể hiện mô hình dự đoán ngẫu nhiên và 1.0 là mô hình phân loại hoàn hảo. AUC càng cao cho thấy khả năng phân biệt giữa các lớp càng tốt. Chỉ số này có ưu điểm không phụ thuộc vào ngưỡng phân loại cụ thể và phản ánh hiệu quả mô hình trên toàn bộ các ngưỡng. Do đó, AUC thường được sử dụng để so sánh nhiều mô hình khác nhau.

Công thức xác định:

$$AUC = \int_0^1 TPRd(FBR)$$

Trong đó:

- + AUC = 1: Mô hình hoàn hảo
- + AUC = 0.5: Mô hình đoán ngẫu nhiên
- + AUC < 0,5: Mô hình kém hơn đoán ngẫu nhiên

Tổng kết

Chỉ số	Công thức	Ý nghĩa
Accuracy	$\frac{TP + TN}{TP + TN + FP + FN}$	Đánh giá tổng thể mô hình.
Precision	$\frac{TP}{TP + FP}$	Độ chính xác của lớp dương.
Recall	$\frac{TP}{TP + FN}$	Khả năng tìm đúng lớp dương.
F1-score	$2 \times \frac{Precision \times Recall}{Precision + Recall}$	Trung bình điều hòa giữa Precision & Recall.
AUC-ROC	$\int_0^1 TPRd(FBR)$	Đánh giá khả năng phân tách giữa hai lớp.

CHƯƠNG 3 TIỀN XỬ LÝ DỮ LIỆU

II. THU THẬP DỮ LIỆU

Trong đề tài “aiMuseum QK9” – Ứng dụng Android nhận dạng các cổ vật trong Bảo tàng Lực lượng Vũ trang Quân khu 9 (Chi nhánh Cần Thơ) qua camera thời gian thực”, việc thu thập dữ liệu hình ảnh là một bước quan trọng, đóng vai trò quyết định đến hiệu quả huấn luyện và khả năng hoạt động chính xác của mô hình nhận dạng cổ vật. Để mô hình học được đặc trưng tốt, dữ liệu cần đảm bảo cả về chất lượng, tính đa dạng, và đại diện cho các loại cổ vật thực tế đang trưng bày tại bảo tàng.

1. Mục tiêu của việc thu thập dữ liệu

Mục tiêu chính là xây dựng một tập dữ liệu gồm hình ảnh của các cổ vật đang được trưng bày tại Bảo tàng Lực lượng Vũ trang Quân khu 9, với yêu cầu:

- Đa dạng góc nhìn, điều kiện ánh sáng và bối cảnh.
- Số lượng đủ lớn cho mỗi loại cổ vật (tối thiểu 50 ảnh/loại).
- Đảm bảo có nhãn chính xác và dữ liệu có thể sử dụng để huấn luyện mô hình học máy.

2. Nguồn dữ liệu



Hình 15 Hình ảnh nguồn dữ liệu thu thập

Dữ liệu được thu thập từ nhiều nguồn kết hợp nhằm khắc phục hạn chế về thời gian và điều kiện thực tế:

- **Quay video tại bảo tàng và cắt ảnh từ video:** Nhóm thực hiện sử dụng thiết bị quay video (điện thoại Android hoặc camera cầm tay) để ghi hình toàn bộ không gian trưng bày và từng cổ vật cụ thể. Sau đó, các khung hình được cắt ra từ video ở những góc và thời điểm phù hợp để tạo thành ảnh tĩnh. Phương pháp này giúp thu được nhiều góc độ khác nhau một cách nhanh chóng và tăng số lượng ảnh hiệu quả.

- **Tải video từ YouTube:** Một số video giới thiệu về Bảo tàng Quân khu 9 được đăng tải trên kênh YouTube của quân đội, truyền hình địa phương hoặc các tổ chức văn hóa. Nhóm nghiên cứu sử dụng các công cụ hỗ trợ để tải video và cắt trích hình ảnh từ các phân cảnh có chứa cổ vật rõ nét, phục vụ cho việc gán nhãn và huấn luyện mô hình.
- **Hình ảnh từ website chính thức của bảo tàng hoặc các bài viết liên quan:** Website hoặc các trang truyền thông của Bảo tàng Lực lượng Vũ trang Quân khu 9 thường đăng tải các bài viết, ảnh sự kiện hoặc mô tả cổ vật. Những hình ảnh này được thu thập, xử lý và phân loại cẩn thận. Trong trường hợp cần sử dụng ảnh từ các nguồn thứ ba, nhóm đảm bảo dẫn nguồn rõ ràng và sử dụng hợp lý trong phạm vi nghiên cứu học thuật.

3. Phương pháp thu thập và xử lý ban đầu

- **Cắt khung hình (frame extraction):** Chỉ chọn các ảnh rõ nét, không mờ nhoè, đảm bảo cổ vật được hiển thị đầy đủ.
- **Phân loại dữ liệu:** Các ảnh sau khi cắt hoặc thu thập được phân loại thủ công theo từng nhóm cổ vật. Cấu trúc thư mục được tổ chức theo tên cổ vật để thuận tiện cho việc huấn luyện và đánh giá mô hình.
- **Tiền xử lý ảnh:** Các ảnh thu thập được xử lý sơ bộ như: điều chỉnh độ sáng/trương phản, resize về kích thước chuẩn, chuyển sang định dạng JPG/PNG, lọc bỏ ảnh nhiễu, bị rung hoặc không rõ chủ thể.
- **Gán nhãn:** Dựa vào tài liệu từ bảo tàng và nội dung video, hình ảnh được gán nhãn thủ công để đảm bảo độ chính xác cao. Việc gán nhãn được thực hiện cẩn thận nhằm phục vụ cho quá trình huấn luyện mô hình học máy giám sát (supervised learning).

4. Thách thức và giải pháp

- **Chất lượng ảnh từ video không đồng đều:** Một số video có độ phân giải thấp hoặc bị rung, dẫn đến ảnh cắt ra không rõ. Để khắc phục, nhóm chỉ chọn các video có chất lượng Full HD trở lên và chọn khung hình kỹ lưỡng.
- **Phản chiếu, ánh sáng yếu:** Nhiều cổ vật được trưng bày trong tủ kính, dễ bị lóa hoặc phản chiếu. Nhóm đã thực hiện các điều chỉnh về góc quay và dùng phần mềm chỉnh sửa ảnh để khử phản sáng.
- **Gian nan trong gán nhãn đúng:** Một số cổ vật không có tên rõ ràng trong video hoặc ảnh. Trong trường hợp này, nhóm tham khảo thêm tài liệu từ bảo tàng, hỏi ý kiến chuyên môn hoặc tra cứu trên các nguồn tin cậy để xác định chính xác tên cổ vật.

III. GÁN NHÃN DỮ LIỆU

Gán nhãn dữ liệu (data labeling) là bước quan trọng giúp mô hình học máy có thể phân biệt và nhận dạng chính xác các cổ vật trong quá trình huấn luyện và triển khai thực tế. Việc gán nhãn đúng và đồng nhất cho từng ảnh đầu vào ảnh hưởng trực tiếp đến độ chính xác của hệ thống nhận dạng cổ vật trong ứng dụng **aiMuseum QK9**.

1. Mục tiêu gán nhãn

Mỗi ảnh trong tập dữ liệu cần được gán một **nhãn định danh** tương ứng với **tên chính xác của cổ vật**, đảm bảo:

- Mô hình học được đặc trưng riêng của từng loại cổ vật.
- Tránh nhầm lẫn giữa các cổ vật có hình dạng hoặc màu sắc tương tự.
- Đảm bảo dữ liệu huấn luyện là dữ liệu “có giám sát” (supervised learning).

2. Quy trình gán nhãn

Quá trình gán nhãn được thực hiện theo các bước sau:

a. Tổ chức dữ liệu theo thư mục:

Tập ảnh được chia thành nhiều thư mục (folder), mỗi thư mục tương ứng với một loại cổ vật, ví dụ: bom, súng, đại bác, Tên thư mục chính là nhãn của cổ vật tương ứng.

b. Đối chiếu với tài liệu mô tả cổ vật:

Mỗi hình ảnh/video được gán nhãn dựa trên việc đối chiếu với:

- Bảng tên cổ vật được trưng bày tại bảo tàng (qua ảnh, video).
 - Danh mục cổ vật do bảo tàng cung cấp (nếu có).
 - Nội dung lời dẫn hoặc mô tả trong video YouTube.
 - Trang web chính thức của bảo tàng hoặc các nguồn học thuật.
- ##### c. Xử lý các trường hợp đặc biệt:
- Nếu cổ vật bị khuất, không rõ tên hoặc có nguy cơ nhầm lẫn, ảnh đó được **đưa vào nhóm kiểm tra thủ công sau** hoặc tạm loại bỏ khỏi tập huấn luyện.
 - Trường hợp một ảnh chứa **nhiều cổ vật**, nhóm sẽ **cắt ảnh** hoặc chỉ gán nhãn nếu cổ vật chính chiếm phần lớn và nổi bật.

d. Công cụ hỗ trợ gán nhãn (tùy chọn):

Để tăng hiệu quả, nhóm có thể sử dụng các công cụ hỗ trợ như:

- LabelImg: gán nhãn vùng chứa cổ vật.

- Label Studio: hỗ trợ nhiều định dạng ảnh và dữ liệu.
- Hoặc gán nhãn trực tiếp qua cấu trúc folder nếu huấn luyện theo dạng classification (phân loại toàn ảnh).

3. Lưu định dạng nhãn

Tùy vào loại mô hình sử dụng, nhãn dữ liệu được lưu dưới các định dạng phù hợp:

- **Dạng classification (phân loại ảnh):**
 - + Ảnh nằm trong thư mục tương ứng với tên cổ vật → mô hình học phân loại toàn ảnh.
 - + Ví dụ: dataset/mu_coi/img001.jpg, dataset/sung_ak/img042.jpg.
- **Dạng detection (nhận diện đối tượng trong ảnh):**
 - + Sử dụng file .xml, .txt (YOLO) chứa tọa độ bounding box + tên cổ vật.

4. Kiểm tra và hiệu chỉnh

Sau khi gán nhãn xong:


- Tiến hành **kiểm tra chéo nội bộ** để phát hiện các lỗi như:
 - + Nhãn sai tên cổ vật.
 - + Nhãn không khớp với nội dung ảnh.
 - + Ảnh bị nhảm lẫn giữa các lớp tương tự nhau.
- Sửa lỗi, chuẩn hóa tên nhãn đảm bảo đồng nhất giữa dữ liệu và code huấn luyện.

IV. PHÂN TÍCH VÀ TĂNG CƯỜNG DỮ LIỆU

Sau khi hoàn tất quá trình thu thập, gán nhãn và xử lý dữ liệu ảnh, nhóm tiến hành bước **phân tích dữ liệu** để đánh giá tổng quan chất lượng tập dữ liệu và thực hiện **tăng cường dữ liệu (data augmentation)** nhằm cải thiện tính đa dạng, nâng cao độ tổng quát (generalization) cho mô hình nhận dạng cổ vật.

1. Phân tích dữ liệu ban đầu

Sau khi thêm dữ liệu, sự thay đổi rõ rệt về số lượng instances ở nhiều lớp trong biểu đồ



Hình 16 Hình ảnh phân tích dữ liệu ban đầu và sau khi tăng cường

cho thấy sự cải thiện đáng kể về phân bố lớp trong tập huấn luyện YOLO. Trước đó, một số lớp như “Pháo” hay “Xe tăng” đã chiếm ưu thế vượt trội, trong khi nhiều lớp như “Máy cán tôn”, “Máy in pedal”, “Trục máy bay B52” hay “B52” có rất ít mẫu – dẫn đến hiện tượng **mất cân bằng lớp** (class imbalance). Điều này gây ra tình trạng **mô hình thiên lệch**: YOLO có xu hướng nhận dạng tốt các lớp phổ biến và bỏ sót hoặc nhận sai các lớp ít xuất hiện.

Việc bổ sung dữ liệu đã giúp tăng đáng kể số lượng ở các lớp yếu, làm cho dữ liệu huấn luyện trở nên **đồng đều và đa dạng hơn**. Nhờ đó, mô hình YOLO có thể:

- **Học đặc trưng tốt hơn** của các lớp hiếm nhờ có thêm ví dụ.
- **Giảm overfitting** vào các lớp phổ biến như “Pháo” hay “Xe tăng”.
- **Tăng độ chính xác phát hiện tổng thể** và **độ nhạy đối với lớp nhỏ** trong giai đoạn inference.
- Cải thiện **mAP (mean Average Precision)** do khả năng phát hiện được mở rộng đều hơn giữa các lớp.


2. Trích đặc trưng qua ResNet50

	A	B	C	D	E	F	G	H
1	Filename	Label	dim 1	dim 2	dim 3	dim 4	dim 5	dim 6
2	VD01_NgoaiTroj	Xe tăng	0	0.79703	1.85187	0.77333	0.80429	0.15553
3	VD01_NgoaiTroj	Xe tăng	0.36232	0.32308	0.88925	0.01383	0.21914	0.00272
4	VD01_NgoaiTroj	Xe tăng	0.14689	0.46297	0.79409	0.01147	0.52095	0.04439
5	VD01_NgoaiTroj	Xe tăng	0.17986	0.16594	0.67553	0.04147	0.21411	0.12085
6	VD01_NgoaiTroj	Xe tăng	0.43554	0.1886	0.80923	0.25838	0.19598	0.01688
7	VD01_NgoaiTroj	Xe tăng	0.61382	0.52457	0.6849	0.59952	0.21206	0.17787
8	VD01_NgoaiTroj	Xe tăng	0.58855	0.49307	0.93192	0.5103	0.0796	0.18351
9	VD01_NgoaiTroj	Xe tăng	0.24009	0.57143	0.62372	0.11268	0.08559	0.03495
10	VD01_NgoaiTroj	Xe tăng	0.22313	0.89683	0.7337	0.09862	0.00929	0.21869
11	VD01_NgoaiTroj	Xe tăng	0.17578	0.9026	1.08948	0.15659	0.16371	0.13291
12	VD01_NgoaiTroj	Xe tăng	0.4251	0.26487	1.95823	0.10058	0.09463	0

Hình 17 Hình ảnh bảng đặc trưng sau khi trích xuất ảnh bằng ResNet50

Trong bước trích xuất đặc trưng, mô hình ResNet50 được sử dụng như một backbone mạnh mẽ để rút trích đặc trưng hình ảnh. Cụ thể, ResNet50 được cấu hình với lớp pooling trung bình toàn cục (global average pooling) nhằm tổng hợp thông tin trên toàn bộ không gian ảnh và tạo ra một vector đặc trưng 1 chiều có độ dài 2048 chiều cho mỗi ảnh. Đây là một biểu diễn nén nhưng giàu thông tin, phản ánh các đặc trưng hình học, màu sắc và kết cấu của đối tượng trong ảnh. Tuy nhiên, thay vì trích xuất đặc trưng từ toàn bộ hình ảnh như cách truyền thống, hệ thống kết hợp thêm mô hình YOLO để thực hiện định vị và cắt ra đúng vùng chứa đối tượng (region of interest), sau đó mới trích đặc trưng trên các vùng này. Cách tiếp cận này giúp loại bỏ thông tin nền không liên quan và làm nổi bật đặc trưng của đối tượng, từ đó cải thiện hiệu quả nhận dạng trong các bước xử lý tiếp theo. Kết quả sau khi trích xuất là một bảng dữ liệu, trong đó mỗi hàng tương ứng với một ảnh (hoặc một đối tượng được phát hiện), gồm tên ảnh, nhãn lớp và 2048 giá trị đặc trưng.

3. Phân bố dữ liệu sau giảm chiều




Hình 18 Hình ảnh phân bố sau khi giảm chiều PCA

Biểu đồ PCA sau khi giảm chiều dữ liệu xuống còn 2 thành phần chính (PC1 và PC2) cho thấy sự phân bố rõ ràng và đồng đều hơn giữa các lớp đối tượng sau khi bổ sung dữ liệu huấn luyện cho mô hình YOLO. Trước đây, do mất cân bằng dữ liệu, nhiều lớp bị chồng lấn trong không gian đặc trưng hoặc không thể hiện được đặc trưng riêng biệt, khiến mô hình dễ nhầm lẫn khi phát hiện. Tuy nhiên, sau khi tăng cường dữ liệu, các điểm dữ liệu bắt đầu hình thành những cụm riêng biệt hơn, thể hiện rằng các lớp đã học được các đặc trưng phân biệt tốt hơn. Các lớp như “Súng thần công”, “Xe tăng”, “Pháo” hay “Trục thăng B52” giờ đây đã có vùng phân bố riêng, không còn lẫn lộn nhiều với các lớp khác.


Điều này chứng minh rằng việc bổ sung dữ liệu không chỉ giúp cân bằng số lượng giữa các lớp, mà còn nâng cao chất lượng biểu diễn đặc trưng của từng lớp trong không gian nhiều chiều mà mô hình học được. Nhờ đó, YOLO có thể huấn luyện hiệu quả hơn, cải thiện độ chính xác khi nhận dạng và giảm thiểu sai lệch do thiếu mẫu ở các lớp hiếm, từ đó tăng độ tin cậy khi triển khai trong thực tế.

4. Mối quan hệ giữa các đặc trưng



Hình 19 Hình ảnh mối quan hệ giữa các đặc trưng

- **Phân phối gần chuẩn:** Hầu hết các thành phần chính (đặc biệt từ PC4 đến PC10) có hình dạng phân phối gần giống với phân phối chuẩn (chuông đối xứng quanh giá trị trung bình), điều này là dấu hiệu tích cực cho PCA vì nó cho thấy dữ liệu sau khi giảm chiều vẫn giữ được tính chất thống kê ổn định.
- **PC1, PC2, PC3 có phân phối lệch:**
 - + PC1 có phân phối lệch trái, với phần lớn giá trị nằm bên trái trục hoành.
 - + PC2 và PC3 cũng có dạng lệch nhẹ, cho thấy dữ liệu ban đầu có thể có những đặc điểm phi tuyến hoặc phân bố không đối xứng.
- **Giá trị phân tán rộng:** Các thành phần chính như PC5 và PC6 có giá trị dao động trong khoảng lớn (từ -20 đến hơn 20), cho thấy chúng vẫn giữ được thông tin đáng kể từ dữ liệu ban đầu.
- **Tầm quan trọng giảm dần:** Mặc dù không có biểu đồ phương sai riêng lẻ (scree plot), nhưng việc xem histogram phân phối cho thấy các PC sau (PC7-PC10) có mật độ tập trung nhiều hơn quanh giá trị trung bình và ít phân tán hơn → hàm ý rằng chúng đóng góp ít hơn vào tổng phương sai của dữ liệu.



Hình 20 Hình ảnh phân bố dữ liệu Boxplot giữa 2 chiều dữ liệu sau khi giảm chiều PCA

Biểu đồ boxplot thể hiện sự phân bố của hai thành phần chính PC1 và PC2 theo từng nhãn cho thấy mức độ phân tách giữa các đối tượng quân sự sau khi giảm chiều dữ liệu bằng PCA. Ở biểu đồ PC1, nhiều lớp như "Xe tăng", "Súng thần công", "Máy bay trực thăng", "Máy in pedal" và "Xe peugeot" có vùng phân bố tương đối riêng biệt, cho thấy các đặc trưng của chúng được mô hình học tốt và dễ phân biệt trên trục PC1. Tuy nhiên, một số lớp như "Trục máy bay B52", "Pháo", "Mỏ neo tàu" có vùng phân bố chồng lấn nhau, điều này có thể dẫn đến sự nhầm lẫn trong quá trình phân loại nếu chỉ dựa vào PC1. Đối với biểu đồ PC2, các lớp như "Lu_Hầm bí mật", "Tàu tuần tiểu PCF" và "Xe tăng" lại có xu hướng phân bố tách biệt hơn, bổ sung khả năng nhận diện khi kết hợp với PC1. Sự hiện diện của các điểm ngoại lai (outliers) trong cả hai biểu đồ là không nhiều và phân bố đều, phản ánh độ ổn định tương đối trong dữ liệu. Nhìn chung, hai thành phần chính đầu tiên đã phân nào giữ lại cấu trúc đặc trưng của dữ liệu, hỗ trợ tốt cho việc phân loại và xác thực hiệu quả mô hình.

CHƯƠNG 4: ĐÁNH GIÁ KẾT QUẢ CÁC MÔ HÌNH


I. KẾT QUẢ CÁC GIẢI THUẬT MÁY HỌC



Hình 21 Hình ảnh kết quả Cross-validation trong quá trình học của các giải thuật

- Biểu đồ trên thể hiện mối quan hệ giữa kích thước tập huấn luyện và độ chính xác khi thực hiện cross-validation của sáu mô hình học máy phổ biến: **K-Nearest Neighbors (KNN)**, **Logistic Regression**, **Naive Bayes**, **Neural Network**, **Random Forest** và **Support Vector Machine (SVM)**. Có thể nhận thấy rằng, khi số lượng mẫu huấn luyện tăng dần từ 250 đến 2250, độ chính xác trung bình của tất cả các mô hình đều có xu hướng tăng lên rõ rệt. Điều này phản ánh đúng bản chất của các mô hình học máy – càng nhiều dữ liệu, khả năng học được đặc trưng phân biệt giữa các lớp càng tốt, từ đó cải thiện hiệu suất dự đoán trên tập kiểm tra.
- Trong số các mô hình được đánh giá, **Neural Network** và **Logistic Regression** là hai mô hình thể hiện hiệu suất cao và ổn định nhất. Logistic Regression mặc dù là một mô hình tuyến tính khá đơn giản, nhưng lại đạt độ chính xác cao và cải thiện đáng kể theo số lượng mẫu, từ khoảng 22% với 250 mẫu lên tới hơn 90% với 2250 mẫu. Ưu điểm của Logistic Regression nằm ở tính đơn giản, khả năng huấn luyện nhanh, dễ triển khai và đặc biệt là ít bị ảnh hưởng bởi overfitting khi dữ liệu tăng. Tuy nhiên, điểm hạn chế của mô hình này là nó giả định mối quan hệ tuyến tính giữa đầu vào và xác suất đầu ra, do đó hiệu suất có thể bị giới hạn nếu dữ liệu mang tính phi tuyến phức tạp.


- **Neural Network**, mặc dù khởi đầu với hiệu suất tương đương Logistic Regression, nhưng càng về sau, nó càng vượt trội nhờ khả năng mô hình hóa các quan hệ phi tuyến và tương tác giữa các đặc trưng. Với 2250 mẫu, độ chính xác cross-validation của mạng nơ-ron đạt tới khoảng 91%, cao nhất trong tất cả các mô hình. Đây là minh chứng rõ ràng cho khả năng mở rộng và học biểu diễn mạnh mẽ của các mạng học sâu. Tuy nhiên, Neural Network yêu cầu lượng dữ liệu tương đối lớn để hoạt động tốt, đồng thời rất dễ bị overfitting nếu không áp dụng các kỹ thuật như regularization, dropout hay early stopping. Ngoài ra, việc thiết lập mô hình và tinh chỉnh siêu tham số cũng phức tạp hơn nhiều so với Logistic Regression.
- **Support Vector Machine (SVM)** cũng là một mô hình rất đáng chú ý trong biểu đồ này. SVM khởi đầu chậm hơn một chút, nhưng hiệu suất tăng đều và đạt khoảng 90% ở mức dữ liệu lớn nhất, chỉ thua Neural Network một chút. SVM đặc biệt hiệu quả trong các bài toán phân lớp với biên rõ ràng giữa các lớp, nhờ khả năng tìm siêu phẳng tối ưu trong không gian đặc trưng cao. Tuy nhiên, mô hình này có thể nhạy cảm với lựa chọn kernel và tham số điều chỉnh như C và gamma. SVM cũng gặp khó khăn khi áp dụng trên tập dữ liệu rất lớn, do chi phí tính toán cao.
- Đối với **KNN**, mô hình này ban đầu có hiệu suất khá thấp (~21%) nhưng tăng khá ổn định lên gần 87% khi số lượng mẫu đạt 2250. Là một mô hình dựa trên khoảng cách, KNN dễ triển khai và diễn giải, tuy nhiên, nó rất nhạy cảm với dữ liệu nhiễu và yêu cầu chuẩn hóa dữ liệu đầu vào. Đồng thời, khi kích thước dữ liệu tăng lớn, chi phí tính toán trong quá trình dự đoán cũng tăng theo, do mô hình cần tính khoảng cách đến tất cả các điểm trong tập huấn luyện. Ngoài ra, KNN không thực sự học mô hình, mà chỉ đơn thuần lưu trữ dữ liệu và áp dụng nguyên lý “đa số thắng thế” trong hàng xóm gần nhất, vì thế hiệu suất có thể dao động mạnh nếu dữ liệu phân bố không đồng đều.
- **Naive Bayes** là mô hình có hiệu suất thấp nhất trong giai đoạn đầu (khoảng 18%) nhưng cũng có cải thiện rõ rệt, lên tới ~84% ở mức dữ liệu cao nhất. Mặc dù đơn giản và cực kỳ nhanh khi huấn luyện, mô hình Naive Bayes giả định rằng các đặc trưng là độc lập với nhau – một giả định thường không thực tế trong dữ liệu thực. Khi các đặc trưng có sự tương quan cao, hiệu suất của Naive Bayes sẽ bị giảm mạnh. Tuy nhiên, trong một số trường hợp dữ liệu nhiễu hoặc khi tốc độ huấn luyện là ưu tiên hàng đầu, Naive Bayes vẫn là một lựa chọn khả thi.
- Cuối cùng, **Random Forest** – mặc dù thường được coi là một trong những mô hình mạnh mẽ và đáng tin cậy trong nhiều bài toán học máy – lại thể hiện hiệu suất yếu nhất trong biểu đồ này. Bắt đầu từ ~20% và tăng dần lên ~83%, Random Forest vẫn nằm dưới các mô hình còn lại, đặc biệt khi so với Neural Network và Logistic Regression. Điều này có thể là do dữ liệu trong bài toán này không phù hợp với cách các cây quyết định hoạt động, hoặc có thể do các tham số như số lượng cây ($n_{\text{estimators}}$), độ sâu cây (max_depth), và cách chia nhánh chưa được tối ưu hóa. Ngoài ra, Random Forest có thể bị overfitting khi các cây con học quá kỹ vào các nhiễu nhỏ trong dữ liệu, đặc biệt nếu không áp dụng các biện pháp kiểm soát như pruning hay giới hạn độ sâu.



Hình 22 Hình ảnh ma trận nhầm lẫn giữa các giải thuật máy học

Dựa trên các ma trận nhầm lẫn, mô hình **Neural Network** và **SVM** cho kết quả phân loại tốt nhất với số lượng dự đoán đúng cao trên hầu hết các lớp, đặc biệt là các lớp phổ biến như "ô tô", "xe máy", "người đi bộ". **Logistic Regression** cũng đạt hiệu suất ổn định, nhưng kém hơn ở các lớp phức tạp hoặc ít dữ liệu. Trong khi đó, **Naive Bayes** và **Random Forest** cho thấy hiệu suất thấp hơn, với nhiều nhầm lẫn giữa các lớp có đặc trưng gần nhau như "trẻ em" và "người lớn". **KNN** dù đơn giản nhưng vẫn bị ảnh hưởng mạnh bởi nhiễu và sự phân bố dữ liệu. Tổng thể, các mô hình phi tuyến như Neural Network và SVM tỏ ra vượt trội hơn trong việc nhận diện chính xác nhiều lớp phức tạp.

II. KẾT QUẢ CỦA GIẢI THUẬT HỌC SÂU (YOLO)



Hình 23 Hình ảnh kết quả của giải thuật học sâu trên YOLOv8n

Biểu đồ trên mô tả toàn bộ quá trình huấn luyện và đánh giá mô hình phát hiện đối tượng (object detection) trong vòng 100 epoch, bao gồm cả các chỉ số tổn thất (losses) và hiệu suất (metrics) chính. Các đường cong thể hiện sự thay đổi của các giá trị trong quá trình học của mô hình, là một công cụ quan trọng để đánh giá khả năng học, tổng quát hóa, và hội tụ.

1. Loss trong quá trình huấn luyện và validation:

Các biểu đồ ở hàng đầu tiên là tổn thất trong quá trình huấn luyện, bao gồm box_loss (tổn thất định vị hộp), cls_loss (tổn thất phân loại), và df_l_loss (Distribution Focal Loss – dùng cho định vị chính xác). Tất cả đều có xu hướng giảm đều theo số epoch, điều này chứng tỏ mô hình học ổn định và không bị gián đoạn trong quá trình cập nhật trọng số. Đặc biệt, không có biểu hiện tăng đột ngột nào, điều đó cho thấy learning rate phù hợp và không xảy ra hiện tượng gradient exploding.

Tương tự, các biểu đồ ở hàng thứ hai là tổn thất trên tập validation, và cũng giảm đều như trên tập train. Đây là tín hiệu rất tốt vì nó chứng minh rằng mô hình không bị **overfitting** – tức là không chỉ học tốt trên dữ liệu huấn luyện mà còn hoạt động hiệu quả trên dữ liệu chưa từng thấy.

2. Precision và Recall:

Precision (độ chính xác) và Recall (tỷ lệ phát hiện đúng) đều tăng nhanh chóng và đạt mức rất cao sau khoảng 20 epoch đầu tiên, ổn định gần mức 0.98. Điều này cho thấy

mô hình có khả năng phát hiện chính xác các đối tượng và đồng thời không bỏ sót nhiều đối tượng trong ảnh. Sự ổn định của hai chỉ số này cũng nói lên rằng quá trình huấn luyện không gặp nhiều loạn, và dữ liệu huấn luyện có chất lượng tốt, cân bằng về phân bố lớp.

3. mAP – mean Average Precision:

Chỉ số $\text{mAP}@0.5$ đạt gần 0.97, cho thấy khả năng phát hiện và định vị đối tượng chính xác với độ chênh lệch nhỏ cho phép. Trong khi đó, $\text{mAP}@0.5:0.95$ – một chỉ số nghiêm ngặt hơn (vì tính trung bình qua nhiều ngưỡng IoU) – đạt khoảng 0.69. Mặc dù thấp hơn, đây vẫn là kết quả tốt đối với nhiều bài toán thực tế, đặc biệt là khi dữ liệu có đối tượng nhỏ hoặc phức tạp.


4. Ưu và nhược điểm:

a. Ưu điểm:

- Mô hình hội tụ tốt và nhanh (khoảng dưới 30 epoch đã có kết quả tốt).
- Không có dấu hiệu overfitting nhờ loss của tập validation cũng giảm đều.
- Precision và recall đều cao, cho thấy độ tin cậy trong dự đoán.
- mAP cao, đặc biệt là $@0.5$, đảm bảo độ chính xác trong định vị.


b. Nhược điểm:

- Chỉ số $\text{mAP}@0.5:0.95$ chưa đạt mức lý tưởng (>0.75), có thể do mô hình vẫn còn gặp khó khăn với các đối tượng nhỏ hoặc bị che khuất.
- Biểu đồ dfl_loss trên tập validation có phần dao động nhẹ ở giai đoạn sau, có thể xem xét kỹ thêm về khả năng mô hình chưa tối ưu hóa hoàn toàn phần định vị chính xác (fine localization).
- Có thể cần cải thiện thêm về augmentation dữ liệu hoặc tinh chỉnh cấu trúc backbone để cải thiện khả năng tổng quát hóa hơn nữa.



Hình 24 Hình ảnh ma trận nhầm lẫn của giải thuật học sâu trong YOLOv8n

- Biểu đồ trên là ma trận nhầm lẫn chuẩn hóa thể hiện hiệu suất của mô hình phân loại các đối tượng quân sự. Kết quả cho thấy mô hình hoạt động rất tốt ở nhiều lớp với độ chính xác gần như tuyệt đối như “Bom”, “Xe tăng”, “Bệ và đạn tên lửa Sam-2”, “Súng thần công” hay “Tàu tuần tiểu PCF”. Tuy nhiên, vẫn còn một số lớp bị nhầm lẫn, đặc biệt là với lớp "background" như “Máy bay trực thăng” (bị nhầm 29%), “Máy pedal” (11%) hay “Xe peugeot” (11%), cho thấy mô hình còn gặp khó khăn khi phân biệt đối tượng với nền ảnh phức tạp hoặc đối tượng nhỏ. Ưu điểm của mô hình là khả năng nhận diện tốt các lớp có đặc trưng rõ rệt, trong khi hạn chế chủ yếu nằm ở việc nhầm lẫn với background – điều này có thể cải thiện bằng cách bổ sung dữ liệu, tăng cường kỹ thuật làm nổi bật đối tượng, hoặc áp dụng các phương pháp huấn luyện tiên tiến hơn như Focal Loss hay backbone mạnh hơn. Nhìn chung, mô hình đạt hiệu quả cao nhưng vẫn cần cải thiện khả năng phân biệt trong các tình huống phức tạp.




Hình 25 Hình ảnh kết quả phản ánh độ chính xác của giải thuật sâu trên Yolov8n

Biểu đồ trên gồm 4 đường cong thể hiện các chỉ số đánh giá mô hình dựa trên mức độ tự tin (confidence) và khả năng phân loại từng lớp đối tượng:

- **F1-Confidence Curve** (trên trái): Đường cong này cho thấy F1-score đạt giá trị cao nhất trong khoảng confidence từ 0.4 đến 0.8. Giá trị trung bình của tất cả các lớp là **0.66**, cho thấy mô hình đạt hiệu quả khá tốt trong việc cân bằng giữa precision và recall. Tuy nhiên, một số lớp như “Máy cán tol” hoặc “Máy in pedal” có F1 thấp hơn, cho thấy mô hình vẫn gặp khó khăn khi phân biệt một số đối tượng có đặc trưng tương đồng hoặc nhiễu cao.
- **Precision-Confidence Curve** (trên phải): Precision nhìn chung rất cao (>0.9) trong khoảng confidence từ 0.3 đến 0.7, đặc biệt nhiều lớp như “Bom”, “Bệ tên lửa Sam-2”, “Trục thẳng”, “Tàu tuần tiểu” đều có đường cong tiến gần đến 1.0, cho thấy mô hình hiếm khi gán nhãn sai khi tự tin. Tuy nhiên, một số lớp như “Máy in pedal” hoặc “Ghe_Xuồng_Thuyền” có precision giảm mạnh ở mức confidence cao, cho thấy khả năng nhận diện sai vẫn còn.
- **Precision-Recall Curve** (dưới trái): Đa phần các lớp đều đạt precision và recall rất tốt, với diện tích dưới đường cong (mAP50) trung bình là **0.971**, cho thấy mô hình hoạt động hiệu quả trên toàn bộ tập lớp. Các lớp như “Xe peugeot” và “Máy in pedal” có performance thấp hơn đôi chút, nhưng nhìn chung vẫn ổn định.

- **Recall-Confidence Curve** (dưới phải): Cho thấy recall giảm mạnh ở mức confidence cao, đồng nghĩa với việc mô hình có xu hướng bỏ sót đối tượng nếu chỉ giữ lại các dự đoán có confidence cao. Điều này phản ánh sự đánh đổi giữa việc chính xác tuyệt đối và khả năng bao phủ đủ đối tượng – nên cân nhắc kỹ nếu áp ngưỡng confidence cao trong ứng dụng thực tế.

III. SO SÁNH CÁC GIẢI THUẬT



Hình 26 Biểu đồ thể hiện F1-score của các giải thuật

- Biểu đồ thể hiện F1-score của các mô hình máy học cho thấy hiệu quả tổng thể trong việc cân bằng giữa độ chính xác (precision) và khả năng bao phủ (recall) của từng mô hình khi áp dụng vào bài toán phân loại. Trong đó, mô hình **CNN (YOLO)** đạt F1-score cao nhất là **0.96**, ngang bằng với **SVM**, nhưng lại thể hiện ưu thế rõ rệt khi làm việc với dữ liệu hình ảnh và bài toán nhận diện đối tượng – vốn là mục tiêu chính trong các hệ thống thị giác máy tính.
- Các mô hình khác như **KNN**, **Logistic Regression** và **Neural Network** cũng cho kết quả cao (0.95), cho thấy độ tin cậy ở mức tương đối tốt. Tuy nhiên, KNN thường gặp vấn đề với dữ liệu lớn vì phải tính khoảng cách với toàn bộ tập dữ liệu huấn luyện, trong khi Logistic Regression có thể không nắm bắt được các mối quan hệ phi tuyến tính phức tạp. Neural Network mặc dù linh hoạt, nhưng lại yêu cầu nhiều tài nguyên và tinh chỉnh.

- Ngược lại, **Bayes (0.92)** và **Random Forest (0.91)** có F1-score thấp hơn, phản ánh khả năng phân loại chưa thực sự hiệu quả trong trường hợp này, có thể do giả định đơn giản hóa hoặc không thích ứng tốt với tính chất phức tạp của dữ liệu.
- Ưu điểm của **YOLO (You Only Look Once)** là khả năng phát hiện vật thể trong ảnh theo thời gian thực với tốc độ nhanh, độ chính xác cao và khả năng định vị đối tượng tốt. Ngoài ra, YOLO tích hợp giai đoạn nhận diện và phân loại vào một mạng duy nhất, giúp giảm thiểu độ trễ và tăng hiệu quả. Điểm yếu có thể nằm ở việc nhận diện vật thể nhỏ hoặc bị che khuất, tuy nhiên với các phiên bản cải tiến gần đây, nhược điểm này đã được khắc phục đáng kể.
- Tổng kết, dựa trên hiệu suất F1-score vượt trội, khả năng xử lý ảnh thời gian thực và tính ứng dụng thực tế cao, **CNN (YOLO) là lựa chọn ưu việt nhất** cho bài toán nhận dạng đối tượng trong tập hợp các mô hình được so sánh.



Hình 27 Kết quả nhận diện ảnh trên YOLOv8n

Hình ảnh trên cho thấy mô hình CNN (YOLO) hoạt động hiệu quả trong việc phát hiện và phân loại nhiều đối tượng quân sự khác nhau như máy bay trực thăng, xe bọc thép, tàu tuần tiểu PCF hay máy in pedal với độ chính xác cao, thể hiện qua các khung bao sát thực và độ tin cậy lớn (confidence ~0.9). Mô hình xử lý tốt các trường hợp góc chụp đa dạng và điều kiện ánh sáng phức tạp, đồng thời cho thấy khả năng tổng quát hóa mạnh mẽ. Tuy vẫn còn một số trường hợp khung bao chồng lấp nhẹ hoặc đối tượng nhỏ bị bỏ sót, kết quả trực quan này khẳng định tính thực tiễn và hiệu quả vượt trội của YOLO trong bài toán nhận diện đối tượng.

IV. TÌM NGUỖNG TỐI ƯU XÁC XUẤT (*Confidence Thresholding*)

Trong bài toán phân loại đa lớp sử dụng Voting Classifier, việc tìm ngưỡng xác suất tối ưu đóng vai trò quan trọng nhằm nâng cao độ tin cậy của hệ thống. Thay vì chấp nhận mọi dự đoán từ mô hình, ta chỉ giữ lại những dự đoán có xác suất cao hơn một ngưỡng nhất định, nhằm giảm thiểu sai số nhận diện sai. Bằng cách đánh giá độ chính xác và tỷ lệ loại bỏ qua từng giá trị ngưỡng từ 0.1 đến 0.99, hệ thống sẽ chọn ra ngưỡng tối ưu tại thời điểm đạt được độ chính xác cao nhất trên các mẫu được giữ lại. Việc này giúp cải thiện hiệu suất thực tế và đảm bảo rằng mô hình chỉ đưa ra quyết định khi đủ mức độ chắc chắn.

1. Các bước tìm ngưỡng

- Giả sử mô hình phân loại đầu ra là phân phối xác suất cho mỗi lớp:

$$\hat{y}_i = \operatorname{argmax}_j P(y=j|x_i)$$

- Nhưng chỉ **nhận diện** (giữ lại $\hat{y}_i$) nếu:

$$\max_j P(y=j|x_i) \geq \theta$$

Ngược lại, nếu $\max_j P(y=j|x_i) < \theta$ thì mô hình sẽ từ chối dự đoán mẫu đó (gán nhãn là -1 hoặc "không nhận diện").

- **Độ chính xác (Accuracy) trên các mẫu được giữ lại** được tính bằng:

$$\text{Accuracy} = \frac{\text{Số mẫu dự đoán đúng}}{\text{Tổng số mẫu được giữ lại}} = \frac{\sum_{i=1}^n 1.(\hat{y}_i = y_i \text{ and } \max_j P(y=j|x_i) \geq \theta)}{\sum_{i=1}^n 1.(\max_j P(y=j|x_i) \geq \theta)}$$


- **Tỷ lệ loại bỏ (Rejection rate)** Là phần trăm mẫu mà mô hình từ chối nhận diện do xác suất thấp hơn ngưỡng:
- **Tìm ngưỡng tối ưu:**

$$\theta^* = \operatorname{argmax}_{\theta} \text{Accuracy}_{\theta}$$

(hoặc có thể dùng *F1-score*, hoặc hàm lợi ích kết hợp *Accuracy* và *Rejection Rate* nếu có yêu cầu riêng).

$$\text{Rejection Rate} = \frac{\text{Số mẫu bị loại bỏ}}{\text{Tổng số mẫu}} = \frac{\sum_{i=1}^n 1.(\max_j P(y=j|x_i) < \theta)}{n}$$

2. Kết quả tìm ngưỡng cục bộ



Biểu đồ trên thể hiện mối quan hệ giữa **ngưỡng xác suất** và hai chỉ số quan trọng: **độ chính xác (Accuracy)** và **tỷ lệ loại bỏ (Rejection Rate)** trong bài toán phân loại đa lớp. Đường màu xanh biểu diễn độ chính xác trên các mẫu được giữ lại (tức là những mẫu có xác suất dự đoán lớn hơn hoặc bằng ngưỡng), trong khi đường màu cam biểu diễn tỷ lệ mẫu bị loại bỏ vì không đủ độ tin cậy.

Khi ngưỡng xác suất tăng từ 0.1 đến gần 1.0, có thể thấy độ chính xác có xu hướng tăng dần và đạt cực đại tại khoảng ngưỡng 0.69. Đây cũng là **ngưỡng tối ưu**, được đánh dấu bằng điểm tròn đỏ và đường kẻ dọc. Tại ngưỡng này, hệ thống đạt được độ chính xác cao nhất trong việc nhận diện, đồng thời kiểm soát tốt tỷ lệ loại bỏ ở mức chấp nhận được (khoảng 40%).

Nếu tiếp tục tăng ngưỡng sau mốc 0.69, độ chính xác gần như không cải thiện thêm mà còn giảm mạnh khi số lượng mẫu bị loại bỏ quá nhiều. Ngược lại, khi ngưỡng quá thấp (dưới 0.3), mô hình nhận diện gần như toàn bộ các mẫu, nhưng độ chính xác lại không đảm bảo, dẫn đến nhiều dự đoán sai.

Qua biểu đồ này, ta có thể rút ra kết luận rằng việc chọn **ngưỡng xác suất hợp lý** là một bước quan trọng nhằm cân bằng giữa độ chính xác và độ bao phủ trong nhận diện. Điều này đặc biệt hữu ích trong các ứng dụng yêu cầu **độ tin cậy cao**, như nhận diện khuôn mặt hoặc phân loại trong môi trường thực tế.

CHƯƠNG 5: PHÂN TÍCH THIẾT KẾ HỆ THỐNG

I. PHÂN TÍCH YÊU CẦU HỆ THỐNG


1. Yêu cầu chức năng

- Hệ thống cho phép người dùng khởi động camera trên thiết bị Android để quét hình ảnh cổ vật.
- Nhận diện cổ vật thông qua mô hình AI đã được huấn luyện trước.
- Hiển thị thông tin chi tiết về cổ vật sau khi nhận diện: tên, miêu tả, lịch sử, hình ảnh, video (nếu có).
- Cho phép truy cập offline, không phụ thuộc vào Internet.
- Hỗ trợ tìm kiếm thông tin của các cổ vật đã nhận dạng trước đây (lịch sử truy xuất).

2. Yêu cầu phi chức năng

- Tốc độ nhận dạng nhanh, độ trễ phụ thuộc vào tốc độ mạng.
- Dung lượng ứng dụng nhỏ, hoạt động ổn định trên thiết bị Android tầm trung.
- Giao diện thân thiện và dễ sử dụng.
- Độ chính xác nhận dạng đạt $\geq 69\%$.


3. Quy trình xử lý



Hình 28 Hình quy trình xử lý của hệ thống

II. XÁC THỰC ĐA NHÂN TỐ

Xác thực đa nhân tố (Multi-Factor Authentication – MFA) là một cơ chế bảo mật yêu cầu người dùng vượt qua từ hai phương thức xác thực độc lập trở lên trước khi được cấp quyền truy cập. Trong ứng dụng *aiMuseum QK9*, MFA được triển khai theo mô hình kết hợp giữa yếu tố tri thức (mật khẩu) và yếu tố sinh trắc học (vân tay), nhằm giảm thiểu rủi ro truy cập trái phép ngay cả khi một yếu tố bị xâm phạm



Hình 29 Hình ảnh minh họa dấu vân tay

Nguồn: <https://www.vinmec.com/vie/bai-viet/dau-van-tay-dna-la-gi-vi>

Về mặt xác suất, giả sử P_{pass} là xác suất đoán đúng mật khẩu và P_{bio} là xác suất giả mạo thành công dữ liệu sinh trắc học, thì xác suất vượt qua toàn bộ hệ thống được tính theo công thức: $P_{MFA} = P_{pass} \times P_{bio}$, $P_{MFA} \ll P_{pass}$

Điều này cho thấy việc bổ sung yếu tố sinh trắc học giúp giảm xác suất tấn công thành công xuống mức cực thấp. Cơ chế hoạt động của MFA trên nền tảng Android sử dụng thư viện **androidx.biometric:biometric:1.1.0**, trong đó API **BiometricPrompt** đóng vai trò trung gian giữa ứng dụng và phần cứng bảo mật. Khi người dùng nhập đúng mật khẩu, hệ thống kích hoạt BiometricPrompt để yêu cầu quét vân tay. Quá trình so khớp được thực hiện trong môi trường bảo mật phần cứng (**Trusted Execution Environment – TEE**), đảm bảo dữ liệu sinh trắc học không rời khỏi thiết bị và không thể bị truy cập bởi phần mềm bên ngoài. Nếu kết quả khớp, tín hiệu xác thực thành công được trả về và kết hợp với phiên đăng nhập bằng mật khẩu để hoàn tất MFA. Cơ chế này vừa đáp ứng yêu cầu bảo mật nghiêm ngặt, vừa duy trì trải nghiệm người dùng nhanh chóng và tiện lợi, với thời gian xác thực vân tay thường dưới một giây.

Cụ thể, quá trình kiểm tra diễn ra như sau:

1. Kiểm tra khả năng phần cứng

Thư viện gọi `BiometricManager.canAuthenticate()` để xem thiết bị có hỗ trợ phần cứng sinh trắc học không.

- + Nếu không có cảm biến → trả về `BIOMETRIC_ERROR_NO_HARDWARE`.
- + Nếu có nhưng bị hỏng → `BIOMETRIC_ERROR_HW_UNAVAILABLE`.

2. Kiểm tra dữ liệu sinh trắc học đã đăng ký

- + Nếu người dùng chưa đăng ký vân tay/khuôn mặt trong **cài đặt hệ thống** → `BIOMETRIC_ERROR_NONE_ENROLLED`.
- + Khi đó, ứng dụng có thể hiển thị thông báo yêu cầu người dùng vào Setting để đăng ký.

3. Kiểm tra trạng thái bảo mật

- + Android yêu cầu thiết bị phải bật khóa màn hình (PIN/PATTERN/PASSWORD) để lưu trữ dữ liệu sinh trắc học.
- + Nếu không bật, sinh trắc học sẽ bị vô hiệu hóa.

4. Xác thực điều kiện phần mềm

- + Kiểm tra API Level có hỗ trợ hay không (BiometricPrompt yêu cầu API 23+ cho vân tay, API 29+ cho khuôn mặt).
- + Kiểm tra các quyền cần truy cập.

III. THIẾT KẾ CHỨC NĂNG VÀ CƠ SỞ DỮ LIỆU

1. Thiết kế chức năng

STT	Tên chức năng	Mô tả
1	Mở camera	Khởi động camera thời gian thật để quét hình ảnh
2	Nhận dạng cổ vật	Mệnh AI nhận biết đối tượng trong khung hình
3	Truy xuất dữ liệu	Dò theo label đã nhận và trình bày thông tin
4	Hiển thị giao diện	Hiển thị đặt trong giao diện thẻ thông tin (card)
5	Mở camera	Khởi động camera thời gian thật để quét hình ảnh


Bảng 2 Bảng mô tả chức năng của hệ thống

2. Thiết kế cơ sở dữ liệu

STT	Trường	Kiểu	Mô tả
1	ten	TEXT	Tên cổ vật – khóa chính
2	mo_ta	TEXT	Thuyết minh
3	hinh_anh	TEXT	Đường dẫn ảnh


Bảng 3 Bảng mô tả cơ sở dữ liệu cho hệ thống

3. Lưu đồ giải thuật



Hình 30 Hình ảnh Lưu đồ giải thuật

IV. XÂY DỰNG ỨNG DỤNG




Hình 31 Hình ảnh các công nghệ sử dụng

Ứng dụng “**aiMuseum QK9**” phiên bản online được xây dựng nhằm hỗ trợ người dùng nhận dạng cổ vật mọi lúc, mọi nơi thông qua kết nối internet. Bên cạnh phiên bản offline hoạt động trực tiếp trên thiết bị, phiên bản online cho phép tải hình ảnh lên và gửi đến máy chủ xử lý để trả về kết quả chính xác hơn, đồng thời cập nhật dữ liệu cổ vật nhanh chóng từ hệ thống trung tâm. Việc xây dựng hệ thống online giúp tăng tính mở rộng, tính cập nhật và tiết kiệm tài nguyên thiết bị người dùng, đặc biệt phù hợp với các thiết bị cấu hình thấp.

Ứng dụng được phát triển bằng **Android Studio (Kotlin)**, kết nối với hệ thống máy chủ thông qua giao thức HTTP hoặc API RESTful. Hình ảnh cổ vật chụp từ camera hoặc chọn từ thư viện sẽ được gửi đến máy chủ qua API. Tại đây, hình ảnh được xử lý bởi mô hình AI YOLOv5 cài đặt trên server (sử dụng Python, Flask, hoặc FastAPI). Sau khi nhận dạng, server sẽ truy xuất cơ sở dữ liệu (MySQL) để lấy thông tin cổ vật tương ứng, và phản hồi lại kết quả qua JSON cho ứng dụng hiển thị.


Về kiến trúc tổng thể, hệ thống gồm ba lớp chính: lớp giao diện người dùng (Android app), lớp API trung gian (RESTful API), và lớp xử lý AI phía server. API sẽ đóng vai trò trung gian nhận hình ảnh, gọi mô hình nhận dạng, lấy thông tin từ cơ sở dữ liệu và trả kết quả về cho client. Dữ liệu cổ vật trên server có thể cập nhật, bổ sung thường xuyên bởi quản trị viên, giúp hệ thống luôn mới, chính xác và đầy đủ. Giao diện người dùng vẫn giữ thiết kế đơn giản, dễ sử dụng, chỉ khác ở chỗ cần có kết nối mạng để thực hiện các tác vụ chính.

Ứng dụng online còn có thể tích hợp thêm nhiều tính năng mở rộng như thống kê số lượt truy cập, thu thập phản hồi từ người dùng, quản lý nội dung (CMS) cho cổ vật, phân quyền truy cập,... Ngoài ra, với khả năng xử lý mạnh từ phía server, mô hình có thể sử dụng phiên bản YOLOv5 lớn hơn (YOLOv5m hoặc YOLOv5x) để tăng độ chính xác mà không làm ảnh hưởng đến hiệu năng ứng dụng phía client.




Hình 32 Hình ảnh các giao diện chính của ứng dụng

- **Trợ lý AI:** Trang thông tin Bảo tàng Quân khu 9 được xây dựng nhằm cung cấp cho người dùng một kênh tiếp cận hiện đại, thuận tiện trong việc tìm hiểu về lịch sử và các hiện vật trưng bày. Hệ thống không chỉ số hóa dữ liệu cổ vật, hình ảnh và video tư liệu mà còn tích hợp trợ lý AI Gemini để hỗ trợ tra cứu thông tin một cách nhanh chóng và chính xác. Người dùng có thể tương tác trực tiếp với AI để đặt câu hỏi, khai thác kiến thức về các chiến dịch, sự kiện, cũng như những nhân vật lịch sử quan trọng. Đồng thời, AI Gemini có khả năng gợi ý lộ trình tham quan, cung cấp các phân tích và liên kết đến nguồn dữ liệu liên quan, giúp nâng cao trải nghiệm học tập và nghiên cứu. Việc ứng dụng trí tuệ nhân tạo vào trang thông tin bảo tàng góp phần tạo nên sự đổi mới trong công tác tuyên truyền, giáo dục truyền thống và bảo tồn giá trị văn hóa – lịch sử, đồng thời mở rộng khả năng tiếp cận của công chúng đối với kho tàng tư liệu quý giá của dân tộc.



Hình 33 Trang thông tin bảo tàng với trợ lý AI

- **Trang kết quả:** hiển thị thông tin đối tượng sau khi hệ thống xử lý hình ảnh. Kết quả bao gồm tên hiện vật, độ chính xác của mô hình (theo tỉ lệ phần trăm), cùng giao diện trực quan giúp người dùng dễ dàng theo dõi. Ngoài ra, trang kết quả còn cung cấp các tùy chọn điều hướng, chẳng hạn nút Quay lại để tiếp tục thực hiện nhận diện đối tượng khác. Việc thiết kế trang kết quả theo hướng đơn giản, trực quan góp phần nâng cao trải nghiệm người dùng, đồng thời minh chứng hiệu quả của mô hình nhận diện hình ảnh được tích hợp trong ứng dụng.



Hình 34 Trang kết quả truy vấn kết quả

Tóm lại, phiên bản trực tuyến (online) của hệ thống “aiMuseum QK9” đã chứng minh được nhiều ưu điểm vượt trội so với bản ngoại tuyến (offline). Trước hết, hệ thống

online tận dụng khả năng kết nối với cơ sở dữ liệu tập trung, nhờ đó mang lại **độ chính xác cao hơn** trong quá trình nhận diện cổ vật. Các mô hình học máy có thể được huấn luyện và tối ưu thường xuyên, đồng thời cập nhật liên tục để bắt kịp sự phát triển của công nghệ và dữ liệu mới.

Một lợi ích khác là **dữ liệu linh hoạt và cập nhật nhanh**, giúp bổ sung, chỉnh sửa hoặc mở rộng thông tin hiện vật một cách kịp thời. Điều này đặc biệt quan trọng trong bối cảnh bảo tàng liên tục bổ sung hiện vật mới hoặc cập nhật các ghi chú lịch sử chi tiết. Hệ thống online cũng dễ dàng **tích hợp các nguồn dữ liệu mở** hoặc kết nối với các thư viện, kho lưu trữ học thuật để nâng cao giá trị tham khảo.

Bên cạnh đó, phiên bản online còn cho phép **mở rộng quy mô** phục vụ cho nhiều đối tượng người dùng khác nhau, từ khách tham quan bảo tàng đến các nhà nghiên cứu, sinh viên và giáo viên. Hệ thống có thể tích hợp thêm các chức năng như chatbot AI, tìm kiếm nâng cao hoặc gợi ý tham quan, mang lại trải nghiệm phong phú hơn. Ngoài ra, việc triển khai online cũng giúp thu thập **dữ liệu sử dụng thực tế**, từ đó cải thiện mô hình nhận diện và giao diện người dùng theo thời gian.

Tuy nhiên, phiên bản online vẫn có một **hạn chế đáng kể**, đó là yêu cầu người dùng phải có **kết nối internet ổn định**. Trong trường hợp môi trường sử dụng có mạng yếu hoặc gián đoạn, việc tra cứu thông tin sẽ gặp khó khăn. Đây là lý do tại sao phiên bản offline vẫn cần thiết, bởi nó đảm bảo khả năng hoạt động độc lập, ngay cả khi không có mạng.

Do đó, sự kết hợp hài hòa giữa phiên bản offline và online chính là giải pháp tối ưu. Bản offline phù hợp trong môi trường bảo tàng, ngoài thực địa hoặc những nơi hạn chế kết nối, trong khi bản online đáp ứng tốt nhu cầu nghiên cứu, giảng dạy và chia sẻ thông tin học thuật. Hai phiên bản bổ trợ lẫn nhau, hình thành nên một **hệ thống hoàn chỉnh, linh hoạt và hiệu quả**, vừa đáp ứng nhu cầu thực tiễn, vừa đảm bảo tính bền vững và khả năng mở rộng trong tương lai.

CHƯƠNG 6 ĐÁNH GIÁ VÀ HƯỚNG PHÁT TRIỂN

I. KẾT QUẢ ĐẠT ĐƯỢC

1. Những thứ đạt được

Sau quá trình thiết kế, xây dựng và thử nghiệm, ứng dụng “**aiMuseum QK9**” đã bước đầu đạt được các mục tiêu đề ra. Hệ thống cho phép nhận dạng cổ vật qua hình ảnh thời gian thực bằng camera điện thoại với tốc độ xử lý nhanh và độ chính xác cao. Mô hình YOLOv5 được huấn luyện với tập dữ liệu thực tế từ bảo tàng, sau khi tích hợp vào ứng dụng cho kết quả chính xác $\geq 90\%$ đối với các cổ vật phổ biến. Giao diện ứng dụng thân thiện, sử dụng ngôn ngữ tiếng Việt, phù hợp với đối tượng người dùng là khách tham quan và cán bộ tại bảo tàng. Ngoài ra, việc hỗ trợ cả hai chế độ nhận dạng offline và online giúp ứng dụng vận hành linh hoạt trong nhiều môi trường khác nhau.

Cơ sở dữ liệu cổ vật được tổ chức khoa học, dễ tra cứu, và có khả năng mở rộng về số lượng bản ghi. Hệ thống xử lý ảnh và truy xuất dữ liệu hoạt động ổn định trên các thiết bị Android từ tầm trung trở lên. Bên cạnh đó, ứng dụng còn mang tính ứng dụng thực tiễn cao, góp phần số hóa hoạt động bảo tàng, nâng cao trải nghiệm tham quan, đồng thời hỗ trợ trong công tác giáo dục truyền thống và nghiên cứu lịch sử.

2. Những hạn chế

Mặc dù đạt được nhiều kết quả khả quan, ứng dụng vẫn còn một số hạn chế nhất định. Số lượng cổ vật được huấn luyện còn hạn chế do thời gian thu thập dữ liệu thực tế tại bảo tàng chưa nhiều. Một số ảnh chụp trong điều kiện ánh sáng yếu hoặc góc nhìn nghiêng có thể khiến mô hình nhận dạng sai hoặc không nhận diện được. Bên cạnh đó, mô hình hoạt động ổn định trên các thiết bị từ trung bình đến cao cấp, nhưng với điện thoại cấu hình yếu, thời gian xử lý có thể bị chậm. Ngoài ra, ứng dụng hiện chưa tích hợp đa ngôn ngữ, điều này gây hạn chế khi phục vụ khách nước ngoài.

II. HƯỚNG PHÁT TRIỂN

Trong thời gian tới, ứng dụng “**aiMuseum QK9**” sẽ tiếp tục được nâng cấp và hoàn thiện theo các hướng sau:

- **Mở rộng dữ liệu huấn luyện:** Thu thập thêm nhiều hình ảnh cổ vật ở các góc độ, điều kiện ánh sáng khác nhau để tăng độ chính xác của mô hình nhận dạng.
- **Nâng cấp mô hình AI:** Áp dụng các mô hình mới hơn như YOLOv8, EfficientDet, hoặc tích hợp AI đa mô thức để xử lý cả hình ảnh lẫn văn bản hoặc giọng nói.
- **Hỗ trợ đa ngôn ngữ:** Bổ sung tiếng Anh, tiếng Pháp,... để phục vụ khách tham quan quốc tế.

- **Tích hợp công nghệ thực tế tăng cường (AR):** Giúp người dùng tương tác với cổ vật dưới dạng 3D ngay trên thiết bị.
- **Hệ thống quản lý nội dung (CMS):** Cho phép cán bộ bảo tàng dễ dàng cập nhật thông tin cổ vật mà không cần can thiệp vào mã nguồn ứng dụng.
- **Thống kê và phản hồi người dùng:** Bổ sung tính năng ghi nhận lượt truy cập, nhận xét, góp ý để cải thiện chất lượng dữ liệu và giao diện.

TÀI LIỆU THAM KHẢO

- [1] Ian Goodfellow, Yoshua Bengio, Aaron Courville, *Deep Learning – Học sâu*, Nhà xuất bản MIT Press, 2016.
- [2] Richard Szeliski, *Thị giác máy tính: Các thuật toán và ứng dụng*, Nhà xuất bản Springer, 2022.
- [3] Francois Chollet, *Học sâu với Python*, Nhà xuất bản Manning, 2021.
- [4] Android Developers, “Tài liệu hướng dẫn phát triển ứng dụng Android – CameraX”, Google. Truy cập tại: <https://developer.android.com/training/camerax>
- [5] Nhóm phát triển OpenCV, “Hướng dẫn phát triển ứng dụng Android với OpenCV”, Truy cập tại: https://docs.opencv.org/4.x/d5/da4/tutorial_android_dev_intro.html
- [6] TensorFlow Team, “Tài liệu TensorFlow Lite – Triển khai mô hình học sâu trên thiết bị di động”, Google. Truy cập tại: <https://www.tensorflow.org/lite>
- [7] PyTorch Team, “Tài liệu PyTorch Mobile và ONNX – Triển khai mô hình AI trên thiết bị Android”, Truy cập tại: <https://pytorch.org/mobile/home/>
- [8] Joseph Redmon và cộng sự, “You Only Look Once: Nhận diện vật thể thời gian thực”, Hội nghị CVPR, 2016.
- [9] Website thông tin bảo tàng lực lượng vũ trang nhân dân quân khu 9: <https://canthotourism.vn/vi/detailtravelplace/?id=555>
- [10] Tài liệu, hình ảnh và nội dung hiện vật thu thập từ Bảo tàng Lực lượng Vũ trang Quân khu 9 – Chi nhánh Cần Thơ (qua khảo sát thực tế và website địa phương).
- [11] Phạm Minh Hải , Đỗ Thị Hoài , Bùi Quang Thành , Nguyễn Ngọc Quang, *Nghiên cứu cơ sở khoa học ứng dụng thuật toán random forest trong phân loại ảnh vệ tinh SPOT6 với khu vực thực nghiệm tại tỉnh Cà Mau*, Viện Khoa học Đo đạc và Bản đồ, Bộ Tài Nguyên và Môi trường