

TRƯỜNG ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

XÂY DỰNG NỀN TẢNG BÁCH KHOA TRI THỨC MỞ
VỀ GIỐNG CÂY TRỒNG VÀ KỸ THUẬT CANH TÁC –
PHÂN HỆ SỔ TAY NÔNG NGHIỆP

BUILDING A WIKI-BASED OPEN KNOWLEDGE
PLATFORM FOR CROP VARIETIES AND
CULTIVATION TECHNIQUES –
AGRICULTURAL NOTEBOOK MODULE

Sinh viên: Nguyễn Đoàn Hoàng Phúc

Mã số: B2207556

Khóa: K48

Cần Thơ, 04/2026

TRƯỜNG ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH KHOA HỌC MÁY TÍNH

Đề tài

XÂY DỰNG NỀN TẢNG BÁCH KHOA TRI THỨC MỞ
VỀ GIỐNG CÂY TRỒNG VÀ KỸ THUẬT CANH TÁC –
PHÂN HỆ SỔ TAY NÔNG NGHIỆP

BUILDING A WIKI-BASED OPEN KNOWLEDGE
PLATFORM FOR CROP VARIETIES AND CULTIVATION
TECHNIQUES - AGRICULTURAL NOTEBOOK MODULE

Giảng viên hướng dẫn
TS. Lưu Tiến Đạo

Sinh viên thực hiện
Nguyễn Đoàn Hoàng Phúc
Mã số: B2207556
Khóa: K48

Cần Thơ, 04/2026

LỜI CẢM ƠN

Để hoàn thành bài luận văn này, em xin gửi lời cảm ơn sâu sắc đến Thầy Lưu Tiến Đạo – người đã tận tình hướng dẫn, hỗ trợ em trong suốt quá trình nghiên cứu và thực hiện đề tài. Những chỉ dẫn và góp ý quý báu của thầy đã giúp em nâng cao kiến thức, rèn luyện kỹ năng, từ đó hoàn thiện bài luận văn một cách tốt nhất.

Em cũng bày tỏ lòng biết ơn đến các Thầy Cô tại trường CNTT&TT, những người đã truyền đạt cho em những kiến thức quan trọng. Đây không chỉ là nền tảng tư duy mà còn là hành trang quý giá cho chặng đường phía trước.

Cuối cùng, em xin chân thành cảm ơn gia đình và bạn bè đã luôn động viên, khích lệ và đồng hành, tiếp thêm động lực để em hoàn thành bài luận văn này một cách trọn vẹn.

Tuy có nhiều sự cố gắng trong suốt quá trình thực hiện bài luận, nhưng không thể tránh khỏi những sai sót. Em rất mong nhận được sự góp ý, chỉ bảo thêm của quý Thầy Cô để bài luận được hoàn thiện hơn.

Em xin trân trọng cảm ơn.

Cần Thơ, ngày ... tháng ... năm 2026

Người viết

Nguyễn Đoàn Hoàng Phúc

MỤC LỤC

DANH MỤC HÌNH ẢNH.....	i
DANH MỤC BẢNG BIỂU.....	ii
DANH MỤC TỪ VIẾT TẮT	iii
ABSTRACT.....	iv
TÓM TẮT	v
I. PHẦN GIỚI THIỆU	1
1. Đặt vấn đề:	1
2. Các nghiên cứu có liên quan:.....	1
2.1. NotebookLM	2
2.2. Open Notebook.....	2
3. Mục tiêu đề tài:	3
4. Đối tượng và phạm vi nghiên cứu:	3
4.1. Đối tượng nghiên cứu:	4
4.2. Phạm vi nghiên cứu:	4
5. Phương pháp nghiên cứu:.....	4
6. Bố cục quyển báo cáo	5
II. PHẦN NỘI DUNG	7
CHƯƠNG 1. MÔ TẢ BÀI TOÁN.....	7
1.1. Mô tả chi tiết bài toán	7
1.2. Vấn đề giải pháp liên quan đến bài toán:.....	8
1.2.1. Kiến trúc RAG.....	8
1.2.2. Nhúng vector (Vector embedding).....	9
1.2.3. Cơ sở dữ liệu vector (Vector database).....	10
1.2.4. Mô hình ngôn ngữ lớn (LLM).....	10
1.2.5. Phương pháp đánh giá độ tương đồng chuỗi (String Similarity).....	11

1.2.6.	Mô hình NLI	12
1.2.7.	Phương pháp đánh giá ALCE.....	12
1.2.8.	MediaWiki và WikiCrop	16
1.2.9.	Các công cụ và thư viện hỗ trợ:	17
CHƯƠNG 2. THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP		20
2.1.	Thiết kế hệ thống.....	20
2.1.1.	Sơ đồ tổng quan hệ thống.....	20
2.1.2.	Sơ đồ cơ sở dữ liệu mức quan niệm.....	21
2.1.3.	Sơ đồ hệ thống trích xuất và tiền xử lý dữ liệu	25
2.1.4.	Sơ đồ hệ thống tạo bài viết từ tài liệu	26
2.2.	Cài đặt giải pháp	26
2.2.1.	Hệ thống trích xuất dữ liệu.....	26
2.2.2.	Hệ thống tiền xử lý dữ liệu.....	30
2.2.3.	Cài đặt cấu trúc dàn ý	32
2.2.4.	Hệ thống tạo bài viết.....	33
2.2.5.	Xây dựng giao diện người dùng.....	37
2.2.6.	Phương pháp đánh giá hệ thống trích xuất	38
2.2.7.	Phương pháp đánh giá hệ thống tạo bài viết	39
CHƯƠNG 3. KIỂM THỬ VÀ ĐÁNH GIÁ.....		42
3.1.	Giao diện sản phẩm.....	42
3.1.1.	Giao diện trang chủ	42
3.1.2.	Giao diện sổ tay	43
3.1.3.	Giao diện phần cài đặt quản lý dàn ý	48
3.1.4.	Giao diện phần cài đặt nguồn.....	49
3.2.	Kết quả thực nghiệm.....	51
3.2.1.	Đánh giá hệ thống truy xuất.....	51

3.2.2. Đánh giá hệ thống tạo bài viết.....	52
3.2.3. Đánh giá hoạt động giao diện:	53
III. PHẦN KẾT LUẬN.....	54
TÀI LIỆU THAM KHẢO.....	56

DANH MỤC HÌNH ẢNH

Hình 1.1. Một ví dụ về quy trình RAG áp dụng trong việc trả lời câu hỏi.....	8
Hình 1.2. Ví dụ về Claim Recall (Nguồn: Gao, Tianyu, et al., 2023)	14
Hình 1.3. Ví dụ về Citation Recall và Citation Precision	15
Hình 2.1. Sơ đồ tổng quan hệ thống	20
Hình 2.2. Sơ đồ CDM thể hiện cơ sở dữ liệu mức quan niệm.....	21
Hình 2.3. Sơ đồ mô tả hệ thống trích xuất và tiền xử lý dữ liệu.....	25
Hình 2.4. Sơ đồ mô tả hệ thống tạo bài viết từ tài liệu.....	26
Hình 2.5. Sơ đồ quy trình trích xuất tài liệu văn bản	27
Hình 2.6. Sơ đồ trích quy trình xuất tập tin âm thanh và video.....	28
Hình 2.7. Sơ đồ quy trình trích xuất trang web.....	29
Hình 2.8. Sơ đồ quy trình trích xuất video youtube.....	29
Hình 2.9. Sơ đồ quy trình tiền xử lý dữ liệu	30
Hình 2.10. Sơ đồ cấu trúc dàn ý.....	32
Hình 2.11. Sơ đồ quy trình tạo bài viết	33
Hình 2.12. Ví dụ về tạo và mở rộng truy vấn.....	34
Hình 2.13. Quy trình truy vấn dữ liệu.....	36
Hình 2.14. Quy trình viết bài và lưu vị trí	37
Hình 2.15. Ví dụ về đoạn văn và danh sách vị trí.....	37
Hình 2.16. Sơ đồ hệ thống đánh giá việc trích xuất dữ liệu	38
Hình 2.17. Ví dụ về đánh giá Citation Recall	39
Hình 2.18. Ví dụ về đánh giá Citation Precision	40
Hình 2.19. Ví dụ về đánh giá Claim Recall	41
Hình 3.1. Giao diện trang chủ.....	42
Hình 3.2. Giao diện sổ tay.....	43
Hình 3.3. Giao diện phân thêm nguồn trong sổ tay	44
Hình 3.4. Giao diện quản lý dàn ý trong sổ tay.....	45
Hình 3.5. Giao diện tạo và hiển thị bài viết trong sổ tay	47
Hình 3.6. Giao diện phân tương tác với bài viết trong sổ tay.....	48
Hình 3.7. Giao diện phân quản lý dàn ý.....	49
Hình 3.8. Giao diện phân quản lý nguồn.....	50

DANH MỤC BẢNG BIỂU

Bảng 2.1. Thực thể USER.....	22
Bảng 2.2. Thực thể SOURCES.....	22
Bảng 2.3. Thực thể SOURCE_CHUNKS.....	22
Bảng 2.4. Thực thể TEMPLATES.....	23
Bảng 2.5. Thực thể NOTEBOOKS	23
Bảng 2.6. Thực thể ARTICLES.....	24
Bảng 2.7. Thực thể CITATION	25
Bảng 3.1. Thành phần trong trang chủ.....	42
Bảng 3.2. Các thành phần trong trang sổ tay	43
Bảng 3.3. Các thành phần trong phần thêm nguồn trong sổ tay	44
Bảng 3.4. Thành phần cho việc quản lý dàn ý trong sổ tay.....	46
Bảng 3.5. Thành phần cho việc tạo và hiển thị bài trong sổ tay	47
Bảng 3.6. Thành phần cho việc tương tác trong sổ tay	48
Bảng 3.7. Thành phần trong phần cài đặt dàn ý	49
Bảng 3.8. Thành phần trong phần quản lý nguồn.....	50
Bảng 3.9. Chi tiết tập dữ liệu đánh giá trích xuất	51
Bảng 3.10. Kết quả đánh giá hệ thống trích xuất.....	52
Bảng 3.11. Kết quả đánh giá hệ thống tạo bài viết	53

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt (Abbreviation)	Từ viết đầy đủ (Origin word)
1	AI	Artificial Intelligence
2	API	Application Programming Interface
3	DOCX	Document Open XML
4	HTML	HyperText Markup Language
5	LLM	Large Language Model
6	NLI	Natural Language Inference
7	NLP	Natural Language Processing
8	OCR	Optical Character Recognition
9	PDF	Portable Document Format
10	RAG	Retrieval-Augmented Generation

ABSTRACT

WikiCrop is a wiki-based open platform on crop varieties and cultivation techniques, developed by lecturers at Can Tho University, aiming to provide scientific information on common crops in the Mekong Delta. The system operates in a manner similar to Wikipedia, allowing users to contribute and share content. To support users in compiling documents and generating content more efficiently, the “Agricultural Handbook” module is proposed to convert collected materials into articles with a unified structure.

Technically, the system uses specialized libraries to extract information from various input data sources, including PyMuPDF for PDF files, python-docx for DOCX files, Trafilatura for web content, Whisper for audio and video, and youtube-transcript-api or yt-dlp for YouTube data. It then applies the RAG method combined with a large language model (LLM) to retrieve relevant information and generate article content based on a predefined outline. The system is evaluated using testing methods such as string similarity for data extraction, along with metrics including Claim Recall, Citation Precision, and Citation Recall to assess content accuracy and the system’s ability to provide reliable source citations.

Results show that the system can transform data from multiple sources into structured articles based on user-provided outlines. Each piece of information in the article is accompanied by a reference to the original document, making it easy for users to verify and edit when necessary. The module is integrated into WikiCrop to support the process of knowledge compilation on the platform.

TÓM TẮT

WikiCrop là nền tảng bách khoa tri thức mở về giống cây trồng và kỹ thuật canh tác do các giảng viên tại Đại học Cần Thơ phát triển, hướng đến việc cung cấp thông tin khoa học cho các loại cây trồng phổ biến tại Đồng bằng sông Cửu Long. Hệ thống vận hành theo mô hình tương tự Wikipedia, cho phép người dùng đóng góp và chia sẻ nội dung. Nhằm hỗ trợ người dùng tổng hợp tài liệu và tạo nội dung thuận tiện hơn, phân hệ “Sổ tay nông nghiệp” được đề xuất để chuyển đổi các tài liệu thu thập được thành những bài viết có cấu trúc thống nhất.

Về mặt kỹ thuật, hệ thống sử dụng các thư viện chuyên dụng để trích xuất thông tin từ nhiều nguồn dữ liệu đầu vào, bao gồm PyMuPDF cho tập tin PDF, python-docx cho tập tin DOCX, Trafilatura cho trang web, Whisper cho dữ liệu âm thanh và video, cùng youtube-transcript-api hoặc yt-dlp cho nội dung YouTube. Sau đó, hệ thống áp dụng phương pháp RAG kết hợp với mô hình ngôn ngữ lớn (LLM) để truy xuất thông tin liên quan và tạo nội dung bài viết theo dàn ý. Hệ thống được đánh giá thông qua các phương pháp kiểm thử như độ tương đồng chuỗi cho quá trình trích xuất dữ liệu, cùng các chỉ số Claim Recall, Citation Precision và Citation Recall nhằm đo lường độ chính xác của nội dung và khả năng trích dẫn nguồn.

Kết quả cho thấy hệ thống có thể chuyển đổi dữ liệu từ nhiều nguồn khác nhau thành bài viết có cấu trúc dựa trên dàn ý do người dùng cung cấp. Mỗi thông tin trong bài viết đều được gắn kèm nguồn tham chiếu từ tài liệu gốc, giúp người dùng dễ dàng kiểm tra và chỉnh sửa khi cần. Phân hệ được tích hợp vào WikiCrop nhằm hỗ trợ quá trình tổng hợp tri thức trên nền tảng.

I. PHẦN GIỚI THIỆU

1. Đặt vấn đề:

WikiCrop là nền tảng bách khoa tri thức mở về giống cây trồng và kỹ thuật canh tác, được xây dựng bởi nhóm giảng viên tại Đại học Cần Thơ với mục tiêu cung cấp thông tin đầy đủ và khoa học cho các nhóm cây trồng phổ biến tại Đồng bằng sông Cửu Long. Tính đến thời điểm thực hiện luận văn, đề tài gốc chưa được nghiệm thu nhưng đã vận hành ổn định theo mô hình tương tự Wikipedia, cho phép người dùng cập nhật và chia sẻ nội dung về giống cây trồng và kỹ thuật canh tác.

Bên cạnh những thông tin mà nền tảng cung cấp, việc người dùng có thể tự mình tổng hợp thông tin và chia sẻ để mở rộng hệ thống cũng là một yếu tố quan trọng. Từ nhu cầu đó, phân hệ “Sổ tay nông nghiệp” được đề xuất nhằm tạo ra một công cụ hỗ trợ người dùng chuyển các tài liệu mà họ thu thập được thành những bài viết trực quan và thống nhất về mặt trình bày. Ý tưởng cốt lõi là cho phép người dùng tự xây dựng các “sổ tay” cá nhân ngay trên nền tảng. Trong mỗi sổ tay, họ có thể bổ sung các nguồn dữ liệu riêng, sau đó tổ chức và tổng hợp chúng thành những bài viết hoàn chỉnh. Cách vận hành này tương tự việc ghi chú và kết nối lại những thông tin hữu ích mà chúng ta bắt gặp trong đời sống hằng ngày. Phân hệ này tập trung vào việc giúp người dùng thuận tiện hơn trong quá trình tổng hợp thông tin, qua đó khuyến khích họ chia sẻ tri thức vào hệ thống, góp phần giúp hệ thống ngày càng phát triển hơn.

Để triển khai ý tưởng này, phân hệ được xây dựng theo hướng trích xuất dữ liệu từ nhiều loại tệp đầu vào bằng các thư viện Python, sau đó áp dụng phương pháp RAG để biến những thông tin đã trích xuất thành bài viết dựa trên một dàn ý khoa học. Phần nội dung được tạo ra có thể được người dùng chỉnh sửa lại nếu cần thiết trước khi gửi lên WikiCrop. Việc tích hợp phân hệ này vào hệ thống không chỉ giúp chuẩn hóa quy trình tạo bài viết mà còn gia tăng trải nghiệm tương tác của người dùng, qua đó góp phần mở rộng kho tri thức của nền tảng.

2. Các nghiên cứu có liên quan:

2.1. NotebookLM

NotebookLM¹ là một trợ lý nghiên cứu dựa trên trí tuệ nhân tạo của Google, được thiết kế nhằm hỗ trợ người dùng tổng hợp, tổ chức và phát triển ý tưởng từ các nguồn tài liệu của mình. Với NotebookLM, người dùng có thể tải lên nhiều loại dữ liệu khác nhau, sau đó hệ thống sẽ hỗ trợ chuyển đổi các nguồn này thành những định dạng dễ tiếp cận như bản tóm tắt, hướng dẫn học tập, bản tổng quan bằng âm thanh hoặc bản đồ tư duy.

Ngoài ra, NotebookLM còn cho phép người dùng trò chuyện trực tiếp với tập tài liệu đã tải lên. Hệ thống sẽ đưa ra câu trả lời dựa trên nội dung của các nguồn dữ liệu này, đồng thời cung cấp trích dẫn cụ thể ngay trong câu trả lời nhằm giúp người dùng dễ dàng kiểm tra và đối chiếu lại thông tin gốc. Nhờ khả năng hỗ trợ tổng hợp và phân tích tài liệu, NotebookLM đã trở thành một công cụ hữu ích cho nhiều đối tượng người dùng, từ các nhà nghiên cứu cần xử lý khối lượng lớn tài liệu đến sinh viên trong quá trình thu thập và tổng hợp nguồn cho các bài báo cáo hoặc luận văn.

Tuy nhiên, NotebookLM vẫn tồn tại một số giới hạn nhất định. Thứ nhất, hệ thống có hạn mức sử dụng, do đó người dùng cần đăng ký các gói trả phí nếu muốn sử dụng đầy đủ tính năng khi làm việc với số lượng lớn tài liệu. Thứ hai, NotebookLM không phải là phần mềm mã nguồn mở, vì vậy người dùng không thể tùy chỉnh hệ thống theo nhu cầu riêng cũng như gặp nhiều hạn chế khi muốn tích hợp công cụ này vào các ứng dụng hoặc nền tảng do mình phát triển.

2.2. Open Notebook

Open Notebook² là một phần mềm mã nguồn mở được phát triển dựa trên ý tưởng của NotebookLM. Tương tự NotebookLM, Open Notebook cũng cung cấp các chức năng hỗ trợ phân tích và tổng hợp nội dung từ nhiều nguồn dữ liệu khác nhau. Hệ thống có thể chuyển đổi các tài liệu đầu vào thành nhiều dạng nội dung như bản ghi chú, bản tóm tắt hoặc podcast nhằm giúp người dùng tiếp cận thông tin một cách thuận tiện hơn.

¹ <https://notebooklm.google.com>

² <https://open-notebook.ai/get-started>

Một điểm khác biệt đáng chú ý so với NotebookLM là Open Notebook có thể chạy trực tiếp trên máy của người dùng, qua đó giúp dữ liệu được lưu trữ và xử lý cục bộ thay vì phải gửi lên máy chủ bên ngoài. Điều này góp phần nâng cao khả năng kiểm soát và bảo mật dữ liệu. Ngoài ra, Open Notebook còn hỗ trợ tích hợp với nhiều mô hình trí tuệ nhân tạo phổ biến như OpenAI, Anthropic, Ollama, Google và LM Studio. Nhờ đặc điểm mã nguồn mở, phần mềm cũng đang được nhiều lập trình viên đóng góp và phát triển, hứa hẹn bổ sung thêm nhiều tính năng mới trong tương lai.

Tuy nhiên, Open Notebook vẫn còn một số hạn chế. Hiện tại phần mềm chưa hỗ trợ giao diện tiếng Việt, gây khó khăn cho một bộ phận người dùng tại Việt Nam. Bên cạnh đó, do được thiết kế như một ứng dụng độc lập, Open Notebook chưa hỗ trợ tích hợp trực tiếp vào các hệ thống sẵn có, vì vậy việc ứng dụng công cụ này vào các nền tảng chuyên biệt vẫn còn gặp nhiều trở ngại.

3. Mục tiêu đề tài:

Mục tiêu của đề tài là xây dựng một hệ thống có khả năng hỗ trợ người dùng chuyển đổi dữ liệu thô ban đầu thành thông tin có cấu trúc, từ đó tạo ra các bài viết hoàn chỉnh dựa trên dàn ý do người dùng cung cấp. Cụ thể, hệ thống cần có khả năng trích xuất dữ liệu từ nhiều loại nguồn đầu vào khác nhau, bao gồm các tệp văn bản, dữ liệu đa phương tiện, cũng như nội dung từ trang web và video YouTube. Quá trình trích xuất phải đảm bảo giữ được cấu trúc và vị trí ban đầu của thông tin (ví dụ: với dữ liệu văn bản cần xác định vị trí của thông tin trong tài liệu như đoạn hoặc trang, với dữ liệu video cần xác định mốc thời gian mà thông tin xuất hiện), từ đó giúp người dùng dễ dàng đối chiếu lại với nguồn dữ liệu gốc khi cần thiết. Sau khi thu được thông tin từ các nguồn dữ liệu, hệ thống sẽ tiến hành tổng hợp và tạo thành bài viết dựa trên nội dung đã trích xuất. Nội dung của bài viết cần được xây dựng dựa trên các thông tin có liên quan trong dữ liệu nguồn, đồng thời cung cấp các tham chiếu tương ứng cho từng nội dung xuất hiện trong bài viết nhằm hỗ trợ người dùng kiểm tra và xác thực thông tin một cách thuận tiện. Cuối cùng, toàn bộ chức năng của hệ thống được triển khai như một phần của nền tảng WikiCrop, qua đó cung cấp cho người dùng thêm một công cụ hỗ trợ trong việc tổng hợp và chia sẻ tri thức trên hệ thống.

4. Đối tượng và phạm vi nghiên cứu:

4.1. Đối tượng nghiên cứu:

Đối tượng chính của đề tài là những người dùng tham gia viết và đóng góp nội dung cho nền tảng WikiCrop, đặc biệt là những người thường xuyên tổng hợp thông tin từ nhiều nguồn tài liệu khác nhau để xây dựng bài viết. Việc tìm hiểu cách làm việc của nhóm người dùng này giúp xác định những khó khăn thực tế trong quá trình thu thập, tổng hợp và trình bày thông tin. Ngoài ra, đề tài cũng tập trung nghiên cứu các công nghệ hỗ trợ xử lý và tổng hợp dữ liệu, cụ thể là mô hình truy xuất tri thức (RAG) và mô hình ngôn ngữ lớn (LLM), nhằm hỗ trợ hệ thống tìm kiếm thông tin liên quan từ các tài liệu nguồn và tạo ra bài viết có nội dung tự nhiên, phù hợp với cấu trúc do người dùng cung cấp.

4.2. Phạm vi nghiên cứu:

Đề tài tập trung vào việc xây dựng một hệ thống có các chức năng chính sau:

- Tự động trích xuất thông tin từ các tài liệu do người dùng cung cấp.
- Tổng hợp các thông tin đã trích xuất để tạo thành một bài viết hoàn chỉnh theo cấu trúc định sẵn.
- Cung cấp giao diện để người dùng xem lại, kiểm tra và chỉnh sửa nội dung sau khi bài viết được tạo.

Phạm vi nghiên cứu của đề tài giới hạn ở việc xử lý và tổng hợp thông tin từ các tài liệu có sẵn. Hệ thống không thực hiện việc đánh giá hay xác minh tính đúng sai của nội dung trong các tài liệu đầu vào, mà giả định rằng các nguồn dữ liệu do người dùng cung cấp là những tài liệu đáng tin cậy và đã được kiểm chứng trước đó. Ngoài ra, hệ thống hiện tập trung vào việc xử lý nội dung văn bản thông thường. Các dạng thông tin phức tạp như bảng biểu hoặc hình ảnh chưa được xử lý và phân tích trong phạm vi của đề tài.

5. Phương pháp nghiên cứu:

Để hoàn thành đề tài, các phương pháp nghiên cứu sau được áp dụng:

- **Nghiên cứu tài liệu và cơ sở lý thuyết:** Tìm hiểu các bài báo khoa học và tài liệu liên quan đến việc tóm tắt đa văn bản, trích xuất thông tin và sinh nội dung tự động bằng trí tuệ nhân tạo. Thông qua đó, đề tài tiếp cận các phương pháp đã

được chứng minh hiệu quả, đồng thời xác định những điểm còn hạn chế để định hướng cải tiến và áp dụng phù hợp vào hệ thống được xây dựng.

- **Khảo sát và phân tích các hệ thống hiện có:** Nghiên cứu các công cụ hỗ trợ tổng hợp tài liệu dựa trên trí tuệ nhân tạo như NotebookLM và Open Notebook. Từ đó phân tích các ưu điểm về chức năng, cách tổ chức dữ liệu và trải nghiệm người dùng để tham khảo trong quá trình thiết kế hệ thống, đồng thời nhận diện những hạn chế của các công cụ này để làm cơ sở đề xuất giải pháp phù hợp cho đề tài.
- **Xây dựng và triển khai giải pháp kỹ thuật:** Thiết kế hệ thống trích xuất thông tin từ nhiều loại dữ liệu đầu vào khác nhau bằng các thư viện chuyên dụng để trích xuất thông tin từ nhiều nguồn dữ liệu đầu vào, bao gồm PyMuPDF cho tập tin PDF, python-docx cho tập tin DOCX, Trafilatura cho trang web, Whisper cho dữ liệu âm thanh và video, cùng youtube-transcript-api hoặc yt-dlp cho nội dung YouTube. Sau đó triển khai cơ chế sinh bài viết dựa trên sự kết hợp giữa mô hình truy xuất tri thức (RAG) và mô hình ngôn ngữ lớn (LLM), nhằm tổng hợp các thông tin đã trích xuất thành nội dung bài viết theo cấu trúc định sẵn.
- **Kiểm thử và đánh giá hệ thống:** Thực hiện kiểm thử để đánh giá hiệu quả của các thành phần trong hệ thống. Cụ thể, quá trình trích xuất dữ liệu được đánh giá thông qua độ tương đồng chuỗi nhằm đo lường độ chính xác của thông tin thu được. Bên cạnh đó, chất lượng bài viết được đánh giá thông qua các chỉ số như Claim Recall, Citation Precision và Citation Recall nhằm kiểm tra mức độ chính xác của nội dung và khả năng trích dẫn nguồn dữ liệu.
- **Phát triển ứng dụng và hoàn thiện giao diện:** Nghiên cứu cấu trúc và giao diện của hệ thống WikiCrop để xây dựng một phân hệ hoàn chỉnh có thể tích hợp vào nền tảng hiện có. Giao diện được thiết kế theo hướng trực quan, dễ sử dụng, hỗ trợ người dùng thao tác thuận tiện trong quá trình tải tài liệu, tạo bài viết và chỉnh sửa nội dung.

6. Bố cục quyền báo cáo

Nội dung của quyền báo cáo như sau:

- **Chương 1. Mô tả bài toán:** Mô tả chi tiết hơn về bài toán và xác định những vấn đề liên quan đến bài toán, đồng thời giới thiệu những công cụ sử dụng

- **Chương 2.** Thiết kế và cài đặt giải pháp: thiết kế cơ sở dữ liệu và những quá trình xử lý liên quan đến bài toán. Sau đó vẽ những lưu đồ giải thuật thể hiện việc cài đặt từng chức năng
- **Chương 3.** Kiểm thử, đánh giá và thảo luận kết quả đạt được: Xây dựng các kịch bản để đánh giá ứng dụng. Qua đó rút ra kết luận và đề xuất những hướng phát triển phù hợp.

II. PHẦN NỘI DUNG

CHƯƠNG 1. MÔ TẢ BÀI TOÁN

1.1. Mô tả chi tiết bài toán

Bài toán của đề tài xuất phát từ thực tế rằng người dùng mong muốn mình có một cuốn “sổ tay” riêng để ghi lại các nguồn dữ liệu mà mình thấy hay, từ đó tổng hợp nguồn thông tin từ dữ liệu này thành các bài viết cung cấp thông tin, giống như việc ghi chú trong sổ tay hàng ngày để kết nối các thông tin mà ta tìm được. Tuy nhiên việc tổng hợp kiến thức từ nhiều nguồn tài liệu khác nhau thường tốn nhiều thời gian và công sức. Khi thực hiện thủ công, người viết phải đọc, chọn lọc và sắp xếp thông tin từ nhiều tài liệu khác nhau trước khi có thể tạo ra một bài viết hoàn chỉnh, khiến quá trình thu thập và tổng hợp thông tin trở nên tốn thời gian và khó quản lý. Vì vậy, đề tài hướng đến việc xây dựng một công cụ có khả năng tự động trích xuất dữ liệu từ các tài liệu đầu vào, chuyển đổi chúng thành thông tin có cấu trúc và hỗ trợ tạo bài viết dựa trên dàn ý do người dùng cung cấp. Cách tiếp cận này giúp quá trình tổng hợp tri thức trở nên nhanh chóng và có hệ thống hơn.


Về mặt kỹ thuật, hệ thống trước hết thực hiện trích xuất nội dung từ các nguồn dữ liệu đầu vào, trong đó mỗi thông tin được lưu trữ kèm theo vị trí của nó trong tài liệu gốc. Các thông tin này sau đó được chuyển đổi thành vector và lưu trữ trong cơ sở dữ liệu vector để phục vụ cho việc truy xuất. Khi người dùng cung cấp dàn ý của bài viết, hệ thống áp dụng phương pháp RAG để tìm kiếm trong cơ sở dữ liệu những thông tin phù hợp với từng mục của dàn ý, sau đó sử dụng mô hình ngôn ngữ lớn (LLM) để tạo nội dung tương ứng. Trong trường hợp không tìm thấy dữ liệu phù hợp, hệ thống sẽ thông báo rằng mục đó chưa có thông tin. Quy trình này giúp đảm bảo nội dung bài viết được xây dựng dựa trên dữ liệu đầu vào, đồng thời hạn chế việc tạo ra những thông tin không liên quan.

Trong quá trình sử dụng, người dùng chỉ cần cung cấp các tài liệu tham khảo cùng với một dàn ý sơ bộ của bài viết. Dựa trên các nguồn dữ liệu này, hệ thống sẽ tự động tổng hợp và soạn thảo nội dung tương ứng. Mỗi thông tin trong bài viết đều được gắn kèm nguồn tham chiếu và liên kết trực tiếp đến vị trí cụ thể trong tài liệu gốc, giúp bài viết minh bạch hơn và cho phép người dùng dễ dàng kiểm tra, đối chiếu cũng như chỉnh sửa lại nội dung khi cần thiết.

1.2. Vấn đề giải pháp liên quan đến bài toán:

1.2.1. Kiến trúc RAG

Retrieval-Augmented Generation (RAG) là kỹ thuật được giới thiệu nhằm tăng cường khả năng của các mô hình ngôn ngữ lớn (LLM) [1]. Phương pháp này kết hợp bộ nhớ nội tại của mô hình đã huấn luyện sẵn với bộ nhớ bên ngoài được lưu trữ trong cơ sở dữ liệu vector, từ đó khắc phục hạn chế cố hữu của các LLM truyền thống khi xử lý những tác vụ đòi hỏi kiến thức cập nhật hoặc chuyên sâu. Điểm nổi bật tại thời điểm ra mắt là RAG cho phép hệ thống mở rộng và cập nhật tri thức chỉ bằng cách thay đổi nguồn tài liệu bên ngoài, mà không cần huấn luyện lại toàn bộ mô hình.



Hình 1.1. Một ví dụ về quy trình RAG áp dụng trong việc trả lời câu hỏi

(Nguồn: Gao, Yunfan, et al., 2023)

Một ứng dụng điển hình của RAG được minh họa trong Hình 1.1. Khi người dùng hỏi ChatGPT về một tin tức mới, mô hình mặc định không thể trả lời chính xác vì dữ liệu huấn luyện không bao gồm sự kiện mới nhất. RAG giải quyết vấn đề này bằng cách truy xuất các tài liệu liên quan từ cơ sở dữ liệu bên ngoài và kết hợp chúng với câu hỏi ban đầu để tạo thành một câu lệnh (prompt) hoàn chỉnh. Nhờ đó, mô hình ngôn ngữ lớn có thể đưa ra câu trả lời chính xác hơn và mang tính cập nhật [2].

Quy trình RAG thường bao gồm ba bước:

- **Đánh chỉ mục (Indexing):** Tài liệu được chia nhỏ thành các đoạn (chunks), mã hóa thành vector và lưu vào cơ sở dữ liệu vector.
- **Truy xuất (Retrieval):** Tìm kiếm k đoạn liên quan nhất đến câu hỏi dựa trên mức độ tương đồng ngữ nghĩa.
- **Tạo sinh (Generation):** Kết hợp câu hỏi gốc và các đoạn đã truy xuất, đưa vào mô hình LLM để sinh ra câu trả lời cuối cùng.

Đề tài ứng dụng RAG vì phương pháp này mang lại nhiều ưu điểm quan trọng, đặc biệt là khả năng tăng độ chính xác và giảm hiện tượng “ảo giác” của mô hình ngôn ngữ lớn. Bằng cách truy xuất thông tin trực tiếp từ các nguồn dữ liệu do người dùng cung cấp, RAG giúp hệ thống tạo ra nội dung bám sát thực tế hơn và nâng cao hiệu quả xử lý thông tin.

1.2.2. Nhúng vector (Vector embedding)

Vector embedding (nhúng vector) là cách chuyển các đơn vị văn bản như từ, câu hoặc đoạn văn thành các dãy số trong không gian nhiều chiều để máy tính có thể xử lý. Mục tiêu là mã hóa ý nghĩa sao cho những từ hoặc câu có nội dung giống nhau sẽ nằm gần nhau trong không gian vector. Cơ chế này bắt nguồn từ thực tế, nơi những từ xuất hiện trong cùng một ngữ cảnh thường có liên quan mật thiết đến nhau. Dựa trên nguyên tắc đó, các mô hình máy học sẽ tự tìm ra các từ phù hợp chỉ bằng cách quan sát chúng xuất hiện cạnh những từ nào trong văn bản. Nhờ vậy, vector embedding trở thành nền tảng cho hầu hết các kỹ thuật NLP hiện đại và là bước khởi đầu của các mô hình hiểu ngữ nghĩa mạnh hơn sau này [3].

Embedding giữ vai trò cốt lõi trong RAG vì toàn bộ quá trình truy xuất phụ thuộc vào việc đo độ tương đồng giữa vector của câu hỏi và vector của các đoạn tài liệu. Khi embedding mô tả chính xác ngữ nghĩa, hệ thống mới có thể tìm ra đúng thông tin cần thiết, từ đó cải thiện độ chính xác của kết quả sinh ra.

Trong đề tài này sử dụng mô hình paraphrase-multilingual-MiniLM-L12-v2, một mô hình nhỏ gọn nhưng hiệu quả, được thiết kế để tạo ra vector embedding chất lượng cao phục vụ các tác vụ tìm kiếm và truy xuất thông tin.

1.2.3. Cơ sở dữ liệu vector (Vector database)

Cơ sở dữ liệu vector (VDB) là các công cụ được thiết kế chuyên biệt để lưu trữ và quản lý hiệu quả những vector đa chiều. Cụ thể, VDB lưu thông tin dưới dạng các dãy số (vector), tức là dạng biểu diễn toán học của các đặc trưng hoặc thuộc tính của dữ liệu. Không giống cơ sở dữ liệu quan hệ truyền thống, VDB cung cấp cơ chế lưu trữ, quản lý và tìm kiếm ở quy mô lớn một cách rất hiệu quả. Nhờ đó, VDB sở hữu nhiều ưu điểm như: hỗ trợ tìm kiếm theo ý nghĩa (ngữ nghĩa), xử lý khối lượng dữ liệu khổng lồ và phản hồi với độ trễ rất thấp. Những khả năng này khiến VDB ngày càng được sử dụng rộng rãi trong các ứng dụng AI, bao gồm cả RAG [4].

Trong kiến trúc RAG của đề tài, cơ sở dữ liệu vector đóng vai trò như một “bộ não” lưu trữ toàn bộ kiến thức đã được số hóa. Mỗi thông tin trích xuất từ dữ liệu ban đầu, sau khi được chuyển thành vector, sẽ được lưu trong cơ sở dữ liệu này. Khi người dùng viết bài, các thông tin trong cơ sở dữ liệu vector sẽ được dùng làm ngữ cảnh để hỗ trợ mô hình ngôn ngữ lớn (LLM) tạo ra nội dung văn bản.

1.2.4. Mô hình ngôn ngữ lớn (LLM)

Mô hình ngôn ngữ lớn (LLM) là các mô hình học sâu được huấn luyện để dự đoán từ tiếp theo trong một chuỗi văn bản dựa trên ngữ cảnh trước đó, nhưng được mở rộng về dữ liệu và số lượng tham số đến mức có thể nắm bắt các quy luật ngôn ngữ phức tạp. Chúng phát triển từ các mô hình thống kê đơn giản, sau đó được nâng cấp bằng mạng nơ-ron để tự học đặc trưng ngữ nghĩa. Bước tiến quan trọng là giai đoạn học trước trên lượng văn bản khổng lồ, giúp mô hình tích lũy hiểu biết rộng về ngôn ngữ trước khi được tinh chỉnh cho từng nhiệm vụ cụ thể. Khi quy mô tham số tăng lên hàng chục hoặc hàng trăm tỷ, các mô hình này xuất hiện thêm nhiều năng lực mới như suy luận, học trong ngữ cảnh và làm theo hướng dẫn phức tạp. Nhờ đó, LLM không còn là công cụ phục vụ từng tác vụ đơn lẻ mà trở thành hệ thống xử lý đa năng, có khả năng giao tiếp và giải quyết nhiều vấn đề thực tiễn của con người [5].

Trong đề tài, LLM được dùng để tổng hợp các đoạn văn bản rời rạc thành một nội dung hoàn chỉnh. Hệ thống sử dụng các mô hình như llama-3.3-70b-versatile và llama-3.1-8b-instant, đều thuộc nhóm mô hình ngôn ngữ mạnh mẽ do Meta phát triển. Với số

lượng tham số cao, những mô hình này hứa hẹn đem lại hiệu quả xử lý ngôn ngữ tốt để có thể ứng dụng vào hệ thống.

1.2.5. Phương pháp đánh giá độ tương đồng chuỗi (String Similarity)

Đánh giá độ tương đồng chuỗi là một bài toán kinh điển. Việc so sánh cứng theo từng từ đôi khi không phản ánh đúng mức độ giống nhau, vì nhiều trường hợp ta không cần hai chuỗi giống nhau hoàn toàn mà chỉ cần biết chúng tương đồng đến mức nào và giống ở những điểm nào. Từ nhu cầu đó, các thuật toán đo độ tương đồng chuỗi ra đời. Một trong số đó là Indel Distance. Indel đo tổng chi phí để chuyển đổi chuỗi A thành chuỗi B chỉ bằng hai thao tác: chèn và xóa ký tự [6]. Khoảng cách Indel có thể được tính trực tiếp từ độ dài chuỗi con chung dài nhất (Longest Common Subsequence – LCS) theo công thức sau:

$$distance(A,B) = |A| + |B| - 2|LCS(A,B)| \quad (1)$$

Trong đó:

- $distance(A, B)$ là khoảng cách giữa hai chuỗi A và B
- $|A|, |B|$ lần lượt là độ dài hai chuỗi của A và B
- $|LCS(A,B)|$ là độ dài chuỗi con chung dài nhất của A và B

Để thuận tiện hơn trong việc sử dụng, chúng ta chuẩn hóa nó thành công thức độ tương đồng chuỗi (string similarity) như sau:

$$String\ similarity\ score = \frac{|A| + |B| - distance(A,B)}{|A| + |B|} \quad (2)$$

Trong đề tài, độ tương đồng chuỗi được sử dụng như một chỉ số kiểm tra chất lượng dữ liệu trích xuất. Thay vì so sánh cứng theo từng ký tự hay từng từ, phép đo tương đồng cho phép đánh giá linh hoạt hơn bằng cách xem xét cấu trúc và mức độ giống nhau thực sự giữa hai chuỗi. Điều này giúp hệ thống nhận diện liệu nội dung trích xuất có đủ gần với thông tin gốc hay không, từ đó đảm bảo dữ liệu đầu vào đạt chất lượng trước khi được đưa vào các bước xử lý tiếp theo. Vì vậy, chỉ số này đóng vai trò như

một lớp kiểm định quan trọng, vừa đủ nghiêm ngặt để phát hiện sai lệch, nhưng không quá khắt khe đến mức loại bỏ những khác biệt nhỏ không ảnh hưởng đến ý nghĩa.

1.2.6. Mô hình NLI

Suy luận ngôn ngữ tự nhiên (Natural Language Inference – NLI) là một bài toán quan trọng trong xử lý ngôn ngữ tự nhiên, dùng để xác định mối quan hệ logic giữa hai câu: câu Tiền đề (Premise) và câu Giả thuyết (Hypothesis) [7]. Trong quá trình xử lý, mô hình NLI tiếp nhận cặp câu này, mã hóa chúng thành vector embedding và đưa qua một bộ phân loại để dự đoán mối liên hệ giữa hai văn bản. Kết quả dự đoán thường thuộc một trong ba nhãn:

- Entailment (Kéo theo/Suy ra) khi Giả thuyết đúng dựa trên thông tin của Tiền đề
- Neutral (Trung lập) khi Giả thuyết có thể đúng nhưng Tiền đề không cung cấp đủ bằng chứng
- Contradiction (Mâu thuẫn) khi Giả thuyết đi ngược lại thông tin của Tiền đề.

Hệ thống sử dụng mô hình mDeBERTa-v3-base-mnli-xnli cho tác vụ suy luận ngôn ngữ tự nhiên (NLI). Đây là mô hình dựa trên kiến trúc DeBERTaV3 tiên tiến, được huấn luyện trước trên tập dữ liệu đa ngôn ngữ quy mô lớn, giúp tối ưu hóa khả năng hiểu ngữ nghĩa sâu sắc cho tiếng Việt.

1.2.7. Phương pháp đánh giá ALCE

Sinh văn bản kết hợp truy xuất (Retrieval-augmented generation - RAG) là một phương pháp đầy triển vọng nhằm giải quyết những hạn chế về giới hạn kiến thức của các mô hình ngôn ngữ lớn (LLM). Tuy nhiên, các bộ tiêu chuẩn hiện hành dùng để đánh giá hệ thống RAG (trong đó có RAGAS) đang mắc phải hai khiếm khuyết cốt lõi: chúng không đo lường được một cách thỏa đáng năng lực của LLM trong việc xử lý truy xuất ngữ cảnh dài, và chúng thiếu một phương pháp đánh giá toàn diện để kiểm định khả năng của LLM trong việc sinh ra các văn bản dài [8].

ALCE (Automatic LLMs' Citation Evaluation) là tiêu chuẩn đánh giá tự động và có thể tái tạo đầu tiên được thiết kế riêng cho nhiệm vụ sinh văn bản có trích dẫn của các mô hình ngôn ngữ lớn. Tiêu chuẩn này giải quyết vấn đề ảo giác bằng cách

buộc mô hình cung cấp trích dẫn tương ứng cho từng nhận định; đồng thời đánh giá toàn bộ hệ thống từ đầu đến cuối, từ truy xuất thông tin đến sinh câu trả lời và đặt trích dẫn đúng vị trí. Những chỉ số đánh giá chính được đề cập là Claim Recall, Citation Recall và Citation Precision [9].

➤ **Claim Recall:**


Đây là chỉ số đo lường mức độ chính xác và mức độ bao phủ thông tin của câu trả lời do mô hình sinh ra so với đáp án chuẩn. Thay vì dựa vào các phép so khớp chuỗi truyền thống vốn dễ sai lệch, Claim Recall chia câu trả lời gốc thành các nhận định phụ độc lập (claims) bằng một LLM, sau đó dùng mô hình suy luận tự nhiên (NLI) để kiểm tra xem câu trả lời của mô hình có đủ căn cứ để “chứng minh” từng nhận định đó hay không. Nhờ cách tiếp cận này, Claim Recall phản ánh trung thực khả năng tái hiện nội dung quan trọng của câu hỏi, đặc biệt hiệu quả với các câu trả lời dài.

$$\text{Claim recall} = \frac{|supported\ claims|}{|total\ claims|} \quad (3)$$

Trong đó:

- $|supported\ claims|$ là những nhận định được mà bài viết trong mô hình có đề cập
- $|total\ claims|$ là tổng số nhận định có trong bài viết gốc

Một ví dụ về Claim Recall được mô tả trong Hình 1.2, hệ thống tiến hành tách câu trả lời đúng ra thành các nhận định nhờ một mô hình LLM là text-davinci-003, sau đó tiến hành so sánh những nhận định đúng này với câu trả lời mà mô hình đưa ra. Kết quả cuối cùng là tỷ lệ số nhận định đúng có trong câu trả lời trên tổng số nhận định có trong câu trả lời gốc.



Hình 1.2. Ví dụ về Claim Recall (Nguồn: Gao, Tianyu, et al., 2023)

➤ Citation Recall


Đây là chỉ số đánh giá xem các câu văn do mô hình sinh ra có được hỗ trợ đầy đủ bởi các nguồn đã trích dẫn hay không. Phương pháp này dùng mô hình NLI để đối chiếu tài liệu được trích dẫn (tiền đề) với câu văn của mô hình (giả thuyết); nếu hệ thống xác định quan hệ kéo theo (entailment), trích dẫn đó được xem là hợp lệ. Nhờ đó, Citation Recall cho thấy mức độ mô hình thật sự dựa vào nguồn trích dẫn thay vì tự “bịa” thông tin. Công thức của Citation Recall được thể hiện như sau:

$$\text{Citation Recall} = \frac{|\text{supported statements}|}{|\text{total statements}|} \quad (4)$$

Trong đó:

- $|\text{supported statements}|$ là những câu mà đúng là được đề cập trong nguồn trích dẫn
- $|\text{total statements}|$ là tổng số câu có trong bài viết mà mô hình đưa ra.

Một ví dụ về Citation Recall được mô tả trong Hình 1.3, tại đây mỗi câu văn và mô hình cho ra, mô hình sẽ sử dụng NLI để kiểm tra xem có đúng là ý nghĩa câu văn đó tồn tại trong nguồn trích dẫn đính kèm hay không. Kết quả cuối cùng là số câu văn được trích dẫn đúng trên tổng số lượng câu văn và đề bài cho ra.



Hình 1.3. Ví dụ về Citation Recall và Citation Precision

(Nguồn: Gao, Tianyu, et al., 2023)

➤ Citation Precision

Đây là chỉ số được dùng để phát hiện các trích dẫn thừa hoặc không liên quan. ALCE không ép mô hình phải trích dẫn ít hay nhiều, nhưng sẽ trừ điểm nếu mô hình đưa vào những nguồn không đóng góp gì cho nội dung. Một trích dẫn bị xem là “rác” nếu chính tài liệu đó không hỗ trợ câu văn, và khi loại bỏ tài liệu này thì các trích dẫn còn lại vẫn đủ để chứng minh câu văn là đúng. Nhờ vậy, Citation Precision phản ánh mức độ “sạch” và hợp lý của các trích dẫn mà mô hình sử dụng. Công thức của Citation Precision được thể hiện như sau:

$$\text{Citation Precision} = \frac{|supported citations|}{|total citations|} \quad (5)$$

Trong đó:

- $|supported citations|$ là số nguồn trích dẫn thực sự cần thiết trong bài viết
- $|total citations|$ là tổng số nguồn trích dẫn mà bài viết có

Một ví dụ về Citation Precision được mô tả trong Hình 1.3, tại mỗi câu văn và nguồn đính kèm mà mô hình cho ra. Hệ thống tiến hành bỏ bớt các nguồn và sử dụng NLI để kiểm tra ý nghĩa câu văn trong các nguồn còn lại. Nếu như sau khi bỏ và câu văn vẫn còn được trích dẫn trong mấy nguồn còn lại thì đó là nguồn thừa, ngược lại thì không. Kết quả cuối cùng là tỷ lệ những nguồn hỗ trợ ý trên tổng số các nguồn được đề cập trong kết quả đầu ra.

1.2.8. MediaWiki và WikiCrop

MediaWiki³ là một nền tảng cộng tác và quản lý tài liệu mã nguồn mở được phát triển và hỗ trợ bởi một cộng đồng năng động. Phần mềm này được sử dụng bởi hàng chục ngàn trang web cùng hàng ngàn công ty và tổ chức, trong đó nổi bật nhất là việc vận hành bách khoa toàn thư Wikipedia. Mục tiêu chính của MediaWiki là giúp người dùng thu thập, tổ chức kiến thức một cách khoa học và cung cấp, chia sẻ những thông tin đó đến với mọi người. Những điểm mạnh của MediaWiki có thể kể đến như sau:

- Mạnh mẽ và đáng tin cậy: Là nền tảng có khả năng xử lý lượng dữ liệu và lưu lượng truy cập khổng lồ một cách ổn định.
- Tính mở và miễn phí: MediaWiki là một phần mềm mã nguồn mở hoàn toàn tự do và miễn phí (free of charge). Điều này mang lại lợi thế to lớn cho các tổ chức, doanh nghiệp, và cả các dự án nghiên cứu khi có thể triển khai một hệ thống quản trị tri thức chuyên nghiệp mà không phải tốn kém chi phí mua bản quyền thương mại.
- Đa ngôn ngữ (Multilingual): Hệ thống hỗ trợ hàng chục ngôn ngữ khác nhau trên toàn thế giới, từ các ngôn ngữ phổ biến như Tiếng Anh, Pháp, Trung, Nhật, cho đến Tiếng Việt, giúp việc tiếp cận và phát triển nội dung trở nên dễ dàng và toàn cầu hóa.

³ <https://www.mediawiki.org/wiki/MediaWiki>

- Khả năng mở rộng và tùy biến cao: Nền tảng cho phép người dùng tùy biến cá nhân hóa (personal customisation) rất sâu, từ giao diện hiển thị, tùy chọn đọc cho đến thói quen chỉnh sửa tài liệu.

Từ những ứng dụng trên, MediaWiki được lựa chọn làm nền tảng cốt lõi để xây dựng và phát triển WikiCrop - một trang bách khoa toàn thư mở chuyên sâu về lĩnh vực nông nghiệp cây trồng. Hệ thống được định hướng trở thành nơi thu thập, tổ chức và chia sẻ tri thức về cụ thể các giống cây trồng và kỹ thuật canh tác. Để hoạt động hiệu quả nhất, sở tay mà chúng ta cài đặt cũng dựa theo chuẩn của MediaWiki để có thể hoạt động một cách trơn tru và mượt mà.

1.2.9. Các công cụ và thư viện hỗ trợ:

Trong quá trình xây dựng hệ thống, việc tận dụng các thư viện và công cụ có sẵn giúp quá trình phát triển trở nên nhanh chóng và hiệu quả hơn nhiều so với việc tự triển khai toàn bộ từ đầu. Các công cụ này cung cấp API tiện dụng và những quy trình đã được chuẩn hóa, cho phép tập trung vào nghiệp vụ chính thay vì xử lý các phần kỹ thuật lặp lại. Trong đề tài, các thư viện được sử dụng gồm:

➤ **Trafilatura**⁴

Trafilatura là một thư viện Python và công cụ dòng lệnh được thiết kế chuyên dụng để thu thập và xử lý văn bản trên môi trường web. Chức năng cốt lõi của thư viện này bao gồm khám phá liên kết, cào dữ liệu (web scraping) và trích xuất nội dung chính của các bài báo, trang web cùng với các siêu dữ liệu (metadata) và bình luận. Nó có khả năng tự động loại bỏ các thành phần nhiễu (như menu, quảng cáo) và giữ lại cấu trúc định dạng chuẩn như đoạn văn, tiêu đề hay danh sách.

➤ **Whisper (OpenAI Whisper)**⁵

Whisper là một mô hình nhận dạng giọng nói tự động (ASR) mã nguồn mở do OpenAI phát triển. Dựa trên tài liệu mã nguồn GitHub, chức năng cơ bản của hệ thống

⁴ trafilatura.readthedocs.io

⁵ openai.com/research/whisper

này là giải mã và chuyển đổi âm thanh thành văn bản (speech-to-text) với độ chính xác cao. Nó được huấn luyện trên lượng dữ liệu khổng lồ, cho phép nhận diện giọng nói trong môi trường nhiều tạp âm, xử lý nhiều ngôn ngữ khác nhau và có khả năng tự động dịch các ngôn ngữ đó sang tiếng Anh.

➤ **python-docx⁶**

python-docx là một thư viện Python chuyên dùng để tạo lập, đọc và cập nhật các tệp văn bản Microsoft Word dưới định dạng .docx. Thông qua các giao diện lập trình, người dùng có thể can thiệp sâu vào cấu trúc tài liệu tự động, bao gồm việc khởi tạo tệp trống, thêm tiêu đề, đoạn văn, chèn bảng biểu, định dạng phong cách chữ và tùy chỉnh kích thước hình ảnh chèn vào Word.

➤ **PyMuPDF⁷**

PyMuPDF là một thư viện Python mang lại hiệu suất cao, chuyên dành cho việc trích xuất dữ liệu, phân tích, chuyển đổi và thao tác với các tệp PDF cùng nhiều định dạng tài liệu khác. Thư viện này cung cấp khả năng đọc và bóc tách cấu trúc tài liệu một cách chi tiết (như lấy văn bản thô, hình ảnh, bảng biểu, siêu dữ liệu), đồng thời cho phép thao tác can thiệp lập trình như gộp, chia nhỏ tệp, thêm chú thích, bôi đen văn bản và bảo toàn định dạng bố cục.

➤ **yt-dlp⁸**

Đây là một công cụ dòng lệnh cực kỳ mạnh mẽ và giàu tính năng, chuyên dùng để tải xuống video và âm thanh. Là một bản mở rộng được bảo trì và cải tiến liên tục từ dự án youtube-dl cũ, chức năng cốt lõi của nó là cho phép người dùng tải toàn bộ video, danh sách phát, tự động trích xuất âm thanh, tải kèm phụ đề và xử lý vượt qua các rào cản như video giới hạn độ tuổi hay yêu cầu đăng nhập từ YouTube và hàng ngàn nền tảng khác.

⁶ python-docx.readthedocs.io

⁷ pymupdf.readthedocs.io

⁸ <https://github.com/yt-dlp/yt-dlp>

➤ **youtube-transcript-api**⁹

Đây là một thư viện Python cung cấp giao diện lập trình (API) để lấy trực tiếp bản ghi văn bản (transcript) hoặc phụ đề của bất kỳ video YouTube nào. Chức năng cơ bản của nó là tự động truy xuất nội dung văn bản (bao gồm cả bản do người dùng tạo thủ công hoặc bản tự động sinh của YouTube), hỗ trợ truy vấn theo nhiều mã ngôn ngữ ưu tiên và tự động dịch thuật phụ đề.

➤ **Groq API**¹⁰

Groq API là một giao diện lập trình ứng dụng cho phép các nhà phát triển truy cập và sử dụng các mô hình trí tuệ nhân tạo mạnh mẽ, được tăng tốc bởi phần cứng Groq – đặc biệt là LPU (Language Processing Unit). Với Groq API, người dùng có thể thực hiện các tác vụ xử lý ngôn ngữ tự nhiên như tạo văn bản, tóm tắt, dịch, hỏi đáp,... một cách cực kỳ nhanh chóng nhờ khả năng suy luận thời gian thực (real-time inference). Groq API hiện hỗ trợ các mô hình LLM phổ biến như LLaMA 2, Mixtral, Gemma, v.v..., với tốc độ phản hồi cực thấp, phù hợp cho cả ứng dụng web lẫn hệ thống nhúng yêu cầu hiệu năng cao. API được thiết kế đơn giản, dễ tích hợp, cho phép triển khai ứng dụng AI mà không cần lo về hạ tầng tính toán phía sau.

➤ **LangChain**¹¹

Framework này hỗ trợ xây dựng ứng dụng LLM với đầy đủ các thành phần của một RAG pipeline, bao gồm quản lý bộ nhớ, tích hợp công cụ và tổ chức luồng xử lý thống nhất. Trong phạm vi đề tài, hệ thống tận dụng công cụ RecursiveCharacterTextSplitter để chia nhỏ nội dung thành các đoạn phù hợp, giúp quá trình nhúng vector, truy vấn và trích xuất thông tin trở nên chính xác và hiệu quả hơn.

⁹ pypi.org/project/youtube-transcript-api/

¹⁰ console.groq.com/docs


¹¹ python.langchain.com

CHƯƠNG 2. THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP

2.1. Thiết kế hệ thống

2.1.1. Sơ đồ tổng quan hệ thống

Hệ thống tổng thể được mô tả trong Hình 2.1 và gồm ba thành phần chính: Frontend, Backend và Cơ sở dữ liệu.



Hình 2.1. Sơ đồ tổng quan hệ thống

Frontend được xây dựng bằng PHP nhằm đảm bảo tính tương thích với WikiCrop, hỗ trợ quá trình tích hợp và triển khai thực tế. Đây cũng đồng thời là nơi để xử lý dữ liệu được trả về và hiển thị nó với người dùng, tạo thành một giao diện thân thiện với người sử dụng.

Backend được phát triển bằng FastAPI và được tách thành ba module như sau:


- Module quản lý dữ liệu chịu trách nhiệm cung cấp các API tương tác trực tiếp với MySQL để lưu trữ dàn ý, nguồn tham khảo và bài viết của người dùng. Khi người dùng gửi các yêu cầu để lấy dữ liệu từ cơ sở dữ liệu, module sẽ xử lý và trả về phản hồi với dữ liệu tương ứng.
- Module trích xuất tài liệu xử lý toàn bộ tài liệu người dùng cung cấp. Sau khi người dùng tải tài liệu lên, hệ thống sẽ tiến hành trích xuất nội dung, tiếp đó module tiền xử lý sẽ chia nhỏ dữ liệu và vector hóa bằng mô hình paraphrase-

multilingual-MiniLM-L12-v2. Dữ liệu sau xử lý được lưu vào ChromaDB để sử dụng cho các bước tiếp theo.

- Module tạo bài viết chịu trách nhiệm sinh bài viết dựa trên dữ liệu đã lưu trong ChromaDB. Module nhận vào một dàn ý, sau đó từng mục trong dàn ý được chuyển thành câu truy vấn tối ưu bằng mô hình ngôn ngữ lớn llama-3.1-8b-instant trước khi đưa vào hệ thống truy xuất. Tại đây, truy vấn được vector hóa bằng mô hình paraphrase-multilingual-MiniLM-L12-v2 và so khớp với các vector phù hợp nhất trong ChromaDB. Những vector được chọn sẽ trở thành nguồn dữ liệu để mô hình llama-3.3-70b-versatile tạo thành các đoạn văn hoàn chỉnh. Cuối cùng, các đoạn này được tổng hợp lại thành một bài viết và trả về cho người dùng.

Về cơ sở dữ liệu, hệ thống sử dụng MySQL làm cơ sở dữ liệu chính để lưu trữ dữ liệu người dùng nhằm tương thích với MediaWiki và WikiCrop, trong khi ChromaDB được lựa chọn cho nhiệm vụ lưu trữ vector nhờ khả năng truy xuất nhanh và hiệu quả.

2.1.2. Sơ đồ cơ sở dữ liệu mức quan niệm



Hình 2.2. Sơ đồ CDM thể hiện cơ sở dữ liệu mức quan niệm

Sơ đồ cơ sở dữ liệu mức quan niệm được thể hiện ở Hình 2.2. Thông tin chi tiết về những bảng dữ liệu như sau:

➤ Bảng USER

Đây là bảng được MediaWiki sử dụng để lưu cơ sở dữ liệu người dùng, trong đó có những thông tin quan trọng như mã người dùng, tên đăng nhập và tên thật của người dùng. Các thuộc tính được thể hiện trong Bảng 2.1.

Bảng 2.1. Thực thể USER

STT	Tên	Kiểu dữ liệu	Mô tả	Khóa
1	user_id	Integer	Mã người dùng	Khóa chính
2	user_name	Varchar(255)	Tên đăng nhập	
3	user_real_name	Varchar(255)	Tên thật người dùng	

➤ Bảng SOURCES

Đây là bảng lưu lại các nguồn thông tin mà người dùng đã cho vào. Bảng sẽ quản lý các thông tin như tên nguồn, loại nguồn, ngày thêm và đường dẫn đối với nguồn là youtube hoặc bài báo. Các thuộc tính được thể hiện trong Bảng 2.2.

Bảng 2.2. Thực thể SOURCES

STT	Tên	Kiểu dữ liệu	Mô tả	Khóa
1	source_id	Integer	Mã của nguồn	Khóa chính
2	title	Varchar(255)	Tên nguồn	
3	type	Varchar(50)	Loại nguồn	
4	url_or_path	Varchar(500)	Đường dẫn của nguồn	

➤ Bảng SOURCE_CHUNKS

Mỗi nguồn được chia làm từng phần nhỏ gọi là chunk (đoạn). Bảng này sẽ hỗ trợ quản lý thông tin nội dung những phần này để có thể truy xuất nhanh chóng và hiệu quả hơn, phục vụ cho việc kiểm tra lại. Các thuộc tính được thể hiện trong Bảng 2.3.

Bảng 2.3. Thực thể SOURCE_CHUNKS

STT	Tên	Kiểu dữ liệu	Mô tả	Khóa
1	source_chunk_id	Integer	Mã chunk	Khóa chính

2	chunk_index	Varchar(255)	Mã dùng để đối chiếu trên ChromaDB	
3	content	Text	Nội dung trong chunk	
4	meta_data	Text	Thông tin vị trí của nó trong nguồn dữ liệu	

➤ **Bảng TEMPLATES**

Đây là bảng dùng để quản lý dữ liệu dàn ý. Nó sẽ lưu những thông tin quan trọng của dàn ý như tên, miêu tả và cấu trúc của dàn ý. Các thuộc tính được thể hiện trong Bảng 2.4.

Bảng 2.4. Thực thể TEMPLATES

STT	Tên	Kiểu dữ liệu	Mô tả	Khóa
1	template_id	Integer	Mã dàn ý	Khóa chính
2	name	Varchar(255)	Tên dàn ý	
3	description	Varchar(255)	Mô tả dàn ý	
4	prompt_structure	Text	Cấu trúc dàn ý lưu dưới dạng JSON	

➤ **BẢNG NOTEBOOKS**

Bảng này dùng để lưu thông tin sổ tay của người dùng. Sổ tay sẽ là nơi để người dùng thêm nguồn vào và tạo bài viết. Ngoài quản lý tên, bảng này còn liên kết với SOURCES để phân biệt người dùng đã lưu nguồn vào sổ tay nào. Các thuộc tính được thể hiện trong Bảng 2.5.

Bảng 2.5. Thực thể NOTEBOOKS

STT	Tên	Kiểu dữ liệu	Mô tả	Khóa
-----	-----	--------------	-------	------

1	notebook_id	Integer	Mã sổ tay	Khóa chính
2	name	Varchar(255)	Tên sổ tay	
3	created_at	Date	Thời điểm tạo sổ	
4	updated_at	Date	Thời điểm cập nhật sổ tay	

➤ **Bảng ARTICLES**

Bảng này dùng để lưu lại thông tin bài viết. Những thông tin bài viết được lưu là nội dung bài viết kèm theo danh sách các tham chiếu mà nó sử dụng để viết bài. Cả hai được lưu dưới dạng JSON để có thể lập qua và hiển thị một cách dễ dàng hơn trên giao diện. Các thuộc tính được thể hiện trong Bảng 2.6.

Bảng 2.6. Thực thể ARTICLES

STT	Tên	Kiểu dữ liệu	Mô tả	Khóa
1	article_id	Integer	Mã bài viết	Khóa chính
2	final_content	Text	Nội dung bài viết lưu dưới dạng JSON	
3	bibliography	Text	Danh sách tham chiếu được lưu dưới dạng JSON	
4	created_at	Date	Thời điểm tạo bài viết	


➤ **Bảng CITATION**

Đây là bảng liên kết giữa SOURCE_CHUNKS và ARTICLES, để lưu lại những chunk được sử dụng để viết bài để người dùng có thể dễ dàng kiểm tra xem nội dung chunk có phù hợp với nội dung bài viết hay không. Các thuộc tính được thể hiện trong Bảng 2.7.

Bảng 2.7. Thực thể CITATION

STT	Tên	Kiểu dữ liệu	Mô tả	Khóa
1	citation_marker	Varchar(50)	Đánh dấu nguồn	

2.1.3. Sơ đồ hệ thống trích xuất và tiền xử lý dữ liệu




Hình 2.3. Sơ đồ mô tả hệ thống trích xuất và tiền xử lý dữ liệu

Sơ đồ hệ thống tiền xử lý dữ liệu được mô tả ở Hình 2.3. Khi người dùng cung cấp tài liệu đầu vào, hệ thống có thể tiếp nhận nhiều loại dữ liệu khác nhau. Mỗi loại dữ liệu sẽ được xử lý bằng một công cụ phù hợp:

- Tập tin PDF được trích xuất nội dung bằng PyMuPDF
- Tập tin DOCX được xử lý bằng python-docx
- Trang web được thu thập nội dung bằng Trafilatura
- Tập tin âm thanh và video được chuyển giọng nói thành văn bản bằng Whisper
- Video YouTube sẽ ưu tiên lấy phụ đề qua youtube-transcript-api. Nếu không có phụ đề, hệ thống sử dụng yt-dlp để tải xuống và chuyển sang tệp âm thanh phục vụ trích xuất.

Sau khi nhận tài liệu, hệ thống trích xuất sẽ bóc tách nội dung và tạo ra các đoạn văn bản kèm theo thông tin định vị, thể hiện vị trí của từng phần thông tin trong tài liệu gốc. Các dữ liệu này được chuyển sang bước tiền xử lý để chia thành các đoạn nhỏ (chunk). Mô hình chia nhỏ được sử dụng là RecursiveCharacterTextSplitter với ý tưởng là chia các văn bản thành các phần bằng nhau. Những chunk này sau đó được vector hóa bằng mô hình embedding paraphrase-multilingual-MiniLM-L12-v2 và được lưu vào cơ sở dữ liệu vector ChromaDB để phục vụ việc truy xuất sau này.

2.1.4. Sơ đồ hệ thống tạo bài viết từ tài liệu




Hình 2.4. Sơ đồ mô tả hệ thống tạo bài viết từ tài liệu

Sơ đồ hệ thống tạo bài viết được mô tả ở Hình 2.4. Người dùng đầu tiên cung cấp một dàn ý gồm nhiều mục, mỗi mục có tiêu đề và phần mô tả chi tiết. Với từng mục trong dàn ý, hệ thống sẽ chuyển nội dung đó thành một truy vấn tìm kiếm. Truy vấn này có thể được tối ưu bằng mô hình ngôn ngữ lớn llama-3.1-8b-instant trước khi được đưa vào bước embedding. Sau khi truy vấn được mã hóa thành vector, hệ thống tìm các vector phù hợp trong ChromaDB, sau đó áp dụng bước Rerank để sắp xếp và chọn ra top-k vector liên quan nhất. Các đoạn thông tin thu được từ những vector này sẽ được mô hình llama-3.3-70b-versatile dùng làm ngữ cảnh để sinh nội dung cho từng mục trong dàn ý. Khi tất cả các đoạn nội dung đã được tạo hoàn chỉnh, hệ thống sẽ ghép lại thành một bài viết hoàn chỉnh và trả về cho người dùng.

2.2. Cài đặt giải pháp


2.2.1. Hệ thống trích xuất dữ liệu

Hệ thống trích xuất dữ liệu là thành phần giữ vai trò chuẩn bị toàn bộ tri thức đầu vào cho hệ thống. Nó chịu trách nhiệm đọc nhiều loại tài liệu khác nhau và chuyển chúng thành cấu trúc chuẩn hóa gồm nội dung văn bản và siêu dữ liệu. Trong đó, thông tin định vị (locator) được thiết kế linh hoạt tùy theo từng loại tài liệu, giúp hệ thống không chỉ lấy được nội dung mà còn truy xuất ngược chính xác vị trí của thông tin trong nguồn gốc ban đầu.




Hình 2.5. Sơ đồ quy trình trích xuất tài liệu văn bản

Đối với các tệp văn bản cục bộ như PDF hoặc DOCX, hệ thống áp dụng quy trình trích xuất riêng cho từng định dạng như Hình 2.5. PDF được xử lý thông qua thư viện PyMuPDF để đọc nội dung theo từng trang và lưu số trang làm thông tin định vị. Với tệp DOCX, thư viện python-docx được dùng để bóc tách nội dung theo từng đoạn văn và lưu chỉ số đoạn văn. Đầu ra cuối cùng của hệ thống sẽ bao gồm các khối thông tin, mỗi khối sẽ bao gồm những thông tin sau: thông tin được trích xuất, loại dữ liệu được trích xuất và vị trí thông tin được trích xuất. Đối với DOCX, loại dữ liệu được trích xuất là “docx” và vị trí thông tin được trích xuất sẽ là số thứ tự đoạn văn mà nó xuất hiện. Đối với PDF, loại dữ liệu được trích xuất là “pdf” và vị trí thông tin được trích xuất sẽ là số thứ tự trang văn bản mà nó xuất hiện.




Hình 2.6. Sơ đồ trích quy trình xuất tệp tin âm thanh và video

Đối với dữ liệu âm thanh và video cục bộ, hệ thống ứng dụng mô hình Whisper để chuyển giọng nói thành văn bản như Hình 2.6. Một điểm hay của Whisper là sau khi trích xuất âm thanh hoặc video, nó không chỉ trả về thông và còn trả về thời điểm bắt đầu và thời điểm kết thúc để xác minh vị trí của đoạn thông tin mà nó nghe được, ta có thể tận dụng điều này để lưu vào trong hệ thống, giúp việc truy xuất dễ dàng hơn. Đầu ra cuối cùng của hệ thống sẽ bao gồm các khối thông tin, mỗi khối sẽ bao gồm những thông tin sau: thông tin được trích xuất, loại dữ liệu được trích xuất (ở đây là “audio” hoặc “video”) và vị trí thông tin được trích xuất, thể hiện qua thời điểm nó bắt đầu và kết thúc trong âm thanh hoặc video (tính bằng giây). Trong hệ thống sử dụng Whisper với kích thước mô hình ở mức “base” để tối ưu thời gian trích xuất.



Hình 2.7. Sơ đồ quy trình trích xuất trang web

Khi trích xuất dữ liệu từ trang web, hệ thống sử dụng Trafilatura để tải mã HTML và tự động tách nội dung chính, loại bỏ các phần nhiễu như menu hoặc quảng cáo, quy trình được mô tả như Hình 2.7. Đầu ra cuối cùng của hệ thống sẽ bao gồm các khối thông tin, mỗi khối sẽ bao gồm những thông tin sau: thông tin được trích xuất, loại dữ liệu được trích xuất (ở đây là “web”) và vị trí thông tin được trích xuất được để trống do thông tin được truy xuất một cách liên mạch, không chia đoạn như văn bản hay thời điểm như âm thanh.




Hình 2.8. Sơ đồ quy trình trích xuất video youtube

Sơ đồ trích xuất video youtube được thể hiện ở Hình 2.8. Riêng đối với video YouTube, hệ thống triển khai quy trình hai bước nhằm tối ưu hiệu suất. Bước đầu tiên ưu tiên tải phụ đề bằng youtube-transcript-api. Cấu trúc của phụ đề youtube sẽ bao gồm thông tin, thời điểm bắt đầu và thời điểm kết thúc của thông tin đó trong video nên nếu tồn tại phụ đề, từng câu phụ đề sẽ được lưu cùng thời điểm nó bắt đầu và kết thúc để có thể định vị. Nếu video không có phụ đề, hệ thống chuyển sang cơ chế dự phòng dùng yt-dlp để tải âm thanh và chuyển đổi bằng Whisper. Đầu ra cuối cùng của hệ thống sẽ

bao gồm các khối thông tin, mỗi khối sẽ bao gồm những thông tin sau: thông tin được trích xuất, loại dữ liệu được trích xuất (ở đây là “youtube”) và vị trí thông tin được trích xuất, thể hiện qua thời điểm nó bắt đầu và kết thúc trong video (tính bằng giây).

2.2.2. Hệ thống tiền xử lý dữ liệu



Hình 2.9. Sơ đồ quy trình tiền xử lý dữ liệu

Tại bước trích xuất dữ liệu, dữ liệu thô đã được chuyển đổi thành các khối thông tin, trong đó nội dung mỗi khối gồm hai thành phần chính: phần nội dung được trích xuất và phần mô tả vị trí xuất hiện (chẳng hạn loại nguồn và vị trí cụ thể trong nguồn gốc).

Kết thúc giai đoạn trích xuất, ta chuyển sang bước tiếp theo. Mục tiêu của bước này là biến các khối thông tin thành dạng tri thức có thể sử dụng được. Điều này được thực hiện bằng cách chia nhỏ các khối quá dài, sau đó chuyển đổi nội dung thành vector ngữ nghĩa để phù hợp cho quá trình truy xuất, rồi lưu toàn bộ vào ChromaDB để phục vụ sử dụng về sau. Quy trình tiền xử lý được mô tả trong Hình 2.9.

Quy trình này được thực thi bằng cách lặp qua từng khối thông tin đã trích xuất, trong đó nội dung trích xuất của mỗi khối sẽ đi qua hai bước xử lý chính: chia nhỏ khối thông tin, vector hóa dữ liệu và lưu vào ChromaDB.

➤ Bước 1: Chia nhỏ khối thông tin

Mục tiêu bước này là chia nhỏ khối thông tin quá dài gây khó khăn cho việc xử lý. Phương pháp được lựa chọn là cửa sổ trượt (Sliding Window Chunking). Cụ thể, ở đây nó được thực hiện bằng cách xét xem độ dài của nội dung trong khối thông tin có vượt

quá 800 ký tự hay không, nếu có nó sẽ thực hiện chia nhỏ dữ liệu trong nội dung và khối thông tin ra làm hai khối nhỏ hơn.

Đầu tiên là chia nội dung thành 800 ký tự, nhưng điều thú vị là nó còn kèm thêm 100 ký tự từ dữ liệu kế tiếp, giúp cho không bị mất ngữ nghĩa. Việc ngắt được đảm bảo bởi công cụ RecursiveCharacterTextSplitter. Công cụ này sẽ chia nhỏ đoạn văn bản dựa trên các ký tự ngắt câu tự nhiên (như dấu chấm, xuống dòng), giúp hạn chế việc mất đi ngữ nghĩa trong bài. Tiếp theo, nó sẽ tách khối thông tin ban đầu thành hai khối thông tin với lượng thông tin nhỏ hơn, những thông tin khác trong khối như thông tin vị trí thì sẽ vẫn được giữ nguyên. Sau khi kết thúc bước này, ta sẽ thu được nhiều khối thông tin với nội dung nhỏ hơn, phục vụ tốt hơn cho quá trình biểu diễn dữ liệu.

➤ **Bước 2: Vector hóa dữ liệu và lưu vào ChromaDB**

Sau khi được chia nhỏ, các dữ liệu từ các khối thông tin này sẽ được chuẩn bị để lưu vào trong cơ sở dữ liệu vector, cụ thể quy trình như sau:


- Vector hóa nội dung: tiến hành sử dụng mô hình paraphrase-multilingual-MiniLM-L12-v2 để chuyển từ nội dung sang vector, phục vụ cho quá trình chuyển đổi dễ dàng hơn
- Bổ sung thêm thông tin vị trí: thêm vào vị trí những thông tin liên quan đến số tay mà nó đang sử dụng và thông tin liên quan đến nguồn dữ liệu của nó để phục vụ cho việc truy xuất và viết bài. Những thông tin như loại nguồn và vị trí của nó trong nguồn đều được giữ nguyên.

Sau những bước xử lý trên, ta thu được danh sách khối thông tin đã tiền xử lý, gồm các thông tin sau:

- Nội dung trích xuất: nội dung được trích xuất từ dữ liệu ban đầu
- Nội dung đã được vector hóa: vector thể hiện nội dung được nhúng bởi mô hình paraphrase-multilingual-MiniLM-L12-v2
- Thông tin vị trí xuất hiện: lưu các thông tin mà nội dung xuất hiện như là thông tin về nguồn dữ liệu và thông tin số tay, đồng thời lưu vị trí mà nội dung xuất hiện (locator)

Sau quá trình này, ta thu được các khối thông tin kèm theo nội dung đã được vector hóa kèm theo thông tin để truy ngược vị trí của nó dễ dàng hơn. Cuối cùng, toàn bộ các khối tin này được lưu vào trong cơ sở dữ liệu vector ChromaDB.

2.2.3. Cài đặt cấu trúc dàn ý




Hình 2.10. Sơ đồ cấu trúc dàn ý

Sơ đồ dàn ý được mô tả trong Hình 2.10. Cấu trúc dàn ý gồm ba phần chính: tên dàn ý, mô tả dàn ý và danh sách các mục. Tên dàn ý dùng để phân biệt giữa các dàn ý khác nhau. Mô tả dàn ý cung cấp thông tin bổ sung về mục đích hoặc phạm vi của dàn ý.

Một dàn ý sẽ bao gồm nhiều mục nhỏ. Ví dụ, đối với bài viết về cây trồng, các mục thường gặp là giới thiệu, đặc điểm, cách trồng. Những mục này giúp chia nội dung thành các phần rõ ràng, dễ đọc và đảm nhận từng nhóm thông tin cụ thể để bài viết trở nên đầy đủ hơn. Trong hệ thống, mỗi mục gồm hai thành phần: tiêu đề và mô tả. Tiêu đề thể hiện tên mục, còn phần mô tả giúp hệ thống hiểu chi tiết hơn để tạo nội dung chính xác.

Toàn bộ các mục được tổ chức thành một danh sách thống nhất để thuận tiện cho quản lý và truy xuất.

2.2.4. Hệ thống tạo bài viết



Hình 2.11. Sơ đồ quy trình tạo bài viết

Sơ đồ tạo bài viết được mô tả ở Hình 2.11. Ý tưởng của quy trình tạo bài viết là mỗi dàn ý được cấu thành từ nhiều mục, trong đó mỗi mục gồm tiêu đề và phần mô tả. Hệ thống sẽ xử lý từng mục độc lập, đưa chúng qua hệ thống tạo đoạn văn để sinh ra đoạn văn tương ứng cùng danh sách nguồn đã được sử dụng trong quá trình tạo đoạn văn đó. Khi ghép toàn bộ các đoạn văn lại, hệ thống thu được một bài viết hoàn chỉnh dựa trên dàn ý ban đầu.

Đầu tiên, để quá trình xử lý mượt hơn và giúp mô hình hiểu đúng nội dung, hệ thống cần bổ sung ngữ cảnh (context). Ngữ cảnh đóng vai trò cung cấp cái nhìn chung về toàn bộ bài, giúp AI nắm được chủ đề tổng quát trước khi đi vào từng mục chi tiết. Trong quy trình này, hệ thống chọn ngẫu nhiên khoảng 10 đoạn (chunk) từ bài gốc, ghép chúng lại thành một đoạn văn liền mạch và sử dụng đoạn ngữ cảnh này làm thông tin nền cho mô hình trong giai đoạn tạo bài viết.


Tiếp theo, từng mục trong dàn ý (gồm tiêu đề vào phần miêu tả) sẽ được đưa qua hệ thống tạo đoạn văn. Quy trình tạo đoạn văn sẽ gồm ba bước chính: tạo và mở rộng truy vấn cho từng mục dàn ý, truy xuất dữ liệu từ cơ sở dữ liệu vector và cuối cùng là sử dụng LLM để tổng hợp lại thành một đoạn văn.

➤ Bước 1: Tạo và mở rộng truy vấn cho từng mục dàn ý

Mục tiêu chính của bước này là chuyển một mục trong dàn ý thành một câu truy vấn đủ rõ ràng và đầy đủ ý nghĩa, nhằm phục vụ quá trình tìm kiếm trong cơ sở dữ liệu

vector và cung cấp nền tảng thông tin cho việc tổng hợp thành đoạn văn ở bước tiếp theo. Hệ thống sử dụng tiêu đề và phần mô tả của từng mục để tạo truy vấn, nhưng vì thông tin ban đầu đôi khi chưa đủ chi tiết nên cần tối ưu lại để nâng cao chất lượng tìm kiếm. Để làm điều này, mô hình ngôn ngữ lớn llama-3.1-8b-instant được dùng để mở rộng và diễn giải lại tiêu đề cùng mô tả thành một câu truy vấn dài và đầy đủ nội dung hơn. Tham số của mô hình là temperature (nhiệt độ) được đặt ở mức 0.3 để mô hình có thể suy luận linh hoạt hơn nhưng vẫn giữ được sự nhất quán với ngữ cảnh đã cung cấp.

Một ví dụ minh họa cho quá trình tạo và tối ưu truy vấn được thể hiện ở Hình 2.12. Nếu chỉ dựa vào tiêu đề và phần mô tả của mục, câu truy vấn tạo ra thường quá ngắn hoặc thiếu thông tin, dẫn đến việc truy xuất không hiệu quả trong ChromaDB. Vì vậy, hệ thống cần đảm nhận thêm nhiệm vụ tổng hợp và mở rộng nội dung này, từ đó tạo ra một câu truy vấn đầy đủ và tối ưu hơn để tìm được đúng các khối thông tin cần thiết.



Hình 2.12. Ví dụ về tạo và mở rộng truy vấn


➤ Bước 2: Truy xuất dữ liệu từ cơ sở dữ liệu vector

Mục tiêu của bước này là lấy dữ liệu từ ChromaDB phù hợp với câu truy vấn đã lưu từ trước đó. Đầu tiên, hệ thống lấy ra một lượng lớn ứng viên tiềm năng (20 đoạn), sau đó dùng một mô hình chấm điểm thông minh hơn để lọc lại 5 đoạn tốt nhất. Được diễn ra tuần tự qua các giai đoạn như sau:

- **Giai đoạn mã hóa (Embedding):** Hệ thống chuyển đổi tiêu đề (query) từ dạng văn bản sang dạng vector toán học sử dụng mô hình nhúng paraphrase-multilingual-MiniLM-L12-v2. Điều này cho phép máy tính có thể "so sánh" ý nghĩa ngữ nghĩa giữa câu hỏi của người dùng và các tài liệu trong cơ sở dữ liệu.

- **Giai đoạn truy xuất (Retrieval):** Hệ thống thực hiện tìm kiếm nhanh trong không gian vector (ChromaDB) để lấy ra 20 kết quả có độ tương đồng gần nhất. Đây là bước lọc thô, ưu tiên tốc độ để thu hẹp phạm vi tìm kiếm từ hàng nghìn đoạn xuống còn vài chục đoạn.
- **Giai đoạn tái xếp hạng (Reranking):** Đây là bước quan trọng nhất của đoạn code. Hệ thống sử dụng một mô hình chuyên biệt (Cross-Encoder) để chấm điểm lại từng cặp câu hỏi và tài liệu. Ở bước này mô hình phân tích sâu sắc mối quan hệ ngữ nghĩa giữa câu hỏi và từng đoạn văn bản. Kết quả là một danh sách các điểm số (scores), thể hiện mức độ liên quan thực sự của tài liệu.
- **Giai đoạn sắp xếp và chọn lọc (Top-k):** Dựa trên điểm số mới từ bước Rerank, hệ thống tiến hành sắp xếp lại toàn bộ danh sách theo thứ tự từ cao xuống thấp và chọn ra 5 kết quả đứng đầu. Đây là những thông tin quan trọng nhất và có khả năng đáp ứng chính xác yêu cầu của truy vấn.
- **Giai đoạn chuẩn hóa đầu ra (Formatting):** Cuối cùng, dữ liệu được đóng gói lại thành cấu trúc gồm nội dung văn bản (content) và vị trí (metadata) để sẵn sàng đưa vào mô hình ngôn ngữ lớn (LLM) để viết bài.

Quy trình truy xuất dữ liệu được thể hiện ở Hình 2.13.




Hình 2.13. Quy trình truy vấn dữ liệu

➤ Bước 3: Sử dụng LLM để tổng hợp thành đoạn văn

Quy trình viết bài và lưu vị trí được thể hiện ở Hình 2.14. Sau khi hoàn tất quá trình thu thập và chọn lọc thông tin, hệ thống sẽ tách dữ liệu thành hai phần: nội dung đã tổng hợp và vị trí tương ứng của các thông tin đó. Tiếp theo, phần nội dung tổng hợp được đưa vào mô hình LLM llama-3.3-70b-versatile để tạo thành đoạn văn hoàn chỉnh, với tham số temperature được giữ ở mức 0.1 nhằm đảm bảo văn bản viết ra chính xác, hạn chế phát sinh thông tin không cần thiết.


Vị trí tổng hợp sẽ được xử lý theo quy trình đánh số thứ tự. Các tham chiếu bắt đầu từ số 1. Mỗi khi xuất hiện một vị trí mới (chẳng hạn như cùng một tài liệu nhưng ở đoạn khác, hoặc một tài liệu hoàn toàn khác), hệ thống sẽ tăng số thứ tự lên.

Hệ thống duy trì một danh sách các vị trí đã được sử dụng trong bài. Nếu một vị trí trùng với vị trí đã có trong danh sách, hệ thống sẽ dùng lại số thứ tự cũ. Nếu là vị trí mới, hệ thống sẽ tạo một số thứ tự mới và thêm vào danh sách. Cách làm này đảm bảo mỗi tham chiếu đều có số thứ tự riêng, không bị trùng lặp. Cuối cùng, vị trí đã xử lý sẽ được lưu vào danh sách để phục vụ cho các bước tiếp theo.



Hình 2.14. Quy trình viết bài và lưu vị trí

Sau khi hoàn tất toàn bộ quy trình, hệ thống thu được một đoạn văn cùng danh sách các vị trí tương ứng với những khối thông tin đã được sử dụng để tạo ra đoạn văn đó. Nhờ vậy, người dùng có thể dễ dàng đối chiếu và kiểm tra lại nguồn gốc của từng phần nội dung. Một ví dụ minh họa cho đoạn văn và danh sách vị trí đã được sắp xếp có thể xem ở Hình 2.15.



Hình 2.15. Ví dụ về đoạn văn và danh sách vị trí

2.2.5. Xây dựng giao diện người dùng

Đầu tiên, dữ liệu được lưu vào MySQL của WikiCrop. Việc lưu cần tuân theo một cấu trúc chuẩn để dễ truy xuất và quản lý. Đây là nơi chứa toàn bộ dữ liệu riêng của

người dùng như dàn ý, nguồn đã thêm, bài viết đã tạo,... giúp người dùng không bị mất dữ liệu và có thể quay lại sử dụng ứng dụng bất cứ lúc nào.

Sau khi hoàn tất phần lưu trữ, ta thiết lập FastAPI để làm backend cho tiện ích mở rộng. Backend này gồm hai nhóm API chính. Một nhóm API dùng để quản lý cơ sở dữ liệu, tương tác trực tiếp với MySQL nhằm lưu và truy xuất thông tin người dùng hiệu quả hơn. Nhóm API còn lại phục vụ việc trích xuất tài liệu và tạo bài viết, bao gồm xử lý dữ liệu đầu vào và lưu vào ChromaDB cũng như sinh bài viết dựa trên dàn ý đã có.


Cuối cùng, ta xây dựng giao diện cho WikiCrop dưới dạng một extension (phần mở rộng). Vì MediaWiki chạy bằng PHP nên giao diện cũng được viết bằng PHP để đồng bộ và thuận tiện trong tích hợp. Lớp giao diện này tương tác trực tiếp với backend FastAPI, giúp toàn bộ hệ thống hoạt động ổn định và liền mạch.

2.2.6. Phương pháp đánh giá hệ thống trích xuất

Mục tiêu đánh giá là kiểm tra mức độ chính xác của hệ thống truy xuất. Đây là yếu tố then chốt để xác định các bước xử lý phía sau có vận hành hiệu quả hay không. Để thực hiện, ta chuẩn bị hai phần:

- Dữ liệu gốc: tập tin chứa nội dung chưa qua trích xuất.
- Dữ liệu đã trích xuất chính xác: thông tin được trích xuất đúng từ dữ liệu gốc.

Tiếp theo, hệ thống trích xuất sẽ được sử dụng để trích xuất dữ liệu từ tập tin gốc. Kết quả thu được sẽ được so sánh với dữ liệu đã trích xuất chính xác bằng cách tính Similariy Score. Điểm Similarity Score càng cao thì mức độ tương đồng giữa hai nguồn càng lớn, đồng nghĩa với việc hệ thống trích xuất hoạt động càng chính xác và hiệu quả. Sơ đồ đánh giá hệ thống trích xuất được thể hiện ở Hình 2.16.




Hình 2.16. Sơ đồ hệ thống đánh giá việc trích xuất dữ liệu

2.2.7. Phương pháp đánh giá hệ thống tạo bài viết

Mục tiêu của phương pháp là kiểm tra xem các bài viết do hệ thống tạo ra có trích dẫn đúng từ các tài liệu gốc hay không. Nếu bài viết chứa nhiều thông tin không có trong tài liệu, tức là xuất hiện ảo giác (hallucination), thì bài viết đó không thể sử dụng. Quy trình đánh giá được tiến hành bằng cách thu thập một bài viết Wikipedia tiếng Việt có đầy đủ các nguồn còn truy cập được, đưa toàn bộ các nguồn này vào hệ thống để tạo lại bài viết, sau đó đánh giá kết quả dựa trên các tiêu chí đã đề ra. Các chỉ số đánh giá được sử dụng là Citation Recall, Citation Precision và Claim Recall.

➤ Citation Recall

Mục tiêu của bước này là xác định bài viết có sử dụng đúng nội dung từ nguồn hay không. Đây là tiêu chí quan trọng nhất vì giúp phát hiện các trường hợp ảo giác. Phương pháp thực hiện dựa trên việc mỗi đoạn văn được sinh ra đều kèm theo nguồn trích dẫn. Hệ thống sử dụng mô hình NLI mDeBERTa-v3-base-mnli-xnli để kiểm tra xem nội dung của đoạn văn có thực sự xuất hiện trong các nguồn đó hay không. Ví dụ về đánh giá Citation Recall được thể hiện ở Hình 2.17.




Hình 2.17. Ví dụ về đánh giá Citation Recall

➤ Citation Precision

Mục tiêu của bước này là kiểm tra xem bài viết có trích dẫn dư thừa hay không. Phương pháp thực hiện bằng cách với mỗi đoạn văn kèm theo các nguồn trích dẫn, hệ thống lần lượt loại bỏ từng nguồn rồi dùng mô hình NLI mDeBERTa-v3-base-mnli-


xnli để kiểm tra xem nội dung đoạn văn có còn được hỗ trợ đầy đủ bởi các nguồn còn lại hay không. Nếu một nguồn bị loại mà NLI vẫn xác nhận đoạn văn được hỗ trợ đúng và đầy đủ, nguồn đó được xem là dư thừa. Ví dụ về đánh giá Citation Precision được thể hiện ở Hình 2.18.



Hình 2.18. Ví dụ về đánh giá Citation Precision

➤ Claim Recall

Mục tiêu của bước này là kiểm tra mức độ đầy đủ nội dung của bài viết, chỉ số càng cao thì bài viết càng đủ ý và cho thấy khả năng truy xuất của hệ thống tốt hơn. Cách đánh giá được thực hiện bằng cách chia bài viết gốc thành các mệnh đề thông qua việc tách từng câu bằng ngôn ngữ mô hình lớn llama-3.3-70b-versatile với tham số temperature đặt ở mức 0.1 để tránh sinh nội dung không cần thiết và chỉ giữ lại ý chính. Sau đó hệ thống kiểm tra xem bao nhiêu mệnh đề xuất hiện trong bài viết được tạo, sử dụng mô hình mDeBERTa-v3-base-mnli-xnli để xác định liệu các mệnh đề này có thực sự xuất hiện trong bài viết sinh ra hay không. Ví dụ về đánh giá Claim Recall được thể hiện ở Hình 2.19.




Hình 2.19. Ví dụ về đánh giá Claim Recall

CHƯƠNG 3. KIỂM THỬ VÀ ĐÁNH GIÁ

3.1. Giao diện sản phẩm

3.1.1. Giao diện trang chủ

Đây là nơi người dùng truy cập vào đầu tiên khi sử dụng sổ tay. Đây là nơi trung gian giúp người dùng đi đến những chức năng khác như quản lý nguồn, quản lý dàn ý và quan trọng nhất là quản lý sổ tay. Hình ảnh giao diện được thể hiện ở Hình 3.1.



Hình 3.1. Giao diện trang chủ


Các thành phần của trang chủ có thể được trình bày như sau:

Bảng 3.1. Thành phần trong trang chủ

STT	Thành phần	Mô tả
1	Nút cài đặt dàn ý	Chuyển đến trang cài đặt dàn ý, giúp người dùng quản lý những dàn ý đã tạo
2	Nút cài đặt nguồn	Chuyển đến trang cài đặt nguồn, giúp người dùng quản lý những nguồn đã thêm vào
3	Danh sách sổ tay	Danh sách những sổ tay người dùng đã tạo, kèm thêm một nút giúp người dùng tạo thêm sổ tay mới

3.1.2. Giao diện sổ tay

Khi tạo một sổ tay mới hoặc khi nhấn vào một sổ tay đã tạo, người dùng sẽ được chuyển đến trang sổ tay. Tại đây cấu trúc được chia làm 3 phần: phần thêm nguồn, phần chọn dàn ý và hiển thị bài viết, cuối cùng là phần thao tác với bài viết và sổ tay. Khi truy cập vào trang này, người dùng sẽ tiến hành thêm nguồn, sau đó chọn dàn ý và hệ thống sẽ tạo bài viết tự động từ nguồn người dùng đã thêm vào. Cuối cùng người dùng có thể chỉnh sửa nội dung, lưu bài viết hoặc gửi bài viết lên hệ thống WikiCrop. Bên cạnh đó người dùng có thể xóa sổ tay nếu thấy không cần thiết. Hình ảnh giao diện sổ tay được thể hiện ở Hình 3.2.



Hình 3.2. Giao diện sổ tay

Các thành phần của sổ tay có thể được trình bày như sau:

Bảng 3.2. Các thành phần trong trang sổ tay

STT	Thành phần	Mô tả
1	Phần thêm nguồn	Phần này sẽ giúp người dùng thêm nguồn và xem lại những nguồn mình đã thêm
2	Phần chọn dàn ý và tạo bài viết	Phần này sẽ giúp người dùng chọn dàn ý sao đó tạo bài viết. Bài được tạo cũng sẽ hiển thị ở đây.

3	Phản thao tác với bài viết và sổ tay	Phần này sẽ giúp người dùng chỉnh sửa, lưu lại hoặc chia sẻ bài viết. Người dùng cũng có thể xóa sổ tay nếu thấy không cần thiết
---	--------------------------------------	--

3.1.2.1. Giao diện phần thêm nguồn

Đây là nơi để người dùng thêm nguồn vào để tiến hành xử lý. Nó gồm một nút “Thêm nguồn mới”, khi nhấn vào thì nó sẽ hiển thị một cửa sổ để người dùng có thể nhập đường dẫn (đối với tài liệu youtube hoặc tài liệu web) hoặc cũng có thể tải lên những tài liệu văn bản, tài liệu âm thanh hoặc video. Khi đã thêm nguồn thành công thì thông tin và trạng thái xử lý của nguồn sẽ được thêm vào danh sách bên dưới cho người dùng tiện theo dõi hơn. Hình ảnh giao diện được trình bày ở Hình 3.3.



Hình 3.3. Giao diện phần thêm nguồn trong sổ tay

Các thành phần của giao diện được trình bày như sau:

Bảng 3.3. Các thành phần trong phần thêm nguồn trong sổ tay


STT	Thành phần	Mô tả
1	Nút thêm nguồn mới	Khi nhấn vào sẽ hiển thị cửa sổ nhập
2	Danh sách nguồn	Nơi hiển thị thông tin và trạng thái của nguồn

3	Phần thêm đường dẫn	Dùng để thêm đường dẫn đối với dạng dữ liệu youtube và web
4	Phần thêm tập tin	Dùng để thêm tập tin văn bản (docx hoặc pdf), âm thanh (mp3) hoặc video (mp4)

3.1.2.2. Giao diện phần quản lý dàn ý và bài viết

➤ Giao diện phần quản lý dàn ý

Đây là phần giúp người dùng chọn dàn ý cho bài viết của mình. Khi nhấn vào nút “Bấm chọn dàn ý”, một cửa sổ sẽ hiện ra. Cửa sổ này gồm có hai phần: phần bên trái cho người dùng tạo một dàn ý mới, phần bên phải cho phép chọn dàn ý có sẵn. Thiết kế này sẽ hỗ trợ người dùng vừa có thể tạo dàn ý theo ý muốn, vừa có thể tái sử dụng những dàn ý cũ để tiết kiệm thời gian. Hình ảnh giao diện được thể hiện ở Hình 3.4.



Hình 3.4. Giao diện quản lý dàn ý trong sổ tay


Các thành phần có thể được trình bày như sau:

Bảng 3.4. Thành phần cho việc quản lý dàn ý trong sổ tay

STT	Thành phần	Mô tả
1	Nút chọn dàn ý	Dùng để hiển thị cửa sổ chọn dàn ý
2	Phần hiển thị tên dàn ý đã chọn	Hiển thị tên dàn ý đã chọn để người dùng tiện theo dõi
3	Biểu mẫu thêm dàn ý mới	Giúp người dùng có thể thêm dàn ý mới nhanh chóng thông qua thêm tên và cấu trúc dàn ý
4	Danh sách dàn ý	Gồm thanh tìm kiếm và danh sách dàn ý đã tạo để người dùng thuận tiện hơn trong việc lựa chọn

➤ **Giao diện tạo và hiển thị bài viết**

Ngay dưới phần chọn dàn ý là phần tạo và hiển thị bài viết. Tại đây người dùng có thể nhấn nút “Tạo bài viết” để tạo bài viết và bài viết sẽ được hiển thị ngay bên dưới. Hình ảnh của giao diện được thể hiện ở Hình 3.5.



Hình 3.5. Giao diện tạo và hiển thị bài viết trong sổ tay


Danh sách các thành phần được thể hiện như sau:

Bảng 3.5. Thành phần cho việc tạo và hiển thị bài trong sổ tay

STT	Thành phần	Mô tả
1	Nút tạo bài viết	Giúp người dùng có thể tạo bài viết
2	Phần hiển thị bài viết	Hiển thị bài viết cho người dùng

3.1.2.3. Giao diện phần thao tác với bài viết

Sau khi tạo bài viết, người dùng có thể thao tác với bài viết và sổ tay. Người dùng có thể chỉnh sửa nội dung, lưu bài viết hoặc gửi bài viết lên hệ thống WikiCrop. Bên cạnh đó người dùng có thể xóa sổ tay nếu thấy không cần thiết. Hình ảnh giao diện được thể hiện ở Hình 3.6.



Hình 3.6. Giao diện phần tương tác với bài viết trong sổ tay


Các thành phần của giao diện được trình bày như sau:

Bảng 3.6. Thành phần cho việc tương tác trong sổ tay

STT	Thành phần	Mô tả
1	Nút sửa nội dung	Khi nhấn vào, nó sẽ vào chế độ chỉnh sửa và giúp người dùng có thể chỉnh sửa bài viết
2	Nút xóa sổ tay	Khi nhấn vào, nó sẽ xóa sổ tay hiện tại và đưa người dùng về trang chủ
3	Nút lưu thay đổi	Khi nhấn vào, nó sẽ lưu bài viết
4	Nút gửi bài viết	Khi nhấn vào, bài viết sẽ được gửi và được quản trị viên WikiCrop xem xét trước khi được tải lên hệ thống

3.1.3. Giao diện phần cài đặt quản lý dàn ý

Tại giao diện này người dùng có thể quản lý dàn ý một cách thuận tiện hơn nhờ giao diện gồm hai phần: bên trái là danh sách các dàn ý đã tạo, hỗ trợ tìm kiếm và xem lại nội dung còn bên phải là biểu mẫu nhập liệu cho phép người dùng tạo một dàn ý mới nhanh chóng. Hình ảnh giao diện được thể hiện ở Hình 3.7.



Hình 3.7. Giao diện phần quản lý dàn ý


Các thành phần giao diện có thể được trình bày như sau:

Bảng 3.7. Thành phần trong phần cài đặt dàn ý

STT	Thành phần	Mô tả
1	Phần tìm kiếm và danh sách dàn ý	Hỗ trợ người dùng tìm kiếm dàn ý và hiển thị danh sách những dàn ý mà họ đã tạo
2	Biểu mẫu tạo dàn ý mới	Hỗ trợ người dùng tạo một dàn ý mới bằng cách điền các thông tin như tên và miêu tả dàn ý, đồng thời thêm cả cấu trúc của dàn ý

3.1.4. Giao diện phần cài đặt nguồn

Tại giao diện này người dùng có thể quản lý dàn ý thuận tiện hơn thông qua giao diện gồm hai phần: bên trái là danh sách các dàn ý đã tạo, hỗ trợ tìm kiếm và xem lại còn bên phải là biểu mẫu nhập thông tin để tạo dàn ý mới một cách nhanh chóng. Giao diện được thể hiện ở Hình 3.8.



Hình 3.8. Giao diện phần quản lý nguồn

Các thành phần của giao diện có thể được thể hiện như sau:

Bảng 3.8. Thành phần trong phần quản lý nguồn

STT	Thành phần	Mô tả
1	Phần chọn sổ tay và nguồn dữ liệu	Gồm một thanh giúp người dùng chọn sổ tay, sau khi chọn sổ tay thì người dùng có thể tiếp tục chọn nguồn dữ liệu họ muốn chỉnh sửa. Thông tin chi tiết của nguồn có thể được hiển thị ở phần dưới cùng
2	Phần danh sách các chunk	Gồm một bảng dữ liệu giúp người dùng xem và quản lý những chunk mà nguồn dữ liệu này trích xuất
3	Phần nội dung chi tiết chunk	Hiển thị thông tin chi tiết về nội dung và vị trí của chunk trong nguồn dữ liệu

3.2. Kết quả thực nghiệm

3.2.1. Đánh giá hệ thống truy xuất.

➤ Tập dữ liệu đánh giá

Dữ liệu được thu thập từ nhiều nguồn và nhiều loại khác nhau có thể đánh giá hệ thống trích xuất một cách chính xác nhất, cụ thể như sau:

- Đối với dữ liệu website: Tổng cộng 30 bài báo được thu thập từ các nguồn tin phổ biến tại Việt Nam như VNExpress, Báo Dân Trí,... Chủ đề chủ yếu liên quan đến nông nghiệp, một số bài thuộc các lĩnh vực khác. Dữ liệu gốc là đường dẫn đến bài báo, còn dữ liệu trích xuất chính xác là nội dung được sao chép trực tiếp từ trang nguồn.
- Đối với dữ liệu file âm thanh: 30 đoạn âm thanh đọc từ báo Dân Trí được sử dụng. Dữ liệu gốc là file âm thanh định dạng mp3, còn dữ liệu trích xuất chính xác là nội dung được sao chép từ bài báo gốc.
- Đối với dữ liệu tập tin văn bản: 30 tập tin văn bản gồm 15 tập tin PDF và 15 tập tin DOCX liên quan đến lĩnh vực nông nghiệp. Dữ liệu gốc là các tập tin văn bản, còn dữ liệu trích xuất chính xác là nội dung được sao chép trực tiếp từ các tập tin này.
- Đối với dữ liệu video: 30 video YouTube có phụ đề được chính chủ kênh cung cấp được lựa chọn. Dữ liệu gốc là file video định dạng mp4, còn dữ liệu trích xuất chính xác được lấy từ phần phụ đề gốc của video.

Bảng 3.9. Chi tiết tập dữ liệu đánh giá trích xuất

Loại dữ liệu	Số tập tin	Nguồn dữ liệu
Dữ liệu website	30	Các nguồn báo lớn tại Việt Nam
Dữ liệu tập tin âm thanh	30	Các nguồn báo lớn tại Việt Nam
Dữ liệu tập tin văn bản	30	Các tập tin liên quan đến nông nghiệp từ WikiCrop

Dữ liệu tập tin video	30	Nhiều nguồn video youtube khác nhau
-----------------------	----	-------------------------------------

➤ Kết quả đánh giá và nhận xét

Kết quả được trình bày như bảng dưới đây

Bảng 3.10. Kết quả đánh giá hệ thống trích xuất

Loại dữ liệu	Similarity Score trung bình
Dữ liệu website	0.97
Dữ liệu tập tin âm thanh	0.9
Dữ liệu tập tin văn bản	1.00
Dữ liệu tập tin video	0.82

Có thể thấy kết quả đều lớn hơn 0.8, cho thấy mô hình hệ thống hoạt động tốt. Điều này cho thấy dữ liệu hệ thống trích xuất trùng với dữ liệu của chúng ta. Đặc biệt cao nhất ở loại dữ liệu văn bản với Similarity Score lên đến 1.00, cho thấy sự tối ưu của thư viện trong việc trích xuất các tài liệu loại này. Đồng thời do việc trích xuất chủ yếu lọc văn bản từ tập tin nên kết quả cũng cho ra vô cùng chính xác. Tổng kết lại, hệ thống có khả năng trích xuất tốt dữ liệu và sẵn sàng để tham gia vào hệ thống tạo bài viết.

3.2.2. Đánh giá hệ thống tạo bài viết

➤ Tập dữ liệu đánh giá

Wikipedia được lựa chọn làm nguồn dữ liệu vì đây là nền tảng mở, miễn phí, nơi nội dung được biên soạn dựa trên các tài liệu tham khảo rõ ràng. Các bài viết tại đây đáp ứng đầy đủ những yếu tố cần thiết cho quá trình đánh giá, đặc biệt là tính minh bạch về nguồn trích dẫn. Dựa trên nguyên tắc chỉ sử dụng các nguồn vẫn còn truy cập được, sau khi sàng lọc, tổng số bài viết thu thập được là 18 bài, chủ yếu thuộc lĩnh vực nông nghiệp nhưng cũng bao gồm thêm một số chủ đề khác do số lượng bài viết liên quan trên Wikipedia tiếng Việt còn hạn chế. Ngoài các bài về nông nghiệp, dữ liệu còn bổ sung thêm nhóm chủ đề về các loại bánh dân gian.

➤ Kết quả đánh giá

Kết quả đánh giá hệ thống tạo bài viết có thể được trình bày tại bảng sau:

Bảng 3.11. Kết quả đánh giá hệ thống tạo bài viết

Chỉ số đánh giá	Giá trị trung bình
Citation Recall	0.94
Citation Precision	0.94
Claim Recall	0.92

Kết quả đánh giá cho thấy hệ thống đạt Citation Recall là 0.94, phản ánh khả năng sử dụng đúng nội dung từ nguồn ở mức tốt. Chỉ số Citation Precision đạt 0.94 cho thấy các nguồn được trích dẫn khá đầy đủ và không bị thừa. Bên cạnh đó, Claim Recall đạt 0.92 chứng minh bài viết bao quát tốt các ý chính cần có. Từ các chỉ số này có thể kết luận rằng hệ thống hoạt động hiệu quả trong việc tạo bài viết bám sát tài liệu gốc và đảm bảo mức độ đầy đủ về nội dung.

3.2.3. Đánh giá hoạt động giao diện:

Hệ thống hoạt động ổn định, không xuất hiện lỗi nghiêm trọng ảnh hưởng đến chức năng cốt lõi, đồng thời đảm bảo khả năng đáp ứng các yêu cầu đặt ra. Điều này cho thấy ứng dụng có thể vận hành hiệu quả trong môi trường thực tế, mang lại trải nghiệm tốt cho người dùng và hỗ trợ tối ưu trong việc quản lý và tạo bài viết.

III. PHẦN KẾT LUẬN

1. Kết quả đạt được

Đề tài đã xây dựng một hệ thống hỗ trợ người dùng chuyển đổi dữ liệu thô thành thông tin có cấu trúc và tạo ra các bài viết hoàn chỉnh dựa trên dàn ý do người dùng cung cấp. Đây được xem như một sổ tay cá nhân dành cho người dùng WikiCrop, nơi họ có thể tổng hợp thông tin của mình thành các bài viết hoàn thiện một cách hiệu quả.

Hệ thống có khả năng trích xuất dữ liệu từ nhiều loại nguồn đầu vào khác nhau, bao gồm tệp văn bản, dữ liệu đa phương tiện, trang web và video YouTube với độ chính xác lên đến 100%. Khả năng trích xuất tốt tạo nền tảng vững chắc để người dùng xử lý nhiều dạng tài liệu, đồng thời đảm bảo chất lượng và độ chính xác cho các bài viết được tạo ra.

Hệ thống tạo bài viết cũng cho thấy hiệu quả rõ rệt khi nội dung được tổng hợp từ các thông tin liên quan trong dữ liệu nguồn và đi kèm tham chiếu chi tiết cho từng phần, giúp người dùng kiểm tra và xác thực thông tin thuận tiện. Với các chỉ số đánh giá gồm Citation Recall đạt 0.94, Citation Precision đạt 0.94 và Claim Recall đạt 0.92, có thể khẳng định hệ thống hoạt động tốt trong việc trích dẫn từ nguồn ban đầu và duy trì độ chính xác cần thiết cho nội dung sinh ra.

Toàn bộ chức năng của hệ thống đã được tích hợp vào nền tảng WikiCrop, cung cấp cho người dùng một công cụ mạnh mẽ để tổng hợp và chia sẻ tri thức. Về mặt ứng dụng, giao diện web trực quan và thân thiện giúp biến mô hình lý thuyết thành giải pháp thực tiễn, hỗ trợ người dùng tạo ra các sổ tay cá nhân một cách thuận tiện và hiệu quả.

2. Hướng phát triển

Bên cạnh những kết quả đã đạt được, luận văn cũng mở ra nhiều hướng phát triển tiềm năng trong tương lai nhằm tiếp tục hoàn thiện và nâng cao năng lực của hệ thống.

Đầu tiên là cải thiện khả năng trích xuất từ các tệp văn bản thông qua OCR, giúp hệ thống xử lý được nhiều dạng tài liệu phức tạp hơn như bảng biểu, sơ đồ hoặc hình ảnh chứa nội dung quan trọng. Hướng mở rộng này cũng có thể áp dụng cho trích xuất dữ liệu từ website, đặc biệt đối với các trang có cấu trúc phức tạp hoặc sử dụng nhiều hình ảnh thay cho văn bản.

Tiếp theo, quá trình đọc và duyệt bài thủ công hiện nay khá tốn thời gian, vì vậy việc hỗ trợ người dùng và quản trị viên kiểm tra bài viết một cách nhanh chóng và thuận tiện hơn là cần thiết. Hệ thống đánh giá chất lượng bài viết vốn đã xác định được mức độ chính xác của nội dung so với nguồn, do đó có thể phát triển thêm tính năng hiển thị trực tiếp những ý không có trong tài liệu gốc. Điều này giúp rút ngắn thời gian duyệt bài và tăng độ tin cậy của nội dung trên nền tảng.

TÀI LIỆU THAM KHẢO

- [1] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in neural information processing systems*, 33, 9459-9474.
- [2] Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., ... & Wang, H. (2023). Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2(1), 32.
- [3] Daniel, J., & Martin, J. H. (2020). Speech and language processing: vector semantics and embeddings. *Speech and Language Processing*.
- [4] Ma, L., Zhang, R., Han, Y., Yu, S., Wang, Z., Ning, Z., ... & Lu, C. T. (2023). A comprehensive survey on vector database: Storage and retrieval technique, challenge. *arXiv preprint arXiv:2310.11703*.
- [5] Gu, J., Jiang, X., Shi, Z., Tan, H., Zhai, X., Xu, C., ... & Guo, J. (2024). A survey on llm-as-a-judge. *The Innovation*.
- [6] Pepin, B. (2020). The Harmonic Indel Distance. *arXiv preprint arXiv:2011.04072*.
- [7] Bowman, S., Angeli, G., Potts, C., & Manning, C. D. (2015, September). A large annotated corpus for learning natural language inference. In *Proceedings of the 2015 conference on empirical methods in natural language processing* (pp. 632-642).
- [8] Qi, Z., Xu, R., Guo, Z., Wang, C., Zhang, H., & Xu, W. (2024, November). Long2rag: Evaluating long-context & long-form retrieval-augmented generation with key point recall. In *Findings of the Association for Computational Linguistics: EMNLP 2024* (pp. 4852-4872).
- [9] Gao, T., Yen, H., Yu, J., & Chen, D. (2023, December). Enabling large language models to generate text with citations. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing* (pp. 6465-6488).

