

Nâng cao độ chính xác phân loại ảnh phương tiện giao thông với SN-ReLU và học Ensemble

Mã Trường Thành, Huỳnh Thanh Phong, Đinh Hữu Thành, Nguyễn Trọng Nguyên, Lê Ngọc Thái, Trần Quốc Khang

CICT, Can Tho University, Vietnam

Email: mtthanh@ctu.edu.vn, phongb2207555@student.ctu.edu.vn, thanhb2207563@student.ctu.edu.vn,

nguyenb2207547@student.ctu.edu.vn, lnthai@ctu.edu.vn, tqkhang@ctu.edu.vn

Tóm tắt: Bài báo đề xuất hàm kích hoạt phi tuyến SN-ReLU như một thay thế cho ReLU trong CNN nhằm giảm suy giảm gradient và hiện tượng nơ-ron chết, qua đó nâng cao khả năng biểu diễn đặc trưng sâu của ảnh phương tiện giao thông. SN-ReLU được tích hợp vào kiến trúc CNN tối ưu khai thác đặc trưng đa tỉ lệ và cải thiện lan truyền gradient ở các tầng đầu. Thay vì sử dụng Softmax truyền thống, nghiên cứu sử dụng Ensemble đa tầng để tinh chỉnh quyết định dựa trên embedding sâu, giúp giảm dao động dự đoán, mở rộng biên phân lớp và tăng độ tin cậy trong điều kiện nhiễu. Thử nghiệm cho thấy mô hình CNN-SN-ReLU-Ensemble đạt 87,21%, cải thiện đáng kể so với CNN-Baseline (GELU: 84,09%; PReLU: 83,99%; ELU: 81,66%; ReLU: 80,76%) và các mô hình học sâu như MobileNetV2 (82,14%), EfficientNetV2-B0 (44,43%) cũng như CNN-SN-ReLU với Softmax 85,22%.

Từ khóa: Activation functions, Deep Learning, Ensemble, CNN, SN-ReLU Phân loại phương tiện.

I. GIỚI THIỆU

Phân loại phương tiện giao thông là bài toán quan trọng trong các hệ thống giao thông thông minh (Intelligent Transportation System - ITS), giám sát và thu phí tự động, đòi hỏi độ chính xác và độ tin cậy cao trong bối cảnh thực tế. Do đó, việc phát triển các kiến trúc mạng nơ-ron tích chập (Convolutional Neural Network - CNN) [1] cùng các hàm kích hoạt mới, kết hợp chiến lược Ensemble là hướng tiếp cận hiệu quả nhằm nâng cao hiệu suất và tính ổn định dự đoán.

Các kiến trúc CNN kinh điển như AlexNet [2], VGG [3] và ResNet [4] đã chứng minh khả năng trích xuất đặc trưng sâu và biểu diễn phi tuyến cho bài toán phân loại phương tiện, đồng thời được áp dụng thành công trong nhiều nghiên cứu thực nghiệm, bao gồm các bối cảnh giao thông tại Việt Nam [5]. Tuy nhiên, các mạng CNN hiện nay chủ yếu sử dụng các hàm kích hoạt cổ điển như ReLU [6] và LeakyReLU [7], vốn dễ gây sụp đổ gradient, hội tụ chậm và làm mất các kích hoạt yếu khi dữ liệu có nhiễu, che khuất hoặc kích thước đối tượng nhỏ [8]. Các hàm kích hoạt cải tiến như PReLU và ELU đã phần nào cải thiện tốc độ hội tụ và khả năng biểu diễn [9], [10], nhưng vẫn chưa giải quyết triệt để vấn đề này.

Trong thực tế, ảnh phương tiện thường chịu ảnh hưởng bởi điều kiện chiếu sáng kém, nhiễu chuyển động và che khuất, khiến nhiều đặc trưng phân biệt có biên độ thấp. Để khắc phục hạn chế của các hàm kích hoạt dựa trên ReLU, nghiên cứu này đề xuất hàm SN-ReLU (Smooth Nonlinear ReLU), được thiết kế trơn và phi đơn điệu, kết

hợp thành phần tương tự Swish [11] và một hạng tử bị chặn lấy cảm hứng từ Softsign [12]. Thiết kế này giúp duy trì gradient ổn định, hạn chế hiện tượng nơ-ron chết và hỗ trợ bảo toàn các kích hoạt yếu trong quá trình huấn luyện.

Bên cạnh đó, thay vì chỉ sử dụng MLP kết hợp Softmax ở đầu ra, nghiên cứu đề xuất kiến trúc CNN tùy biến kết hợp Ensemble nhằm khai thác tốt hơn cấu trúc phi tuyến của dữ liệu phương tiện [5]. Một bộ dữ liệu phương tiện giao thông tổng hợp được xây dựng, chủ yếu thu thập từ Internet và bổ sung 15% dữ liệu thực địa tại Cần Thơ. Kết quả thực nghiệm cho thấy phương pháp đề xuất cải thiện khoảng 2–3% độ chính xác so với các mô hình CNN truyền thống và lightweight, đồng thời duy trì hiệu suất ổn định trong các điều kiện nhiễu, che khuất và đa tỷ lệ.

II. PHƯƠNG PHÁP ĐỀ XUẤT

Ký hiệu và quy ước. Trong phần phương pháp, $x \in \mathbb{R}$ ký hiệu giá trị tiền kích hoạt (pre-activation) tại mỗi nơ-ron CNN; $f(\cdot)$ là hàm kích hoạt, cụ thể là SN-ReLU, và $f'(\cdot)$ là đạo hàm bậc nhất của nó. Ký hiệu $C^1(\mathbb{R})$ biểu thị lớp các hàm khả vi với đạo hàm liên tục. Trong phân tích huấn luyện, Z là biến ngẫu nhiên mô tả phân phối pre-activation, còn $\mathbb{E}[\cdot]$ và $\mathbb{P}(\cdot)$ lần lượt là toán tử kỳ vọng và xác suất. Các ký hiệu này được dùng thống nhất để phân tích tính trơn, độ mượt gradient và độ ổn định lan truyền ngược của SN-ReLU.

A. Xây dựng hàm kích hoạt

Nhóm nghiên cứu đề xuất một hàm kích hoạt trơn, phi đơn điệu được tổng hợp và lấy cảm hứng từ Swish và Softsign, đặt tên là SN-ReLU (Smooth Nonlinear ReLU). “SN-ReLU đặc biệt phù hợp cho các tác vụ thị giác yêu cầu kích hoạt phi đơn điệu mượt mà, lan truyền gradient ổn định và bảo toàn các tín hiệu phân biệt yếu, chẳng hạn như nhận dạng chi tiết và phân tích hình ảnh chất lượng thấp”. Hàm SN-ReLU được định nghĩa bởi:

$$SN-ReLU(x) = x \sigma(0.8x) + \frac{0.1x}{1 + |x|} \text{ trong đó } \sigma(x) = \frac{1}{1 + e^{-x}} \text{ là hàm sigmoid.}$$

Hình 2 mô tả hàm kích hoạt SN-ReLU, thiết kế này kết hợp tuyến tính từng phần của ReLU với một thành phần làm mượt có đạo hàm dương trên toàn trục số. Nhờ đó, SN-ReLU vừa giữ được khả năng hội tụ nhanh của ReLU, vừa khắc phục hiện tượng nơ-ron chết và làm ổn định gradient trong quá trình lan truyền ngược, đặc biệt




Figure 1: Kiến trúc CNN tùy chỉnh Ensemble với hàm kích hoạt SN-ReLU.

hữu ích trong bối cảnh dữ liệu nhiễu và điều kiện ánh sáng biến thiên khi nhận dạng phương tiện giao thông ngoài trời.




Figure 2: Minh họa hàm SN-ReLU (a) và đạo hàm của SN-ReLU (b) trên số thực.

Proposition 1 (Tính liên tục). *Hàm $f(x)$ liên tục trên toàn trục thực.*

Proof: Xét hai thành phần của SN-ReLU: $h_1(x) = x \sigma(0.8x)$ và $h_2(x) = \frac{x}{1+|x|}$.

Hàm sigmoid $\sigma(0.8x)$ liên tục trên $\mathbb{R}$, và phép nhân với x không làm mất tính liên tục. Do đó, $h_1(x)$ liên tục trên toàn trục thực. Hàm $h_2(x)$ liên tục trên $\mathbb{R}$ vì mẫu số $1+|x|$ luôn dương và giới hạn trái-phải tại $x=0$ trùng nhau: $\lim_{x \rightarrow 0^-} h_2(x) = \lim_{x \rightarrow 0^+} h_2(x) = 0$.

Kết luận: Tổng của hai hàm liên tục vẫn liên tục, nên $f(x) = h_1(x) + 0.1 h_2(x)$ liên tục trên toàn $\mathbb{R}$. ■

Proposition 2 (Khả vi và đạo hàm liên tục). *Hàm kích hoạt f khả vi và có đạo hàm liên tục trên $\mathbb{R}$, tức $f \in C^1(\mathbb{R})$.*

Proof: Xét hai thành phần của SN-ReLU: $h_1(x) = x \sigma(0.8x)$ và $h_2(x) = \frac{x}{1+|x|}$.

Do hàm sigmoid $\sigma(\cdot)$ trơn trên $\mathbb{R}$, nên h_1 khả vi trên $\mathbb{R}$ với đạo hàm $h'_1(x) = \sigma(0.8x) + 0.8x \sigma'(0.8x)$, và $h'_1(x)$ liên tục trên $\mathbb{R}$.

Đối với h_2 , ta có biểu diễn từng phần:

$$h_2(x) = \begin{cases} \frac{x}{1+x}, & x > 0 \\ \frac{x}{1-x}, & x < 0 \end{cases} \quad h'_2(x) = \begin{cases} \frac{1}{(1+x)^2}, & x > 0 \\ \frac{1}{(1-x)^2}, & x < 0 \end{cases}$$

Hơn nữa $\lim_{x \rightarrow 0^-} h'_2(x) = \lim_{x \rightarrow 0^+} h'_2(x) = 1$, nên đạo hàm của h_2 tồn tại và liên tục tại $x=0$. Do đó, $h_2 \in C^1(\mathbb{R})$.

Kết luận: Vì tổng của các hàm thuộc $C^1(\mathbb{R})$ vẫn thuộc $C^1(\mathbb{R})$, nên $f(x) = h_1(x) + 0.1 h_2(x)$ khả vi và có đạo hàm liên tục trên toàn trục thực $\mathbb{R}$. ■

Proposition 3 (Hàm Lipschitz và độ mượt). *Hàm kích hoạt $f(x) = x \sigma(0.8x) + 0.1 \frac{x}{1+|x|}$ là Lipschitz liên tục trên $\mathbb{R}$, tức tồn tại $L < \infty$ sao cho:*

$$|f(x) - f(y)| \leq L|x - y|, \quad \forall x, y \in \mathbb{R}.$$

Proof: Vì $f \in C^1(\mathbb{R})$ (đã chứng minh ở Mệnh đề trước), chỉ cần chỉ ra đạo hàm f' bị chặn trên $\mathbb{R}$. Ta có $f'(x) = h'_1(x) + 0.1 h'_2(x)$, trong đó: $h'_1(x) = \sigma(0.8x) + 0.8x \sigma'(0.8x)$ và $h'_2(x) = \frac{1}{(1+|x|)^2}$.

Trước hết, do $0 < \sigma(t) < 1$ với mọi t , suy ra

$$|\sigma(0.8x)| \leq 1, \quad \forall x \in \mathbb{R}.$$

Ngoài ra, do $0 < h'_2(x) \leq 1$ với mọi $x \in \mathbb{R}$, suy ra $|0.1 h'_2(x)| \leq 0.1$.

Xét hạng tử còn lại. Đặt $y = 0.8x$ và xét hàm:

$$g(y) = |y| \sigma'(y).$$

Vì $\sigma'(y) = \sigma(y)(1-\sigma(y))$ suy giảm theo hàm mũ khi $|y| \rightarrow \infty$, ta có $\lim_{|y| \rightarrow \infty} g(y) = 0$ và g liên tục trên $\mathbb{R}$. Do đó theo định lý Weierstrass, g đạt cực đại trên $\mathbb{R}$ và

$$M := \sup_{y \in \mathbb{R}} |y| \sigma'(y) < \infty.$$

$$\implies |0.8x \sigma'(0.8x)| = |y \sigma'(y)| \leq M, \quad \forall x \in \mathbb{R}.$$

Kết hợp các đánh giá trên, với mọi $x \in \mathbb{R}$ ta có

$$\begin{aligned} |f'(x)| &\leq |\sigma(0.8x)| + |0.8x \sigma'(0.8x)| + 0.1 |h'_2(x)| \\ &\implies |f'(x)| \leq 1 + M + 0.1. \end{aligned}$$

Kết luận: Do đó f' bị chặn trên $\mathbb{R}$. Theo định lý giá trị trung bình, f là Lipschitz liên tục với một hằng số Lipschitz có thể chọn là $L = 1 + M + 0.1$. ■

Ghi chú. Có thể tính xấp xỉ $\sup_{y \in \mathbb{R}} |y| \sigma'(y) \approx 0.224$, do đó có thể lấy $L \approx 1.324$.

Proposition 4 (Giảm nguy cơ nơ-ron chết theo nghĩa miền gradient bằng 0). *Giả sử biến pre-activation Z có phân phối liên tục. Với ReLU $r(x) = \max(0, x)$, ta có $\mathbb{P}(r'(Z) = 0) = \mathbb{P}(Z \leq 0) > 0$, tức tồn tại một miền có xác suất dương mà gradient bằng 0. Ngược lại, với SN-ReLU, mặc dù $f'(x)$ có thể triệt tiêu tại các điểm rời rạc, nhưng không tồn tại khoảng con nào mà trên đó $f'(x) \equiv 0$. Do đó, $\mathbb{P}(f'(Z) = 0) = 0$.*

Proof: Với ReLU, đạo hàm gần như khắp nơi thỏa

$$r'(x) = \begin{cases} 1, & x > 0, \\ 0, & x < 0, \end{cases}$$

(và có thể quy ước $r'(0) = 0$). Suy ra $\mathbb{P}(r'(Z) = 0) = \mathbb{P}(Z \leq 0)$.

Xét đạo hàm SN-ReLU:

$$f'(x) = \sigma(0.8x) + 0.8x\sigma'(0.8x) + 0.1 \frac{1}{(1+|x|)^2}$$

Vì $\sigma(t) > 0, 0 \leq \sigma'(t) \leq \frac{1}{4}$, suy ra $|0.8x\sigma'(0.8x)| \leq 0.2|x|$. Do đó tồn tại $\delta > 0$ sao cho $f'(x) > 0$ với mọi $|x| < \delta$. Giả sử tồn tại khoảng mở I sao cho $f'(x) = 0$ với mọi $x \in I$. Khi đó mâu thuẫn với tính dương của $f'(x)$ trên $(-\delta, \delta)$. Vì vậy, $f'(x)$ không thể triệt tiêu trên bất kỳ khoảng con nào của $\mathbb{R}$.

Suy ra tập nghiệm $\mathcal{N} := \{x \in \mathbb{R} : f'(x) = 0\}$ chỉ gồm các điểm rời rạc và có độ đo Lebesgue bằng 0. Vì Z có phân phối liên tục $\mathbb{P}(f'(Z) = 0) = \mathbb{P}(Z \in \mathcal{N}) = 0$.

Kết luận: Đạo hàm $f'(x)$ chỉ có thể triệt tiêu tại một tập các điểm rời rạc, không tạo thành khoảng con nào của $\mathbb{R}$; do đó $\mathbb{P}(f'(Z) = 0) = 0$, và SN-ReLU không tạo ra các miền có gradient bằng 0 với xác suất dương, qua đó làm giảm đáng kể nguy cơ nơ-ron chết so với ReLU. ■

Proposition 5 (Gradient kỳ vọng và vanishing gradient (dạng kỳ vọng)). *Giả sử Z có phân phối đối xứng quanh 0 và liên tục (nên $\mathbb{P}(Z > 0) = \frac{1}{2}$). Khi đó $\mathbb{E}[f'(Z)] > \mathbb{E}[r'(Z)] = \frac{1}{2}$.*

Proof: Xét đạo hàm SN-ReLU ta có:

$$f'(x) = \sigma(0.8x) + 0.8x\sigma'(0.8x) + 0.1 \frac{1}{(1+|x|)^2}.$$

Ta đặt các hạng tử: $A(Z) = \sigma(0.8Z)$, $B(Z) = 0.8Z\sigma'(0.8Z)$ và $H(Z) = 0.1 \frac{1}{(1+|Z|)^2}$.

Vì Z đối xứng quanh 0 và $\sigma'(t)$ là hàm chẵn, nên $B(Z)$ là hàm lẻ theo Z và do đó $\mathbb{E}[B(Z)] = 0$. Hơn nữa, do $\sigma(t) + \sigma(-t) = 1$ và Z đối xứng, ta có $\mathbb{E}[A(Z)] = \frac{1}{2}$. Cuối cùng, $H(Z) > 0$ với mọi Z , nên $\mathbb{E}[H(Z)] > 0$.

$$\begin{aligned} \implies \mathbb{E}[f'(Z)] &= \mathbb{E}[A(Z)] + \mathbb{E}[B(Z)] + \mathbb{E}[H(Z)] \\ &= \frac{1}{2} + \mathbb{E}[H(Z)] > \frac{1}{2}. \end{aligned}$$

Với ReLU, $r'(Z) = \mathbf{1}_{\{Z > 0\}}$ nên $\mathbb{E}[r'(Z)] = \mathbb{P}(Z > 0) = \frac{1}{2}$, do Z đối xứng và liên tục. Vậy $\mathbb{E}[f'(Z)] > \mathbb{E}[r'(Z)]$. ■

B. Cấu trúc CNN tùy chỉnh

Kiến trúc CNN được thiết kế nhằm xử lý sự biến đổi hình thái đa tỉ lệ của phương tiện giao thông, đòi hỏi khả năng mã hóa đặc trưng sâu đồng thời hạn chế suy giảm tín hiệu sớm. Mô hình gồm ba khối tích chập với số kênh tăng dần để mở rộng không gian biểu diễn, kết hợp ReLU và SN-ReLU nhằm cân bằng giữa độ sắc nét đặc trưng và tính ổn định gradient. Cụ thể, khối đầu tiên sử dụng SN-ReLU để giảm mất mát tín hiệu trong điều kiện nhiễu, trong khi các khối sau luân phiên ReLU/SN-ReLU nhằm duy trì đặc trưng biên và hạn chế suy giảm gradient. Batch Normalization [13] được áp dụng xuyên suốt để đảm bảo hội tụ ổn định.

Gọi $\mathbf{x}_i \in \mathbb{R}^{H_i \times W_i \times C_i}$ là bản đồ đặc trưng đầu ra của khối CNN thứ i . Mỗi bản đồ được nén bằng Global Average Pooling (GAP), $\mathbf{x}'_i = \text{GAP}(\mathbf{x}_i) \in \mathbb{R}^{C_i}$, sau đó các vector được hợp nhất bằng phép nối $\mathbf{x}_{\text{concat}} = [\mathbf{x}'_1, \mathbf{x}'_2, \dots, \mathbf{x}'_n]$, cho phép kết hợp đặc trưng cấu trúc cấp thấp và đặc trưng ngữ nghĩa cấp cao trong một không gian biểu diễn thống nhất. Vector hợp nhất được ánh xạ phi tuyến $z = \text{ReLU}(W\mathbf{x}_{\text{concat}} + b)$, SN-ReLU được sử dụng ở các tầng sâu để cải thiện quá trình học, trong khi ReLU được giữ ở các tầng khác nhằm đảm bảo tốc độ và hiệu quả tính toán.

Biểu diễn sâu z được trích xuất làm embedding ngữ nghĩa và đưa vào mô-đun Ensemble để tinh chỉnh quyết định phân lớp, thay vì chỉ dựa vào Softmax đơn tầng. Softmax chuẩn hóa phân phối xác suất:

$$\text{Softmax}(z_i) = \frac{\exp(z_i)}{\sum_{j=1}^C \exp(z_j)}, \quad i = 1, \dots, C,$$

trong đó $\mathbf{z} = [z_1, \dots, z_C]$ là vector logit và C là số lớp. Mô hình được tối ưu bằng Categorical Cross-Entropy, $\mathcal{L}_{\text{CCE}}(y, \hat{y}) = -\sum_{i=1}^C y_i \log(\hat{y}_i)$.

Việc kết hợp Cross-Entropy với SN-ReLU ở các tầng đầu giúp duy trì gradient ổn định trong dữ liệu nhiễu hoặc biên độ thấp, cải thiện chất lượng embedding trước khi đưa vào Ensemble. Cơ chế hai tầng này giúp tăng độ phân biệt lớp và giảm hiện tượng *over-confidence* của Softmax.

C. Xây dựng cơ chế hợp nhất quyết định đa tầng

Sau khi CNN học xong biểu diễn, mô hình không sử dụng Softmax mà áp dụng cơ chế hợp nhất quyết định đa tầng dựa trên các bộ học truyền thống Random Forest và SVM, kế thừa các hướng CNN-SVM [14]. Cách tiếp cận này giúp mở rộng biên phân lớp, cải thiện khả năng khái quát hóa và tăng độ tin cậy suy luận thông qua khai thác embedding sâu. Embedding cuối $F_{\text{CNN}}(x) \in \mathbb{R}^d$ được giảm chiều xuống không gian 256 chiều bằng Principal Component Analysis (PCA), thông qua một phép biến đổi tuyến tính không giám sát nhằm loại bỏ dư thừa đặc trưng và giảm chi phí tính toán cho các tầng Ensemble phía sau.

Ở tầng thứ nhất, $F_{\text{CNN}}(x)$ được đưa vào Random Forest để tạo phân bố xác suất sơ cấp $P^{(1)}$. Tầng thứ hai sử dụng Stacking Classifier với Logistic Regression để kết hợp embedding và $P^{(1)}$, tạo phân bố quyết định ổn định hơn. Ở tầng cuối, các dự đoán từ Stacking, MLP và SVM được hợp nhất bằng soft voting: $P_{\text{final}} = \alpha P_{\text{stacking}} + \beta P_{\text{MLP}} + \gamma P_{\text{SVM}}$ trong đó $\alpha + \beta + \gamma = 1$, với quyết định cuối bằng Soft Voting: $\hat{y} = \arg \max_{c \in \mathcal{C}} \sum_{k=1}^K w_k P_k(y = c | x)$.

Cơ chế hợp nhất ba tầng giúp giảm nhiễu quyết định và tăng độ chắc chắn suy luận trong các kịch bản giao thông phức tạp. Hình 1 minh họa kiến trúc CNN-SN-ReLU-Ensemble được đề xuất.

III. THIẾT KẾ THỬ NGHIỆM

Để đánh giá hiệu quả kiến trúc CNN với SN-ReLU và cơ chế Ensemble ba tầng, nghiên cứu xây dựng một quy trình thử nghiệm chuẩn hóa, bao gồm thiết lập dữ liệu, tiền xử lý, cấu hình huấn luyện và so sánh với các mô hình nền. Quy trình được triển khai đồng bộ từ đầu vào đến đánh giá, bao phủ tiền xử lý ảnh, tăng cường dữ liệu, lựa chọn baseline, tối ưu tham số và tiêu chí đánh

giá định lượng. Mục tiêu là kiểm chứng khả năng cải thiện độ ổn định phân lớp trong điều kiện nhiễu thực tế, đồng thời phân tích đóng góp của từng thành phần (CNN, SN-ReLU, Ensemble) vào tổng thể.

A. Bộ dữ liệu và nhãn phân loại

Bộ dữ liệu được xây dựng cho bài toán phân loại phương tiện giao thông gồm 6 lớp phổ biến tại Cần Thơ (Bảng I), với tổng cộng 38,586 ảnh từ hai nguồn: (i) ảnh thực địa chiếm 15% (5,775 ảnh): thu thập trong điều kiện đa dạng về thời tiết, góc nhìn và nền cảnh; (ii) ảnh trực tuyến chiếm 85% (32,811 ảnh): từ các nguồn uy tín như OpenImages, Kaggle, Google Dataset Search và AI City Challenge.

Table I: Phân phối dữ liệu phương tiện giao thông

Class	Train	Val	Test	Total
bicycle	2,079	1,359	1,359	4,797
boat	5,338	1,779	1,780	8,897
bus	3,325	1,108	1,108	5,541
car	5,721	1,907	1,907	9,535
motorcycle	3,662	1,220	1,220	6,102
truck	2,228	743	743	3,714
Total	22,353	8,116	8,117	38,586

Ảnh thực địa có chất lượng ổn định, trong khi ảnh Internet đa dạng về bối cảnh và độ phân giải; do đó các kỹ thuật tiền xử lý và tăng cường dữ liệu được áp dụng nhằm thu hẹp khác biệt giữa hai nguồn. Dữ liệu được rà soát thủ công để loại bỏ ảnh mờ, ảnh không chứa đối tượng, ảnh gắn nhãn sai hoặc không phù hợp (Hình 3). Do phân bố lớp chưa đồng đều, dữ liệu được chia theo stratified split với tỷ lệ 45% huấn luyện, 27.5% xác thực và 27.5% kiểm tra, kết hợp lấy mẫu mini-batch nhằm duy trì phân bố lớp ổn định trong quá trình huấn luyện.




Figure 3: Mô tả ảnh chất lượng tốt ((a), (b)) và ảnh mờ, nhiễu cao ((c), (d)) bị loại bỏ trong tập dữ liệu.

B. Chuẩn hóa dữ liệu và thông số huấn luyện

Để giảm nhiễu không gian và chuẩn hóa đặc trưng, pipeline tiền xử lý và chuẩn hóa. Các tham số huấn luyện được cấu hình phù hợp cho kiến trúc CNN tùy biến với SN-ReLU, EfficientNetV2-B0, MobileNetV2 và các mô hình so sánh, bao gồm tốc độ học, số epoch, kích thước batch và các cơ chế điều chỉnh tối ưu, nhằm bảo đảm học đặc trưng ổn định trước khi chuyển sang giai đoạn phân lớp tăng cường bằng Ensemble được mô tả trong Bảng II. Ảnh đầu vào x sau đó được ánh xạ thành embedding cuối cùng thông qua mạng CNN: $F_{\text{CNN}}(x) = f_{\text{feat}}(x; \theta_{\text{CNN}}) \in \mathbb{R}^d$, trong đó $F_{\text{CNN}}(x)$ là vector đặc trưng nén, phản ánh

các thông tin phân biệt quan trọng phục vụ phân loại. Mô hình CNN được thiết kế với đầu vào kích thước $128 \times 128 \times 3$, bao gồm ba khối tích chập, theo sau bởi tầng trích xuất đặc trưng toàn cục và các tầng kết nối đầy đủ. Đồng thời CNN-SN-ReLU (Params $\approx 1.279\text{M}$, Size $\approx 4.9\text{MB}$) có số tham số thấp hơn MobileNetV2 và EfficientNetV2-B0, cho thấy ưu thế về độ gọn nhẹ và hiệu quả tài nguyên.

Table II: Cấu hình tham số tăng cường dữ liệu và cấu hình siêu tham số huấn luyện mô hình

(a) Tăng cường và tiền xử lý dữ liệu

Technique	Applied Parameters
Random Flip	Horizontal flip, $p = 0.5$
Random Rotation	± 0.05 rad
Random Zoom	$\pm 5\%$ zoom
Gaussian Filter	amount = 1.2, 3×3 kernel
High-Boost Filter	boost factor = 1.5, 3×3 kernel

(b) Siêu tham số huấn luyện và Ensemble

Component	Hyperparameters
Epochs	$E = 50$
Batch size	$B = 128$
Optimizer	Adam, $\eta = 0.001$
Loss	Sparse Categorical Cross-Entropy
LR schedule	$\eta \leftarrow 0.5\eta$ (patience = 3)
CNN embedding	$\mathbf{f} = F_{\text{CNN}}(x)$
PCA	$\mathbf{z} = \text{PCA}_{256}(\mathbf{f})$
Random Forest	$T = 150$ trees
Logistic Regression	$\text{iter}_{\text{max}} = 500$
MLP	Hidden units $h = 128$
SVM	Linear kernel, probability = True
Voting	$p = \frac{1}{3}(p_s + p_m + p_v)$

IV. KẾT QUẢ THỰC NGHIỆM

A. So sánh độ chính xác

Để đánh giá hiệu quả của SN-ReLU, chúng tôi so sánh trực tiếp mô hình đề xuất với các kiến trúc chuẩn và mô hình tự xây dựng, sử dụng cùng tập dữ liệu, quy trình tiền xử lý và siêu tham số huấn luyện nhằm đảm bảo tính công bằng. Năm mô hình được khảo sát gồm: CNN-Baseline (ReLU, GELU, PReLU, ELU), CNN-SN-ReLU, CNN-SN-ReLU-Ensemble, MobileNetV2 và EfficientNetV2-B0. Kết quả cho thấy CNN-SN-ReLU-Ensemble đạt hiệu suất cao nhất (87.21%), vượt rõ rệt các mô hình đơn lẻ và các backbone phổ biến. Lợi thế này đến từ sự ổn định gradient và biên độ kích hoạt do SN-ReLU mang lại, giúp từng CNN thành phần hội tụ nhanh hơn; khi kết hợp ensemble, phương sai dự đoán tiếp tục được giảm mạnh, tạo phân bố xác suất mượt và tin cậy hơn. Nhờ đó, mô hình xử lý tốt dữ liệu nhiễu và biến thiên lớn về hình dạng-bối cảnh, trong khi vẫn giữ cấu trúc nhẹ và hiệu quả tham số. So với phân lớp Softmax truyền thống, cấu trúc ensemble trên embedding CNN cho thấy xu hướng ổn định hơn về xác suất dự đoán, đặc biệt khi sử dụng SN-ReLU nhờ mang lại phân bố xác suất ổn định.




Figure 4: Kết quả thực nghiệm giữa các mô hình (a) và ma trận nhầm lẫn của CNN-SNReLU-Ensemble (b)

Ma trận nhầm lẫn chuẩn hóa cho thấy các lỗi phân loại chủ yếu xảy ra giữa các lớp có đặc trưng hình thái gần giống nhau, đặc biệt trong các ảnh thực địa với góc chụp phức tạp, che khuất hoặc điều kiện chiếu sáng không ổn định. Một số sai lệch cũng xuất hiện ở các mẫu có đối tượng nhỏ hoặc nền nhiễu, làm suy giảm khả năng trích xuất đặc trưng cục bộ. Tuy nhiên, tỷ lệ nhầm lẫn nhìn chung thấp, cho thấy CNN-SN-ReLU-Ensemble có khả năng phân biệt lớp tốt và độ ổn định cao.

B. Tốc độ và chi phí tính toán

Bên cạnh độ chính xác, chúng tôi đánh giá SN-ReLU về chi phí tính toán và mức tiêu thụ tài nguyên trong huấn luyện. Nhờ cấu trúc đơn giản hơn Mish và Swish, SN-ReLU được kỳ vọng cho tốc độ huấn luyện nhanh hơn và sử dụng tài nguyên hiệu quả, trong khi vẫn duy trì chất lượng mô hình. Hiệu quả được đo bằng thời gian huấn luyện mỗi epoch, FLOPs và bộ nhớ GPU (theo dõi bằng *nvidia-smi*), trên cùng kiến trúc CNN và phần cứng cố định, với kết quả trung bình trong (bảng III). Kết quả cho thấy SN-ReLU làm tăng nhẹ thời gian huấn luyện so với ReLU do độ phức tạp tính toán cao hơn. Tuy nhiên, mức sử dụng bộ nhớ GPU gần như không tăng, cho thấy sự đánh đổi hợp lý giữa chi phí tính toán và hiệu quả tài nguyên.

Table III: So sánh thời gian huấn luyện trên 1 epoch, FLOPs và bộ nhớ GPU giữa các hàm kích hoạt.

Activation	Time/ Epoch (s)	GPU Memory (MiB)
ReLU (baseline)	86.6	14 062
SN-ReLU (ours)	131.5	12 420
Mish	105.9	12 420
Swish	108.6	12 420

C. Lan truyền gradient và quá trình hội tụ

Khả năng lan truyền gradient được đánh giá thông qua giá trị trung bình (Mean) và phương sai (Var) của độ lớn gradient tại từng tầng. Kết quả ở Bảng IV cho thấy SN-ReLU duy trì cân bằng tốt giữa mức độ và độ ổn định gradient, đặc biệt ở các tầng đầu, qua đó cải thiện lan truyền gradient và ổn định huấn luyện CNN sâu. Đánh giá tác động của hàm kích hoạt SN-ReLU đối với quá trình tối ưu bằng việc phân tích ba đại lượng: (i) tốc độ giảm loss trong 10 epochs đầu, (ii) tốc độ giảm loss trong 20 epochs đầu, và (iii) tốc độ giảm loss trong 50 epochs đầu.




Figure 5: Biến thiên giá trị train loss theo từng epochs của SN-ReLU, Swish, Mish và ReLU

Mỗi chỉ số được đo bằng giá trị trung bình qua 5 lần huấn luyện độc lập để tăng độ tin cậy thống kê. Để so sánh định lượng hiệu quả hội tụ của SN-ReLU so với ReLU, hàm phân tích tỷ lệ thay đổi loss tại epoch e :

$$\Delta L_a(e) = \frac{L_{\text{ReLU}}(e) - L_a(e)}{L_{\text{ReLU}}(e)} \times 100(\%)$$

Trong đó $L_{\text{ReLU}}(e)$ và $L_a(e)$ lần lượt là loss của ReLU và hàm kích hoạt a tại epoch e . Giá trị $\Delta L_a(e) > 0$ cho thấy a cải thiện hội tụ so với ReLU, và ngược lại.

Table IV: Thống kê gradient trên các lớp tích chập của mô hình với các hàm kích hoạt

(a) Giá trị trung bình (Mean) của độ lớn gradient

Layer	SN-ReLU	GELU	ReLU	PReLU
conv1	1.30E-02	1.77E-02	7.77E-03	1.65E-02
conv2	1.90E-03	2.15E-03	7.06E-04	3.28E-03
conv3	1.46E-03	2.45E-03	2.02E-03	2.06E-03
conv4	3.42E-03	4.82E-03	4.19E-03	3.53E-03
conv5	2.03E-03	2.66E-03	2.75E-03	2.34E-03
conv6	3.04E-03	3.14E-03	3.28E-03	2.80E-03

(b) Phương sai (Var) của độ lớn gradient

Layer	SN-ReLU	GELU	ReLU	PReLU
conv1	4.41E-06	6.48E-07	8.50E-06	1.08E-06
conv2	4.58E-06	6.96E-06	1.24E-06	1.58E-05
conv3	1.62E-06	1.26E-06	7.88E-07	5.56E-06
conv4	1.34E-05	1.44E-05	1.79E-05	1.45E-05
conv5	5.74E-06	1.19E-05	1.10E-05	7.32E-06
conv6	1.07E-05	1.28E-05	1.54E-05	1.00E-05

SN-ReLU được thiết kế nhằm thúc đẩy hội tụ sớm và ổn định gradient trong tối ưu. Kết quả ở Hình 5 cho thấy, dù Mish có training loss thấp hơn nhẹ ở các epoch muộn, SN-ReLU đạt loss thấp hơn rõ rệt ở giai đoạn đầu-giữa (10-20 epoch) nhờ duy trì biên độ kích hoạt và dòng gradient ổn định, giúp mô hình nhanh đạt trạng thái tối ưu đáng tin cậy. Thực nghiệm độ trễ suy luận trên phần cứng CPU Intel Core i5-1135G7 với 8GB RAM cho thấy SN-ReLU gần như không làm tăng độ trễ so với ReLU, còn phiên bản Ensemble chỉ phát sinh chi phí ở mức chấp nhận được và thông lượng suy luận giảm 30% (Hình 6), khẳng định tính phù hợp cho huấn luyện nhanh và triển khai trong điều kiện tài nguyên hạn chế.




Figure 6: Kết quả thực nghiệm về hiệu năng suy luận của các mô hình (1) CNN-SN-ReLU Ensemble; (2) CNN-SN-ReLU Softmax; (3) CNN-ReLU Softmax.

D. Triển khai thực tế

Nhằm đánh giá khả năng ứng dụng thực tiễn, nghiên cứu xây dựng một hệ thống demo trên nền web cho bài toán phân loại phương tiện giao thông sử dụng CNN-SN-ReLU-Ensemble. Hệ thống nhận đầu vào là một hình ảnh, sau đó, mô hình được sử dụng để suy luận và kết quả được hiển thị tên phương tiện cùng các thông tin mô tả cơ bản. Giao diện hệ thống cho phép so sánh trực quan giữa CNN-Baseline và mô hình đề xuất CNN-SN-ReLU-Ensemble.




Figure 7: Ảnh giao diện hệ thống nhận diện và truy vấn thông tin phương tiện giao thông.

V. KẾT LUẬN VÀ ĐỊNH HƯỚNG PHÁT TRIỂN

Nghiên cứu đề xuất một kiến trúc CNN tùy biến kết hợp hàm kích hoạt SN-ReLU và cơ chế Ensemble nhằm nâng cao độ ổn định và khả năng khái quát trong bài toán phân loại phương tiện giao thông. Xuất phát từ hạn chế của các hàm kích hoạt truyền thống trong môi trường ảnh thực tế có biến thiên lớn, SN-ReLU giúp tăng cường biểu diễn phi tuyến và duy trì lan truyền gradient ổn định, trong khi Ensemble khai thác hiệu quả tính đa dạng mô hình để cải thiện độ tin cậy quyết định. Thực nghiệm cho thấy mô hình CNN-SN-ReLU-Ensemble đạt độ chính xác và độ ổn định cao hơn so với các kiến trúc CNN chuẩn, hội tụ nhanh hơn trong điều kiện ánh sáng phức tạp và nhiễu mạnh, mà không làm gia tăng đáng kể chi phí tính toán. Các kết quả này khẳng định tính khả thi và hiệu quả của hướng thiết kế dựa trên cải tiến hàm kích hoạt kết hợp Ensemble. Hướng nghiên cứu tiếp theo tập trung vào việc mở rộng mô hình thông qua tìm kiếm kiến trúc tự động, tích hợp cơ chế chú ý hoặc Transformer, cùng các chiến lược học bán giám sát và tối ưu cho xử lý thời gian thực nhằm tăng khả năng triển khai trong hệ thống giao thông thông minh. Đồng thời, mô hình sẽ được đánh giá trên các bộ dữ liệu chuẩn như CIFAR-10 hoặc Pascal

VOC để kiểm chứng khả năng tổng quát và so sánh trực tiếp với các phương pháp hiện có.

REFERENCES

- [1] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 2002.
- [2] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 1097–1105, 2012.
- [3] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*, 2015.
- [4] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- [5] Amgad Abdallah Mahmoud, Andreas Pester, Maha M. Muttardi, Frederic Andres, Shihori Tanabe, Nicolas Greneche, and Hesham H. Ali. Cheby-kans: Advanced kolmogorov-arnold networks for applying geometric deep learning in quantum chemistry applications. *IEEE Access*, 13:130525–130534, 2025.
- [6] Abien Fred Agarap. Deep learning using rectified linear units (relu). *arXiv preprint arXiv:1803.08375*, 2018.
- [7] Jin Xu, Zishan Li, Bowen Du, Miaomiao Zhang, and Jing Liu. Reluplex made more practical: Leaky relu. In *2020 IEEE Symposium on Computers and Communications (ISCC)*, pages 1–7, 2020.
- [8] Alexander Shustanov and Pavel Yakimov. Cnn design for real-time traffic sign recognition. *Procedia engineering*, 201:718–725, 2017.
- [9] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 1026–1034, 2015.
- [10] Djork-Arne Clevert, Thomas Unterthiner, and Sepp Hochreiter. Fast and accurate deep network learning by exponential linear units (elus). *International Conference on Learning Representations (ICLR)*, 2016.
- [11] Prajit Ramachandran, Barret Zoph, and Quoc Le. Swish: a self-gated activation function. 10 2017.
- [12] Chih-Hsiang Chang, En-Hui Zhang, and Shih-Hsu Huang. Softsign function hardware implementation using piecewise linear approximation. In *2019 International Symposium on Intelligent Signal Processing and Communication Systems (ISPACS)*, pages 1–2, 2019.
- [13] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift, 2015.
- [14] Abien Fred Agarap. An architecture combining convolutional neural network (cnn) and support vector machine (svm) for image classification. *arXiv preprint arXiv:1712.03541*, 2017.